

ラグランジェ・ファイナンス

Quant Technology 1st Step

Eiichi Horigome

Table of contents

はじめに	12
第 I 部 実証会計・ファイナンス	13
第 1 章 R によるデータ分析の基礎	14
1.1 R 環境と基本操作	14
1.1.1 使用するパッケージ	14
1.1.2 R の基本操作	14
1.2 ベクトルとデータ構造	16
1.2.1 ベクトル	16
1.2.2 行列、リスト、データフレーム	18
1.3 関数・統計・確率分布	21
1.3.1 条件判定と独自関数	21
1.3.2 記述統計	22
1.3.3 確率分布	23
1.4 データ読み込みと dplyr	26
1.4.1 プロジェクト内のデータを読み込む	26
1.4.2 dplyr によるデータ操作	29
1.5 stringr・tidyr・purrr	34
1.5.1 stringr による文字列処理	34
1.5.2 tidyr によるデータ整形	35
1.5.3 purrr による反復処理	37
1.6 可視化と総合演習	40
1.6.1 ggplot2 による可視化	40
1.6.2 総合演習	45
1.7 まとめ	48
第 2 章財務データの整理と分析	50
2.1 分析環境とデータディレクトリ	50
2.1.1 使用するパッケージ	50
2.1.2 プロジェクトとデータディレクトリ	50
2.2 財務データの読み込みと整備	52
2.2.1 財務データの読み込み	52
2.2.2 データ構造の確認	54
2.2.3 データ型と並び順の整理	55

2.3 標本構成と売上高分布	56
2.3.1 年度別・産業別のデータ構成	56
2.3.2 売上高の分布	59
2.4 株主資本と ROE 分析	61
2.4.1 株主資本と ROE	61
2.4.2 産業別の ROE	63
2.4.3 企業の順位付け	65
2.5 上級デュポン・モデル	66
2.5.1 ROE のデュポン分解	66
2.5.2 PM と ATO の関係	68
2.6 財務指標の要約と中間データ	71
2.6.1 複数の財務指標を同じ形式で要約する	71
2.6.2 中間データの保存	71
2.7 まとめ	73
第 3 章株式データと時系列分析	74
3.1 分析環境と株式データの整備	74
3.1.1 パッケージの準備	74
3.1.2 プロジェクトとデータディレクトリ	75
3.1.3 株式データの読み込み	76
3.1.4 必須列の確認	77
3.1.5 欠損値の確認	78
3.1.6 データ型と並び順の整理	79
3.1.7 パネルキーの確認	79
3.1.8 月次観測数の確認	80
3.2 月次リターンと時価総額	80
3.2.1 配当と調整係数	80
3.2.2 時価総額	81
3.2.3 前月株価の追加	83
3.2.4 月次株式リターン	84
3.2.5 無リスク金利の整合性	84
3.2.6 月次超過リターン	87
3.3 月次リターンの分析	87
3.3.1 月次リターンの要約統計量	87
3.3.2 月次リターンの分布	89
3.3.3 累積リターン	89
3.4 年次リターンと年度末時価総額	90
3.4.1 月次リターンから年次リターンへの集約	90
3.4.2 年度末時価総額	92
3.5 財務データとの結合	93
3.5.1 前章の財務データ	93
3.5.2 結合前のキー診断	94
3.5.3 年次データの結合	95
3.5.4 月次データの結合	96

3.5.5 売上高・利益・時価総額の可視化	96
3.6 統計分析と分析用データ	98
3.6.1 一標本 t 検定	98
3.6.2 簿価時価比率と株式リターン	99
3.6.3 年度別回帰と purrr	101
3.6.4 分析用データの保存	102
3.7 まとめ	104
第 4 章ファクターモデル	105
4.1 分析環境と入力データ	105
4.1.1 パッケージの準備	105
4.1.2 プロジェクトとデータディレクトリ	106
4.1.3 第 3 章の出力を読み込む	107
4.1.4 必須列とパネルキー	109
4.1.5 補助関数	110
4.2 ポートフォリオ形成と市場リターン	111
4.2.1 前年度情報の準備	111
4.2.2 市場ポートフォリオ	112
4.2.3 ポートフォリオ形成データ	115
4.3 単変量ポートフォリオ・ソートと CAPM	118
4.3.1 企業規模 10 分位ポートフォリオ	118
4.3.2 簿価時価比率 10 分位ポートフォリオ	121
4.3.3 CAPM の推定	123
4.4 2×3 ポートフォリオと SMB・HML	127
4.4.1 2×3 Size-BE/ME ポートフォリオ	127
4.4.2 SMB と HML	131
4.4.3 ファクターの要約統計量	133
4.5 FF3 モデルと CAPM 比較	135
4.5.1 FF3 モデルの推定	135
4.5.2 CAPM と FF3 の比較	138
4.6 ファクター・データの保存	141
4.6.1 保存と検証	141
4.7 まとめ	142
第 5 章資産価格モデル	143
5.1 分析環境とデータ準備	143
5.1.1 外部パッケージの読み込みとデータの準備	143
5.2 FF3 モデルと株式資本コスト	143
5.2.1 FF3 モデルの推定	143
5.2.2 ファクター・ローディングの整理	144
5.2.3 ファクター・リスクプレミアムの計算	144
5.2.4 FF3 モデルによる株式資本コストの推定	144
5.3 株式資本コストと配当成長	145
5.3.1 株式資本コストの分布	145

5.3.2 時価総額別の株式資本コスト	145
5.3.3 配当利回りの計算	145
5.3.4 潜在配当成長率の推定	146
5.4 リスクモデルと投資ユニバース	146
5.4.1 ファクターの分散共分散行列	146
5.4.2 投資対象企業の選定	146
5.4.3 誤差項の分散共分散行列	146
5.4.4 リターンの分散共分散行列	147
5.4.5 期待リターンのベクトル	147
5.5 平均分散ポートフォリオ	147
5.5.1 quadprog パッケージの準備	147
5.5.2 平均分散最適化問題の設定	147
5.5.3 最適化結果の構造	148
5.5.4 最適保有比率とポートフォリオ・リスク	148
5.6 効率的フロンティア	148
5.6.1 複数の目標期待リターンによる最適化	148
5.6.2 効率的フロンティアの描画	148
5.7 まとめ	149
第 6 章 イベントスタディ	150
6.1 イベントスタディの基礎と分析環境	150
6.1.1 イベントスタディの考え方	150
6.1.2 パッケージの準備	151
6.1.3 プロジェクトとデータディレクトリ	151
6.2 入力データの整備と検証	152
6.2.1 入力ファイルの確認	152
6.2.2 データの読み込み	154
6.2.3 必須列の確認	154
6.2.4 データ型の整理	155
6.2.5 データの概要	157
6.2.6 キーの重複確認	157
6.2.7 欠損値の確認	158
6.3 決算サブライズとイベント日の設定	159
6.3.1 決算サブライズ	159
6.3.2 取引日カレンダー	161
6.3.3 イベント日 0 の設定	163
6.4 推定期間とマーケット・モデル	164
6.4.1 推定期間とイベント期間	164
6.4.2 イベント・パネルの作成	166
6.4.3 データ利用可能性の診断	167
6.4.4 マーケット・モデルの推定	169
6.4.5 完全なイベント期間を持つイベント	173
6.5 異常リターンと日次集計	174
6.5.1 異常リターンと CAR	174

6.5.2 AAR と CAAR	176
6.6 イベント・ウィンドウ分析と結果保存	182
6.6.1 複数のイベント・ウィンドウ	182
6.6.2 決算サプライズと短期 CAR	187
6.6.3 結果の保存	188
6.7 まとめ	191
第 II 部 金融工学と金融数学	192
第 II-1 章 確定キャッシュフロー債券評価	193
1.1 金利期間構造の確認	193
1.2 マーケットコンベンション	197
1.2.1 一般的な市場慣行	197
1.2.2 日本の債券市場における慣行	198
1.3 固定利付債計算	201
1.3.1 クリーン価格から最終利回り	202
1.3.2 最終利回りから価格	203
1.3.3 金利リスク	204
1.3.4 デュレーションとコンベクシティによる価格変化の近似	205
1.4 キャッシュフローによる検証	206
1.4.1 フラットな利回りによる価格評価	208
1.5 計算結果のまとめ	211
第 II-2 章 金利カーブ構築と債券先物 CTD、BPV	213
2.1 金利カーブの基礎	213
2.1.1 ゼロ金利ノード	214
2.1.2 ゼロカーブ	215
2.1.3 カーブの表現	216
2.2 補間と参照日	220
2.2.1 補間方式とフォワード金利	220
2.2.2 参照日と評価日	225
2.3 ブートストラップ	226
2.3.1 預金と債券	226
2.3.2 預金とスワップ	228
2.4 カーブ操作と検証	231
2.4.1 Implied Term Structure	231
2.4.2 カーブの平行シフト	233
2.4.3 カーブの検証	236
2.5 国債先物の基礎	240
2.5.1 計算条件と市場慣行	240
2.5.2 受渡適格国債	242
2.5.3 現物債評価	243
2.5.4 キャッシュフロー検証	244
2.5.5 経過利子	246

2.6 CTD 分析と先物 BPV	247
2.6.1 受渡適格銘柄と変換係数	247
2.6.2 グロスペースシス	248
2.6.3 キャリーとネットベースシス	248
2.6.4 インプライド・レポ	249
2.6.5 CTD 調整後の先物 BPV	252
2.7 まとめ	253
第 II-3 章 OIS スワップとマルチカーブ評価	255
3.1 IBOR 改革と OIS の基礎	255
3.1.1 IBOR 改革と歴史的背景	255
3.1.2 OIS と翌日物金利	256
3.2 TONA カーブと短期 OIS 評価	258
3.2.1 TONA 市場レート	258
3.2.2 TONA OIS カーブの構築	259
3.2.3 JPY 短期 OIS の評価	260
3.2.4 フェアレートの手計算	261
3.3 日次複利と Fixing	262
3.3.1 OIS 変動レグの日次複利	262
3.3.2 Fixing の確定と再評価	265
3.4 SOFR とマルチカーブ評価	266
3.4.1 SOFR 市場レートと OIS カーブ	266
3.4.2 SOFR OIS の評価	268
3.4.3 マルチカーブ評価	268
3.4.4 シングルカーブ評価との比較	271
3.5 ケーススタディ 1：EONIA カーブと OIS 評価	272
3.5.1 評価日と EONIA 市場データ	272
3.5.2 EONIA カーブの構築	273
3.5.3 ベンチマーク値の確認	274
3.5.4 市場レートの再現性	275
3.5.5 5 年 OIS の構築	276
3.5.6 OIS の構築と計算結果の照合	277
3.5.7 市場固定金利とフェアレート	279
3.5.8 固定レグと翌日物レグ	280
3.6 ケーススタディ 2：市場レート変動と評価損益	281
3.6.1 市場レートシナリオ	281
3.6.2 シナリオ別 EONIA カーブ	283
3.6.3 同一 OIS の再評価	284
3.6.4 基準シナリオの照合	287
3.6.5 市場レート変動と評価損益	288
3.6.6 1 ベーシスポイント当たりの評価変化	288
3.7 まとめ	289
参考資料	290

第 II-4 章 Black モデル	291
4.1 Black-Scholes-Merton と Black-76	292
4.1.1 Black-Scholes-Merton モデル	292
4.1.2 Black-76 モデル	292
4.1.3 Black-76 の入力条件	293
4.2 Black-76 による解析評価	294
4.2.1 Black 公式による価格と Greeks	294
4.2.2 Black 過程による European option 評価	295
4.3 Black-Scholes-Merton と European option	296
4.3.1 Black-Scholes-Merton モデルの入力条件	296
4.3.2 European put の解析解と二項 Tree	298
4.4 Monte Carlo 評価	299
4.4.1 擬似乱数 Monte Carlo 評価	299
4.4.2 Monte Carlo パスの可視化	301
4.4.3 Black 過程の 1 パス	303
4.5 American put の早期行使価値	305
4.6 準 Monte Carlo と Longstaff-Schwartz 法	307
4.6.1 Sobol 系列によるパス生成	307
4.6.2 Longstaff-Schwartz 法	309
4.7 まとめ	312
第 II-5 章 Normal (Bachelier) モデル	314
5.1 Normal モデルの基礎	315
5.1.1 金利モデルと測度	315
5.1.2 Bachelier 価格公式	315
5.1.3 Normal volatility の単位	316
5.2 SOFR 先物オプション	317
5.2.1 先物価格から金利への変換	317
5.2.2 価格と Greeks	318
5.3 マイナス金利とボラティリティ分析	320
5.3.1 ゼロ金利とマイナス金利	320
5.3.2 インプライド Normal ボラティリティ	321
5.3.3 金利・ボラティリティ・時間シナリオ	322
5.4 Caplet と Cap	325
5.5 Swaption 評価	327
5.5.1 フォワードスワップレートとアニュイティ	327
5.5.2 Bachelier Swaption	329
5.6 Black volatility と Normal volatility	331
5.7 まとめ	332
第 II-6 章 SABR モデル	334
6.1 SABR モデルとパラメータ	335
6.1.1 SABR パラメータの役割	335
6.1.2 Alpha	335

6.1.3 Beta	335
6.1.4 Volatility of volatility	335
6.1.5 Rho	335
6.1.6 Hagan 近似とカリブレーション	336
6.2 Black SABR のカリブレーション	336
6.2.1 市場データ	336
6.2.2 パラメータ・カリブレーション	338
6.2.3 ボラティリティ・スマイル	340
6.3 SABR パラメータの感応度	343
6.4 Shifted SABR と負の金利	347
6.5 Shifted SABR Normal のカリブレーション	347
6.5.1 市場データ	347
6.5.2 パラメータ・カリブレーション	349
6.5.3 Normal ボラティリティ・スマイル	351
6.6 外挿とモデル比較	354
6.6.1 カリブレーション範囲外の Strike	354
6.6.2 Black SABR と Shifted SABR Normal	355
6.7 まとめ	356
第 II-7 章 Callable Bond と Hull-White モデル	358
7.1 Hull-White モデルと債券条件	359
7.1.1 Hull-White 1-factor モデル	359
7.1.2 債券条件	359
7.1.3 Bullet Bond	361
7.1.4 初期カーブと Hull-White モデル	362
7.2 Callable Bond の構築と Tree 評価	364
7.2.1 コールスケジュール	364
7.2.2 Callable Bond の Tree 評価	365
7.3 Hull-White パラメータ感応度	366
7.4 Bermudan Receiver Swaption との比較	368
7.5 Vasicek モデルと Hull-White モデル	370
7.5.1 Vasicek モデルとの違い	370
7.5.2 Vasicek と Hull-White のゼロ金利曲線	371
7.6 カリブレーションと数値検証	374
7.6.1 Hull-White モデルのカリブレーション	374
7.6.2 1Y×5Y ATM Swap	375
7.6.3 One-helper calibration	377
7.6.4 European Swaption の Engine 比較	379
7.6.5 Tree step の収束	382
7.7 まとめ	384
第 II-8 章信用リスクと CDS	386
8.1 信用リスクと CDS の基礎	387
8.1.1 デフォルト時刻と生存確率	387

8.1.2 Recovery Rate と Loss Given Default	388
8.1.3 CDS Spread と Hazard Rate の近似	388
8.2 フラットカーブによる CDS 評価	388
8.2.1 フラットカーブによる 1 年物 CDS	388
8.2.2 Hazard Rate 近似と確率曲線	390
8.2.3 CDS Schedule とカーブ	392
8.2.4 MidPoint CDS Engine	394
8.2.5 CDS キャッシュフローと確率表	396
8.3 Premium Leg と Protection Leg	397
8.3.1 Premium Leg の手計算	397
8.3.2 Protection Leg の手計算	397
8.3.3 Risky PV01 と Fair Spread	398
8.4 Hazard Rate 推定と感応度	400
8.4.1 Zero-NPV CDS から Hazard Rate を推定する	400
8.4.2 Spread と Recovery Rate の感応度	402
8.5 標準 CDS2015 と ISDA カーブ	403
8.5.1 標準 CDS と CDS2015 満期	403
8.5.2 標準 CDS2015 Schedule	405
8.5.3 ISDA 用割引カーブ	406
8.5.4 ISDA 整合 Hazard Rate の推定	407
8.6 ISDA Engine と評価比較	409
8.6.1 ISDA CDS Engine	409
8.6.2 Accrual rebate と NPV 分解	410
8.6.3 Fair Spread と Fair Upfront	411
8.6.4 ISDA 用キャッシュフロー表	413
8.6.5 MidPoint 型近似と ISDA Engine	414
8.6.6 MidPoint Engine と ISDA Engine の比較	415
8.7 まとめ	417
第 II-9 章エキゾチック・デリバティブと PRDC	419
9.1 PRDC の商品構造と市場条件	420
9.1.1 商品条件	420
9.1.2 Coupon Schedule	422
9.1.3 Domestic、Foreign および Discount Curve	425
9.2 FX プロセスと Coupon Payoff	426
9.2.1 FX Process	426
9.2.2 Coupon Payoff	428
9.3 Monte Carlo による PRDC 評価	431
9.3.1 Coupon 日ベースの FX 時間グリッド	431
9.3.2 サンプル FX パス	433
9.3.3 PRDC の現在価値	435
9.3.4 期待 Coupon とキャッシュフロー	437
9.4 Coupon の期間構造と分布	439
9.4.1 期待 Coupon の期間構造	439

9.4.2 Coupon Cap / Floor 到達確率	440
9.4.3 Coupon 分布	441
9.5 FX 感応度と Monte Carlo 誤差	443
9.5.1 FX Spot 感応度	443
9.5.2 FX Volatility 感応度	445
9.5.3 Monte Carlo 標準誤差	448
9.6 モデルの限界と Part II 総括	449
9.6.1 PRDC 評価の限界	449
9.6.2 金利を決定論的とした	449
9.6.3 FX volatility を一定とした	449
9.6.4 相関を明示的に扱っていない	450
9.6.5 発行体コール権を含めていない	450
9.6.6 Part II のまとめ	450
9.7 まとめ	451

はじめに

『ラグランジェ・ファイナンス』は、実証会計・ファイナンスと金融工学を、R および tidyverse を用いて学ぶための入門書である。

第 I 部では、R の基本操作、財務データ、株式時系列、ファクターモデル、資産価格モデルおよびイベントスタディを扱う。第 II 部では、確定キャッシュフロー、金利期間構造、OIS スワップ、オプション評価モデル、信用リスクおよびエキゾチック・デリバティブを扱う。

各章では、理論だけでなく、再現可能なコードと計算結果を対応させながら金融分析の実装方法を確認する。

第Ⅰ部 実証会計・ファイナンス

第 1 章 R によるデータ分析の基礎

本章では、R によるデータ分析に必要な基本操作を、Base R から tidyverse へ段階的に学ぶ。前半では、オブジェクト、ベクトル、行列、リスト、データフレーム、関数、条件判定、記述統計および確率分布を扱う。後半では、`dplyr`、`stringr`、`tidyr`、`purrr`、`ggplot2` を用いて、データの読み込み、整形、集計、反復処理、可視化を一つの流れとして組み立てる。

Base R の項目構成は、Posit が公開している [Base R Cheatsheet](#) を参考にしている。本章のコードでは、反復処理に明示的なループを使わず、ベクトル化または `purrr::map()` 系関数を用いる。また、パイプ演算子はすべて `|>` に統一する。

1.1 R 環境と基本操作

1.1.1 使用するパッケージ

本章では tidyverse を使用する。tidyverse には、データ操作の `dplyr`、文字列処理の `stringr`、データ整形の `tidyr`、反復処理の `purrr`、可視化の `ggplot2` などが含まれる。

```
suppressPackageStartupMessages({  
  library(tidyverse)  
  library(ggthemes)  
  library(QuantLib)  
  library(GaussQuant)  
})
```

パッケージが未導入の場合は、RStudio の Console で一度だけ次を実行する。

```
install.packages("tidyverse")
```

1.1.2 R の基本操作

オブジェクトと代入

R では、計算結果やデータをオブジェクトとして保存する。代入には `<-` を用いる。

```
risk_free_rate <- 0.01  
future_cash_flow <- 100  
  
present_value <- future_cash_flow / (1 + risk_free_rate)
```

```
present_value
```

```
[1] 99.0099
```

オブジェクト名には、内容が分かる英単語を用いる。本書では複数の単語をアンダースコアで結ぶ snake_case を基本とする。

四則演算と代表的な数学関数

```
2 + 3
```

```
[1] 5
```

```
10 - 4
```

```
[1] 6
```

```
6 * 7
```

```
[1] 42
```

```
100 / 4
```

```
[1] 25
```

```
2^5
```

```
[1] 32
```

```
sqrt(16)
```

```
[1] 4
```

```
log(exp(1))
```

```
[1] 1
```

```
abs(-3)
```

```
[1] 3
```

```
round(pi, digits = 3)
```

```
[1] 3.142
```

```
signif(pi, digits = 4)
```

```
[1] 3.142
```

オブジェクトの型と構造

```
numeric_value <- 10.5
```

```
integer_value <- 10L
```

```
character_value <- "Finance"
```

```
logical_value <- TRUE
```

```
class(numeric_value)
```

```
[1] "numeric"
```

```
class(integer_value)
```

```
[1] "integer"
```

```
class(character_value)
```

```
[1] "character"
```

```
class(logical_value)
```

```
[1] "logical"
```

```
typeof(numeric_value)
```

```
[1] "double"
```

```
str(numeric_value)
```

```
num 10.5
```

欠損値

欠損値は NA で表す。欠損値の有無は `is.na()` で確認する。

```
returns_with_na <- c(0.02, NA, -0.01, 0.03)
```

```
is.na(returns_with_na)
```

```
[1] FALSE TRUE FALSE FALSE
```

```
sum(is.na(returns_with_na))
```

```
[1] 1
```

```
mean(returns_with_na, na.rm = TRUE)
```

```
[1] 0.01333333
```

1.2 ベクトルとデータ構造

1.2.1 ベクトル

ベクトルの作成

```
interest_rates <- c(0.01, 0.015, 0.02)
```

```
year_sequence <- 1:5
```



```
fine_grid <- seq(from = 0, to = 1, by = 0.25)
repeated_values <- rep(100, times = 5)

interest_rates
```

```
[1] 0.010 0.015 0.020
```

```
year_sequence
```

```
[1] 1 2 3 4 5
```

```
fine_grid
```

```
[1] 0.00 0.25 0.50 0.75 1.00
```

```
repeated_values
```

```
[1] 100 100 100 100 100
```

ベクトルの要素

R の添字は 1 から始まる。

```
interest_rates[1]
```

```
[1] 0.01
```

```
interest_rates[2:3]
```

```
[1] 0.015 0.020
```

```
interest_rates[-1]
```

```
[1] 0.015 0.020
```

```
interest_rates[interest_rates >= 0.015]
```

```
[1] 0.015 0.020
```

名前付きベクトル

```
portfolio_weights <- c(stock = 0.6, bond = 0.3, cash = 0.1)
```

```
portfolio_weights
```

```
stock bond cash
  0.6   0.3   0.1
```

```
portfolio_weights["bond"]
```

```
bond
```

```
0.3
```

```
sum(portfolio_weights)
```

```
[1] 1
```

ベクトル化

Rでは、多くの計算をベクトル全体に一度に適用できる。

```
discount_rates <- seq(0.01, 0.05, by = 0.01)
cash_flow <- 100

present_values <- cash_flow / (1 + discount_rates)

tibble(discount_rates, present_values)
```

```
# A tibble: 5 x 2
  discount_rates present_values
      <dbl>         <dbl>
1      0.01         99.0
2      0.02         98.0
3      0.03         97.1
4      0.04         96.2
5      0.05         95.2
```

1.2.2 行列、リスト、データフレーム

行列

```
return_matrix <- matrix(
  c(0.01, 0.02, -0.01, 0.03, 0.00, 0.01),
  nrow = 3,
  ncol = 2,
  byrow = TRUE
)

colnames(return_matrix) <- c("stock_a", "stock_b")
rownames(return_matrix) <- c("month_1", "month_2", "month_3")

return_matrix
```

```
      stock_a stock_b
month_1   0.01   0.02
month_2  -0.01   0.03
month_3   0.00   0.01
```

```
return_matrix[, "stock_a"]
```

```
month_1 month_2 month_3
      0.01   -0.01    0.00
```

```
colMeans(return_matrix)
```

```
stock_a stock_b
      0.00    0.02
```

リスト

リストには、型や長さの異なるオブジェクトをまとめて保存できる。

```
analysis_result <- list(
  model_name = "simple return model",
  coefficients = c(alpha = 0.001, beta = 1.05),
  observations = 60L,
  converged = TRUE
)
```

```
analysis_result$model_name
```

```
[1] "simple return model"
```

```
analysis_result$coefficients
```

```
alpha  beta
0.001  1.050
```

```
analysis_result[["observations"]]
```

```
[1] 60
```

データフレーム

```
firm_data_base <- data.frame(
  firm_id = 1:3,
  firm_name = c("Firm A", "Firm B", "Firm C"),
  roe = c(0.08, 0.12, 0.15)
)
```

```
firm_data_base
```

```
  firm_id firm_name  roe
1       1   Firm A 0.08
2       2   Firm B 0.12
3       3   Firm C 0.15
```

```
str(firm_data_base)
```

```
'data.frame':  3 obs. of  3 variables:
 $ firm_id  : int  1 2 3
 $ firm_name: chr  "Firm A" "Firm B" "Firm C"
 $ roe      : num  0.08 0.12 0.15
```

tidyverse では、データフレームを拡張した tibble を用いる。

```
firm_data <- tibble(
  firm_id = 1:3,
  firm_name = c("Firm A", "Firm B", "Firm C"),
  roe = c(0.08, 0.12, 0.15)
)
```

```
firm_data
```

```
# A tibble: 3 x 3
  firm_id firm_name  roe
  <int> <chr>      <dbl>
1     1 1 Firm A    0.08
2     2 2 Firm B    0.12
3     3 3 Firm C    0.15
```

少量のデータを行単位で記述する場合は tribble() が便利である。

```
project_data <- tribble(
  ~project, ~initial_cost, ~cash_flow,
  "A",      100,      120,
  "B",      150,      175,
  "C",      200,      215
)
```

```
project_data
```

```
# A tibble: 3 x 3
  project initial_cost cash_flow
  <chr>      <dbl>      <dbl>
1 A          100        120
2 B          150        175
3 C          200        215
```

1.3 関数・統計・確率分布

1.3.1 条件判定と独自関数

条件判定

```
npv <- 5.2

investment_decision <- if (npv >= 0) {
  "投資を実行する"
} else {
  "投資を見送る"
}

investment_decision
```

```
[1] "投資を実行する"
```

ベクトルに対する複数の条件分岐には `case_when()` を用いる。

```
credit_scores <- tibble(score = c(85, 72, 58, 91))

credit_scores |>
  mutate(
    rating = case_when(
      score >= 80 ~ "A",
      score >= 65 ~ "B",
      TRUE ~ "C"
    )
  )
```

```
# A tibble: 4 x 2
  score rating
  <dbl> <chr>
1    85 A
2    72 B
3    58 C
4    91 A
```

独自関数

```
calculate_present_value <- function(cash_flow, discount_rate, years = 1) {
  cash_flow / (1 + discount_rate)^years
}
```

```
calculate_present_value(cash_flow = 100, discount_rate = 0.02, years = 3)
```

```
[1] 94.23223
```

関数はベクトルをそのまま受け取れるように設計すると再利用しやすい。

```
calculate_present_value(
  cash_flow = c(100, 100, 100),
  discount_rate = 0.02,
  years = 1:3
)
```

```
[1] 98.03922 96.11688 94.23223
```

1.3.2 記述統計

代表値と散らばり

```
sample_returns <- c(0.01, 0.03, -0.02, 0.00, 0.04, 0.02)
```

```
mean(sample_returns)
```

```
[1] 0.01333333
```

```
median(sample_returns)
```

```
[1] 0.015
```

```
min(sample_returns)
```

```
[1] -0.02
```

```
max(sample_returns)
```

```
[1] 0.04
```

```
range(sample_returns)
```

```
[1] -0.02 0.04
```

```
var(sample_returns)
```

```
[1] 0.0004666667
```

```
sd(sample_returns)
```

```
[1] 0.02160247
```

```
quantile(sample_returns)
```

0%	25%	50%	75%	100%
-0.0200	0.0025	0.0150	0.0275	0.0400

共分散と相関

```
stock_a <- c(0.01, 0.03, -0.02, 0.02, 0.04)
stock_b <- c(0.00, 0.02, -0.01, 0.01, 0.03)

cov(stock_a, stock_b)
```

```
[1] 0.00035
```

```
cor(stock_a, stock_b)
```

```
[1] 0.9615239
```

順位

```
firm_returns <- c(0.08, 0.12, -0.03, 0.05)

rank(firm_returns)
```

```
[1] 3 4 1 2
```

```
rank(-firm_returns)
```

```
[1] 2 1 4 3
```

```
order(firm_returns, decreasing = TRUE)
```

```
[1] 2 1 4 3
```

1.3.3 確率分布

R の確率分布関数には共通した命名規則がある。

接頭辞	内容
r	乱数を生成する
d	確率密度または確率質量を求める
p	累積確率を求める
q	累積確率に対応する分位点を求める

一様分布

```
set.seed(1234)

uniform_random <- runif(n = 10, min = 0, max = 1)

uniform_random
```

```
[1] 0.113703411 0.622299405 0.609274733 0.623379442 0.860915384 0.640310605
[7] 0.009495756 0.232550506 0.666083758 0.514251141
```

```
dunif(0.5, min = 0, max = 1)
```

```
[1] 1
```

```
punif(0.5, min = 0, max = 1)
```

```
[1] 0.5
```

```
qunif(0.95, min = 0, max = 1)
```

```
[1] 0.95
```

正規分布

```
set.seed(1234)
```

```
normal_random <- rnorm(n = 10, mean = 0, sd = 1)
```

```
normal_random
```

```
[1] -1.2070657 0.2774292 1.0844412 -2.3456977 0.4291247 0.5060559
[7] -0.5747400 -0.5466319 -0.5644520 -0.8900378
```

```
dnorm(0, mean = 0, sd = 1)
```

```
[1] 0.3989423
```

```
pnorm(1.96, mean = 0, sd = 1)
```

```
[1] 0.9750021
```

```
qnorm(0.975, mean = 0, sd = 1)
```

```
[1] 1.959964
```

dnorm() は正規分布の密度、pnorm() は指定した値以下となる確率、qnorm() は指定した累積確率に対応する分位点を返す。

```
probability_below <- pnorm(-0.02, mean = 0.01, sd = 0.03)
```

```
value_at_risk_95 <- qnorm(0.05, mean = 0.01, sd = 0.03)
```

```
probability_below
```

```
[1] 0.1586553
```

```
value_at_risk_95
```

```
[1] -0.03934561
```


二項分布

```
set.seed(1234)

binomial_random <- rbinom(n = 10, size = 20, prob = 0.6)

binomial_random

[1] 15 11 11 11 10 11 17 14 11 12

dbinom(12, size = 20, prob = 0.6)

[1] 0.1797058

pbinom(12, size = 20, prob = 0.6)

[1] 0.5841071

qbinom(0.95, size = 20, prob = 0.6)

[1] 16
```

ポアソン分布

```
set.seed(1234)

poisson_random <- rpois(n = 10, lambda = 3)

poisson_random

[1] 1 3 3 3 5 3 0 2 4 3

dpois(2, lambda = 3)

[1] 0.2240418

ppois(2, lambda = 3)

[1] 0.4231901

qpois(0.95, lambda = 3)

[1] 6
```

分布関数の比較

```
distribution_functions <- tribble(
  ~distribution, ~random_function, ~density_function, ~cumulative_function, ~quantile_function,
  "一様分布",    "runif()",          "dunif()",          "punif()",          "qunif()",
```

```

"正規分布",      "rnorm()",      "dnorm()",      "pnorm()",      "qnorm()",
"二項分布",      "rbinom()",     "dbinom()",     "pbinom()",     "qbinom()",
"ポアソン分布", "rpois()",      "dpois()",      "ppois()",      "qpois()"
)

```

```
distribution_functions
```

```

# A tibble: 4 x 5
  distribution random_function density_function cumulative_function
  <chr>         <chr>         <chr>         <chr>
1 一様分布      runif()        dunif()        punif()
2 正規分布      rnorm()        dnorm()        pnorm()
3 二項分布      rbinom()       dbinom()       pbinom()
4 ポアソン分布 rpois()        dpois()        ppois()
# i 1 more variable: quantile_function <chr>

```

1.4 データ読込みと dplyr

1.4.1 プロジェクト内のデータを読み込む

本書で使用するデータは、プロジェクトルートの `simulation_data` ディレクトリに置かれている。絶対パスをコードへ直接書くと、プロジェクトを別の場所へ移したときに動かなくなる。そのため、現在の作業ディレクトリと `_quarto.yml` を利用してプロジェクトルートを確認する。

```

project_candidates <- unique(c(
  Sys.getenv("QUARTO_PROJECT_DIR"),
  getwd(),
  dirname(getwd())
))

project_candidates <- project_candidates[nzchar(project_candidates)]

project_matches <- project_candidates[
  file.exists(file.path(project_candidates, "_quarto.yml"))
]

if (length(project_matches) == 0) {
  stop("LagrangeFinanceのプロジェクトルートを確認できません。")
}

project_dir <- normalizePath(project_matches[1], winslash = "/", mustWork = TRUE)
data_dir <- file.path(project_dir, "simulation_data")

if (!dir.exists(data_dir)) {

```

```
stop("simulation_dataディレクトリが見つかりません: ", data_dir)
}
```

```
project_dir
```

```
[1] "C:/AnalyticFin/Projects/LagrangeFinance"
```

```
data_dir
```

```
[1] "C:/AnalyticFin/Projects/LagrangeFinance/simulation_data"
```

simulation_data 以下の CSV ファイルを再帰的に確認する。

```
csv_paths <- list.files(
  path = data_dir,
  pattern = "\\\\.csv$",
  full.names = TRUE,
  recursive = TRUE
)

normalized_data_dir <- normalizePath(data_dir, winslash = "/", mustWork = TRUE)
normalized_csv_paths <- normalizePath(csv_paths, winslash = "/", mustWork = FALSE)

csv_catalog <- tibble(
  file_name = basename(csv_paths),
  relative_path = substring(
    normalized_csv_paths,
    first = nchar(normalized_data_dir) + 2
  )
) |>
  arrange(relative_path)

csv_catalog
```

```
# A tibble: 27 x 2
```

	file_name	relative_path
	<chr>	<chr>
1	ch03_daily_stock_return.csv	ch03_daily_stock_return.csv
2	ch03_output.csv	ch03_output.csv
3	ch04_financial_data.csv	ch04_financial_data.csv
4	ch04_output.csv	ch04_output.csv
5	ch05_accounting_standard.csv	ch05_accounting_standard.csv
6	ch05_earnings_management.csv	ch05_earnings_management.csv
7	ch05_messy_stock_return.csv	ch05_messy_stock_return.csv
8	ch05_output1.csv	ch05_output1.csv
9	ch05_output2.csv	ch05_output2.csv

```
10 ch05_stock_data.csv          ch05_stock_data.csv
# i 17 more rows
```

第1章では、従来から使用している `ch03_daily_stock_return.csv` を読み込む。ファイルが `simulation_data` 内のサブディレクトリに置かれていても検索できる。

```
daily_return_candidates <- csv_paths[
  basename(csv_paths) == "ch03_daily_stock_return.csv"
]

if (length(daily_return_candidates) == 0) {
  stop("ch03_daily_stock_return.csvがsimulation_data以下に見つかりません。")
}

daily_return_path <- daily_return_candidates[1]

daily_stock_return <- readr::read_csv(
  daily_return_path,
  show_col_types = FALSE
)

required_columns <- c("date", "firm1", "firm2")
missing_columns <- setdiff(required_columns, names(daily_stock_return))

if (length(missing_columns) > 0) {
  stop(
    "必要な列が不足しています: ",
    paste(missing_columns, collapse = ", ")
  )
}

daily_stock_return <- daily_stock_return |>
  mutate(date = as.Date(date))

daily_stock_return

# A tibble: 21 x 3
   date      firm1    firm2
<date>    <dbl>    <dbl>
1 2020-04-01 -0.0395  0.0770
2 2020-04-02  0.00598 -0.00725
3 2020-04-03  0.0558  -0.0173
4 2020-04-06  0.0419  0.00217
5 2020-04-07 -0.0202  0.0755
6 2020-04-08 -0.00229 -0.0962
```

```

7 2020-04-09 0.0817 0.0788
8 2020-04-10 0.0346 0.0215
9 2020-04-13 0.0326 0.135
10 2020-04-14 -0.0377 0.0380
# i 11 more rows

```

データの構造を確認する

```
glimpse(daily_stock_return)
```

```

Rows: 21
Columns: 3
$ date <date> 2020-04-01, 2020-04-02, 2020-04-03, 2020-04-06, 2020-04-07, 202~
$ firm1 <dbl> -0.039482142, 0.005978689, 0.055786605, 0.041934669, -0.02019279~
$ firm2 <dbl> 0.0769625974, -0.0072488484, -0.0173040800, 0.0021689573, 0.0755~

```

```
summary(daily_stock_return)
```

date	firm1	firm2
Min. :2020-04-01	Min. : -0.072071	Min. : -0.0962117
1st Qu.:2020-04-08	1st Qu.: -0.027029	1st Qu.: -0.0196147
Median :2020-04-15	Median : 0.005979	Median : -0.0003056
Mean :2020-04-15	Mean : 0.014161	Mean : 0.0080253
3rd Qu.:2020-04-22	3rd Qu.: 0.044812	3rd Qu.: 0.0379793
Max. :2020-04-30	Max. : 0.171297	Max. : 0.1352008

```
nrow(daily_stock_return)
```

```
[1] 21
```

```
ncol(daily_stock_return)
```

```
[1] 3
```

```
names(daily_stock_return)
```

```
[1] "date" "firm1" "firm2"
```

1.4.2 dplyr によるデータ操作

列を選ぶ

```
daily_stock_return |>
  select(date, firm1)
```

```

# A tibble: 21 x 2
  date      firm1
  <date>    <dbl>
1 2020-04-01 -0.0395

```

```

2 2020-04-02  0.00598
3 2020-04-03  0.0558
4 2020-04-06  0.0419
5 2020-04-07 -0.0202
6 2020-04-08 -0.00229
7 2020-04-09  0.0817
8 2020-04-10  0.0346
9 2020-04-13  0.0326
10 2020-04-14 -0.0377
# i 11 more rows

```

行を抽出する

```

daily_stock_return |>
  filter(firm1 > 0)

```

```

# A tibble: 12 x 3
   date      firm1  firm2
<date>    <dbl>  <dbl>
1 2020-04-02 0.00598 -0.00725
2 2020-04-03 0.0558  -0.0173
3 2020-04-06 0.0419   0.00217
4 2020-04-09 0.0817   0.0788
5 2020-04-10 0.0346   0.0215
6 2020-04-13 0.0326   0.135
7 2020-04-15 0.00988  0.0114
8 2020-04-17 0.171    0.0395
9 2020-04-20 0.0463   0.0373
10 2020-04-22 0.0515  -0.0538
11 2020-04-27 0.00454 -0.0196
12 2020-04-30 0.0448  -0.0134

```

複数の条件を同時に指定できる。

```

daily_stock_return |>
  filter(firm1 > 0, firm2 > 0)

```

```

# A tibble: 6 x 3
   date      firm1  firm2
<date>    <dbl>  <dbl>
1 2020-04-06 0.0419  0.00217
2 2020-04-09 0.0817  0.0788
3 2020-04-10 0.0346  0.0215
4 2020-04-13 0.0326  0.135
5 2020-04-15 0.00988 0.0114
6 2020-04-17 0.171   0.0395

```

```
7 2020-04-20 0.0463 0.0373
```

列を追加する

```
return_data <- daily_stock_return |>
  mutate(
    spread = firm1 - firm2,
    firm1_gross_return = 1 + firm1,
    firm2_gross_return = 1 + firm2,
    market_direction = case_when(
      firm1 > 0 & firm2 > 0 ~ "both_positive",
      firm1 < 0 & firm2 < 0 ~ "both_negative",
      TRUE ~ "mixed"
    )
  )
```

```
return_data
```

```
# A tibble: 21 x 7
```

	date	firm1	firm2	spread	firm1_gross_return	firm2_gross_return
	<date>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
1	2020-04-01	-0.0395	0.0770	-0.116	0.961	1.08
2	2020-04-02	0.00598	-0.00725	0.0132	1.01	0.993
3	2020-04-03	0.0558	-0.0173	0.0731	1.06	0.983
4	2020-04-06	0.0419	0.00217	0.0398	1.04	1.00
5	2020-04-07	-0.0202	0.0755	-0.0957	0.980	1.08
6	2020-04-08	-0.00229	-0.0962	0.0939	0.998	0.904
7	2020-04-09	0.0817	0.0788	0.00286	1.08	1.08
8	2020-04-10	0.0346	0.0215	0.0130	1.03	1.02
9	2020-04-13	0.0326	0.135	-0.103	1.03	1.14
10	2020-04-14	-0.0377	0.0380	-0.0756	0.962	1.04

```
# i 11 more rows
```

```
# i 1 more variable: market_direction <chr>
```

並び替える

```
return_data |>
  arrange(firm1)
```

```
# A tibble: 21 x 7
```

	date	firm1	firm2	spread	firm1_gross_return	firm2_gross_return
	<date>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
1	2020-04-28	-0.0721	-0.0469	-0.0252	0.928	0.953
2	2020-04-24	-0.0414	-0.00411	-0.0373	0.959	0.996
3	2020-04-01	-0.0395	0.0770	-0.116	0.961	1.08

```

4 2020-04-14 -0.0377  0.0380  -0.0756                0.962                1.04
5 2020-04-23 -0.0289 -0.0355   0.00661              0.971                0.965
6 2020-04-16 -0.0270 -0.0535   0.0265                0.973                0.947
7 2020-04-07 -0.0202  0.0755  -0.0957                0.980                1.08
8 2020-04-21 -0.0146 -0.000306 -0.0143              0.985                1.000
9 2020-04-08 -0.00229 -0.0962   0.0939              0.998                0.904
10 2020-04-27  0.00454 -0.0196   0.0242              1.00                0.980
# i 11 more rows
# i 1 more variable: market_direction <chr>

```

```

return_data |>
  arrange(desc(firm1))

```

```

# A tibble: 21 x 7
   date      firm1    firm2  spread firm1_gross_return firm2_gross_return
<date>    <dbl>    <dbl>   <dbl>          <dbl>          <dbl>
1 2020-04-17 0.171    0.0395  0.132          1.17           1.04
2 2020-04-09 0.0817    0.0788  0.00286        1.08           1.08
3 2020-04-03 0.0558   -0.0173  0.0731         1.06           0.983
4 2020-04-22 0.0515   -0.0538  0.105          1.05           0.946
5 2020-04-20 0.0463    0.0373  0.00905        1.05           1.04
6 2020-04-30 0.0448   -0.0134  0.0582         1.04           0.987
7 2020-04-06 0.0419    0.00217  0.0398         1.04           1.00
8 2020-04-10 0.0346    0.0215   0.0130         1.03           1.02
9 2020-04-13 0.0326    0.135   -0.103         1.03           1.14
10 2020-04-15 0.00988  0.0114  -0.00155       1.01           1.01
# i 11 more rows
# i 1 more variable: market_direction <chr>

```

要約する

```

return_data |>
  summarise(
    observations = n(),
    mean_firm1 = mean(firm1),
    sd_firm1 = sd(firm1),
    mean_firm2 = mean(firm2),
    sd_firm2 = sd(firm2),
    correlation = cor(firm1, firm2)
  )

```

```

# A tibble: 1 x 6
  observations mean_firm1 sd_firm1 mean_firm2 sd_firm2 correlation
      <int>      <dbl>   <dbl>      <dbl>   <dbl>      <dbl>
1         21    0.0142   0.0538    0.00803  0.0544    0.233

```


グループごとに集計する

```
return_data |>
  group_by(market_direction) |>
  summarise(
    observations = n(),
    mean_firm1 = mean(firm1),
    mean_firm2 = mean(firm2),
    .groups = "drop"
  ) |>
  arrange(desc(observations))
```

```
# A tibble: 3 x 4
  market_direction observations mean_firm1 mean_firm2
  <chr>              <int>      <dbl>      <dbl>
1 mixed                8      0.00816    0.00989
2 both_positive        7      0.0598     0.0466
3 both_negative        6     -0.0310    -0.0394
```

件数を数える

```
return_data |>
  count(market_direction, sort = TRUE)
```

```
# A tibble: 3 x 2
  market_direction      n
  <chr>              <int>
1 mixed                8
2 both_positive        7
3 both_negative        6
```

データを結合する

```
firm_master <- tribble(
  ~firm, ~firm_name, ~industry,
  "firm1", "Firm A", "Machinery",
  "firm2", "Firm B", "Chemicals"
)

return_summary <- return_data |>
  summarise(
    firm1 = mean(firm1),
    firm2 = mean(firm2)
  ) |>
```

```

pivot_longer(
  cols = everything(),
  names_to = "firm",
  values_to = "mean_return"
)

return_summary |>
  left_join(firm_master, by = "firm")

```

```

# A tibble: 2 x 4
  firm mean_return firm_name industry
<chr>      <dbl> <chr>      <chr>
1 firm1    0.0142 Firm A      Machinery
2 firm2    0.00803 Firm B      Chemicals

```

1.5 stringr • tidyr • purrr

1.5.1 stringr による文字列処理

文字列処理では、関数名が `str_` で始まる `stringr` を使用する。

```

company_names <- tibble(
  raw_name = c(
    " Alpha Holdings Co., Ltd. ",
    "Beta Financial Group",
    "Gamma Industries"
  )
)

company_names <- company_names |>
  mutate(
    clean_name = str_squish(raw_name),
    lower_name = str_to_lower(clean_name),
    name_length = str_length(clean_name),
    contains_group = str_detect(clean_name, regex("group", ignore_case = TRUE)),
    first_word = str_extract(clean_name, "^[A-Za-z]+")
  )

company_names

```

```

# A tibble: 3 x 6
  raw_name      clean_name lower_name name_length contains_group first_word
<chr>          <chr>      <chr>          <int> <lgl>          <chr>
1 " Alpha Holdings~ Alpha Hol~ alpha hol~      24 FALSE      Alpha
2 "Beta Financial G~ Beta Fina~ beta fina~      20 TRUE       Beta

```

```
3 "Gamma Industries" Gamma Ind~ gamma ind~          16 FALSE          Gamma
```

置換と結合

```
company_names |>
  mutate(
    short_name = str_remove(clean_name, regex(" co\\.\\. , ltd\\.\\. $", ignore_case = TRUE)),
    display_name = str_c(first_word, " / ", name_length, " characters")
  ) |>
  select(clean_name, short_name, display_name)
```

```
# A tibble: 3 x 3
  clean_name          short_name      display_name
  <chr>              <chr>          <chr>
1 Alpha Holdings Co., Ltd. Alpha Holdings Alpha / 24 characters
2 Beta Financial Group  Beta Financial Group Beta / 20 characters
3 Gamma Industries     Gamma Industries Gamma / 16 characters
```

1.5.2 tidyr によるデータ整形

wide 形式から long 形式へ変換する

元のデータでは、`firm1` と `firm2` が別々の列に格納されている。`pivot_longer()` を使うと、企業名とリターンをそれぞれ一つの列へまとめられる。

```
return_long <- daily_stock_return |>
  pivot_longer(
    cols = c(firm1, firm2),
    names_to = "firm",
    values_to = "return"
  )

return_long
```

```
# A tibble: 42 x 3
  date      firm    return
  <date>   <chr>   <dbl>
1 2020-04-01 firm1 -0.0395
2 2020-04-01 firm2  0.0770
3 2020-04-02 firm1  0.00598
4 2020-04-02 firm2 -0.00725
5 2020-04-03 firm1  0.0558
6 2020-04-03 firm2 -0.0173
7 2020-04-06 firm1  0.0419
8 2020-04-06 firm2  0.00217
9 2020-04-07 firm1 -0.0202
```

```
10 2020-04-07 firm2 0.0755
# i 32 more rows
```

long 形式から wide 形式へ戻す

```
return_long |>
  pivot_wider(
    names_from = firm,
    values_from = return
  )
```

```
# A tibble: 21 x 3
  date      firm1    firm2
<date>    <dbl>    <dbl>
1 2020-04-01 -0.0395  0.0770
2 2020-04-02  0.00598 -0.00725
3 2020-04-03  0.0558  -0.0173
4 2020-04-06  0.0419  0.00217
5 2020-04-07 -0.0202  0.0755
6 2020-04-08 -0.00229 -0.0962
7 2020-04-09  0.0817  0.0788
8 2020-04-10  0.0346  0.0215
9 2020-04-13  0.0326  0.135
10 2020-04-14 -0.0377  0.0380
# i 11 more rows
```

文字列を複数列へ分ける

```
security_codes <- tibble(
  security_id = c("JP-1001", "JP-1002", "US-2001")
)
```

```
security_codes |>
  separate_wider_delim(
    security_id,
    delim = "-",
    names = c("country", "code")
  )
```

```
# A tibble: 3 x 2
  country code
<chr>    <chr>
1 JP      1001
2 JP      1002
3 US      2001
```

欠損値を処理する

```
missing_data <- tibble(  
  firm = c("A", "B", "C"),  
  return = c(0.02, NA, -0.01)  
)  
  
missing_data |>  
  replace_na(list(return = 0))
```

```
# A tibble: 3 x 2  
  firm return  
  <chr> <dbl>  
1 A      0.02  
2 B       0  
3 C     -0.01
```

```
missing_data |>  
  drop_na()
```

```
# A tibble: 2 x 2  
  firm return  
  <chr> <dbl>  
1 A      0.02  
2 C     -0.01
```

1.5.3 purrr による反復処理

map() と型を指定する map 系関数

map() は結果をリストとして返す。数値ベクトルが必要な場合は map_dbl() を用いる。

```
discount_rates <- c(0.01, 0.02, 0.03, 0.04)  
  
discount_rates |>  
  map(\(rate) calculate_present_value(100, rate))
```

```
[[1]]  
[1] 99.0099
```

```
[[2]]  
[1] 98.03922
```

```
[[3]]  
[1] 97.08738
```

```
[[4]]
[1] 96.15385
```

```
present_value_table <- tibble(
  discount_rate = discount_rates,
  present_value = discount_rates |>
    map_dbl(\(rate) calculate_present_value(100, rate))
)

present_value_table
```

```
# A tibble: 4 x 2
  discount_rate present_value
      <dbl>         <dbl>
1      0.01          99.0
2      0.02          98.0
3      0.03          97.1
4      0.04          96.2
```

map2() で二つのベクトルを同時に処理する

```
cash_flows <- c(100, 120, 150)
years <- c(1, 2, 3)

map2_dbl(
  cash_flows,
  years,
  \(cash_flow, year) calculate_present_value(cash_flow, 0.02, year)
)
```

```
[1] 98.03922 115.34025 141.34835
```

pmap() で複数の列を処理する

```
cash_flow_scenarios <- tribble(
  ~cash_flow, ~discount_rate, ~years,
    100,      0.01,      1,
    120,      0.02,      2,
    150,      0.03,      3
)

cash_flow_scenarios |>
  mutate(
    present_value = pmap_dbl(
      list(cash_flow, discount_rate, years),
```

```

    \(cash_flow, discount_rate, years) {
      calculate_present_value(cash_flow, discount_rate, years)
    }
  )
)

```

A tibble: 3 x 4

	cash_flow	discount_rate	years	present_value
	<dbl>	<dbl>	<dbl>	<dbl>
1	100	0.01	1	99.0
2	120	0.02	2	115.
3	150	0.03	3	137.

複数列へ同じ集計を適用する

```

return_columns <- c("firm1", "firm2")

return_columns |>
  map_dfr(
    \(column_name) {
      values <- daily_stock_return[[column_name]]

      tibble(
        firm = column_name,
        observations = length(values),
        mean = mean(values),
        standard_deviation = sd(values),
        minimum = min(values),
        maximum = max(values)
      )
    }
  )

```

A tibble: 2 x 6

	firm	observations	mean	standard_deviation	minimum	maximum
	<chr>	<int>	<dbl>	<dbl>	<dbl>	<dbl>
1	firm1	21	0.0142	0.0538	-0.0721	0.171
2	firm2	21	0.00803	0.0544	-0.0962	0.135

複数の確率分布を同じ形式で生成する

```

set.seed(1234)

distribution_specs <- tribble(

```

```

~distribution, ~generator,
"uniform",      \(n) runif(n, min = -1, max = 1),
"normal",       \(n) rnorm(n, mean = 0, sd = 1),
"poisson",      \(n) rpois(n, lambda = 3)
)

simulated_distributions <- distribution_specs |>
  mutate(values = map(generator, \(generator) generator(1000))) |>
  select(~generator) |>
  unnest_longer(values)

simulated_distributions

```

```

# A tibble: 3,000 x 2
  distribution values
  <chr>         <dbl>
1 uniform      -0.773
2 uniform       0.245
3 uniform       0.219
4 uniform       0.247
5 uniform       0.722
6 uniform       0.281
7 uniform      -0.981
8 uniform      -0.535
9 uniform       0.332
10 uniform      0.0285
# i 2,990 more rows

```

walk() で副作用だけを実行する

walk() は、返り値を保存するのではなく、表示などの副作用だけを順番に実行するときに使う。

```

c("firm1", "firm2") |>
  walk(\(firm) print(str_c("集計対象: ", firm)))

```

```

[1] "集計対象: firm1"
[1] "集計対象: firm2"

```


1.6 可視化と総合演習

1.6.1 ggplot2 による可視化

ggplot2 では、データを ggplot() へ渡し、aes() で変数と視覚要素の対応を指定し、geom_*() で図形を追加する。


折れ線グラフ

```
return_long |>
  ggplot(aes(x = date, y = return, linetype = firm)) +
  geom_line(linewidth = 0.7) +
  labs(
    x = "Date",
    y = "Daily Return",
    linetype = "Firm"
  ) +
  theme_classic()
```




ヒストグラム

```
return_long |>
  ggplot(aes(x = return)) +
  geom_histogram(bins = 10, boundary = 0) +
  facet_wrap(vars(firm), ncol = 1) +
  labs(
    x = "Daily Return",
    y = "Count"
  ) +
  theme_classic()
```



密度関数


```
return_long |>
  ggplot(aes(x = return, linetype = firm)) +
  geom_density(linewidth = 0.8) +
  labs(
    x = "Daily Return",
    y = "Density",
    linetype = "Firm"
  ) +
  theme_classic()
```



正規分布の密度と累積分布


```
normal_curve <- tibble(
  x = seq(-4, 4, length.out = 401),
  density = dnorm(x),
  cumulative_probability = pnorm(x)
)

normal_curve |>
  pivot_longer(
    cols = c(density, cumulative_probability),
    names_to = "function_type",
    values_to = "value"
  ) |>
  ggplot(aes(x = x, y = value)) +
  geom_line(linewidth = 0.8) +
  facet_wrap(vars(function_type), scales = "free_y", ncol = 1) +
  labs(
    x = "x",
    y = NULL
  ) +
  theme_classic()
```



シミュレーション結果を比較する

```
simulated_distributions |>
  ggplot(aes(x = values)) +
  geom_histogram(bins = 30) +
  facet_wrap(vars(distribution), scales = "free") +
  labs(
    x = "Simulated Value",
    y = "Count"
  ) +
  theme_classic()
```



1.6.2 総合演習

最後に、`simulation_data` から読み込んだ日次リターンを、読み込み、整形、集計、反復処理、可視化の順に分析する。

分析用データを作る

```
analysis_data <- daily_stock_return |>
  pivot_longer(
    cols = c(firm1, firm2),
    names_to = "firm",
    values_to = "return"
  ) |>
  mutate(
    gross_return = 1 + return,
    direction = case_when(
      return > 0 ~ "positive",
      return < 0 ~ "negative",
      TRUE ~ "zero"
    )
  ) |>
  arrange(firm, date)

analysis_data
```

```
# A tibble: 42 x 5
  date      firm    return gross_return direction
<date>    <chr>    <dbl>      <dbl> <chr>
1 2020-04-01 firm1 -0.0395      0.961 negative
2 2020-04-02 firm1  0.00598      1.01  positive
3 2020-04-03 firm1  0.0558      1.06  positive
4 2020-04-06 firm1  0.0419      1.04  positive
5 2020-04-07 firm1 -0.0202      0.980 negative
6 2020-04-08 firm1 -0.00229      0.998 negative
7 2020-04-09 firm1  0.0817      1.08  positive
8 2020-04-10 firm1  0.0346      1.03  positive
9 2020-04-13 firm1  0.0326      1.03  positive
10 2020-04-14 firm1 -0.0377      0.962 negative
# i 32 more rows
```

企業別の要約統計量を計算する

```
firm_summary <- analysis_data |>
  group_by(firm) |>
  summarise(
    observations = n(),
    mean_return = mean(return),
    standard_deviation = sd(return),
    minimum_return = min(return),
    maximum_return = max(return),
    positive_ratio = mean(return > 0),
    .groups = "drop"
  )

firm_summary
```

```
# A tibble: 2 x 7
  firm observations mean_return standard_deviation minimum_return
<chr>          <int>      <dbl>          <dbl>          <dbl>
1 firm1           21    0.0142          0.0538         -0.0721
2 firm2           21    0.00803         0.0544         -0.0962
# i 2 more variables: maximum_return <dbl>, positive_ratio <dbl>
```

累積リターンを計算する

```
cumulative_return_data <- analysis_data |>
  group_by(firm) |>
  mutate(
    cumulative_gross_return = cumprod(gross_return),
```

```

    cumulative_return = cumulative_gross_return - 1
  ) |>
  ungroup()

cumulative_return_data

# A tibble: 42 x 7
   date      firm    return gross_return direction cumulative_gross_return
<date>   <chr>    <dbl>      <dbl> <chr>          <dbl>
1 2020-04-01 firm1 -0.0395    0.961 negative      0.961
2 2020-04-02 firm1  0.00598    1.01  positive      0.966
3 2020-04-03 firm1  0.0558    1.06  positive      1.02
4 2020-04-06 firm1  0.0419    1.04  positive      1.06
5 2020-04-07 firm1 -0.0202    0.980 negative      1.04
6 2020-04-08 firm1 -0.00229   0.998 negative      1.04
7 2020-04-09 firm1  0.0817    1.08  positive      1.12
8 2020-04-10 firm1  0.0346    1.03  positive      1.16
9 2020-04-13 firm1  0.0326    1.03  positive      1.20
10 2020-04-14 firm1 -0.0377    0.962 negative      1.16
# i 32 more rows
# i 1 more variable: cumulative_return <dbl>

```

purrr で企業別の統計量を再計算する

```

firm_names <- unique(analysis_data$firm)

firm_names |>
  map_dfr(
    \(firm_name) {
      firm_returns <- analysis_data |>
        filter(firm == firm_name) |>
        pull(return)

      tibble(
        firm = firm_name,
        mean_return = mean(firm_returns),
        volatility = sd(firm_returns),
        lower_5_percent = quantile(firm_returns, 0.05),
        upper_95_percent = quantile(firm_returns, 0.95)
      )
    }
  )

```

```


# A tibble: 2 x 5

```

	firm	mean_return	volatility	lower_5_percent	upper_95_percent
	<chr>	<dbl>	<dbl>	<dbl>	<dbl>
1	firm1	0.0142	0.0538	-0.0414	0.0817
2	firm2	0.00803	0.0544	-0.0538	0.0788

累積リターンを可視化する

```
cumulative_return_data |>
  ggplot(aes(x = date, y = cumulative_return, linetype = firm)) +
  geom_line(linewidth = 0.8) +
  geom_hline(yintercept = 0, linetype = "dotted") +
  labs(
    x = "Date",
    y = "Cumulative Return",
    linetype = "Firm"
  ) +
  theme_classic()
```



1.7 まとめ

本章では、Base R の基本的なデータ構造と関数から出発し、記述統計、確率分布、tidyverse によるデータ分析までを一通り確認した。重要な点は次のとおりである。

- オブジェクト名には内容を表す snake_case を用いる。
- 同じ計算を複数の値へ適用するときは、まずベクトル化を検討する。

- 反復処理が必要な場合は `purrr::map()` 系関数を用いる。
- データ操作は `dplyr`、文字列処理は `stringr`、整形は `tidyr` を用いる。
- パイプ演算子は `|>` に統一する。
- グラフは `ggplot2` でデータ、変数、図形を分けて組み立てる。
- データファイルは絶対パスではなく、プロジェクトルートを基準に読み込む。

次章以降では、本章で学んだ操作を用いて、財務データと株式データの分析を進める。

第 2 章財務データの整理と分析

本章では、企業の財務データを読み込み、データ型、欠損値、年度構成、産業構成を確認した上で、株主資本、自己資本利益率（ROE）および上級デュポン・モデルの構成要素を計算する。第 1 章で学んだ `dplyr`、`tidyr`、`purrr`、`ggplot2` を、実際のパネルデータ分析へ応用する。

本章のコードは、次の方針で統一する。

- パイプ演算子には `|>` を使う。
- 明示的な `for`、`while`、`repeat` ループは使わない。
- データ操作には `dplyr` と `tidyr` を使う。
- 反復的な処理が必要な場合は `purrr::map()` 系関数を使う。
- 入力データはプロジェクトルートの `simulation_data` 以下から検索する。
- 中間データは `simulation_data/derived` へ保存し、元データを上書きしない。

2.1 分析環境とデータディレクトリ

2.1.1 使用するパッケージ

```
suppressPackageStartupMessages({  
  library(tidyverse)  
  library(ggthemes)  
  library(QuantLib)  
  library(GaussQuant)  
})
```

パッケージが未導入の場合は、RStudio の Console で一度だけ次を実行する。

```
install.packages("tidyverse")
```

2.1.2 プロジェクトとデータディレクトリ

第 1 章と同様に、現在の作業ディレクトリと `_quarto.yml` を利用して、LagrangeFinance のプロジェクトルートを確認する。これにより、リポジトリを別の場所へ移しても、絶対パスを書き換えずに実行できる。

```
project_candidates <- unique(c(  
  Sys.getenv("QUARTO_PROJECT_DIR"),  
  getwd(),  
  dirname(getwd())
```

```

))

project_candidates <- project_candidates[nzchar(project_candidates)]

project_matches <- project_candidates[
  file.exists(file.path(project_candidates, "_quarto.yml"))
]

if (length(project_matches) == 0) {
  stop("LagrangeFinanceのプロジェクトルートを確認できません。")
}

project_dir <- normalizePath(project_matches[1], winslash = "/", mustWork = TRUE)
data_dir <- file.path(project_dir, "simulation_data")
derived_data_dir <- file.path(data_dir, "derived")

if (!dir.exists(data_dir)) {
  stop("simulation_dataディレクトリが見つかりません: ", data_dir)
}

project_dir

```

```
[1] "C:/AnalyticFin/Projects/LagrangeFinance"
```

```
data_dir
```

```
[1] "C:/AnalyticFin/Projects/LagrangeFinance/simulation_data"
```

simulation_data 以下の CSV ファイルを再帰的に取得する。

```

csv_paths <- list.files(
  path = data_dir,
  pattern = "\\\\.csv$",
  full.names = TRUE,
  recursive = TRUE
)

normalized_data_dir <- normalizePath(data_dir, winslash = "/", mustWork = TRUE)
normalized_csv_paths <- normalizePath(csv_paths, winslash = "/", mustWork = FALSE)

csv_catalog <- tibble(
  file_name = basename(csv_paths),
  relative_path = substring(
    normalized_csv_paths,
    first = nchar(normalized_data_dir) + 2
  )
)

```

```

) |>
  arrange(relative_path)

csv_catalog

# A tibble: 27 x 2
  file_name                relative_path
  <chr>                    <chr>
1 ch03_daily_stock_return.csv ch03_daily_stock_return.csv
2 ch03_output.csv           ch03_output.csv
3 ch04_financial_data.csv    ch04_financial_data.csv
4 ch04_output.csv           ch04_output.csv
5 ch05_accounting_standard.csv ch05_accounting_standard.csv
6 ch05_earnings_management.csv ch05_earnings_management.csv
7 ch05_messy_stock_return.csv ch05_messy_stock_return.csv
8 ch05_output1.csv          ch05_output1.csv
9 ch05_output2.csv          ch05_output2.csv
10 ch05_stock_data.csv       ch05_stock_data.csv
# i 17 more rows

```

2.2 財務データの読み込みと整備

2.2.1 財務データの読み込み

本章では `ch04_financial_data.csv` を使用する。ファイルが `simulation_data` 内のサブディレクトリに置かれていても、ファイル名から検索できる。

```

financial_data_candidates <- csv_paths[
  basename(csv_paths) == "ch04_financial_data.csv"
]

if (length(financial_data_candidates) == 0) {
  stop("ch04_financial_data.csvがsimulation_data以下に見つかりません。")
}

if (length(financial_data_candidates) > 1) {
  stop(
    "ch04_financial_data.csvが複数見つかりました: ",
    paste(financial_data_candidates, collapse = ", ")
  )
}

financial_data_path <- financial_data_candidates[1]

```

```
financial_data_raw <- readr::read_csv(
  financial_data_path,
  show_col_types = FALSE
)
```

```
financial_data_path
```

```
[1] "C:/AnalyticFin/Projects/LagrangeFinance/simulation_data/ch04_financial_data.csv"
```

```
financial_data_raw
```

```
# A tibble: 7,920 x 11
```

	year	firm_ID	industry_ID	sales	OX	NFE	X	OA	FA	OL	FO
	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
1	2015	1	1	5261.	437.	NA	287.	13006.	3543.	4373.	2481.
2	2016	1	1	5949.	564.	50.7	513.	13866.	4642.	4534.	3960.
3	2017	1	1	6505.	691.	29.5	662.	13953.	7744.	5111.	6159.
4	2018	1	1	6846.	751.	86.5	665.	18818.	7285.	5137.	10124.
5	2019	1	1	7572.	959.	298.	660.	18190	9735.	5488.	11362.
6	2020	1	1	7538.	778.	-65.5	844.	20463.	10274.	5371.	13772.
7	2015	2	1	3506.	45.8	5.75	40.1	2978.	2258.	1840.	2341.
8	2016	2	1	3491.	51.2	1.88	49.4	3185.	1882.	1769.	2216.
9	2017	2	1	3946.	83.4	7.53	75.9	3392.	2425.	1955.	2727.
10	2018	2	1	4139.	93.4	6.82	86.6	3569.	2331.	2022.	2694.

```
# i 7,910 more rows
```

分析に必要な列が存在することを確認する。

```
required_columns <- c(
  "firm_ID",
  "industry_ID",
  "year",
  "sales",
  "OA",
  "OL",
  "FO",
  "FA",
  "X",
  "OX",
  "NFE"
)
```

```
missing_columns <- setdiff(required_columns, names(financial_data_raw))
```

```
if (length(missing_columns) > 0) {
  stop(
```

```

    "財務データに必要な列が不足しています: ",
    paste(missing_columns, collapse = ", ")
  )
}

```

2.2.2 データ構造の確認

```
glimpse(financial_data_raw)
```

Rows: 7,920

Columns: 11

```

$ year      <dbl> 2015, 2016, 2017, 2018, 2019, 2020, 2015, 2016, 2017, 2018~
$ firm_ID   <dbl> 1, 1, 1, 1, 1, 1, 2, 2, 2, 2, 2, 2, 3, 3, 3, 3, 3, 3, 4, 4~
$ industry_ID <dbl> 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1~
$ sales     <dbl> 5261.40, 5948.96, 6505.06, 6846.38, 7572.24, 7537.63, 3505~
$ OX        <dbl> 437.49, 564.14, 691.18, 751.29, 958.53, 778.37, 45.82, 51.~
$ NFE       <dbl> NA, 50.667498, 29.543157, 86.486500, 298.049774, -65.45877~
$ X          <dbl> 286.64, 513.48, 661.64, 664.80, 660.48, 843.83, 40.07, 49.~
$ OA        <dbl> 13005.55, 13865.58, 13952.58, 18818.48, 18190.00, 20462.86~
$ FA        <dbl> 3543.43, 4642.16, 7743.99, 7284.72, 9735.13, 10274.25, 225~
$ OL        <dbl> 4372.96, 4534.22, 5111.22, 5137.28, 5487.96, 5371.38, 1840~
$ FO        <dbl> 2480.72, 3959.70, 6159.02, 10123.91, 11362.22, 13772.15, 2~

```

```

financial_data_raw |>
  summarise(
    observations = n(),
    variables = ncol(financial_data_raw),
    first_year = min(year, na.rm = TRUE),
    last_year = max(year, na.rm = TRUE),
    firms = n_distinct(firm_ID),
    industries = n_distinct(industry_ID)
  )

```

A tibble: 1 x 6

	observations	variables	first_year	last_year	firms	industries
	<int>	<int>	<dbl>	<dbl>	<int>	<int>
1	7920	11	2015	2020	1515	10

列ごとの欠損数と欠損率を確認する。

```

missing_summary <- financial_data_raw |>
  summarise(
    across(
      everything(),
      list(

```

```

      missing = ~ sum(is.na(.x)),
      missing_rate = ~ mean(is.na(.x))
    ),
    .names = "{.col}__{.fn}"
  )
) |>
pivot_longer(
  cols = everything(),
  names_to = c("variable", ".value"),
  names_sep = "__"
) |>
arrange(desc(missing_rate), variable)

missing_summary

```

```

# A tibble: 11 x 3
  variable      missing missing_rate
  <chr>         <int>         <dbl>
1 NFE             1      0.000126
2 FA              0          0
3 FO              0          0
4 OA              0          0
5 OL              0          0
6 OX              0          0
7 X              0          0
8 firm_ID         0          0
9 industry_ID     0          0
10 sales          0          0
11 year           0          0

```

2.2.3 データ型と並び順の整理

企業 ID と産業 ID は分類を表すためファクター型にし、年度は整数型へ変換する。また、前年度の値を正しく取得できるよう、企業 ID と年度で並べ替える。

```

financial_data <- financial_data_raw |>
  mutate(
    firm_ID = as.factor(firm_ID),
    industry_ID = as.factor(industry_ID),
    year = as.integer(year)
  ) |>
  arrange(firm_ID, year)

glimpse(financial_data)

```

```

Rows: 7,920
Columns: 11
$ year      <int> 2015, 2016, 2017, 2018, 2019, 2020, 2015, 2016, 2017, 2018~
$ firm_ID   <fct> 1, 1, 1, 1, 1, 1, 2, 2, 2, 2, 2, 2, 3, 3, 3, 3, 3, 4, 4~
$ industry_ID <fct> 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1~
$ sales     <dbl> 5261.40, 5948.96, 6505.06, 6846.38, 7572.24, 7537.63, 3505~
$ OX        <dbl> 437.49, 564.14, 691.18, 751.29, 958.53, 778.37, 45.82, 51.~
$ NFE       <dbl> NA, 50.667498, 29.543157, 86.486500, 298.049774, -65.45877~
$ X          <dbl> 286.64, 513.48, 661.64, 664.80, 660.48, 843.83, 40.07, 49.~
$ OA        <dbl> 13005.55, 13865.58, 13952.58, 18818.48, 18190.00, 20462.86~
$ FA        <dbl> 3543.43, 4642.16, 7743.99, 7284.72, 9735.13, 10274.25, 225~
$ OL        <dbl> 4372.96, 4534.22, 5111.22, 5137.28, 5487.96, 5371.38, 1840~
$ FO        <dbl> 2480.72, 3959.70, 6159.02, 10123.91, 11362.22, 13772.15, 2~

```

企業と年度の組合せが重複していないか確認する。

```

panel_key_duplicates <- financial_data |>
  count(firm_ID, year, name = "observations") |>
  filter(observations > 1)

panel_key_duplicates

```

```

# A tibble: 0 x 3
# i 3 variables: firm_ID <fct>, year <int>, observations <int>

```

重複がある場合は、企業・年度の一意性を確認してから先へ進む必要がある。

```

if (nrow(panel_key_duplicates) > 0) {
  stop("firm_IDとyearの組合せに重複があります。")
}

```

2.3 標本構成と売上高分布

2.3.1 年度別・産業別のデータ構成

年度別の企業数

旧コードでは年度ごとにループして企業数を数えていた。本章では `group_by()` と `summarise()` で一度に集計する。

```

firms_by_year <- financial_data |>
  group_by(year) |>
  summarise(
    firms = n_distinct(firm_ID),
    observations = n(),
    .groups = "drop"
  ) |>
  arrange(year)

```




```
firms_by_year
```

```
# A tibble: 6 x 3
```

	year	firms	observations
	<int>	<int>	<int>
1	2015	1266	1266
2	2016	1293	1293
3	2017	1319	1319
4	2018	1323	1323
5	2019	1356	1356
6	2020	1363	1363

```
firms_by_year |>
  ggplot(aes(x = year, y = firms)) +
  geom_line() +
  geom_point() +
  scale_x_continuous(breaks = firms_by_year$year) +
  scale_y_continuous(
    labels = scales::label_comma(),
    expand = expansion(mult = c(0, 0.05))
  ) +
  labs(
    x = "Year",
    y = "Number of Firms",
    title = "Number of Firms by Year"
  ) +
  theme_classic()
```



産業別の企業数

```
latest_year <- max(financial_data$year, na.rm = TRUE)


firms_by_industry <- financial_data |>
  filter(year == latest_year) |>
  count(industry_ID, name = "firms", sort = TRUE)

firms_by_industry
```

A tibble: 10 x 2

	industry_ID	firms
	<fct>	<int>
1	3	309
2	10	291
3	7	233
4	1	192
5	9	123
6	8	71
7	5	59
8	2	37
9	4	28
10	6	20

```
firms_by_industry |>
  slice_head(n = 15) |>
  ggplot(aes(x = reorder(industry_ID, firms), y = firms)) +
  geom_col() +
  coord_flip() +
  scale_y_continuous(
    labels = scales::label_comma(),
    expand = expansion(mult = c(0, 0.05))
  ) +
  labs(
    x = "Industry ID",
    y = "Number of Firms",
    title = paste("Largest Industries in", latest_year)
  ) +
  theme_classic()
```



2.3.2 売上高の分布

売上高は企業規模によって大きく異なるため、元の値と自然対数の両方を確認する。

```
sales_summary <- financial_data |>
  summarise(
    observations = sum(!is.na(sales)),
    minimum = min(sales, na.rm = TRUE),
    first_quartile = quantile(sales, 0.25, na.rm = TRUE),
    median = median(sales, na.rm = TRUE),
    mean = mean(sales, na.rm = TRUE),
    third_quartile = quantile(sales, 0.75, na.rm = TRUE),
    maximum = max(sales, na.rm = TRUE)
  )
```


sales_summary

A tibble: 1 x 7


	observations	minimum	first_quartile	median	mean	third_quartile	maximum
	<int>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
1	7920	205.	16103.	40431.	166007.	118314.	3496433

```
financial_data |>
  filter(year == latest_year, !is.na(sales), sales >= 0) |>
  ggplot(aes(x = sales)) +
  geom_histogram(bins = 40) +
  scale_x_continuous(labels = scales::label_comma()) +
  scale_y_continuous(expand = expansion(mult = c(0, 0.05))) +
```

```
labs(  
  x = "Sales",  
  y = "Count",  
  title = paste("Distribution of Sales in", latest_year)  
) +  
theme_classic()
```



```
financial_data |>  
  filter(year == latest_year, !is.na(sales), sales > 0) |>  
  ggplot(aes(x = log(sales))) +  
  geom_histogram(bins = 40) +  
  scale_y_continuous(expand = expansion(mult = c(0, 0.05))) +  
  labs(  
    x = "Log Sales",  
    y = "Count",  
    title = paste("Distribution of Log Sales in", latest_year)  
  ) +  
  theme_classic()
```



2.4 株主資本と ROE 分析

2.4.1 株主資本と ROE

本章では、営業資産から営業負債を控除した純営業資産と、金融負債から金融資産を控除した純金融負債の差として株主資本を計算する。

$$BE_t = (OA_t - OL_t) - (FO_t - FA_t)$$

ROE は当期純利益を期首株主資本で割って計算する。

$$ROE_t = \frac{X_t}{BE_{t-1}}$$

ゼロ除算や無限大を欠損値へ変換する関数を用意する。

```
safe_divide <- function(numerator, denominator) {
  result <- numerator / denominator
  replace(result, !is.finite(result), NA_real_)
}
```

```
financial_data <- financial_data |>
  mutate(
    NOA = OA - OL,
    NFO = FO - FA,
    BE = NOA - NFO
  ) |>
  group_by(firm_ID) |>
```

```

arrange(year, .by_group = TRUE) |>
mutate(
  lagged_BE = lag(BE),
  ROE = safe_divide(X, lagged_BE)
) |>
ungroup()

financial_data |>
  select(firm_ID, industry_ID, year, X, BE, lagged_BE, ROE) |>
  slice_head(n = 10)

```

A tibble: 10 x 7

	firm_ID	industry_ID	year	X	BE	lagged_BE	ROE
	<fct>	<fct>	<int>	<dbl>	<dbl>	<dbl>	<dbl>
1	1	1	2015	287.	9695.	NA	NA
2	1	1	2016	513.	10014.	9695.	0.0530
3	1	1	2017	662.	10426.	10014.	0.0661
4	1	1	2018	665.	10842.	10426.	0.0638
5	1	1	2019	660.	11075.	10842.	0.0609
6	1	1	2020	844.	11594.	11075.	0.0762
7	2	1	2015	40.1	1055.	NA	NA
8	2	1	2016	49.4	1082.	1055.	0.0468
9	2	1	2017	75.9	1135.	1082.	0.0702
10	2	1	2018	86.6	1184.	1135.	0.0763

ROE の要約統計量を確認する。

```

financial_data |>
  summarise(
    observations = sum(!is.na(ROE)),
    mean = mean(ROE, na.rm = TRUE),
    median = median(ROE, na.rm = TRUE),
    standard_deviation = sd(ROE, na.rm = TRUE),
    first_percentile = quantile(ROE, 0.01, na.rm = TRUE),
    ninety_ninth_percentile = quantile(ROE, 0.99, na.rm = TRUE)
  )

```

A tibble: 1 x 6


	observations	mean	median	standard_deviation	first_percentile
	<int>	<dbl>	<dbl>	<dbl>	<dbl>
1	6405	0.0777	0.0728	0.0663	-0.0795

i 1 more variable: ninety_ninth_percentile <dbl>

極端値の影響を避けるため、1 パーセンタイルから 99 パーセンタイルまでを表示する。

```
roe_limits <- quantile(
  financial_data$ROE,
  probs = c(0.01, 0.99),
  na.rm = TRUE
)

financial_data |>
  filter(
    !is.na(ROE),
    between(ROE, roe_limits[1], roe_limits[2])
  ) |>
  ggplot(aes(x = ROE)) +
  geom_histogram(bins = 50) +
  scale_x_continuous(labels = scales::label_percent()) +
  scale_y_continuous(expand = expansion(mult = c(0, 0.05))) +
  labs(
    x = "ROE",
    y = "Count",
    title = "Distribution of Return on Equity"
  ) +
  theme_classic()
```



2.4.2 産業別の ROE

```
industry_roe_summary <- financial_data |>
  group_by(industry_ID) |>
```

```

summarise(
  firms = n_distinct(firm_ID),
  observations = sum(!is.na(ROE)),
  mean_ROE = mean(ROE, na.rm = TRUE),
  median_ROE = median(ROE, na.rm = TRUE),
  .groups = "drop"
) |>
filter(observations > 0) |>
arrange(desc(mean_ROE))

industry_roe_summary

```

```

# A tibble: 10 x 5
  industry_ID firms observations mean_ROE median_ROE
  <fct>      <int>      <int>      <dbl>      <dbl>
1 2          40        186    0.108      0.103
2 6          34        127    0.0951     0.0920
3 8          80        349    0.0937     0.0847
4 5          67        259    0.0857     0.0849
5 9         136        531    0.0834     0.0798
6 1         225        918    0.0773     0.0751
7 3         327       1433    0.0755     0.0701
8 10        314       1388    0.0753     0.0705
9 4          34        138    0.0737     0.0727
10 7        258       1076    0.0676     0.0604


```

産業ごとの標本数が小さすぎる場合、平均値は一部企業の影響を強く受ける。ここでは ROE の観測数が 50 以上の産業だけを比較する。

```

industry_roe_summary |>
  filter(observations >= 50) |>
  slice_max(order_by = mean_ROE, n = 15, with_ties = FALSE) |>
  ggplot(aes(x = reorder(industry_ID, mean_ROE), y = mean_ROE)) +
  geom_col() +
  coord_flip() +
  geom_hline(yintercept = 0) +
  scale_y_continuous(labels = scales::label_percent()) +
  labs(
    x = "Industry ID",
    y = "Mean ROE",
    title = "Industries with High Mean ROE"
  ) +
  theme_classic()

```

2.4.3 企業の順位付け

最新年度について、産業内で ROE が高い企業から順に順位を付ける。`dense_rank()` を使うと、同順位がある場合でも次の順位を飛ばさない。

```
latest_roe_ranking <- financial_data |>
  filter(year == latest_year, !is.na(ROE)) |>
  group_by(industry_ID) |>
  mutate(ROE_rank = dense_rank(desc(ROE))) |>
  ungroup() |>
  arrange(industry_ID, ROE_rank)

latest_roe_ranking |>
  select(industry_ID, ROE_rank, firm_ID, ROE) |>
  slice_head(n = 20)
```

A tibble: 20 x 4

	industry_ID	ROE_rank	firm_ID	ROE
	<fct>	<int>	<fct>	<dbl>
1	1	1	8	0.388
2	1	2	90	0.334
3	1	3	225	0.301
4	1	4	81	0.231
5	1	5	171	0.218
6	1	6	138	0.207
7	1	7	66	0.203
8	1	8	153	0.198
9	1	9	181	0.191

10	1	10 65	0.189
11	1	11 92	0.175
12	1	12 195	0.157
13	1	13 13	0.155
14	1	14 23	0.153
15	1	15 148	0.150
16	1	16 214	0.146
17	1	17 115	0.146
18	1	18 201	0.143
19	1	19 50	0.142
20	1	20 143	0.142

各産業で ROE が最も高い企業を抽出する。

```
top_firm_by_industry <- latest_roe_ranking |>
  group_by(industry_ID) |>
  slice_max(order_by = ROE, n = 1, with_ties = FALSE) |>
  ungroup() |>
  select(industry_ID, firm_ID, ROE)

top_firm_by_industry
```

```
# A tibble: 10 x 3
  industry_ID firm_ID   ROE
  <fct>      <fct>   <dbl>
1 1          8      0.388
2 2        242      0.375
3 3        475      0.498
4 4        619      0.149
5 5        661      0.267
6 6        719      0.142
7 7        929      0.564
8 8       1042      0.256
9 9       1167      0.235
10 10      1380      0.250
```

2.5 上級デュポン・モデル

2.5.1 ROE のデュポン分解

上級デュポン・モデルでは、ROE を純営業資産利益率と財務レバレッジの効果へ分解する。

$$ROE_t = RNOA_t + FLEV_{t-1}(RNOA_t - NBC_t)$$

ここで、各構成要素を次のように定義する。

$$RNOA_t = \frac{OX_t}{NOA_{t-1}}$$

$$PM_t = \frac{OX_t}{Sales_t}$$

$$ATO_t = \frac{Sales_t}{NOA_{t-1}}$$

$$FLEV_{t-1} = \frac{NFO_{t-1}}{BE_{t-1}}$$

$$NBC_t = \frac{NFE_t}{NFO_{t-1}}$$

```
financial_data_dupont <- financial_data |>
  group_by(firm_ID) |>
  arrange(year, .by_group = TRUE) |>
  mutate(
    lagged_NOA = lag(NOA),
    lagged_NFO = lag(NFO),
    RNOA = safe_divide(OX, lagged_NOA),
    PM = safe_divide(OX, sales),
    ATO = safe_divide(sales, lagged_NOA),
    lagged_FLEV = safe_divide(lagged_NFO, lagged_BE),
    NBC = safe_divide(NFE, lagged_NFO),
    ROE_DuPont = RNOA + lagged_FLEV * (RNOA - NBC),
    DuPont_gap = ROE - ROE_DuPont
  ) |>
  ungroup()

financial_data_dupont |>
  select(
    firm_ID,
    year,
    ROE,
    RNOA,
    PM,
    ATO,
    lagged_FLEV,
    NBC,
    ROE_DuPont,
    DuPont_gap
  ) |>
  slice_head(n = 10)
```

```
# A tibble: 10 x 10
  firm_ID year   ROE   RNOA   PM   ATO lagged_FLEV   NBC ROE_DuPont
  <fct>   <int>   <dbl>   <dbl>   <dbl> <dbl>   <dbl>   <dbl>   <dbl>
1 1      2015 NA      NA      0.0832 NA      NA      NA      NA
2 1      2016 0.0530 0.0654 0.0948 0.689   -0.110 -0.0477 0.0530
3 1      2017 0.0661 0.0741 0.106   0.697   -0.0682 -0.0433 0.0661
4 1      2018 0.0638 0.0850 0.110   0.774   -0.152 -0.0546 0.0638
5 1      2019 0.0609 0.0701 0.127   0.553    0.262  0.105   0.0609
6 1      2020 0.0762 0.0613 0.103   0.593    0.147 -0.0402 0.0762
7 2      2015 NA      NA      0.0131 NA      NA      NA      NA
8 2      2016 0.0468 0.0451 0.0147 3.07     0.0783 0.0227 0.0468
9 2      2017 0.0702 0.0589 0.0211 2.79     0.309 0.0225 0.0702
10 2     2018 0.0763 0.0650 0.0226 2.88     0.266 0.0226 0.0763

# i 1 more variable: DuPont_gap <dbl>
```

デュポン分解で再構成した ROE と、直接計算した ROE の差を確認する。

```
financial_data_dupont |>
  summarise(
    comparable_observations = sum(!is.na(DuPont_gap)),
    mean_absolute_gap = mean(abs(DuPont_gap), na.rm = TRUE),
    maximum_absolute_gap = max(abs(DuPont_gap), na.rm = TRUE)
  )
```

```
# A tibble: 1 x 3
  comparable_observations mean_absolute_gap maximum_absolute_gap
          <int>           <dbl>           <dbl>
1             6405         0.000000367         0.0000208
```

2.5.2 PM と ATO の関係

営業利益率 PM と純営業資産回転率 ATO は、企業の事業モデルを異なる側面から表す。産業別中央値を使って両者の関係を確認する。

```
industry_pm_ato <- financial_data_dupont |>
  group_by(industry_ID) |>
  summarise(
    observations = sum(complete.cases(PM, ATO)),
    median_PM = median(PM, na.rm = TRUE),
    median_ATO = median(ATO, na.rm = TRUE),
    median_RNOA = median(RNOA, na.rm = TRUE),
    .groups = "drop"
  ) |>
  filter(
    observations >= 50,
    is.finite(median_PM),
```


```
is.finite(median_ATO)
)

industry_pm_ato
```

```
# A tibble: 10 x 5
```

	industry_ID	observations	median_PM	median_ATO	median_RNOA
	<fct>	<int>	<dbl>	<dbl>	<dbl>
1	1	918	0.0253	3.94	0.0839
2	2	186	0.0378	2.41	0.109
3	3	1433	0.0481	1.83	0.0897
4	4	138	0.0401	1.78	0.0759
5	5	259	0.0346	2.51	0.0976
6	6	127	0.0482	1.30	0.0741
7	7	1076	0.0318	2.52	0.0806
8	8	349	0.0747	1.07	0.0635
9	9	531	0.0426	2.18	0.0985
10	10	1388	0.0446	1.96	0.0907


```
industry_pm_ato |>
  ggplot(aes(x = median_ATO, y = median_PM)) +
  geom_point() +
  labs(
    x = "Industry Median ATO",
    y = "Industry Median PM",
    title = "Profit Margin and Asset Turnover by Industry"
  ) +
  theme_classic()
```



主要産業について PM の分布を箱ひげ図で比較する。

```
major_industries <- firms_by_industry |>
  slice_head(n = 8) |>
  pull(industry_ID)

financial_data_dupont |>
  filter(
    year == latest_year,
    industry_ID %in% major_industries,
    !is.na(PM)
  ) |>
  ggplot(aes(x = industry_ID, y = PM)) +
  geom_boxplot(outlier.alpha = 0.25) +
  coord_cartesian(ylim = quantile(
    financial_data_dupont$PM,
    probs = c(0.01, 0.99),
    na.rm = TRUE
  )) +
  labs(
    x = "Industry ID",
    y = "Profit Margin",
    title = paste("Profit Margin by Industry in", latest_year)
  ) +
  theme_classic()
```



2.6 財務指標の要約と中間データ

2.6.1 複数の財務指標を同じ形式で要約する

複数列に同じ集計を適用する場合は、列名のベクトルと `purrr::map_dfr()` を組み合わせられる。

```
financial_metrics <- c("sales", "BE", "ROE", "RNOA", "PM", "ATO")

metric_summary <- financial_metrics |>
  map_dfr(
    \(metric_name) {
      values <- financial_data_dupont[[metric_name]]
      finite_values <- values[is.finite(values)]

      tibble(
        metric = metric_name,
        observations = length(finite_values),
        mean = mean(finite_values),
        median = median(finite_values),
        standard_deviation = sd(finite_values),
        minimum = min(finite_values),
        maximum = max(finite_values)
      )
    }
  )

metric_summary
```

```
# A tibble: 6 x 7
  metric observations      mean      median standard_deviation minimum maximum
  <chr>         <int>    <dbl>    <dbl>          <dbl>    <dbl>    <dbl>
1 sales           7920 166007.   40431.        381980.    205.    3.50e+6
2 BE             7920 111517.   26882.        420624.    137.    2.54e+7
3 ROE            6405    0.0777    0.0728         0.0663  -0.702    1.41e+0
4 RNOA            6405    0.111    0.0859         0.126  -0.820    1.83e+0
5 PM             7920    0.0455    0.0406         0.0422  -0.201    3.83e-1
6 ATO            6405    2.71     2.10          1.87     0.258    9.82e+0
```

2.6.2 中間データの保存

第3章では、本章で計算した株主資本、前年度株主資本、ROEなどを株式データと結合する。そのため、整理済みデータを `simulation_data/derived/ch04_output.csv` へ保存する。元の `ch04_financial_data.csv` は変更しない。

保存対象には、上級デュポン・モデルの計算結果も含める。

```
if (!dir.exists(derived_data_dir)) {
  dir.create(derived_data_dir, recursive = TRUE)
}

financial_output_path <- file.path(
  derived_data_dir,
  "ch04_output.csv"
)

readr::write_csv(
  financial_data_dupont,
  financial_output_path
)

financial_output_path
```

```
[1] "C:/AnalyticFin/Projects/LagrangeFinance/simulation_data/derived/ch04_output.csv"
file.info(financial_output_path)[, c("size", "mtime")]
```

	size	mtime
C:/AnalyticFin/Projects/LagrangeFinance/simulation_data/derived/ch04_output.csv	2425789	
C:/AnalyticFin/Projects/LagrangeFinance/simulation_data/derived/ch04_output.csv	2026-07-25 02:40:34	

保存した CSV を読み直し、行数と列名が一致することを確認する。

```
financial_output_check <- readr::read_csv(
  financial_output_path,
  show_col_types = FALSE
)

stopifnot(nrow(financial_output_check) == nrow(financial_data_dupont))
stopifnot(identical(names(financial_output_check), names(financial_data_dupont)))

tibble(
  output_file = financial_output_path,
  rows = nrow(financial_output_check),
  columns = ncol(financial_output_check)
)
```

```
# A tibble: 1 x 3
  output_file      rows columns
  <chr>          <int>   <int>
```


1 C:/AnalyticFin/Projects/LagrangeFinance/simulation_data/derived~ 7920 25

2.7 まとめ

本章では、財務データを再現可能な相対パスで読み込み、データ型、欠損値、パネルデータのキーを確認した。次に、年度別・産業別の企業構成、売上高の分布、株主資本、ROE、産業内順位を計算した。最後に、ROE を RNOA、財務レバレッジ、純借入コストへ分解し、第 3 章で利用する整理済み CSV を `simulation_data/derived` へ保存した。

第 3 章では、月次株式データからリターンを計算し、本章の財務データと結合する。

第 3 章 株式データと時系列分析

本章では、月次株式データから株式リターン、超過リターン、時価総額を作成し、年次財務データと結合する。前章で整理した財務データを利用し、株式データと会計データを一つの分析用データセットへ統合することが目的である。

本章では次の処理を順番に行う。

1. 株式データの構造とパネルキーを確認する
2. 株価、配当、調整係数から月次リターンを計算する
3. 時価総額と超過リターンを作成する
4. 月次リターンを年次リターンへ集約する
5. 前章の財務データと結合する
6. リターンの分布、累積リターン、回帰分析を確認する
7. 第 4 章以降で使用するデータを保存する

反復処理には `for` 文を使わず、`purrr::map()` 系を利用する。パイプ演算子は native pipe の `|>` に統一する。

3.1 分析環境と株式データの整備

3.1.1 パッケージの準備

本章では `tidyverse` と `broom` を利用する。`broom` は、回帰分析の結果を tidy なデータフレームへ変換するためのパッケージである。

```
suppressPackageStartupMessages({
  library(tidyverse)
  library(ggthemes)
  library(QuantLib)
  library(GaussQuant)
})
library(tidyverse)
library(broom)
```

パッケージをまだインストールしていない場合だけ、次のコードを R コンソールで実行する。

```
install.packages(c("tidyverse", "broom"))
```

3.1.2 プロジェクトとデータディレクトリ

RStudio でチャンクを個別に実行する場合と、Quarto で章全体をレンダリングする場合には、作業ディレクトリが異なることがある。そのため、プロジェクトルートを実行時に確認する。

```
project_candidates <- unique(c(
  Sys.getenv("QUARTO_PROJECT_DIR"),
  getwd(),
  dirname(getwd())
))

project_candidates <- project_candidates[nzchar(project_candidates)]

project_matches <- project_candidates[
  file.exists(file.path(project_candidates, "_quarto.yml"))
]

if (length(project_matches) == 0) {
  stop("LagrangeFinanceのプロジェクトルートを確認できません。")
}

project_dir <- normalizePath(
  project_matches[1],
  winslash = "/",
  mustWork = TRUE
)

data_dir <- file.path(project_dir, "simulation_data")
derived_data_dir <- file.path(data_dir, "derived")

if (!dir.exists(data_dir)) {
  stop("simulation_dataディレクトリが見つかりません: ", data_dir)
}

project_dir
data_dir
derived_data_dir
```

simulation_data 以下にある CSV ファイルを確認する。

```
csv_paths <- list.files(
  path = data_dir,
  pattern = "\\\\.csv$",
  full.names = TRUE,
```

```

    recursive = TRUE
  )

normalized_data_dir <- normalizePath(
  data_dir,
  winslash = "/",
  mustWork = TRUE
)

normalized_csv_paths <- normalizePath(
  csv_paths,
  winslash = "/",
  mustWork = FALSE
)

csv_catalog <- tibble(
  file_name = basename(csv_paths),
  relative_path = substring(
    normalized_csv_paths,
    first = nchar(normalized_data_dir) + 2
  )
) |>
  arrange(relative_path)

csv_catalog

```

3.1.3 株式データの読み込み

株式データは `ch05_stock_data.csv` に保存されている。ファイル名は旧教材の章番号に由来するが、本書では第3章の入力データとして使用する。

```

stock_data_candidates <- csv_paths[
  basename(csv_paths) == "ch05_stock_data.csv"
]

if (length(stock_data_candidates) == 0) {
  stop("ch05_stock_data.csvがsimulation_data以下に見つかりません。")
}

if (length(stock_data_candidates) > 1) {
  stop(
    "ch05_stock_data.csvが複数見つかりました: ",
    paste(stock_data_candidates, collapse = ", ")
  )
}

```

```
}

stock_data_path <- stock_data_candidates[1]

stock_data_raw <- readr::read_csv(
  stock_data_path,
  show_col_types = FALSE
)

stock_data_path
stock_data_raw
```

データの行数、列数、企業数、対象期間を確認する。

```
stock_data_overview <- stock_data_raw |>
  summarise(
    observations = n(),
    variables = ncol(stock_data_raw),
    firms = n_distinct(firm_ID),
    first_year = min(year, na.rm = TRUE),
    last_year = max(year, na.rm = TRUE),
    first_month_ID = min(month_ID, na.rm = TRUE),
    last_month_ID = max(month_ID, na.rm = TRUE)
  )

stock_data_overview
```

データ型と列名を確認する。

```
glimpse(stock_data_raw)

tibble(
  position = seq_along(names(stock_data_raw)),
  variable = names(stock_data_raw),
  class = map_chr(stock_data_raw, \(x) class(x)[1])
)
```

3.1.4 必須列の確認

本章の計算には次の列が必要である。

```
required_stock_columns <- c(
  "year",
  "month",
  "month_ID",
  "firm_ID",
```

```

"stock_price",
"shares_outstanding",
"DPS",
"adjustment_coefficient",
"R_F"
)

missing_stock_columns <- setdiff(
  required_stock_columns,
  names(stock_data_raw)
)

if (length(missing_stock_columns) > 0) {
  stop(
    "株式データに必要な列が不足しています: ",
    paste(missing_stock_columns, collapse = ", ")
  )
}

```

3.1.5 欠損値の確認

各変数について欠損数と欠損率を計算する。`across()` に複数の関数を渡し、結果を `pivot_longer()` で縦長に整理する。

```

stock_missing_summary <- stock_data_raw |>
  summarise(
    across(
      everything(),
      list(
        missing = \(x) sum(is.na(x)),
        missing_rate = \(x) mean(is.na(x))
      ),
      .names = "{.col}__{.fn}"
    )
  ) |>
  pivot_longer(
    cols = everything(),
    names_to = c("variable", ".value"),
    names_sep = "__"
  ) |>
  arrange(desc(missing_rate), variable)

stock_missing_summary

```

3.1.6 データ型と並び順の整理

企業 ID、年、月、月 ID を整数型に統一する。企業ごとの時系列計算を正しく行うため、`firm_ID` と `month_ID` の順に並べる。

```
stock_data <- stock_data_raw |>
  mutate(
    firm_ID = as.integer(firm_ID),
    year = as.integer(year),
    month = as.integer(month),
    month_ID = as.integer(month_ID),
    month_date = lubridate::make_date(year, month, 1)
  ) |>
  arrange(firm_ID, month_ID)

glimpse(stock_data)
```

3.1.7 パネルキーの確認

月次株式データでは、`firm_ID` と `month_ID` の組合せが各行を一意に識別する。

```
stock_key_duplicates <- stock_data |>
  count(firm_ID, month_ID, name = "observations") |>
  filter(observations > 1)

stock_key_duplicates
```

重複があれば、`lag()` による前月値の計算や財務データとの結合が不安定になるため、ここで停止する。

```
if (nrow(stock_key_duplicates) > 0) {
  stop("firm_IDとmonth_IDの組合せに重複があります。")
}
```

月 ID と年月の対応も一意であることを確認する。

```
month_calendar_check <- stock_data |>
  distinct(month_ID, year, month, month_date) |>
  count(month_ID, name = "calendar_rows") |>
  filter(calendar_rows > 1)

month_calendar_check

if (nrow(month_calendar_check) > 0) {
  stop("同じmonth_IDに複数の年月が対応しています。")
}
```

3.1.8 月次観測数の確認

年度別の企業数と観測数を確認する。

```
stock_observations_by_year <- stock_data |>
  group_by(year) |>
  summarise(
    firms = n_distinct(firm_ID),
    observations = n(),
    first_month_ID = min(month_ID),
    last_month_ID = max(month_ID),
    .groups = "drop"
  ) |>
  arrange(year)

stock_observations_by_year
```

企業ごとの観測月数を確認する。

```
observations_by_firm <- stock_data |>
  count(firm_ID, name = "months") |>
  arrange(desc(months), firm_ID)

observations_by_firm
```

3.2 月次リターンと時価総額

3.2.1 配当と調整係数

株式リターンを計算するには、株価変化だけでなく配当と株式分割等の調整係数も考慮する。

配当が支払われた観測を確認する。

```
dividend_observations <- stock_data |>
  filter(!is.na(DPS), DPS != 0) |>
  select(
    firm_ID,
    year,
    month,
    month_ID,
    stock_price,
    DPS,
    adjustment_coefficient
  ) |>
  arrange(firm_ID, month_ID)
```



```
dividend_observations |>
  slice_head(n = 20)
```

調整係数が 1 と異なる観測を確認する。

```
adjustment_observations <- stock_data |>
  filter(
    !is.na(adjustment_coefficient),
    !near(adjustment_coefficient, 1)
  ) |>
  select(
    firm_ID,
    year,
    month,
    month_ID,
    stock_price,
    DPS,
    adjustment_coefficient
  ) |>
  arrange(firm_ID, month_ID)

adjustment_observations |>
  slice_head(n = 20)
```

配当と調整係数の件数を集計する。

```
corporate_action_summary <- stock_data |>
  summarise(
    observations = n(),
    dividend_observations = sum(
      !is.na(DPS) & DPS != 0
    ),
    adjusted_observations = sum(
      !is.na(adjustment_coefficient) &
      !near(adjustment_coefficient, 1)
    )
  )

corporate_action_summary
```

3.2.2 時価総額

企業 i の月 t における時価総額 $ME_{i,t}$ は、株価 $P_{i,t}$ と発行済株式数 $N_{i,t}$ の積である。

$$ME_{i,t} = P_{i,t}N_{i,t}$$

```
stock_data <- stock_data |>
  mutate(
    ME = stock_price * shares_outstanding
  )

stock_data |>
  select(
    firm_ID,
    month_date,
    stock_price,
    shares_outstanding,
    ME
  ) |>
  slice_head(n = 10)
```

時価総額が有限かつ正である観測を確認する。

```
invalid_market_equity <- stock_data |>
  filter(
    !is.na(ME),
    !is.finite(ME) | ME <= 0
  ) |>
  select(
    firm_ID,
    month_ID,
    stock_price,
    shares_outstanding,
    ME
  )

invalid_market_equity
```

時価総額は右に長い分布を持つため、横軸を対数目盛りにして可視化する。

```
stock_data |>
  filter(is.finite(ME), ME > 0) |>
  ggplot(aes(x = ME)) +
  geom_histogram(bins = 50) +
  scale_x_log10(
    labels = scales::label_comma()
  ) +
  scale_y_continuous(
    expand = expansion(mult = c(0, 0.05))
  )
```

```
) +  
labs(  
  x = "Market Equity (log scale)",  
  y = "Count",  
  title = "Distribution of Market Equity"  
) +  
theme_classic()
```

3.2.3 前月株価の追加

企業ごとに `lag()` を適用し、前月株価を作成する。

```
stock_data <- stock_data |>  
  group_by(firm_ID) |>  
  arrange(month_ID, .by_group = TRUE) |>  
  mutate(  
    lagged_stock_price = lag(stock_price),  
    lagged_month_ID = lag(month_ID)  
  ) |>  
  ungroup()
```

連続する月 ID から取得した前月株価かどうかを確認する。

```
stock_data <- stock_data |>  
  mutate(  
    consecutive_month = month_ID - lagged_month_ID == 1L,  
    lagged_stock_price = if_else(  
      consecutive_month,  
      lagged_stock_price,  
      NA_real_  
    )  
  )  
  
stock_data |>  
  select(  
    firm_ID,  
    month_ID,  
    stock_price,  
    lagged_stock_price,  
    consecutive_month  
  ) |>  
  slice_head(n = 12)
```

3.2.4 月次株式リターン

企業 i の月 t における月次株式リターン $R_{i,t}$ を、次式で計算する。

$$R_{i,t} = \frac{(P_{i,t} + D_{i,t})A_{i,t} - P_{i,t-1}}{P_{i,t-1}}$$

ここで、 $P_{i,t}$ は株価、 $D_{i,t}$ は一株当たり配当、 $A_{i,t}$ は調整係数である。

```
stock_data <- stock_data |>
  mutate(
    R = case_when(
      is.na(lagged_stock_price) ~ NA_real_,
      lagged_stock_price <= 0 ~ NA_real_,
      is.na(stock_price) ~ NA_real_,
      is.na(DPS) ~ NA_real_,
      is.na(adjustment_coefficient) ~ NA_real_,
      TRUE ~ (
        (stock_price + DPS) * adjustment_coefficient -
          lagged_stock_price
      ) / lagged_stock_price
    ),
    R = if_else(is.finite(R), R, NA_real_)
  )
```

計算例を確認する。

```
stock_data |>
  select(
    firm_ID,
    month_date,
    lagged_stock_price,
    stock_price,
    DPS,
    adjustment_coefficient,
    R
  ) |>
  filter(!is.na(R)) |>
  slice_head(n = 15)
```

3.2.5 無リスク金利の整合性

同じ月の無リスク金利はすべての企業に共通であることを確認する。

```
#| label: validate-risk-free-rate

monthly_rate <- function(x) {
  values <- x[is.finite(x)]

  if (length(values) == 0) {
    return(NA_real_)
  }

  median(values)
}

risk_free_rate_by_month <- stock_data |>
  group_by(
    month_ID,
    year,
    month,
    month_date
  ) |>
  summarise(
    observations = n(),
    valid_rates = sum(is.finite(R_F)),
    distinct_rates = n_distinct(R_F[is.finite(R_F)]),
    minimum_R_F = {
      values <- R_F[is.finite(R_F)]

      if (length(values) == 0) {
        NA_real_
      } else {
        min(values)
      }
    },
    maximum_R_F = {
      values <- R_F[is.finite(R_F)]

      if (length(values) == 0) {
        NA_real_
      } else {
        max(values)
      }
    },
    R_F_month = monthly_rate(R_F),
    .groups = "drop"
```

```

) |>
mutate(
  R_F_spread = maximum_R_F - minimum_R_F
) |>
arrange(month_ID)

risk_free_rate_diagnostics <- risk_free_rate_by_month |>
  filter(distinct_rates > 1) |>
  select(
    month_ID,
    year,
    month,
    observations,
    valid_rates,
    distinct_rates,
    minimum_R_F,
    maximum_R_F,
    R_F_spread,
    R_F_month
  )

risk_free_rate_diagnostics
#| label: standardize-risk-free-rate

stock_data <- stock_data |>
  select(-R_F) |>
  left_join(
    risk_free_rate_by_month |>
      select(
        month_ID,
        R_F = R_F_month
      ),
    by = "month_ID"
  )

missing_monthly_risk_free_rate <- stock_data |>
  distinct(month_ID, R_F) |>
  filter(!is.finite(R_F))

missing_monthly_risk_free_rate

if (nrow(missing_monthly_risk_free_rate) > 0) {
  stop("月次無リスク金利を作成できないmonth_IDがあります。")
}

```

}

3.2.6 月次超過リターン

月次超過リターン $R_{i,t}^e$ は、株式リターンから無リスク金利を引いて計算する。

$$R_{i,t}^e = R_{i,t} - R_{F,t}$$

```
stock_data <- stock_data |>
  mutate(
    Re = R - R_F,
    Re = if_else(is.finite(Re), Re, NA_real_)
  )
```

3.3 月次リターンの分析

3.3.1 月次リターンの要約統計量

歪度と尖度を計算する関数を定義する。

```
calculate_skewness <- function(x) {
  values <- x[is.finite(x)]

  if (length(values) < 3 || near(sd(values), 0)) {
    return(NA_real_)
  }

  mean(
    ((values - mean(values)) / sd(values))^3
  )
}

calculate_kurtosis <- function(x) {
  values <- x[is.finite(x)]

  if (length(values) < 4 || near(sd(values), 0)) {
    return(NA_real_)
  }

  mean(
    ((values - mean(values)) / sd(values))^4
  )
}
```

月次リターンと月次超過リターンを縦長に変換し、同じ処理で集計する。

```
monthly_return_summary <- stock_data |>
  select(R, Re) |>
  pivot_longer(
    cols = everything(),
    names_to = "return_type",
    values_to = "return"
  ) |>
  filter(is.finite(return)) |>
  group_by(return_type) |>
  summarise(
    observations = n(),
    mean = mean(return),
    median = median(return),
    standard_deviation = sd(return),
    minimum = min(return),
    first_quartile = quantile(return, 0.25),
    third_quartile = quantile(return, 0.75),
    maximum = max(return),
    skewness = calculate_skewness(return),
    kurtosis = calculate_kurtosis(return),
    .groups = "drop"
  )

monthly_return_summary
```

企業ごとの要約統計量を `purrr::map_dfr()` で計算する。ここでは観測数が多い企業から6社を選ぶ。

```
sample_firm_ids <- stock_data |>
  filter(is.finite(R)) |>
  count(firm_ID, sort = TRUE) |>
  slice_head(n = 6) |>
  pull(firm_ID)

firm_return_summary <- sample_firm_ids |>
  map_dfr(
    \(firm_id) {
      firm_returns <- stock_data |>
        filter(
          firm_ID == firm_id,
          is.finite(R)
        ) |>
        pull(R)
    }
  )
```



```

    tibble(
      firm_ID = firm_id,
      observations = length(firm_returns),
      mean_return = mean(firm_returns),
      volatility = sd(firm_returns),
      minimum_return = min(firm_returns),
      maximum_return = max(firm_returns)
    )
  }
)

firm_return_summary

```

3.3.2 月次リターンの分布

極端な値によって分布の中心が見えにくくならないよう、1% 点から 99% 点の範囲を表示する。

```

return_plot_limits <- quantile(
  stock_data$R,
  probs = c(0.01, 0.99),
  na.rm = TRUE
)

stock_data |>
  filter(is.finite(R)) |>
  ggplot(aes(x = R)) +
  geom_histogram(bins = 60) +
  coord_cartesian(xlim = return_plot_limits) +
  scale_y_continuous(
    expand = expansion(mult = c(0, 0.05))
  ) +
  labs(
    x = "Monthly Stock Return",
    y = "Count",
    title = "Distribution of Monthly Stock Returns"
  ) +
  theme_classic()

```

3.3.3 累積リターン

月次グロスリターン $1 + R_{i,t}$ を時系列方向に掛け合わせることで、累積グロスリターンを求める。

$$G_{i,T} = \prod_{t=1}^T (1 + R_{i,t})$$

```

cumulative_return_data <- stock_data |>
  filter(
    firm_ID %in% sample_firm_ids,
    is.finite(R)
  ) |>
  group_by(firm_ID) |>
  arrange(month_ID, .by_group = TRUE) |>
  mutate(
    cumulative_gross_return = cumprod(1 + R),
    cumulative_return = cumulative_gross_return - 1
  ) |>
  ungroup()

```

代表企業の累積リターンを可視化する。

```

cumulative_return_data |>
  mutate(firm_ID = as.factor(firm_ID)) |>
  ggplot(
    aes(
      x = month_date,
      y = cumulative_gross_return,
      linetype = firm_ID
    )
  ) +
  geom_line(linewidth = 0.7) +
  geom_hline(
    yintercept = 1,
    linetype = "dotted"
  ) +
  labs(
    x = NULL,
    y = "Cumulative Gross Return",
    linetype = "Firm ID",
    title = "Cumulative Returns of Selected Firms"
  ) +
  theme_classic()

```

3.4 年次リターンと年度末時価総額

3.4.1 月次リターンから年次リターンへの集約

欠損値を除き、グロスリターンを掛け合わせる関数を定義する。

```

compound_return <- function(x) {
  values <- x[is.finite(x)]

```

```

if (length(values) == 0) {
  return(NA_real_)
}

prod(1 + values) - 1
}

```

企業・年度ごとに月次株式リターンと無リスク金利を累積する。

```

annual_stock_data <- stock_data |>
  group_by(firm_ID, year) |>
  summarise(
    months = n(),
    valid_return_months = sum(is.finite(R)),
    R = compound_return(R),
    R_F = compound_return(R_F),
    .groups = "drop"
  ) |>
  mutate(
    Re = R - R_F,
    Re = if_else(is.finite(Re), Re, NA_real_)
  ) |>
  arrange(firm_ID, year)

annual_stock_data

```

年次リターンの要約統計量を確認する。

```

annual_return_summary <- annual_stock_data |>
  summarise(
    observations = sum(is.finite(R)),
    mean_return = mean(R, na.rm = TRUE),
    median_return = median(R, na.rm = TRUE),
    volatility = sd(R, na.rm = TRUE),
    minimum_return = min(R, na.rm = TRUE),
    maximum_return = max(R, na.rm = TRUE)
  )

annual_return_summary

```

年度別に年次超過リターンの分布を確認する。

```

annual_return_by_year <- annual_stock_data |>
  group_by(year) |>
  summarise(
    firms = sum(is.finite(Re)),

```

```

mean_excess_return = mean(Re, na.rm = TRUE),
median_excess_return = median(Re, na.rm = TRUE),
volatility = sd(Re, na.rm = TRUE),
.groups = "drop"
)

```

annual_return_by_year

```

annual_return_by_year |>
  ggplot(
    aes(
      x = year,
      y = mean_excess_return
    )
  ) +
  geom_col() +
  geom_hline(
    yintercept = 0,
    linetype = "dotted"
  ) +
  scale_x_continuous(
    breaks = annual_return_by_year$year
  ) +
  scale_y_continuous(
    labels = scales::label_percent()
  ) +
  labs(
    x = "Year",
    y = "Mean Annual Excess Return",
    title = "Mean Annual Excess Return by Year"
  ) +
  theme_classic()

```

3.4.2 年度末時価総額

各企業・各年度について、最後に観測された月の時価総額を年度末時価総額として取得する。

```

year_end_market_equity <- stock_data |>
  filter(is.finite(ME), ME > 0) |>
  group_by(firm_ID, year) |>
  slice_max(
    order_by = month_ID,
    n = 1,
    with_ties = FALSE
  )

```

```
) |>
ungroup() |>
transmute(
  firm_ID,
  year,
  year_end_month_ID = month_ID,
  ME
)

year_end_market_equity
```

3.5 財務データとの結合

3.5.1 前章の財務データ

第2章で作成した `simulation_data/derived/ch04_output.csv` を読み込む。

```
financial_output_path <- file.path(
  derived_data_dir,
  "ch04_output.csv"
)

if (!file.exists(financial_output_path)) {
  stop(
    "第2章の出力が見つかりません。第2章を先に実行してください: ",
    financial_output_path
  )
}

financial_data <- readr::read_csv(
  financial_output_path,
  show_col_types = FALSE
) |>
mutate(
  firm_ID = as.integer(firm_ID),
  year = as.integer(year),
  industry_ID = as.integer(industry_ID)
) |>
arrange(firm_ID, year)

financial_output_path
glimpse(financial_data)
```

結合に必要な財務変数を確認する。

```

required_financial_columns <- c(
  "firm_ID",
  "year",
  "industry_ID",
  "sales",
  "X",
  "BE",
  "lagged_BE",
  "ROE"
)

missing_financial_columns <- setdiff(
  required_financial_columns,
  names(financial_data)
)

if (length(missing_financial_columns) > 0) {
  stop(
    "第2章の出力に必要な列が不足しています: ",
    paste(missing_financial_columns, collapse = ", ")
  )
}

```

財務データの `firm_ID` と `year` の組合せが一意であることを再確認する。

```

financial_key_duplicates <- financial_data |>
  count(firm_ID, year, name = "observations") |>
  filter(observations > 1)

financial_key_duplicates

if (nrow(financial_key_duplicates) > 0) {
  stop("財務データのfirm_IDとyearの組合せに重複があります。")
}

```

3.5.2 結合前のキー診断

株式データに存在するが財務データに存在しない企業・年度を確認する。

```

stock_keys_without_financial_data <- annual_stock_data |>
  distinct(firm_ID, year) |>
  anti_join(
    financial_data |>
      distinct(firm_ID, year),
    by = c("firm_ID", "year")
  )

```

```
)

stock_keys_without_financial_data
```

財務データに存在するが年次株式データに存在しない企業・年度も確認する。

```
financial_keys_without_stock_data <- financial_data |>
  distinct(firm_ID, year) |>
  anti_join(
    annual_stock_data |>
      distinct(firm_ID, year),
    by = c("firm_ID", "year")
  )

financial_keys_without_stock_data
```

結合前の診断結果をまとめる。

```
join_key_diagnostics <- tribble(
  ~item, ~observations,
  "stock keys without financial data",
  nrow(stock_keys_without_financial_data),
  "financial keys without stock data",
  nrow(financial_keys_without_stock_data)
)

join_key_diagnostics
```

3.5.3 年次データの結合

年次株式データを基準に、財務データと年度末時価総額を結合する。

```
annual_data <- annual_stock_data |>
  left_join(
    financial_data,
    by = c("firm_ID", "year")
  ) |>
  left_join(
    year_end_market_equity,
    by = c("firm_ID", "year")
  ) |>
  arrange(firm_ID, year)

glimpse(annual_data)
```

結合後もパネルキーが一意であることを確認する。

```

annual_data_duplicates <- annual_data |>
  count(firm_ID, year, name = "observations") |>
  filter(observations > 1)

annual_data_duplicates

if (nrow(annual_data_duplicates) > 0) {
  stop("annual_dataのfirm_IDとyearの組合せに重複があります。")
}

```

3.5.4 月次データの結合

月次株式データに年次財務データを結合する。同じ年度の財務情報が、各月の行へ付与される。

```

monthly_data <- stock_data |>
  left_join(
    financial_data,
    by = c("firm_ID", "year")
  ) |>
  arrange(firm_ID, month_ID)

glimpse(monthly_data)

```

結合前後で月次データの行数が変化していないことを確認する。

```

stopifnot(
  nrow(monthly_data) == nrow(stock_data)
)

tibble(
  stock_rows = nrow(stock_data),
  monthly_rows = nrow(monthly_data),
  annual_rows = nrow(annual_data)
)

```

3.5.5 売上高・利益・時価総額の可視化

最新年度の企業について、売上高、当期純利益、時価総額の関係をバブルチャートで確認する。

```

latest_analysis_year <- annual_data |>
  filter(
    is.finite(sales),
    sales > 0,
    is.finite(X),
    X > 0,

```



```
    is.finite(ME),
    ME > 0
  ) |>
  summarise(
    latest_year = max(year)
  ) |>
  pull(latest_year)

bubble_chart_data <- annual_data |>
  filter(
    year == latest_analysis_year,
    is.finite(sales),
    sales > 0,
    is.finite(X),
    X > 0,
    is.finite(ME),
    ME > 0
  )

bubble_chart_data
```

```
bubble_chart_data |>
  ggplot(
    aes(
      x = log(sales),
      y = log(X),
      size = ME
    )
  ) +
  geom_point(alpha = 0.35) +
  scale_size(
    range = c(1, 12),
    name = "Market Equity"
  ) +
  labs(
    x = "Log Sales",
    y = "Log Net Income",
    title = paste(
      "Sales, Earnings and Market Equity in",
      latest_analysis_year
    )
  ) +
  theme_classic()
```

3.6 統計分析と分析用データ

3.6.1 一標本 t 検定

観測数が最も多い企業を選び、月次超過リターンの平均が 0 と異なるかを検定する。

```
test_firm_id <- stock_data |>
  filter(is.finite(Re)) |>
  count(firm_ID, sort = TRUE) |>
  slice_head(n = 1) |>
  pull(firm_ID)

test_firm_returns <- stock_data |>
  filter(
    firm_ID == test_firm_id,
    is.finite(Re)
  ) |>
  pull(Re)

tibble(
  firm_ID = test_firm_id,
  observations = length(test_firm_returns),
  mean_excess_return = mean(test_firm_returns),
  standard_deviation = sd(test_firm_returns)
)
```

t 値を定義から計算する。

$$t = \frac{\bar{R}^e - 0}{s(R^e)/\sqrt{n}}$$

```
manual_t_value <- (
  mean(test_firm_returns) - 0
) / (
  sd(test_firm_returns) /
  sqrt(length(test_firm_returns))
)

manual_t_value
```

t.test() の結果を broom::tidy() で整理する。

```
t_test_result <- t.test(
  test_firm_returns,
  mu = 0
```

```
)

broom::tidy(t_test_result)
```

3.6.2 簿価時価比率と株式リターン

前年度末の時価総額を作成し、期首株主資本を前年度末時価総額で割って簿価時価比率を計算する。

```
annual_data <- annual_data |>
  group_by(firm_ID) |>
  arrange(year, .by_group = TRUE) |>
  mutate(
    lagged_ME = lag(ME),
    lagged_BEME = lagged_BE / lagged_ME,
    lagged_BEME = if_else(
      is.finite(lagged_BEME) &
        lagged_BEME > 0,
      lagged_BEME,
      NA_real_
    )
  ) |>
  ungroup()
```

回帰に使用できる年度別観測数を確認する。

```
regression_observations_by_year <- annual_data |>
  filter(
    is.finite(Re),
    is.finite(lagged_BEME)
  ) |>
  count(year, name = "observations") |>
  arrange(year)

regression_observations_by_year
```

最新の利用可能年度を回帰対象にする。

```
regression_year <- regression_observations_by_year |>
  filter(observations >= 30) |>
  summarise(year = max(year)) |>
  pull(year)

lm_sample_data <- annual_data |>
  filter(
    year == regression_year,
```

```
    is.finite(Re),
    is.finite(lagged_BEME)
  ) |>
  select(
    firm_ID,
    year,
    Re,
    lagged_BEME
  )

lm_sample_data
```

散布図と回帰直線を描く。

```
beme_plot_limit <- quantile(
  lm_sample_data$lagged_BEME,
  0.99,
  na.rm = TRUE
)

lm_sample_data |>
  ggplot(
    aes(
      x = lagged_BEME,
      y = Re
    )
  ) +
  geom_point(alpha = 0.35) +
  geom_smooth(
    method = "lm",
    se = FALSE
  ) +
  coord_cartesian(
    xlim = c(0, beme_plot_limit)
  ) +
  labs(
    x = "Lagged Book-to-Market Ratio",
    y = "Annual Excess Return",
    title = paste(
      "Book-to-Market Ratio and Excess Return in",
      regression_year
    )
  ) +
  theme_classic()
```

線形回帰を推定する。

```
lm_result <- lm(  
  Re ~ lagged_BEME,  
  data = lm_sample_data  
)  
  
broom::tidy(lm_result)
```

モデル全体の結果を確認する。

```
broom::glance(lm_result)
```

3.6.3 年度別回帰と purrr

年度ごとの回帰を `nest()` と `purrr::map()` で実行する。明示的なループは使用しない。

```
yearly_regression_models <- annual_data |>  
  filter(  
    is.finite(Re),  
    is.finite(lagged_BEME)  
  ) |>  
  group_by(year) |>  
  filter(n() >= 30) |>  
  ungroup() |>  
  nest(data = -year) |>  
  mutate(  
    model = map(  
      data,  
      \(data) lm(  
        Re ~ lagged_BEME,  
        data = data  
      )  
    ),  
    coefficients = map(  
      model,  
      broom::tidy  
    ),  
    fit = map(  
      model,  
      broom::glance  
    )  
  )  
  
yearly_regression_models
```

年度別の回帰係数を一つのデータフレームへ展開する。

```
yearly_regression_coefficients <- yearly_regression_models |>
  select(year, coefficients) |>
  unnest(coefficients) |>
  arrange(year, term)

yearly_regression_coefficients
```

決定係数と標本数をまとめる。

```
yearly_regression_fit <- yearly_regression_models |>
  select(year, fit) |>
  unnest(fit) |>
  select(
    year,
    r.squared,
    adj.r.squared,
    sigma,
    statistic,
    p.value,
    nobs
  ) |>
  arrange(year)

yearly_regression_fit
```

3.6.4 分析用データの保存

第4章以降で使用するため、月次データと年次データを `simulation_data/derived` に保存する。元の入力 CSV は上書きしない。

```
if (!dir.exists(derived_data_dir)) {
  dir.create(
    derived_data_dir,
    recursive = TRUE
  )
}

monthly_output_path <- file.path(
  derived_data_dir,
  "ch05_output1.csv"
)

annual_output_path <- file.path(
```

```
derived_data_dir,  
"ch05_output2.csv"  
)
```

`purrr::walk2()` を用いて 2 つのデータフレームを保存する。

```
output_data <- list(  
  monthly = monthly_data,  
  annual = annual_data  
)  
  
output_paths <- c(  
  monthly = monthly_output_path,  
  annual = annual_output_path  
)  
  
walk2(  
  output_data,  
  output_paths,  
  \(data, path) {  
    readr::write_csv(  
      data,  
      path  
    )  
  }  
)  
  
output_paths
```

保存したファイルを読み直し、行数と列名を検証する。

```
output_verification <- imap_dfr(  
  output_data,  
  \(expected_data, data_name) {  
    output_path <- output_paths[[data_name]]  
  
    output_check <- readr::read_csv(  
      output_path,  
      show_col_types = FALSE  
    )  
  
    stopifnot(  
      nrow(output_check) ==  
      nrow(expected_data)  
    )  
  }  
)
```

```
stopifnot(  
  identical(  
    names(output_check),  
    names(expected_data)  
  )  
)  
  
tibble(  
  data = data_name,  
  output_file = output_path,  
  rows = nrow(output_check),  
  columns = ncol(output_check),  
  size_bytes = file.info(output_path)$size  
)  
}  
)  
  
output_verification
```

3.7 まとめ

本章では、株価、配当、調整係数から月次リターンを作成し、無リスク金利を差し引いて超過リターンを計算した。さらに、月次リターンを年次リターンへ集約し、第2章で作成した財務データと結合した。

分析用データは次の2ファイルに保存される。

```
simulation_data/derived/ch05_output1.csv  
simulation_data/derived/ch05_output2.csv
```

第4章では、この月次データと年次データを利用して、市場ポートフォリオ、ポートフォリオ・ソート、CAPM、Fama-Frenchの3ファクター・モデルを構築する。

第 4 章ファクターモデル

本章では、第 3 章で作成した月次株式データと年次財務データを利用し、市場ポートフォリオ、企業規模ポートフォリオ、簿価時価比率ポートフォリオ、SMB、HML を構築する。さらに、企業規模ポートフォリオを対象として CAPM と Fama–French の 3 ファクター・モデルを推定する。

本章では次の処理を順番に行う。

1. 第 3 章の月次・年次データを読み込む
2. 前年度末の情報だけを使ってポートフォリオを形成する
3. 市場ポートフォリオと市場超過リターンを計算する
4. 企業規模と簿価時価比率によるポートフォリオ・ソートを行う
5. 2×3 ポートフォリオから SMB と HML を構築する
6. CAPM と FF3 モデルを `purrr::map()` で一括推定する
7. 第 5 章以降で使用するファクター・データを保存する

反復処理には明示的な `for` 文を使わず、`purrr::map()` 系を利用する。パイプ演算子は native pipe の `|>` に統一する。

4.1 分析環境と入力データ

4.1.1 パッケージの準備

```
suppressPackageStartupMessages({  
  library(tidyverse)  
  library(ggthemes)  
  library(QuantLib)  
  library(GaussQuant)  
  library(tidyverse)  
  library(broom)  
})
```

パッケージをまだインストールしていない場合だけ、次のコードを R コンソールで実行する。

```
install.packages(c("tidyverse", "broom"))
```

4.1.2 プロジェクトとデータディレクトリ

RStudio でチャンクを個別実行する場合と、Quarto で章全体をレンダリングする場合の両方に対応するため、プロジェクトルートを実行時に確認する。

```
project_candidates <- unique(c(
  Sys.getenv("QUARTO_PROJECT_DIR"),
  getwd(),
  dirname(getwd())
))

project_candidates <- project_candidates[nzchar(project_candidates)]

project_matches <- project_candidates[
  file.exists(file.path(project_candidates, "_quarto.yml"))
]

if (length(project_matches) == 0) {
  stop("LagrangeFinanceのプロジェクトルートを確認できません。")
}

project_dir <- normalizePath(
  project_matches[1],
  winslash = "/",
  mustWork = TRUE
)

data_dir <- file.path(project_dir, "simulation_data")
derived_data_dir <- file.path(data_dir, "derived")

if (!dir.exists(data_dir)) {
  stop("simulation_dataディレクトリが見つかりません: ", data_dir)
}

if (!dir.exists(derived_data_dir)) {
  stop(
    "derivedディレクトリが見つかりません。第2章と第3章を先に実行してください: ",
    derived_data_dir
  )
}

project_dir
```

```
data_dir
derived_data_dir
```

4.1.3 第3章の出力を読み込む

第3章では次の2ファイルを作成した。

```
simulation_data/derived/ch05_output1.csv
simulation_data/derived/ch05_output2.csv
```

ch05_output1.csv は月次データ、ch05_output2.csv は年次データである。ファイル名は旧教材の章番号に由来する。

```
monthly_input_path <- file.path(
  derived_data_dir,
  "ch05_output1.csv"
)

annual_input_path <- file.path(
  derived_data_dir,
  "ch05_output2.csv"
)

input_paths <- c(
  monthly = monthly_input_path,
  annual = annual_input_path
)

missing_input_paths <- input_paths[
  !file.exists(input_paths)
]

if (length(missing_input_paths) > 0) {
  stop(
    "第3章の出力が見つかりません。第3章を先に実行してください: ",
    paste(missing_input_paths, collapse = ", ")
  )
}

input_paths

monthly_data <- readr::read_csv(
  monthly_input_path,
  show_col_types = FALSE
) |>
```

```
mutate(
  firm_ID = as.integer(firm_ID),
  year = as.integer(year),
  month = as.integer(month),
  month_ID = as.integer(month_ID),
  month_date = as.Date(month_date)
) |>
arrange(firm_ID, month_ID)

annual_data <- readr::read_csv(
  annual_input_path,
  show_col_types = FALSE
) |>
mutate(
  firm_ID = as.integer(firm_ID),
  year = as.integer(year)
) |>
arrange(firm_ID, year)

glimpse(monthly_data)
glimpse(annual_data)

input_data_overview <- tribble(
  ~data, ~observations, ~variables, ~firms, ~first_year, ~last_year,
  "monthly",
  nrow(monthly_data),
  ncol(monthly_data),
  n_distinct(monthly_data$firm_ID),
  min(monthly_data$year, na.rm = TRUE),
  max(monthly_data$year, na.rm = TRUE),
  "annual",
  nrow(annual_data),
  ncol(annual_data),
  n_distinct(annual_data$firm_ID),
  min(annual_data$year, na.rm = TRUE),
  max(annual_data$year, na.rm = TRUE)
)

input_data_overview
```

4.1.4 必須列とパネルキー

```
required_monthly_columns <- c(
  "year", "month", "month_ID", "month_date",
  "firm_ID", "R", "R_F", "Re", "ME"
)

required_annual_columns <- c(
  "year", "firm_ID", "ME", "BE", "lagged_BE"
)

missing_monthly_columns <- setdiff(
  required_monthly_columns,
  names(monthly_data)
)

missing_annual_columns <- setdiff(
  required_annual_columns,
  names(annual_data)
)

if (length(missing_monthly_columns) > 0) {
  stop(
    "月次データに必要な列が不足しています: ",
    paste(missing_monthly_columns, collapse = ", ")
  )
}

if (length(missing_annual_columns) > 0) {
  stop(
    "年次データに必要な列が不足しています: ",
    paste(missing_annual_columns, collapse = ", ")
  )
}

monthly_key_duplicates <- monthly_data |>
  count(firm_ID, month_ID, name = "observations") |>
  filter(observations > 1)

annual_key_duplicates <- annual_data |>
  count(firm_ID, year, name = "observations") |>
  filter(observations > 1)
```

```
monthly_key_duplicates
annual_key_duplicates

if (nrow(monthly_key_duplicates) > 0) {
  stop("月次データのfirm_IDとmonth_IDの組合せに重複があります。")
}

if (nrow(annual_key_duplicates) > 0) {
  stop("年次データのfirm_IDとyearの組合せに重複があります。")
}
```

4.1.5 補助関数

```
median_safe <- function(x) {
  values <- x[is.finite(x)]

  if (length(values) == 0) {
    return(NA_real_)
  }

  median(values)
}

mean_safe <- function(x) {
  values <- x[is.finite(x)]

  if (length(values) == 0) {
    return(NA_real_)
  }

  mean(values)
}

weighted_mean_safe <- function(x, weight) {
  valid <- is.finite(x) &
    is.finite(weight) &
    weight > 0

  if (!any(valid)) {
    return(NA_real_)
  }

  sum(x[valid] * weight[valid]) /
```

```

    sum(weight[valid])
}

significance_stars <- function(p_value) {
  case_when(
    is.na(p_value) ~ "",
    p_value < 0.01 ~ "***",
    p_value < 0.05 ~ "**",
    p_value < 0.10 ~ "*",
    TRUE ~ ""
  )
}

```

4.2 ポートフォリオ形成と市場リターン

4.2.1 前年度情報の準備

ポートフォリオ形成には、リターンが実現する年度より前に利用可能な情報だけを使う。本章では、年度 t の月次リターンに対して、年度 $t-1$ 末の時価総額と株主資本を用いる。

```

if (!"lagged_ME" %in% names(annual_data)) {
  annual_data <- annual_data |>
    group_by(firm_ID) |>
    arrange(year, .by_group = TRUE) |>
    mutate(lagged_ME = lag(ME)) |>
    ungroup()
}

if (!"lagged_BEME" %in% names(annual_data)) {
  annual_data <- annual_data |>
    mutate(
      lagged_BEME = lagged_BE / lagged_ME
    )
}

annual_data <- annual_data |>
  mutate(
    lagged_ME = if_else(
      is.finite(lagged_ME) & lagged_ME > 0,
      lagged_ME,
      NA_real_
    ),
    lagged_BEME = if_else(
      is.finite(lagged_BEME) & lagged_BEME > 0,

```

```

    lagged_BEME,
    NA_real_
  )
) |>
arrange(firm_ID, year)

```

```

lagged_variable_availability <- annual_data |>
  group_by(year) |>
  summarise(
    firms = n_distinct(firm_ID),
    valid_lagged_ME = sum(is.finite(lagged_ME)),
    valid_lagged_BEME = sum(is.finite(lagged_BEME)),
    valid_for_2x3 = sum(
      is.finite(lagged_ME) &
      is.finite(lagged_BEME)
    ),
    .groups = "drop"
  ) |>
  arrange(year)

lagged_variable_availability

```

4.2.2 市場ポートフォリオ

年度 t の企業 i の市場ポートフォリオ・ウェイト $w_{i,t}^M$ は、前年度末時価総額から計算する。

$$w_{i,t}^M = \frac{ME_{i,t-1}}{\sum_j ME_{j,t-1}}$$

```

market_membership <- annual_data |>
  filter(
    is.finite(lagged_ME),
    lagged_ME > 0
  ) |>
  group_by(year) |>
  mutate(
    market_weight = lagged_ME /
      sum(lagged_ME)
  ) |>
  ungroup() |>
  select(
    year,
    firm_ID,
    lagged_ME,

```



```

    market_weight
  )

market_membership

market_weight_check <- market_membership |>
  group_by(year) |>
  summarise(
    firms = n_distinct(firm_ID),
    weight_sum = sum(market_weight),
    minimum_weight = min(market_weight),
    maximum_weight = max(market_weight),
    .groups = "drop"
  )

market_weight_check

if (any(abs(market_weight_check$weight_sum - 1) > 1e-10)) {
  stop("市場ポートフォリオの年度別ウェイト合計が1ではありません。")
}

```

市場ポートフォリオの月次リターンは、前年度末時価総額による加重平均である。

$$R_{M,t} = \sum_i w_{i,t}^M R_{i,t}$$

```

market_return_data <- monthly_data |>
  inner_join(
    market_membership,
    by = c("year", "firm_ID")
  ) |>
  group_by(
    month_ID,
    year,
    month,
    month_date
  ) |>
  summarise(
    R_F = median_safe(R_F),
    R_M = weighted_mean_safe(R, lagged_ME),
    eligible_firms = n_distinct(firm_ID),
    valid_return_firms = sum(
      is.finite(R) &
      is.finite(lagged_ME) &
      lagged_ME > 0
    )
  )

```

```

    ),
    .groups = "drop"
  ) |>
  mutate(
    R_Me = R_M - R_F,
    return_coverage = valid_return_firms /
      eligible_firms
  ) |>
  arrange(month_ID)

market_return_data

```

```

invalid_market_months <- market_return_data |>
  filter(
    !is.finite(R_F) |
    !is.finite(R_M) |
    !is.finite(R_Me)
  )

invalid_market_months

if (nrow(invalid_market_months) > 0) {
  stop("市場リターンを作成できない月があります。")
}

```

```

market_return_summary <- market_return_data |>
  summarise(
    observations = n(),
    mean_market_return = mean(R_M),
    mean_market_excess_return = mean(R_Me),
    market_volatility = sd(R_M),
    minimum_market_return = min(R_M),
    maximum_market_return = max(R_M),
    minimum_coverage = min(return_coverage)
  )

market_return_summary

```

```

market_return_data |>
  ggplot(aes(x = R_Me)) +
  geom_histogram(bins = 40) +
  geom_vline(xintercept = 0, linetype = "dotted") +
  labs(
    x = "Monthly Market Excess Return",
    y = "Count",

```

```

    title = "Distribution of Market Excess Returns"
  ) +
  theme_classic()

```

```

market_return_data |>
  arrange(month_ID) |>
  mutate(
    cumulative_gross_market_return =
      cumprod(1 + R_M)
  ) |>
  ggplot(
    aes(
      x = month_date,
      y = cumulative_gross_market_return
    )
  ) +
  geom_line(linewidth = 0.8) +
  geom_hline(yintercept = 1, linetype = "dotted") +
  labs(
    x = NULL,
    y = "Cumulative Gross Return",
    title = "Value-Weighted Market Portfolio"
  ) +
  theme_classic()

```

4.2.3 ポートフォリオ形成データ

企業規模と簿価時価比率の両方が利用可能な企業を共通の形成ユニバースとする。

```

formation_universe <- annual_data |>
  filter(
    is.finite(lagged_ME),
    lagged_ME > 0,
    is.finite(lagged_BEME),
    lagged_BEME > 0
  ) |>
  select(
    year,
    firm_ID,
    lagged_ME,
    lagged_BEME
  )

formation_universe

```

```

formation_breakpoints <- formation_universe |>
  group_by(year) |>
  summarise(
    firms = n_distinct(firm_ID),
    size_median = median(lagged_ME),
    BEME_30 = quantile(
      lagged_BEME,
      probs = 0.30,
      names = FALSE
    ),
    BEME_70 = quantile(
      lagged_BEME,
      probs = 0.70,
      names = FALSE
    ),
    .groups = "drop"
  ) |>
  arrange(year)

formation_breakpoints

```

```

formation_data <- formation_universe |>
  left_join(
    formation_breakpoints,
    by = "year"
  ) |>
  group_by(year) |>
  mutate(
    ME_rank10 = ntile(lagged_ME, 10),
    BEME_rank10 = ntile(lagged_BEME, 10)
  ) |>
  ungroup() |>
  mutate(
    size_group = if_else(
      lagged_ME <= size_median,
      "S",
      "B"
    ),
    BEME_group = case_when(
      lagged_BEME <= BEME_30 ~ "L",
      lagged_BEME <= BEME_70 ~ "N",
      TRUE ~ "H"
    ),
    FF_portfolio_type = paste0(

```

```

        size_group,
        BEME_group
    ),
    FF_portfolio_type = factor(
        FF_portfolio_type,
        levels = c(
            "SL", "SN", "SH",
            "BL", "BN", "BH"
        )
    )
) |>
select(
    year,
    firm_ID,
    lagged_ME,
    lagged_BEME,
    ME_rank10,
    BEME_rank10,
    size_group,
    BEME_group,
    FF_portfolio_type
)

formation_data

portfolio_membership_counts <- formation_data |>
count(
    year,
    FF_portfolio_type,
    name = "firms"
) |>
complete(
    year,
    FF_portfolio_type,
    fill = list(firms = 0)
) |>
arrange(
    year,
    FF_portfolio_type
)

empty_portfolios <- portfolio_membership_counts |>
filter(firms == 0)

```

```
portfolio_membership_counts
empty_portfolios

if (nrow(empty_portfolios) > 0) {
  stop("企業が割り当てられていない2×3ポートフォリオがあります。")
}
```

4.3 単変量ポートフォリオ・ソートと CAPM

4.3.1 企業規模 10 分位ポートフォリオ

企業規模 10 分位ごとに、等加重リターンと前年度末時価総額加重リターンを計算する。

```
size_decile_returns <- monthly_data |>
  inner_join(
    formation_data |>
      select(
        year,
        firm_ID,
        lagged_ME,
        ME_rank10
      ),
    by = c("year", "firm_ID")
  ) |>
  group_by(
    month_ID,
    year,
    month,
    month_date,
    ME_rank10
  ) |>
  summarise(
    R_F = median_safe(R_F),
    R_equal = mean_safe(R),
    R_value = weighted_mean_safe(
      R,
      lagged_ME
    ),
    firms = n_distinct(firm_ID),
    valid_return_firms = sum(is.finite(R)),
    .groups = "drop"
  ) |>
  mutate(
    Re_equal = R_equal - R_F,
```

```

    Re_value = R_value - R_F
  ) |>
  arrange(
    month_ID,
    ME_rank10
  )

size_decile_returns

```

```

size_decile_coverage <- size_decile_returns |>
  group_by(month_ID) |>
  summarise(
    portfolios = n_distinct(ME_rank10),
    .groups = "drop"
  ) |>
  filter(portfolios != 10)

size_decile_coverage

if (nrow(size_decile_coverage) > 0) {
  stop("10個の企業規模ポートフォリオがそろわない月があります。")
}

```

```

size_decile_summary <- size_decile_returns |>
  group_by(ME_rank10) |>
  summarise(
    months = n(),
    mean_equal_excess_return = mean(
      Re_equal,
      na.rm = TRUE
    ),
    mean_value_excess_return = mean(
      Re_value,
      na.rm = TRUE
    ),
    value_return_volatility = sd(
      Re_value,
      na.rm = TRUE
    ),
    .groups = "drop"
  ) |>
  arrange(ME_rank10)

size_decile_summary

```

```
size_decile_summary |>
  select(
    ME_rank10,
    equal_weighted = mean_equal_excess_return,
    value_weighted = mean_value_excess_return
  ) |>
  pivot_longer(
    cols = c(
      equal_weighted,
      value_weighted
    ),
    names_to = "weighting",
    values_to = "mean_excess_return"
  ) |>
  mutate(
    ME_rank10 = factor(
      ME_rank10,
      levels = 1:10
    )
  ) |>
  ggplot(
    aes(
      x = ME_rank10,
      y = mean_excess_return,
      fill = weighting
    )
  ) +
  geom_col(position = "dodge") +
  geom_hline(yintercept = 0, linetype = "dotted") +
  scale_y_continuous(
    labels = scales::label_percent()
  ) +
  labs(
    x = "Size Decile",
    y = "Mean Monthly Excess Return",
    fill = "Weighting",
    title = "Size-Sorted Portfolio Returns"
  ) +
  theme_classic()
```


4.3.2 簿価時価比率 10 分位ポートフォリオ

```
BEME_decile_returns <- monthly_data |>
  inner_join(
    formation_data |>
      select(
        year,
        firm_ID,
        lagged_ME,
        BEME_rank10
      ),
    by = c("year", "firm_ID")
  ) |>
  group_by(
    month_ID,
    year,
    month,
    month_date,
    BEME_rank10
  ) |>
  summarise(
    R_F = median_safe(R_F),
    R_equal = mean_safe(R),
    R_value = weighted_mean_safe(
      R,
      lagged_ME
    ),
    firms = n_distinct(firm_ID),
    valid_return_firms = sum(is.finite(R)),
    .groups = "drop"
  ) |>
  mutate(
    Re_equal = R_equal - R_F,
    Re_value = R_value - R_F
  ) |>
  arrange(
    month_ID,
    BEME_rank10
  )

BEME_decile_returns
```

```

BEME_decile_summary <- BEME_decile_returns |>
  group_by(BEME_rank10) |>
  summarise(
    months = n(),
    mean_equal_excess_return = mean(
      Re_equal,
      na.rm = TRUE
    ),
    mean_value_excess_return = mean(
      Re_value,
      na.rm = TRUE
    ),
    value_return_volatility = sd(
      Re_value,
      na.rm = TRUE
    ),
    .groups = "drop"
  ) |>
  arrange(BEME_rank10)

BEME_decile_summary

```

```

BEME_decile_summary |>
  select(
    BEME_rank10,
    equal_weighted = mean_equal_excess_return,
    value_weighted = mean_value_excess_return
  ) |>
  pivot_longer(
    cols = c(
      equal_weighted,
      value_weighted
    ),
    names_to = "weighting",
    values_to = "mean_excess_return"
  ) |>
  mutate(
    BEME_rank10 = factor(
      BEME_rank10,
      levels = 1:10
    )
  ) |>
  ggplot(
    aes(

```

```

    x = BEME_rank10,
    y = mean_excess_return,
    fill = weighting
  )
) +
geom_col(position = "dodge") +
geom_hline(yintercept = 0, linetype = "dotted") +
scale_y_continuous(
  labels = scales::label_percent()
) +
labs(
  x = "Book-to-Market Decile",
  y = "Mean Monthly Excess Return",
  fill = "Weighting",
  title = "Book-to-Market-Sorted Portfolio Returns"
) +
theme_classic()

```

4.3.3 CAPM の推定

CAPM では、ポートフォリオ p の超過リターンを市場超過リターンで説明する。

$$R_{p,t}^e = \alpha_p + \beta_p R_{M,t}^e + \varepsilon_{p,t}$$

```

CAPM_data <- size_decile_returns |>
  select(
    month_ID,
    ME_rank10,
    Re = Re_value
  ) |>
  inner_join(
    market_return_data |>
      select(
        month_ID,
        R_Me
      ),
    by = "month_ID"
  ) |>
  filter(
    is.finite(Re),
    is.finite(R_Me)
  ) |>
  arrange(

```

```
    ME_rank10,  
    month_ID  
  )  
  
CAPM_data
```

`nest()` で各規模ポートフォリオのデータをまとめ、`map()` で同じ回帰式を適用する。

```
CAPM_models <- CAPM_data |>  
  group_by(ME_rank10) |>  
  nest() |>  
  mutate(  
    model = map(  
      data,  
      \(data) lm(  
        Re ~ R_Me,  
        data = data  
      )  
    ),  
    coefficients = map(  
      model,  
      broom::tidy  
    ),  
    fit = map(  
      model,  
      broom::glance  
    )  
  )  
  
CAPM_models
```

```
CAPM_results <- CAPM_models |>  
  select(  
    ME_rank10,  
    coefficients  
  ) |>  
  unnest(coefficients) |>  
  mutate(  
    significance = significance_stars(  
      p.value  
    )  
  ) |>  
  arrange(  
    ME_rank10,  
    term
```

```
)
```

```
CAPM_results
```

```
CAPM_fit <- CAPM_models |>
```

```
  select(
    ME_rank10,
    fit
  ) |>
  unnest(fit) |>
  select(
    ME_rank10,
    r.squared,
    adj.r.squared,
    sigma,
    statistic,
    p.value,
    nobs
  ) |>
  arrange(ME_rank10)
```

```
CAPM_fit
```

```
CAPM_alpha <- CAPM_results |>
```

```
  filter(term == "(Intercept)") |>
  transmute(
    ME_rank10,
    CAPM_alpha = estimate,
    standard_error = std.error,
    statistic,
    p_value = p.value,
    significance
  )
```

```
CAPM_alpha
```

```
CAPM_alpha |>
```

```
  mutate(
    ME_rank10 = factor(
      ME_rank10,
      levels = 1:10
    )
  ) |>
  ggplot(
    aes(
```

```

    x = ME_rank10,
    y = CAPM_alpha
  )
) +
geom_col() +
geom_hline(yintercept = 0, linetype = "dotted") +
scale_y_continuous(
  labels = scales::label_percent()
) +
labs(
  x = "Size Decile",
  y = "CAPM Alpha",
  title = "CAPM Alphas of Size Portfolios"
) +
theme_classic()

```

証券市場線

```

CAPM_beta <- CAPM_results |>
  filter(term == "R_Me") |>
  transmute(
    ME_rank10,
    CAPM_beta = estimate,
    beta_p_value = p.value
  )

security_market_line_data <- size_decile_summary |>
  select(
    ME_rank10,
    mean_excess_return =
      mean_value_excess_return
  ) |>
  left_join(
    CAPM_beta,
    by = "ME_rank10"
  )

mean_market_excess_return <- mean(
  market_return_data$R_Me,
  na.rm = TRUE
)

security_market_line_data

```

```
security_market_line_data |>
  ggplot(
    aes(
      x = CAPM_beta,
      y = mean_excess_return
    )
  ) +
  geom_point() +
  geom_text(
    aes(label = ME_rank10),
    nudge_y = 0.0005
  ) +
  geom_abline(
    intercept = 0,
    slope = mean_market_excess_return,
    linetype = "dashed"
  ) +
  scale_y_continuous(
    labels = scales::label_percent()
  ) +
  labs(
    x = "Market Beta",
    y = "Mean Monthly Excess Return",
    title = "Security Market Line"
  ) +
  theme_classic()
```

4.4 2×3 ポートフォリオと SMB・HML

4.4.1 2×3 Size-BE/ME ポートフォリオ

Fama-French 型の SMB と HML を作成するため、企業規模を Small と Big の 2 群、簿価時価比率を Low、Neutral、High の 3 群に分ける。

ポートフォリオ	企業規模	簿価時価比率
SL	Small	Low
SN	Small	Neutral
SH	Small	High
BL	Big	Low
BN	Big	Neutral
BH	Big	High

```
FF_portfolio_returns <- monthly_data |>
  inner_join(
    formation_data |>
      select(
        year,
        firm_ID,
        lagged_ME,
        size_group,
        BEME_group,
        FF_portfolio_type
      ),
    by = c("year", "firm_ID")
  ) |>
  filter(
    !is.na(FF_portfolio_type)
  ) |>
  group_by(
    month_ID,
    year,
    month,
    month_date,
    FF_portfolio_type,
    size_group,
    BEME_group
  ) |>
  summarise(
    R_F = median_safe(R_F),
    R = weighted_mean_safe(
      R,
      lagged_ME
    ),
    firms = n_distinct(firm_ID),
    valid_return_firms = sum(is.finite(R)),
    .groups = "drop"
  ) |>
  mutate(
    Re = R - R_F
  ) |>
  arrange(
    month_ID,
    FF_portfolio_type
  )
```



```
FF_portfolio_returns
```

```
FF_portfolio_coverage <- FF_portfolio_returns |>
  group_by(month_ID) |>
  summarise(
    portfolios = n_distinct(
      FF_portfolio_type
    ),
    .groups = "drop"
  ) |>
  filter(portfolios != 6)

FF_portfolio_coverage

if (nrow(FF_portfolio_coverage) > 0) {
  stop("6個のSize--BE/MEポートフォリオがそろわない月があります。")
}
```

```
FF_portfolio_summary <- FF_portfolio_returns |>
  group_by(
    FF_portfolio_type,
    size_group,
    BEME_group
  ) |>
  summarise(
    months = n(),
    mean_return = mean(R),
    mean_excess_return = mean(Re),
    volatility = sd(R),
    .groups = "drop"
  ) |>
  arrange(FF_portfolio_type)

FF_portfolio_summary
```

```
FF_portfolio_summary |>
  ggplot(
    aes(
      x = BEME_group,
      y = mean_excess_return,
      fill = size_group
    )
  ) +
  geom_col(position = "dodge") +
  geom_text(
```

```

aes(
  label = FF_portfolio_type,
  group = size_group
),
position = position_dodge(width = 0.9),
vjust = -0.5
) +
geom_hline(yintercept = 0, linetype = "dotted") +
scale_y_continuous(
  labels = scales::label_percent(),
  expand = expansion(
    mult = c(0.05, 0.15)
  )
) +
labs(
  x = "Book-to-Market Group",
  y = "Mean Monthly Excess Return",
  fill = "Size Group",
  title = "Six Size--Book-to-Market Portfolios"
) +
theme_classic()

```

```

FF_portfolio_returns |>
  group_by(FF_portfolio_type) |>
  arrange(month_ID, .by_group = TRUE) |>
  mutate(
    cumulative_gross_return =
      cumprod(1 + R)
  ) |>
  ungroup() |>
  ggplot(
    aes(
      x = month_date,
      y = cumulative_gross_return,
      linetype = FF_portfolio_type
    )
  ) +
  geom_line(linewidth = 0.7) +
  geom_hline(yintercept = 1, linetype = "dotted") +
  labs(
    x = NULL,
    y = "Cumulative Gross Return",
    linetype = "Portfolio",
    title = "Cumulative Returns of Six Portfolios"
  )

```

```
) +  
theme_classic()
```

4.4.2 SMB と HML

SMB は Small ポートフォリオの平均リターンから Big ポートフォリオの平均リターンを引いて計算する。

$$SMB_t = \frac{SL_t + SN_t + SH_t}{3} - \frac{BL_t + BN_t + BH_t}{3}$$

HML は High ポートフォリオの平均リターンから Low ポートフォリオの平均リターンを引いて計算する。

$$HML_t = \frac{SH_t + BH_t}{2} - \frac{SL_t + BL_t}{2}$$

```
FF_portfolio_wide <- FF_portfolio_returns |>  
  select(  
    month_ID,  
    year,  
    month,  
    month_date,  
    FF_portfolio_type,  
    R  
  ) |>  
  pivot_wider(  
    names_from = FF_portfolio_type,  
    values_from = R  
  ) |>  
  arrange(month_ID)  
  
FF_portfolio_wide
```

```
SMB_HML_data <- FF_portfolio_wide |>  
  mutate(  
    SMB = (  
      SL + SN + SH  
    ) / 3 - (  
      BL + BN + BH  
    ) / 3,  
    HML = (  
      SH + BH  
    ) / 2 - (  
      SL + BL  
    ) / 2  
  ) |>
```

```
select(  
  month_ID,  
  year,  
  month,  
  month_date,  
  SL,  
  SN,  
  SH,  
  BL,  
  BN,  
  BH,  
  SMB,  
  HML  
)
```

SMB_HML_data

```
factor_data <- market_return_data |>
```

```
  select(  
    month_ID,  
    year,  
    month,  
    month_date,  
    R_F,  
    R_M,  
    R_Me,  
    market_return_coverage =  
      return_coverage  
  ) |>
```

```
inner_join(  
  SMB_HML_data,  
  by = c(  
    "month_ID",  
    "year",  
    "month",  
    "month_date"  
  )  
) |>  
arrange(month_ID)
```

factor_data

```
invalid_factor_rows <- factor_data |>
```

```
  filter(  
    
```

```

!if_all(
  c(
    R_F,
    R_M,
    R_Me,
    SMB,
    HML
  ),
  is.finite
)

invalid_factor_rows

if (nrow(invalid_factor_rows) > 0) {
  stop("ファクター・データに欠損値または非有限値があります。")
}

```

4.4.3 ファクターの要約統計量

複数のファクターを `map_dfr()` で同じ形式に集計する。

```

factor_names <- c(
  "R_Me",
  "SMB",
  "HML"
)

factor_summary <- factor_names |>
  map_dfr(
    \(factor_name) {
      values <- factor_data[[factor_name]]
      finite_values <- values[is.finite(values)]

      tibble(
        factor = factor_name,
        observations = length(finite_values),
        mean = mean(finite_values),
        standard_deviation = sd(finite_values),
        minimum = min(finite_values),
        median = median(finite_values),
        maximum = max(finite_values),
        t_value = mean(finite_values) / (
          sd(finite_values) /

```

```
      sqrt(length(finite_values))
    )
  )
}
)

factor_summary
```

```
factor_correlation <- factor_data |>
  select(
    R_Me,
    SMB,
    HML
  ) |>
  cor(
    use = "complete.obs"
  )

factor_correlation
```

```
factor_data |>
  select(
    month_date,
    R_Me,
    SMB,
    HML
  ) |>
  pivot_longer(
    cols = c(
      R_Me,
      SMB,
      HML
    ),
    names_to = "factor",
    values_to = "return"
  ) |>
  ggplot(
    aes(
      x = month_date,
      y = return
    )
  ) +
  geom_line(linewidth = 0.6) +
  geom_hline(yintercept = 0, linetype = "dotted") +
```

```

facet_wrap(
  vars(factor),
  ncol = 1,
  scales = "free_y"
) +
scale_y_continuous(
  labels = scales::label_percent()
) +
labs(
  x = NULL,
  y = "Monthly Return",
  title = "Market, SMB and HML Factors"
) +
theme_classic()

```

4.5 FF3 モデルと CAPM 比較

4.5.1 FF3 モデルの推定

Fama–French の 3 ファクター・モデルは、ポートフォリオの超過リターンを市場、SMB、HML で説明する。

$$R_{p,t}^e = \alpha_p + \beta_{M,p} R_{M,t}^e + \beta_{SMB,p} SMB_t + \beta_{HML,p} HML_t + \varepsilon_{p,t}$$

```

FF3_data <- size_decile_returns |>
  select(
    month_ID,
    ME_rank10,
    Re = Re_value
  ) |>
  inner_join(
    factor_data |>
      select(
        month_ID,
        R_Me,
        SMB,
        HML
      ),
    by = "month_ID"
  ) |>
  filter(
    if_all(
      c(
        Re,

```

```
      R_Me,  
      SMB,  
      HML  
    ),  
    is.finite  
  )  
)|>  
arrange(  
  ME_rank10,  
  month_ID  
)  
  
FF3_data
```

```
FF3_models <- FF3_data |>  
  group_by(ME_rank10) |>  
  nest() |>  
  mutate(  
    model = map(  
      data,  
      \(data) lm(  
        Re ~ R_Me + SMB + HML,  
        data = data  
      )  
    ),  
    coefficients = map(  
      model,  
      broom::tidy  
    ),  
    fit = map(  
      model,  
      broom::glance  
    )  
  )  
  
FF3_models
```

```
FF3_results <- FF3_models |>  
  select(  
    ME_rank10,  
    coefficients  
  ) |>  
  unnest(coefficients) |>  
  mutate(  
    
```



```
      significance = significance_stars(
        p.value
      )
    ) |>
  arrange(
    ME_rank10,
    term
  )
FF3_results
```

```
FF3_fit <- FF3_models |>
  select(
    ME_rank10,
    fit
  ) |>
  unnest(fit) |>
  select(
    ME_rank10,
    r.squared,
    adj.r.squared,
    sigma,
    statistic,
    p.value,
    nobs
  ) |>
  arrange(ME_rank10)
FF3_fit
```

```
FF3_alpha <- FF3_results |>
  filter(term == "(Intercept)") |>
  transmute(
    ME_rank10,
    FF3_alpha = estimate,
    standard_error = std.error,
    statistic,
    p_value = p.value,
    significance
  )
FF3_alpha
```

```
FF3_alpha |>
  mutate(
    ME_rank10 = factor(
      ME_rank10,
      levels = 1:10
    )
  ) |>
  ggplot(
    aes(
      x = ME_rank10,
      y = FF3_alpha
    )
  ) +
  geom_col() +
  geom_hline(yintercept = 0, linetype = "dotted") +
  scale_y_continuous(
    labels = scales::label_percent()
  ) +
  labs(
    x = "Size Decile",
    y = "FF3 Alpha",
    title = "FF3 Alphas of Size Portfolios"
  ) +
  theme_classic()
```

4.5.2 CAPM と FF3 の比較

```
model_alpha_comparison <- CAPM_alpha |>
  select(
    ME_rank10,
    CAPM_alpha
  ) |>
  left_join(
    FF3_alpha |>
      select(
        ME_rank10,
        FF3_alpha
      ),
    by = "ME_rank10"
  ) |>
  pivot_longer(
    cols = c(
      CAPM_alpha,
```

```

      FF3_alpha
    ),
    names_to = "model",
    values_to = "alpha"
  )

```

```
model_alpha_comparison
```

```

model_alpha_comparison |>
  mutate(
    ME_rank10 = factor(
      ME_rank10,
      levels = 1:10
    )
  ) |>
  ggplot(
    aes(
      x = ME_rank10,
      y = alpha,
      fill = model
    )
  ) +
  geom_col(position = "dodge") +
  geom_hline(yintercept = 0, linetype = "dotted") +
  scale_y_continuous(
    labels = scales::label_percent()
  ) +
  labs(
    x = "Size Decile",
    y = "Monthly Alpha",
    fill = "Model",
    title = "CAPM and FF3 Alphas"
  ) +
  theme_classic()

```

```

model_fit_comparison <- CAPM_fit |>
  select(
    ME_rank10,
    CAPM_adjusted_R2 =
      adj.r.squared
  ) |>
  left_join(
    FF3_fit |>
      select(

```

```
      ME_rank10,
      FF3_adjusted_R2 =
        adj.r.squared
    ),
    by = "ME_rank10"
  )

model_fit_comparison

model_fit_comparison |>
  pivot_longer(
    cols = c(
      CAPM_adjusted_R2,
      FF3_adjusted_R2
    ),
    names_to = "model",
    values_to = "adjusted_R2"
  ) |>
  mutate(
    ME_rank10 = factor(
      ME_rank10,
      levels = 1:10
    )
  ) |>
  ggplot(
    aes(
      x = ME_rank10,
      y = adjusted_R2,
      fill = model
    )
  ) +
  geom_col(position = "dodge") +
  labs(
    x = "Size Decile",
    y = "Adjusted R-squared",
    fill = "Model",
    title = "Model Fit: CAPM and FF3"
  ) +
  theme_classic()
```

4.6 ファクター・データの保存

4.6.1 保存と検証

第5章以降で使用するファクター・データを、`simulation_data/derived/ch06_output.csv` に保存する。

```
factor_output <- factor_data |>
  select(
    month_ID,
    year,
    month,
    month_date,
    R_F,
    R_M,
    R_Me,
    SMB,
    HML,
    SL,
    SN,
    SH,
    BL,
    BN,
    BH,
    market_return_coverage
  )
```

factor_output

```
factor_output_path <- file.path(
  derived_data_dir,
  "ch06_output.csv"
)

readr::write_csv(
  factor_output,
  factor_output_path
)

factor_output_path
file.info(
  factor_output_path
)[, c("size", "mtime")]
```

保存したファイルを読み直し、行数と列名を検証する。

```

factor_output_check <- readr::read_csv(
  factor_output_path,
  show_col_types = FALSE
)

stopifnot(
  nrow(factor_output_check) ==
    nrow(factor_output)
)

stopifnot(
  identical(
    names(factor_output_check),
    names(factor_output)
  )
)

tibble(
  output_file = factor_output_path,
  rows = nrow(factor_output_check),
  columns = ncol(factor_output_check),
  first_month = min(
    factor_output_check$month_ID
  ),
  last_month = max(
    factor_output_check$month_ID
  )
)

```

4.7 まとめ

本章では、前年度末時価総額を用いて市場ポートフォリオと企業規模ポートフォリオを構築した。さらに、企業規模と簿価時価比率による独立 2×3 ソートから 6 ポートフォリオを作成し、SMB と HML を計算した。

回帰分析では、企業規模 10 分位ポートフォリオに対して CAPM と FF3 モデルを推定し、アルファと決定係数を比較した。回帰の反復処理には `nest()` と `purrr::map()` を用いており、明示的なループは使用していない。

作成したファクター・データは次の場所に保存される。

```
simulation_data/derived/ch06_output.csv
```

第5章では、このファクター・データを利用して、個別企業の資本コスト、共分散構造、平均分散ポートフォリオを分析する。

第 5 章 資産価格モデル

5.1 分析環境とデータ準備

5.1.1 外部パッケージの読み込みとデータの準備

```
library(tidyverse)
library(broom)

monthly_data <- read_csv("ch05_output1.csv")
annual_data <- read_csv("ch05_output2.csv")
factor_data <- read_csv("ch06_output.csv")

monthly_data <- monthly_data %>%
  group_by(firm_ID) %>% # firm_IDでグループ化
  mutate(is_public_2020 = (max(month_ID) == 72), # 2020年の年末時点で上場しているかフラグ付け
         N_observations = n()) %>% # 各firm_IDのデータ数をカウント
  ungroup() %>%
  filter(is_public_2020 == TRUE, # 2020年の年末時点で上場しているfirm_IDを抽出
         N_observations >= 36) %>% # 36ヶ月以上のデータがあるfirm_IDを抽出
  select(-N_observations) # N_observations列を削除

annual_data <- monthly_data %>% # monthly_dataに含まれるyearとfirm_IDのペアを抽出
  select(year, firm_ID) %>%
  unique() %>%
  left_join(annual_data, by = c("year", "firm_ID")) # annual_dataとmonthly_dataでyearとfirm_IDのペアを
```

5.2 FF3 モデルと株式資本コスト

5.2.1 FF3 モデルの推定

```
firm_ID_set <- unique(monthly_data$firm_ID) # firm_IDの固有要素を抽出
N_firms <- length(firm_ID_set) # firm_ID_setの要素数をカウント

monthly_data <- monthly_data %>%
  select(-R_F) %>% # R_Fはmonthly_dataとfactor_dataで重複するので削除
```

```

full_join(factor_data, by = "month_ID")

FF3_results <- list(NA) # 推定結果を保存するために空のリストを準備

for (i in 1:N_firms) {

  FF3_results[[i]] <- monthly_data %>%
    filter(firm_ID == firm_ID_set[i]) %>%
    lm(Re ~ 0 + R_Me + SMB + HML, data = .) %>% # 冒頭に"0 +"を追加して定数項をゼロに
    tidy() %>%
    mutate(firm_ID = firm_ID_set[i]) %>% # 推定対象のfirm_IDを保存
    select(firm_ID, everything())

}

FF3_results <- do.call(rbind, FF3_results) # do.call()関数を用いて複数のデータフレームから構成されるリストを

```

5.2.2 ファクター・ローディングの整理

```

FF3_loadings <- FF3_results %>%
  pivot_wider(id_cols = "firm_ID", names_from = "term", values_from = "estimate") %>% # term列の値に対応
  rename(beta_M = R_Me, beta_SMB = SMB, beta_HML = HML) # 列名を変更

```

5.2.3 ファクター・リスクプレミアムの計算

```

factor_risk_premium <- apply(factor_data[, 4:6], 2, mean) * 12 # 12を掛けて年次プレミアムに換算

##           R_Me           SMB           HML

## 0.04800514 0.07858358 0.08328208

```

5.2.4 FF3 モデルによる株式資本コストの推定

```

expected_R_FF3 <- as.matrix(FF3_loadings[, 2:4]) %*% factor_risk_premium # Fama-Frenchの3ファクター・
FF3_cost_of_capital <- tibble(firm_ID = FF3_loadings$firm_ID, cost_of_capital = as.vector(expected_R_FF3))

```


5.3 株式資本コストと配当成長

5.3.1 株式資本コストの分布

```
ggplot(FF3_cost_of_capital) +
  geom_histogram(aes(x = cost_of_capital)) +
  labs(x = "FF3 Cost of Capital", y = "Count") +
  scale_y_discrete(expand = c(0, 0)) +
  theme_classic()
```

5.3.2 時価総額別の株式資本コスト

```
annual_data_2020 <- annual_data %>%
  group_by(firm_ID) %>% # 企業ごとに時価総額を計算
  mutate(lagged_ME = lag(ME)) %>%
  ungroup() %>%
  filter(year == 2020) %>% # 2020年のデータのみ抽出
  mutate(ME_rank2 = as.factor(ntile(lagged_ME, 2)), # 時価総額に基づき二分割
         ME_rank2 = fct_recode(ME_rank2,
                                Small = "1",
                                Large = "2")) %>%
  full_join(FF3_cost_of_capital, by = "firm_ID") %>% # 株式資本コストの推定値を追加
  drop_na() # 欠損値を削除

ggplot(annual_data_2020) +
  geom_density(aes(x = cost_of_capital, group = ME_rank2, linetype = ME_rank2)) + # 密度関数を描くには、
  labs(x = "FF3 Cost of Capital", y = "Estimated Density", linetype = "Firm Type") +
  scale_y_continuous(expand = c(0, 0), breaks = NULL) + # break引数で目盛り線を非表示に指定
  theme_classic()
```

5.3.3 配当利回りの計算

```
dividend_yield_2020 <- monthly_data %>%
  filter(year == 2020) %>%
  group_by(firm_ID) %>% # firm_IDでグループ化
  summarize(annual_dividend = sum(DPS * shares_outstanding), # 各月の配当支払総額を合計
            latest_ME = ME[which.max(month_ID)]) %>% # 最新の時価総額を保存
  mutate(dividend_yield = annual_dividend / latest_ME) %>% # 配当利回りの実績値を計算
  filter(dividend_yield > 0) # 無配の企業を落とす
```

5.3.4 潜在配当成長率の推定

```
dividend_yield_2020 %>%
  left_join(FF3_cost_of_capital, by = "firm_ID") %>% # 株式資本コストの推定値を追加
  mutate(implied_dividend_growth = (cost_of_capital - dividend_yield) / (1 + dividend_yield)) # 配当
```

5.4 リスクモデルと投資ユニバース

5.4.1 ファクターの分散共分散行列

```
Sigma_FF3 <- 12 * cov(factor_data[, 4:6]) # 12を掛けて年次データに換算

##           R_Me           SMB           HML

## R_Me  0.020685969 -0.003901607  0.001529890

## SMB   -0.003901607  0.006268377 -0.001886351

## HML    0.001529890 -0.001886351  0.003915638
```

5.4.2 投資対象企業の選定

```
N_portfolio_firms <- 100 # 投資対象の企業を100社に限定

investment_universe <- annual_data %>%
  filter(year == 2020) %>% # 2020年度のデータを抽出
  filter(rank(desc(ME)) <= N_portfolio_firms) %>% # その中で時価総額が上位100社の銘柄を抽出
  select(firm_ID) %>%
  unlist() # データフレームからベクトルに変換

names(investment_universe) <- NULL # firm_IDという列名を消去
```

5.4.3 誤差項の分散共分散行列

```
Sigma_epsilon <- monthly_data %>%
  filter(firm_ID %in% investment_universe) %>% # 投資対象に含まれるデータのみを抽出
  left_join(FF3_loadings, by = "firm_ID") %>%
  mutate(R_FF3 = R_F + beta_M * R_Me + beta_SMB * SMB + beta_HML * HML, # ファクターの実現値からFama-Fr
         epsilon = R - R_FF3) %>% # 実際のリターンとの違いから誤差項を推定
  group_by(firm_ID) %>%
```

```

summarize(epsilon_variance = 12 * var(epsilon, na.rm = TRUE)) %>% # firm_IDごとに誤差項の分散を推定
select(epsilon_variance) %>%
unlist() %>% # データフレームからベクトルに変換
diag() # ベクトルから対角行列を作成

```

5.4.4 リターンの分散共分散行列

```

beta <- FF3_loadings %>%
  filter(firm_ID %in% investment_universe) %>% # 投資対象に含まれるデータのみを抽出
  select(-firm_ID) %>% # ファクター・ローディングのみを抽出
  as.matrix() # データフレームから行列に変換

Sigma <- beta %*% Sigma_FF3 %*% t(beta) + Sigma_epsilon # 分解式に基づいて分散共分散行列を計算

```

5.4.5 期待リターンのベクトル

```

mu <- FF3_cost_of_capital %>% # 7.1.2節の推定結果をそのまま利用
  filter(firm_ID %in% investment_universe) %>% # 投資対象に含まれるデータのみを抽出
  select(-firm_ID) %>%
  unlist() # データフレームからベクトルに変換

names(mu) <- NULL # cost_of_capitalという列名を消去

##      [1]  0.203791678 -0.001750860  0.071846430 ... (中略) ...  0.088872719  0.153100331  0.361662758

```

5.5 平均分散ポートフォリオ

5.5.1 quadprog パッケージの準備

```

install.packages("quadprog") # quadprogはquadratic programming (二次計画法) の略

```

5.5.2 平均分散最適化問題の設定

```

library(quadprog) # quadprogの読み込み

target_return <- 0.1 # 目標期待リターンを0.1に設定

Dmat <- Sigma # 分散共分散行列
dvec <- rep(0, N_portfolio_firms) # 対応項無し
Amat <- cbind(mu, rep(1, N_portfolio_firms)) # 目標期待リターン, 及び保有比率の係数
bvec <- c(target_return, 1) # 目標期待リターン, 及び保有比率の合計値

```

```
MV_portfolio <- solve.QP(Dmat, dvec, Amat, bvec, meq = 2) # 等号制約の数をmeq引数で表す
```

5.5.3 最適化結果の構造

```
str(MV_portfolio) # solve.QP()関数の返り値の構造を確認
```

5.5.4 最適保有比率とポートフォリオ・リスク

```
optimal_weight <- MV_portfolio$solution # 最適保有比率を保存
print(optimal_weight[1:10]) # 最初の10社のみ表示

minimized_risk <- sqrt(2 * MV_portfolio$value) # 平均分散ポートフォリオのリスクを保存して表示
print(minimized_risk)
```

5.6 効率的フロンティア

5.6.1 複数の目標期待リターンによる最適化

```
target_return <- seq(-0.1, 0.4, length = 100) # -0.1から0.4の範囲を離散化して目標期待リターンを100次元のベ
N_points <- length(target_return) # target_returnの次元100をN_pointsと定義

optimal_weight <- matrix(NA, nrow = N_points, ncol = N_portfolio_firms) # 各目標期待リターンに対して最適
minimized_risk <- rep(NA, N_points) # 同様に平均分散ポートフォリオのリスクを保存する空ベクトルを準備

for (i in 1:N_points) { # 平均分散ポートフォリオの計算を100回繰り返す
  bvec <- c(target_return[i], 1)
  MV_portfolio <- solve.QP(Dmat, dvec, Amat, bvec, meq = 2)
  optimal_weight[i, ] <- MV_portfolio$solution # 結果の保存
  minimized_risk[i] <- sqrt(2 * MV_portfolio$value)
}

print(optimal_weight[N_points, 1:10]) # target_return = 0.4のときの最適保有比率（最初の10社のみ）

print(minimized_risk[N_points]) # target_return = 0.4のときの平均分散ポートフォリオのリスク
```

5.6.2 効率的フロンティアの描画

```
MV_frontier <- tibble(target_return, minimized_risk)

ggplot(MV_frontier) +
```

```
geom_line(aes(x = target_return, y = minimized_risk)) + # x軸にtarget_return, y軸にminimized_riskを指定
coord_flip() + # 縦軸と横軸をひっくり返すのにcoord_flip()関数を用いる
labs(x = "Expected Return", y = "Risk") +
theme_classic()
```

5.7 まとめ

本章では、Fama-French の 3 ファクター・モデルを用いて、企業別のファクター・ローディングと株式資本コストを推定した。

さらに、ファクターと誤差項から株式リターンの分散共分散行列を構築し、二次計画法による平均分散ポートフォリオと効率的フロンティアを確認した。

第6章 イベントスタディ

本章では、企業の決算発表を対象としてイベントスタディを行う。イベントスタディは、特定の企業イベントの前後に観察された株式リターンから、通常時に予想されるリターンを差し引き、イベント固有の株価反応を測定する方法である。

本章では次の処理を順番に行う。

1. 個別株リターン、市場リターン、イベント情報を読み込む
2. 決算サプライズを計算し、イベントを5群に分類する
3. 発表日の翌営業日をイベント日0として取引日を対応付ける
4. 推定期間を使ってイベントごとのマーケット・モデルを推定する
5. 異常リターンと累積異常リターンを計算する
6. AAR、CAAR、複数のイベント・ウィンドウについて統計的検定を行う
7. イベント単位と日次集計の結果を保存する

反復処理には明示的なループを使わず、`purrr::map()`、`pmap_dfr()`、`walk2()`を使用する。パイプ演算子は native pipe の `|>` に統一する。

6.1 イベントスタディの基礎と分析環境

6.1.1 イベントスタディの考え方

企業 i の日 t における実現リターンを $R_{i,t}$ 、市場リターンを $R_{M,t}$ とする。推定期間では、次のマーケット・モデルを推定する。

$$R_{i,t} = \alpha_i + \beta_i R_{M,t} + \varepsilon_{i,t}$$

推定された通常リターンは次式で表される。

$$\widehat{R}_{i,t} = \hat{\alpha}_i + \hat{\beta}_i R_{M,t}$$

異常リターン $AR_{i,t}$ は、実現リターンと通常リターンの差である。

$$AR_{i,t} = R_{i,t} - \widehat{R}_{i,t}$$

イベント日から日 t までの累積異常リターン $CAR_{i,t}$ は、異常リターンを累積して計算する。

$$CAR_{i,t} = \sum_{\tau=T_1}^t AR_{i,\tau}$$

6.1.2 パッケージの準備

```
suppressPackageStartupMessages({  
  library(tidyverse)  
  library(ggthemes)  
  library(QuantLib)  
  library(GaussQuant)  
  library(tidyverse)  
  library(broom)  
})
```

パッケージをまだインストールしていない場合だけ、次のコードを R コンソールで実行する。

```
install.packages(c("tidyverse", "broom"))
```

6.1.3 プロジェクトとデータディレクトリ

```
project_candidates <- unique(c(  
  Sys.getenv("QUARTO_PROJECT_DIR"),  
  getwd(),  
  dirname(getwd())  
)  
)  
  
project_candidates <- project_candidates[nzchar(project_candidates)]  
  
project_matches <- project_candidates[  
  file.exists(file.path(project_candidates, "_quarto.yml"))  
,  
,  
]  
  
if (length(project_matches) == 0) {  
  stop("LagrangeFinanceのプロジェクトルートを確認できません。")  
}  
  
project_dir <- normalizePath(  
  project_matches[1],  
  winslash = "/",  
  mustWork = TRUE  
)  
  
data_dir <- file.path(project_dir, "simulation_data")
```

```
derived_data_dir <- file.path(data_dir, "derived")

if (!dir.exists(data_dir)) {
  stop("simulation_dataディレクトリが見つかりません: ", data_dir)
}

project_dir
data_dir
derived_data_dir
```

6.2 入力データの整備と検証

6.2.1 入力ファイルの確認

本章では次の3ファイルを使用する。

```
ch08_return_data.csv
ch08_market_return_data.csv
ch08_event_data.csv
```

ファイル名は旧教材の章番号に由来するが、本書では第6章の入力データとして使用する。

```
csv_paths <- list.files(
  path = data_dir,
  pattern = "\\\\.csv$",
  full.names = TRUE,
  recursive = TRUE
)

normalized_data_dir <- normalizePath(
  data_dir,
  winslash = "/",
  mustWork = TRUE
)

normalized_csv_paths <- normalizePath(
  csv_paths,
  winslash = "/",
  mustWork = FALSE
)

csv_catalog <- tibble(
  file_name = basename(csv_paths),
  relative_path = substring(
    normalized_csv_paths,
```



```

    first = nchar(normalized_data_dir) + 2
  )
) |>
  arrange(relative_path)

csv_catalog

```

ファイル名を受け取り、simulation_data 以下で一意に存在するパスを返す関数を定義する。

```

find_data_file <- function(file_name) {
  candidates <- csv_paths[
    basename(csv_paths) == file_name
  ]

  if (length(candidates) == 0) {
    stop(
      file_name,
      "がsimulation_data以下に見つかりません。"
    )
  }

  if (length(candidates) > 1) {
    stop(
      file_name,
      "が複数見つかりました: ",
      paste(candidates, collapse = ", ")
    )
  }

  candidates[1]
}

```

```

input_file_names <- c(
  return_data =
    "ch08_return_data.csv",
  market_return_data =
    "ch08_market_return_data.csv",
  event_data =
    "ch08_event_data.csv"
)

input_paths <- input_file_names |>
  map_chr(find_data_file)

input_paths

```

6.2.2 データの読み込み

```
return_data_raw <- readr::read_csv(  
  input_paths[["return_data"]],  
  show_col_types = FALSE  
)  
  
market_return_data_raw <- readr::read_csv(  
  input_paths[["market_return_data"]],  
  show_col_types = FALSE  
)  
  
event_data_raw <- readr::read_csv(  
  input_paths[["event_data"]],  
  show_col_types = FALSE  
)  
  
return_data_raw  
market_return_data_raw  
event_data_raw
```

6.2.3 必須列の確認

```
required_return_columns <- c(  
  "date",  
  "firm_ID",  
  "R"  
)  
  
required_market_columns <- c(  
  "date",  
  "R_M"  
)  
  
required_event_columns <- c(  
  "event_date",  
  "firm_ID",  
  "earnings_forecast",  
  "realized_earnings",  
  "lagged_ME"  
)
```

```
missing_return_columns <- setdiff(
  required_return_columns,
  names(return_data_raw)
)

missing_market_columns <- setdiff(
  required_market_columns,
  names(market_return_data_raw)
)

missing_event_columns <- setdiff(
  required_event_columns,
  names(event_data_raw)
)

if (length(missing_return_columns) > 0) {
  stop(
    "個別株リターンに必要な列が不足しています: ",
    paste(missing_return_columns, collapse = ", ")
  )
}

if (length(missing_market_columns) > 0) {
  stop(
    "市場リターンに必要な列が不足しています: ",
    paste(missing_market_columns, collapse = ", ")
  )
}

if (length(missing_event_columns) > 0) {
  stop(
    "イベントデータに必要な列が不足しています: ",
    paste(missing_event_columns, collapse = ", ")
  )
}
```

6.2.4 データ型の整理

```
return_data <- return_data_raw |>
  transmute(
    date = as.Date(date),
    firm_ID = as.integer(firm_ID),
```

```

    R = as.numeric(R)
  ) |>
  arrange(
    firm_ID,
    date
  )

market_return_data <- market_return_data_raw |>
  transmute(
    date = as.Date(date),
    R_M = as.numeric(R_M)
  ) |>
  arrange(date)

event_data <- event_data_raw |>
  mutate(
    event_date = as.Date(event_date),
    firm_ID = as.integer(firm_ID),
    earnings_forecast =
      as.numeric(earnings_forecast),
    realized_earnings =
      as.numeric(realized_earnings),
    lagged_ME = as.numeric(lagged_ME)
  ) |>
  arrange(
    event_date,
    firm_ID
  )

glimpse(return_data)
glimpse(market_return_data)
glimpse(event_data)

```

日付を変換できなかった行がないことを確認する。

```

invalid_return_dates <- return_data |>
  filter(is.na(date))

invalid_market_dates <- market_return_data |>
  filter(is.na(date))

invalid_event_dates <- event_data |>
  filter(is.na(event_date))

```

```
invalid_return_dates
invalid_market_dates
invalid_event_dates

if (
  nrow(invalid_return_dates) > 0 |
  nrow(invalid_market_dates) > 0 |
  nrow(invalid_event_dates) > 0
) {
  stop("日付へ変換できない行があります。")
}
```

6.2.5 データの概要

```
input_data_overview <- tribble(
  ~data, ~observations, ~firms, ~first_date, ~last_date,
  "individual returns",
  nrow(return_data),
  n_distinct(return_data$firm_ID),
  min(return_data$date),
  max(return_data$date),
  "market returns",
  nrow(market_return_data),
  NA_integer_,
  min(market_return_data$date),
  max(market_return_data$date),
  "events",
  nrow(event_data),
  n_distinct(event_data$firm_ID),
  min(event_data$event_date),
  max(event_data$event_date)
)

input_data_overview
```

6.2.6 キーの重複確認

```
return_key_duplicates <- return_data |>
  count(
    firm_ID,
    date,
    name = "observations"
```

```
) |>
  filter(observations > 1)

market_key_duplicates <- market_return_data |>
  count(
    date,
    name = "observations"
  ) |>
  filter(observations > 1)

event_key_duplicates <- event_data |>
  count(
    firm_ID,
    event_date,
    name = "events"
  ) |>
  filter(events > 1)

return_key_duplicates
market_key_duplicates
event_key_duplicates

if (nrow(return_key_duplicates) > 0) {
  stop("個別株リターンのfirm_IDとdateの組合せに重複があります。")
}

if (nrow(market_key_duplicates) > 0) {
  stop("市場リターンのdateに重複があります。")
}

if (nrow(event_key_duplicates) > 0) {
  stop("同じ企業・同じ日に複数のイベントがあります。")
}
```

6.2.7 欠損値の確認

```
missing_summary <- list(
  individual_returns = return_data,
  market_returns = market_return_data,
  events = event_data
) |>
  imap_dfr(
    \(data, data_name) {
```

```

data |>
  summarise(
    across(
      everything(),
      list(
        missing =
          \(\x) sum(is.na(x)),
        missing_rate =
          \(\x) mean(is.na(x))
      ),
      .names = "{.col}__{.fn}"
    )
  ) |>
  pivot_longer(
    cols = everything(),
    names_to = c(
      "variable",
      ".value"
    ),
    names_sep = "__"
  ) |>
  mutate(
    data = data_name,
    .before = 1
  )
}
) |>
  arrange(
    data,
    desc(missing_rate),
    variable
  )

missing_summary

```

6.3 決算サプライズとイベント日の設定

6.3.1 決算サプライズ

旧章では予想利益から実現利益を引いていたが、本章では解釈を明確にするため、実現利益から予想利益を引く。

$$Surprise_i = \frac{RealizedEarnings_i - ForecastEarnings_i}{ME_{i,-1}}$$

正の値は実現利益が予想を上回ったことを、負の値は予想を下回ったことを表す。

```
event_data <- event_data |>
  mutate(
    event_ID = row_number(),
    event_year =
      lubridate::year(event_date),
    earnings_surprise = case_when(
      !is.finite(lagged_ME) ~ NA_real_,
      lagged_ME <= 0 ~ NA_real_,
      !is.finite(earnings_forecast) ~ NA_real_,
      !is.finite(realized_earnings) ~ NA_real_,
      TRUE ~ (
        realized_earnings -
        earnings_forecast
      ) / lagged_ME
    ),
    earnings_surprise = if_else(
      is.finite(earnings_surprise),
      earnings_surprise,
      NA_real_
    )
  )
```

年度ごとに決算サプライズを5群へ分類する。グループ1が最も弱い決算、グループ5が最も強い決算を表す。

```
event_data <- event_data |>
  group_by(event_year) |>
  mutate(
    event_strength = if_else(
      is.finite(earnings_surprise),
      ntile(earnings_surprise, 5L),
      NA_integer_
    )
  ) |>
  ungroup() |>
  mutate(
    event_strength = factor(
      event_strength,
      levels = 1:5,
      ordered = TRUE
    )
  )

event_data
```



```
event_strength_summary <- event_data |>
  group_by(
    event_year,
    event_strength
  ) |>
  summarise(
    events = n(),
    mean_surprise = mean(
      earnings_surprise,
      na.rm = TRUE
    ),
    median_surprise = median(
      earnings_surprise,
      na.rm = TRUE
    ),
    .groups = "drop"
  ) |>
  arrange(
    event_year,
    event_strength
  )

event_strength_summary
```

決算サプライズを計算できないイベントがある場合は分析対象から除外する。

```
invalid_surprise_events <- event_data |>
  filter(
    !is.finite(earnings_surprise) |
    is.na(event_strength)
  )

invalid_surprise_events
```

6.3.2 取引日カレンダー

市場リターンの日付を取引日カレンダーとして使用する。

```
trading_calendar <- market_return_data |>
  distinct(date) |>
  arrange(date) |>
  mutate(
    date_ID = row_number()
  ) |>
```

```
select(
  date_ID,
  date
)

trading_calendar
```

市場リターンへ日付 ID を追加し、個別株リターンと結合する。

```
market_return_with_ID <- market_return_data |>
  inner_join(
    trading_calendar,
    by = "date"
  ) |>
  select(
    date_ID,
    date,
    R_M
  )

return_market_data <- return_data |>
  inner_join(
    market_return_with_ID,
    by = "date"
  ) |>
  select(
    firm_ID,
    date_ID,
    R,
    R_M
  ) |>
  arrange(
    firm_ID,
    date_ID
  )

return_market_data
```

個別株と市場リターンを結合できなかった日付を確認する。

```
return_dates_without_market <- return_data |>
  distinct(date) |>
  anti_join(
    market_return_data |>
      distinct(date),
```

```

    by = "date"
  )

market_dates_without_returns <- market_return_data |>
  distinct(date) |>
  anti_join(
    return_data |>
      distinct(date),
    by = "date"
  )

return_dates_without_market
market_dates_without_returns

```

6.3.3 イベント日 0 の設定

決算発表は取引終了後に行われると仮定する。そのため、発表日が取引日であっても、次の取引日をイベント日 0 とする。発表日が休日の場合は、最初の翌取引日がイベント日 0 となる。

`findInterval()` を用い、明示的なループを使わずに翌取引日を求める。

```

trading_dates <- trading_calendar$date

event_data <- event_data |>
  mutate(
    event_trade_date_ID =
      findInterval(
        as.numeric(event_date),
        as.numeric(trading_dates)
      ) + 1L,
    event_trade_date_ID = if_else(
      event_trade_date_ID <=
        nrow(trading_calendar),
      event_trade_date_ID,
      NA_integer_
    ),
    event_trade_date =
      trading_dates[
        event_trade_date_ID
      ]
  )

event_data |>
  select(

```

```

    event_ID,
    firm_ID,
    event_date,
    event_trade_date,
    event_trade_date_ID,
    event_strength,
    earnings_surprise
  )

```

取引日を割り当てられないイベントを確認する。

```

events_without_trading_day <- event_data |>
  filter(
    is.na(event_trade_date_ID) |
    is.na(event_trade_date)
  )

events_without_trading_day

if (nrow(events_without_trading_day) > 0) {
  stop("翌取引日を割り当てられないイベントがあります。")
}

```

イベント対象企業が個別株リターンに含まれていることを確認する。

```

event_firms_without_returns <- event_data |>
  distinct(firm_ID) |>
  anti_join(
    return_data |>
      distinct(firm_ID),
    by = "firm_ID"
  )

event_firms_without_returns

if (nrow(event_firms_without_returns) > 0) {
  stop("個別株リターンが存在しないイベント企業があります。")
}

```

6.4 推定期間とマーケット・モデル

6.4.1 推定期間とイベント期間

本章では、イベント日 0 を基準として次の期間を使用する。

期間	相対取引日	用途
推定期間	-130 日から-31 日	マーケット・モデルの推定
事前イベント期間	-30 日から-1 日	発表前の株価反応
イベント日	0 日	発表後最初の取引日
事後イベント期間	1 日から 30 日	発表後の株価反応

推定期間は 100 取引日、イベント期間は 61 取引日である。

```
estimation_start <- -130L
estimation_end <- -31L
event_start <- -30L
event_end <- 30L

minimum_estimation_observations <- 80L

window_parameters <- tribble(
  ~parameter, ~value,
  "estimation_start", estimation_start,
  "estimation_end", estimation_end,
  "event_start", event_start,
  "event_end", event_end,
  "minimum_estimation_observations",
  minimum_estimation_observations
)

window_parameters
```

```
estimation_window_length <-
  estimation_end -
  estimation_start + 1L

event_window_length <-
  event_end -
  event_start + 1L

tibble(
  estimation_window_length =
    estimation_window_length,
  event_window_length =
    event_window_length
)
```

6.4.2 イベント・パネルの作成

各イベントについて、推定期間の開始からイベント期間の終了までの相対取引日を作成する。

```
relative_day_sequence <- seq(
  estimation_start,
  event_end
)

full_sample_data <- event_data |>
  filter(
    is.finite(earnings_surprise),
    !is.na(event_strength)
  ) |>
  select(
    event_ID,
    firm_ID,
    event_date,
    event_trade_date,
    event_trade_date_ID,
    event_year,
    event_strength,
    earnings_surprise
  ) |>
  tidyr::crossing(
    relative_day =
      relative_day_sequence
  ) |>
  mutate(
    date_ID =
      event_trade_date_ID +
      relative_day
  ) |>
  left_join(
    trading_calendar,
    by = "date_ID"
  ) |>
  left_join(
    return_market_data,
    by = c(
      "firm_ID",
      "date_ID"
    )
  )
```

```

) |>
  arrange(
    event_ID,
    relative_day
  )

full_sample_data

```

パネルの行数が理論値と一致することを確認する。

```

expected_event_count <- event_data |>
  filter(
    is.finite(earnings_surprise),
    !is.na(event_strength)
  ) |>
  nrow()

expected_rows <-
  expected_event_count *
  length(relative_day_sequence)

stopifnot(
  nrow(full_sample_data) ==
    expected_rows
)

tibble(
  events = n_distinct(
    full_sample_data$event_ID
  ),
  relative_days =
    length(relative_day_sequence),
  expected_rows = expected_rows,
  actual_rows = nrow(full_sample_data)
)

```

6.4.3 データ利用可能性の診断

イベントごとに、推定期間とイベント期間で利用できる観測数を確認する。

```

event_data_coverage <- full_sample_data |>
  group_by(
    event_ID,
    firm_ID,
    event_strength
  )

```

```
) |>
summarise(
  estimation_days =
    sum(
      between(
        relative_day,
        estimation_start,
        estimation_end
      )
    ),
  valid_estimation_days =
    sum(
      between(
        relative_day,
        estimation_start,
        estimation_end
      ) &
      is.finite(R) &
      is.finite(R_M)
    ),
  event_days =
    sum(
      between(
        relative_day,
        event_start,
        event_end
      )
    ),
  valid_event_days =
    sum(
      between(
        relative_day,
        event_start,
        event_end
      ) &
      is.finite(R) &
      is.finite(R_M)
    ),
  .groups = "drop"
) |>
arrange(event_ID)

event_data_coverage
```



```

event_coverage_summary <- event_data_coverage |>
  summarise(
    events = n(),
    complete_estimation_window =
      sum(
        valid_estimation_days ==
          estimation_window_length
      ),
    usable_estimation_window =
      sum(
        valid_estimation_days >=
          minimum_estimation_observations
      ),
    complete_event_window =
      sum(
        valid_event_days ==
          event_window_length
      ),
    usable_both_windows =
      sum(
        valid_estimation_days >=
          minimum_estimation_observations &
        valid_event_days ==
          event_window_length
      )
  )

event_coverage_summary

```

6.4.4 マーケット・モデルの推定

推定期間のデータだけを抽出する。

```

estimation_window_data <- full_sample_data |>
  filter(
    between(
      relative_day,
      estimation_start,
      estimation_end
    ),
    is.finite(R),
    is.finite(R_M)
  ) |>
  arrange(

```

```

    event_ID,
    relative_day
  )

estimation_window_data

```

推定可能なイベントを選ぶ。最低観測数を満たし、市場リターンが一定でないことを条件とする。

```

estimable_events <- estimation_window_data |>
  group_by(event_ID) |>
  summarise(
    estimation_observations = n(),
    distinct_market_returns =
      n_distinct(R_M),
    .groups = "drop"
  ) |>
  filter(
    estimation_observations >=
      minimum_estimation_observations,
    distinct_market_returns > 1
  )

estimable_events

```

`nest()` と `map()` を用い、イベントごとにマーケット・モデルを推定する。

```

market_models <- estimation_window_data |>
  semi_join(
    estimable_events,
    by = "event_ID"
  ) |>
  group_by(event_ID) |>
  nest() |>
  mutate(
    model = map(
      data,
      \(data) lm(
        R ~ R_M,
        data = data
      )
    ),
    coefficients = map(
      model,
      broom::tidy
    ),
  )

```

```

    fit = map(
      model,
      broom::glance
    )
  )
)

market_models

```

回帰係数を横持ちに変換する。

```

market_model_coefficients <- market_models |>
  select(
    event_ID,
    coefficients
  ) |>
  unnest(coefficients) |>
  select(
    event_ID,
    term,
    estimate
  ) |>
  pivot_wider(
    names_from = term,
    values_from = estimate
  ) |>
  rename(
    alpha = `(Intercept)`,
    beta = R_M
  )

market_model_coefficients

```

残差標準偏差、決定係数、観測数を取り出す。

```

market_model_fit <- market_models |>
  select(
    event_ID,
    fit
  ) |>
  unnest(fit) |>
  transmute(
    event_ID,
    sigma_AR = sigma,
    r_squared = r.squared,
    adjusted_r_squared =

```

```

      adj.r.squared,
      estimation_observations =
        nobs
    )

market_model_fit

```

イベント情報、回帰係数、適合度を統合する。

```

market_model_parameters <- event_data |>
  select(
    event_ID,
    firm_ID,
    event_date,
    event_trade_date,
    event_year,
    event_strength,
    earnings_surprise
  ) |>
  inner_join(
    market_model_coefficients,
    by = "event_ID"
  ) |>
  inner_join(
    market_model_fit,
    by = "event_ID"
  ) |>
  arrange(event_ID)

market_model_parameters

```

```

market_model_summary <- market_model_parameters |>
  summarise(
    estimated_events = n(),
    mean_alpha = mean(alpha),
    mean_beta = mean(beta),
    median_beta = median(beta),
    minimum_beta = min(beta),
    maximum_beta = max(beta),
    mean_r_squared = mean(r_squared),
    mean_sigma_AR = mean(sigma_AR),
    minimum_observations =
      min(estimation_observations),
    maximum_observations =
      max(estimation_observations)
  )

```

```

)

market_model_summary

market_model_parameters |>
  ggplot(aes(x = beta)) +
  geom_histogram(bins = 40) +
  geom_vline(
    xintercept = 1,
    linetype = "dotted"
  ) +
  labs(
    x = "Market Beta",
    y = "Count",
    title = "Distribution of Event-Specific Market Betas"
  ) +
  theme_classic()

```

6.4.5 完全なイベント期間を持つイベント

マーケット・モデルを推定でき、かつ 61 取引日のイベント期間で個別株と市場リターンがすべて観測できるイベントだけを採用する。

```

eligible_events <- event_data_coverage |>
  filter(
    valid_estimation_days >=
      minimum_estimation_observations,
    valid_event_days ==
      event_window_length
  ) |>
  semi_join(
    market_model_parameters,
    by = "event_ID"
  ) |>
  select(
    event_ID,
    firm_ID,
    event_strength,
    valid_estimation_days,
    valid_event_days
  )

eligible_events

```

```

eligible_event_summary <- eligible_events |>
  count(
    event_strength,
    name = "events"
  ) |>
  complete(
    event_strength,
    fill = list(events = 0)
  ) |>
  arrange(event_strength)

eligible_event_summary

```

各イベント強度に少なくとも2件のイベントが必要である。

```

insufficient_event_groups <- eligible_event_summary |>
  filter(events < 2)

insufficient_event_groups

if (nrow(insufficient_event_groups) > 0) {
  stop(
    "統計的検定に必要なイベント数を満たさないイベント強度があります。"
  )
}

```

6.5 異常リターンと日次集計

6.5.1 異常リターンと CAR

イベント期間のデータにマーケット・モデルの推定値を結合する。

```

event_window_data <- full_sample_data |>
  filter(
    between(
      relative_day,
      event_start,
      event_end
    )
  ) |>
  semi_join(
    eligible_events,
    by = "event_ID"
  ) |>
  inner_join(

```

```
market_model_parameters |>
  select(
    event_ID,
    alpha,
    beta,
    sigma_AR,
    r_squared,
    estimation_observations
  ),
  by = "event_ID"
) |>
mutate(
  normal_return =
    alpha + beta * R_M,
  AR = R - normal_return
) |>
group_by(event_ID) |>
arrange(
  relative_day,
  .by_group = TRUE
) |>
mutate(
  CAR = cumsum(AR)
) |>
ungroup() |>
arrange(
  event_ID,
  relative_day
)

event_window_data
```

計算後に欠損値や非有限値がないことを確認する。

```
invalid_event_window_rows <- event_window_data |>
  filter(
    !is.finite(R) |
    !is.finite(R_M) |
    !is.finite(normal_return) |
    !is.finite(AR) |
    !is.finite(CAR)
  )

invalid_event_window_rows
```

```
if (nrow(invalid_event_window_rows) > 0) {
  stop("イベント期間のARまたはCARに欠損値があります。")
}
```

```
event_window_data |>
  select(
    event_ID,
    firm_ID,
    event_strength,
    relative_day,
    date,
    R,
    R_M,
    normal_return,
    AR,
    CAR
  ) |>
  slice_head(n = 20)
```

6.5.2 AAR と CAAR

イベント強度別に、平均異常リターン（AAR）と平均累積異常リターン（CAAR）を計算する。

$$AAR_{g,t} = \frac{1}{N_g} \sum_{i \in g} AR_{i,t}$$

$$CAAR_{g,t} = \frac{1}{N_g} \sum_{i \in g} CAR_{i,t}$$

```
significance_stars <- function(p_value) {
  case_when(
    is.na(p_value) ~ "",
    p_value < 0.01 ~ "****",
    p_value < 0.05 ~ "**",
    p_value < 0.10 ~ "*",
    TRUE ~ ""
  )
}
```

```
daily_event_statistics <- event_window_data |>
  group_by(
    relative_day,
    event_strength
  ) |>
```



```
summarise(
  events = n_distinct(event_ID),
  AAR = mean(AR),
  CAAR = mean(CAR),
  standard_deviation_AR = sd(AR),
  standard_deviation_CAR = sd(CAR),
  .groups = "drop"
) |>
mutate(
  standard_error_AAR =
    standard_deviation_AR /
    sqrt(events),
  standard_error_CAAR =
    standard_deviation_CAR /
    sqrt(events),
  t_AAR = if_else(
    is.finite(standard_error_AAR) &
      standard_error_AAR > 0,
    AAR / standard_error_AAR,
    NA_real_
  ),
  t_CAAR = if_else(
    is.finite(standard_error_CAAR) &
      standard_error_CAAR > 0,
    CAAR / standard_error_CAAR,
    NA_real_
  ),
  p_AAR = if_else(
    is.finite(t_AAR),
    2 * pt(
      -abs(t_AAR),
      df = events - 1
    ),
    NA_real_
  ),
  p_CAAR = if_else(
    is.finite(t_CAAR),
    2 * pt(
      -abs(t_CAAR),
      df = events - 1
    ),
    NA_real_
  ),
```

```

    significance_AAR =
      significance_stars(p_AAR),
    significance_CAAR =
      significance_stars(p_CAAR)
  ) |>
  arrange(
    event_strength,
    relative_day
  )

daily_event_statistics

```

イベント強度を区別しない全イベントの AAR と CAAR も計算する。

```

overall_daily_statistics <- event_window_data |>
  group_by(relative_day) |>
  summarise(
    events = n_distinct(event_ID),
    AAR = mean(AR),
    CAAR = mean(CAR),
    standard_deviation_AR = sd(AR),
    standard_deviation_CAR = sd(CAR),
    .groups = "drop"
  ) |>
  mutate(
    standard_error_AAR =
      standard_deviation_AR /
      sqrt(events),
    standard_error_CAAR =
      standard_deviation_CAR /
      sqrt(events),
    t_AAR = if_else(
      is.finite(standard_error_AAR) &
        standard_error_AAR > 0,
      AAR / standard_error_AAR,
      NA_real_
    ),
    t_CAAR = if_else(
      is.finite(standard_error_CAAR) &
        standard_error_CAAR > 0,
      CAAR / standard_error_CAAR,
      NA_real_
    ),
    p_AAR = if_else(

```

```

    is.finite(t_AAR),
    2 * pt(
      -abs(t_AAR),
      df = events - 1
    ),
    NA_real_
  ),
  p_CAAR = if_else(
    is.finite(t_CAAR),
    2 * pt(
      -abs(t_CAAR),
      df = events - 1
    ),
    NA_real_
  ),
  significance_AAR =
    significance_stars(p_AAR),
  significance_CAAR =
    significance_stars(p_CAAR)
) |>
  arrange(relative_day)

overall_daily_statistics

```

イベント強度別 CAAR

```

daily_event_statistics |>
  ggplot(
    aes(
      x = relative_day,
      y = CAAR,
      linetype = event_strength
    )
  ) +
  annotate(
    "rect",
    xmin = -1,
    xmax = 1,
    ymin = -Inf,
    ymax = Inf,
    alpha = 0.08
  ) +
  geom_line(linewidth = 0.8) +

```

```
geom_hline(  
  yintercept = 0,  
  linetype = "dotted"  
) +  
scale_y_continuous(  
  labels = scales::label_percent()  
) +  
labs(  
  x = "Relative Trading Day",  
  y = "CAAR",  
  linetype = "Event Strength",  
  title = "CAAR by Earnings-Surprise Group"  
) +  
theme_classic()
```

イベント日前後の AAR

```
daily_event_statistics |>  
  filter(  
    between(  
      relative_day,  
      -10,  
      10  
    )  
  ) |>  
ggplot(  
  aes(  
    x = relative_day,  
    y = AAR,  
    linetype = event_strength  
  )  
) +  
geom_line(linewidth = 0.8) +  
geom_point() +  
geom_vline(  
  xintercept = 0,  
  linetype = "dotted"  
) +  
geom_hline(  
  yintercept = 0,  
  linetype = "dotted"  
) +  
scale_x_continuous(  
  labels = scales::label_day2()  
)
```

```
breaks = seq(-10, 10, 2)
) +
scale_y_continuous(
  labels = scales::label_percent()
) +
labs(
  x = "Relative Trading Day",
  y = "AAR",
  linetype = "Event Strength",
  title = "Average Abnormal Returns around the Event"
) +
theme_classic()
```

最も強いイベント群について、イベント日前後5日の検定結果を表示する。

```
strongest_event_daily_table <- daily_event_statistics |>
  filter(
    event_strength == 5,
    between(
      relative_day,
      -5,
      5
    )
  ) |>
  select(
    relative_day,
    events,
    AAR,
    t_AAR,
    p_AAR,
    significance_AAR,
    CAAR,
    t_CAAR,
    p_CAAR,
    significance_CAAR
  )

strongest_event_daily_table
```

6.6 イベント・ウィンドウ分析と結果保存

6.6.1 複数のイベント・ウィンドウ

日次の CAR だけでなく、実務でよく利用される複数のイベント・ウィンドウについて、イベント単位の累積異常リターンを計算する。

```
summary_windows <- tribble(
  ~window_ID, ~window_label, ~start_day, ~end_day,
  "m1_p1", "[ -1, +1]", -1L, 1L,
  "0_p1", "[ 0, +1]", 0L, 1L,
  "m5_p5", "[ -5, +5]", -5L, 5L,
  "m30_p30", "[ -30, +30]", -30L, 30L
)

summary_windows
```

`pmap_dfr()` を使って、各ウィンドウに同じ集計処理を適用する。

```
event_level_window_returns <- pmap_dfr(
  summary_windows,
  \(window_ID,
    window_label,
    start_day,
    end_day) {
    event_window_data |>
      filter(
        between(
          relative_day,
          start_day,
          end_day
        )
      ) |>
      group_by(
        event_ID,
        firm_ID,
        event_date,
        event_trade_date,
        event_year,
        event_strength,
        earnings_surprise
      ) |>
      summarise(
        CAR_window = sum(AR),
```

```

      observed_days = n(),
      .groups = "drop"
    ) |>
    mutate(
      window_ID = .env$window_ID,
      window_label = .env$window_label,
      start_day = .env$start_day,
      end_day = .env$end_day,
      expected_days =
        .env$end_day -
        .env$start_day + 1L,
      .before = CAR_window
    )
  }
) |>
  arrange(
    window_ID,
    event_ID
  )

event_level_window_returns

```

各ウィンドウに必要な日数がそろっていることを確認する。

```

invalid_window_observations <-
  event_level_window_returns |>
  filter(
    observed_days != expected_days
  )

invalid_window_observations

if (nrow(invalid_window_observations) > 0) {
  stop("イベント・ウィンドウの日数が不足するイベントがあります。")
}

```

イベント強度別の平均 CAR と t 検定を計算する。

```

event_window_summary <- event_level_window_returns |>
  group_by(
    window_ID,
    window_label,
    start_day,
    end_day,
    event_strength
  )

```

```

) |>
summarise(
  events = n_distinct(event_ID),
  mean_CAR = mean(CAR_window),
  median_CAR = median(CAR_window),
  standard_deviation_CAR =
    sd(CAR_window),
  positive_CAR_ratio =
    mean(CAR_window > 0),
  .groups = "drop"
) |>
mutate(
  standard_error_CAR =
    standard_deviation_CAR /
    sqrt(events),
  t_value = if_else(
    is.finite(standard_error_CAR) &
      standard_error_CAR > 0,
    mean_CAR /
      standard_error_CAR,
    NA_real_
  ),
  p_value = if_else(
    is.finite(t_value),
    2 * pt(
      -abs(t_value),
      df = events - 1
    ),
    NA_real_
  ),
  significance =
    significance_stars(p_value)
) |>
arrange(
  window_ID,
  event_strength
)

event_window_summary

```

全イベントを対象としたウィンドウ別結果も計算する。

```

overall_window_summary <- event_level_window_returns |>
  group_by(

```



```
    window_ID,  
    window_label,  
    start_day,  
    end_day  
  ) |>  
  summarise(  
    events = n_distinct(event_ID),  
    mean_CAR = mean(CAR_window),  
    median_CAR = median(CAR_window),  
    standard_deviation_CAR =  
      sd(CAR_window),  
    positive_CAR_ratio =  
      mean(CAR_window > 0),  
    .groups = "drop"  
  ) |>  
  mutate(  
    standard_error_CAR =  
      standard_deviation_CAR /  
      sqrt(events),  
    t_value = if_else(  
      is.finite(standard_error_CAR) &  
        standard_error_CAR > 0,  
      mean_CAR /  
        standard_error_CAR,  
      NA_real_  
    ),  
    p_value = if_else(  
      is.finite(t_value),  
      2 * pt(  
        -abs(t_value),  
        df = events - 1  
      ),  
      NA_real_  
    ),  
    significance =  
      significance_stars(p_value)  
  ) |>  
  arrange(window_ID)  
  
overall_window_summary
```

短期 CAR の分布

```
event_level_window_returns |>
  filter(window_ID == "m1_p1") |>
  ggplot(
    aes(
      x = event_strength,
      y = CAR_window
    )
  ) +
  geom_boxplot(
    outlier.alpha = 0.25
  ) +
  geom_hline(
    yintercept = 0,
    linetype = "dotted"
  ) +
  scale_y_continuous(
    labels = scales::label_percent()
  ) +
  labs(
    x = "Event Strength",
    y = "CAR [-1, +1]",
    title = "Short-Window CAR by Earnings Surprise"
  ) +
  theme_classic()
```

ウィンドウ別平均 CAR

```
event_window_summary |>
  ggplot(
    aes(
      x = event_strength,
      y = mean_CAR,
      fill = window_label
    )
  ) +
  geom_col(
    position = "dodge"
  ) +
  geom_hline(
    yintercept = 0,
    linetype = "dotted"
  )
```

```

) +
scale_y_continuous(
  labels = scales::label_percent()
) +
labs(
  x = "Event Strength",
  y = "Mean CAR",
  fill = "Window",
  title = "Mean CAR across Event Windows"
) +
theme_classic()

```

6.6.2 決算サプライズと短期 CAR

イベント強度は決算サプライズの順位情報だけを使用する。ここでは連続変数としての決算サプライズと、短期 CAR [-1,+1] の関係を回帰分析で確認する。

```

surprise_regression_data <-
  event_level_window_returns |>
  filter(
    window_ID == "m1_p1",
    is.finite(earnings_surprise),
    is.finite(CAR_window)
  )

surprise_regression_data

```

```

surprise_regression <- lm(
  CAR_window ~ earnings_surprise,
  data = surprise_regression_data
)

broom::tidy(surprise_regression)
broom::glance(surprise_regression)

```

```

surprise_regression_data |>
  ggplot(
    aes(
      x = earnings_surprise,
      y = CAR_window
    )
  ) +
  geom_point(alpha = 0.35) +
  geom_smooth(
    method = "lm",

```

```

    se = FALSE
  ) +
  geom_hline(
    yintercept = 0,
    linetype = "dotted"
  ) +
  scale_y_continuous(
    labels = scales::label_percent()
  ) +
  labs(
    x = "Standardized Earnings Surprise",
    y = "CAR [-1, +1]",
    title = "Earnings Surprise and Short-Window CAR"
  ) +
  theme_classic()

```

6.6.3 結果の保存

イベント単位の結果を作成する。各イベント・ウィンドウの CAR を横持ちに変換し、マーケット・モデルの推定値と結合する。

```

event_window_wide <- event_level_window_returns |>
  select(
    event_ID,
    window_ID,
    CAR_window
  ) |>
  pivot_wider(
    names_from = window_ID,
    values_from = CAR_window,
    names_prefix = "CAR_"
  )

event_level_output <- market_model_parameters |>
  semi_join(
    eligible_events,
    by = "event_ID"
  ) |>
  left_join(
    event_window_wide,
    by = "event_ID"
  ) |>
  arrange(event_ID)

```

```
event_level_output
```

日次のイベント結果と日次集計結果も保存対象とする。

```
event_daily_output <- event_window_data |>
  select(
    event_ID,
    firm_ID,
    event_date,
    event_trade_date,
    event_year,
    event_strength,
    earnings_surprise,
    relative_day,
    date,
    R,
    R_M,
    normal_return,
    AR,
    CAR,
    alpha,
    beta,
    sigma_AR,
    r_squared,
    estimation_observations
  )

event_summary_output <- daily_event_statistics |>
  arrange(
    event_strength,
    relative_day
  )
```

3つのCSV ファイルを `simulation_data/derived` に保存する。

```
if (!dir.exists(derived_data_dir)) {
  dir.create(
    derived_data_dir,
    recursive = TRUE
  )
}

output_data <- list(
  event_results =
    event_level_output,
```

```

    event_daily =
      event_daily_output,
    event_summary =
      event_summary_output
  )

  output_paths <- c(
    event_results = file.path(
      derived_data_dir,
      "ch08_event_results.csv"
    ),
    event_daily = file.path(
      derived_data_dir,
      "ch08_event_daily.csv"
    ),
    event_summary = file.path(
      derived_data_dir,
      "ch08_event_summary.csv"
    )
  )

```

```
output_paths
```

```

walk2(
  output_data,
  output_paths,
  \(data, path) {
    readr::write_csv(
      data,
      path
    )
  }
)

```

```
output_paths
```

保存したファイルを読み直し、行数と列名を検証する。

```

output_verification <- imap_dfr(
  output_data,
  \(expected_data, data_name) {
    output_path <-
      output_paths[[data_name]]

    output_check <- readr::read_csv(

```

```
    output_path,
    show_col_types = FALSE
  )

  stopifnot(
    nrow(output_check) ==
      nrow(expected_data)
  )

  stopifnot(
    identical(
      names(output_check),
      names(expected_data)
    )
  )

  tibble(
    data = data_name,
    output_file = output_path,
    rows = nrow(output_check),
    columns = ncol(output_check),
    size_bytes =
      file.info(output_path)$size
  )
}
)

output_verification
```

6.7 まとめ

本章では、決算発表の翌取引日をイベント日 0 として、マーケット・モデルによるイベントスタディを実施した。推定期間にはイベント日の 130 取引日前から 31 取引日前までの 100 日を使用し、イベント期間には 30 取引日前から 30 取引日後までの 61 日を使用した。

イベントごとの回帰推定には `nest()` と `purrr::map()`、複数のイベント・ウィンドウには `pmap_dfr()`、複数ファイルの保存には `walk2()` を使用した。明示的なループは使用していない。

結果は次の 3 ファイルに保存される。

```
simulation_data/derived/ch08_event_results.csv
simulation_data/derived/ch08_event_daily.csv
simulation_data/derived/ch08_event_summary.csv
```

第Ⅱ部 金融工学と金融数学

第 II-1 章確定キャッシュフロー債券評価

金融では、異なる時点に発生する金額をそのまま比較することはできない。今日受け取る 100 円と 1 年後に受け取る 100 円では、運用可能期間や金利が異なるため、経済的な価値も異なるからである。そこで、時点の異なるキャッシュフローを評価する場合には、将来の金額を現在価値へ割引くか、現在の金額を将来価値へ換算し、同一時点の価値にそろえる必要がある。金融商品の価格評価では、通常、将来のすべてのキャッシュフローを評価時点の現在価値へ換算する。

```
knitr::opts_chunk$set(
  collapse = TRUE,
  comment = "#>",
  warning = FALSE,
  message = FALSE
)

suppressPackageStartupMessages({
  library(tidyverse)
  library(ggthemes)
  library(QuantLib)
  library(GaussQuant)
  library(tidyverse)
  library(broom)
})
```

1.1 金利期間構造の確認

債券価格は、将来の各キャッシュフローを支払時点に対応する割引係数で現在価値へ換算し、その合計として求める。個別債券の評価に入る前に、金利期間構造をスポットレート、割引係数およびフォワードレートの三つの側面から確認する。

市場で直接観測される金利は、必ずしも各満期に対応するスポットレートではない。市場では、預金金利、OIS レート、スワップレート、国債の価格や複利利回りなどが観測される。これらの市場情報と、日数計算規則、利払頻度および受渡日などのマーケットコンベンションを用いて、各満期のゼロクーポン・スポットレートとディスカウントファクター（以下、DF）を順次求める。この手続きをブートストラップという。

スポットレートは、評価時点から特定の満期までのゼロクーポン金利を表す。DF は、将来の 1 単位の金額を評価時点の価値へ換算する倍率であり、債券、スワップおよびデリバティブのキャッシュフロー評価に直接用

いられる。さらに、異なる満期の DF を比較することで、将来の一定期間に適用されるフォワードレートを求めることができる。このように、市場で観測される複数の金利商品からスポットレート、DF およびフォワードレートからなる金利期間構造を構築することは、金融工学における価格評価の基礎となる。

以下では、EONIA の市場データから構築した金利曲線を用いて、スポットカーブ、DF カーブおよびフォワードカーブの関係を確認する。さらに、本章では、固定利付債を例として、クリーン価格、ダーティ価格、経過利子、最終利回り、デュレーションおよびコンベクシティを計算する。あわせて、日数計算規則、休日カレンダー、営業日調整、受渡日および利払スケジュールといったマーケットコンベンションを確認する。


```
eonia_benchmark <- GaussQuant::eonia_curve_benchmark_GQL()

eonia_curve_tbl <- eonia_benchmark$final_validation$quote_repricing |>
  dplyr::select(
    pillar_date,
    discount_factor,
    zero_rate,
    one_day_forward_rate
  ) |>
  dplyr::filter(!is.na(.data$pillar_date)) |>
  dplyr::distinct(.data$pillar_date, .keep_all = TRUE) |>
  dplyr::arrange(.data$pillar_date)


spot_curve_plot <- eonia_curve_tbl |>
  dplyr::filter(!is.na(.data$zero_rate)) |>
  ggplot2::ggplot(
    ggplot2::aes(
      x = .data$pillar_date,
      y = 100 * .data$zero_rate
    )
  ) +
  ggplot2::geom_line(linewidth = 0.7) +
  ggplot2::geom_point(size = 1.5) +
  ggplot2::scale_x_date(
    date_breaks = "5 years",
    date_labels = "%Y"
  ) +
  ggplot2::labs(
    title = "EONIAスポットカーブ",
    x = "満期",
    y = "スポットレート (%)"
  ) +
  ggplot2::theme_minimal()

discount_curve_plot <- eonia_curve_tbl |>
  dplyr::filter(!is.na(.data$discount_factor)) |>
```


```
ggplot2::ggplot(  
  ggplot2::aes(  
    x = .data$pillar_date,  
    y = .data$discount_factor  
  )  
) +  
ggplot2::geom_line(linewidth = 0.7) +  
ggplot2::geom_point(size = 1.5) +  
ggplot2::scale_x_date(  
  date_breaks = "5 years",  
  date_labels = "%Y"  
) +  
ggplot2::labs(  
  title = "EONIA割引係数カーブ",  
  x = "満期",  
  y = "割引係数"  
) +  
ggplot2::theme_minimal()  
  
forward_curve_plot <- eonia_curve_tbl |>  
  dplyr::filter(!is.na(.data$one_day_forward_rate)) |>  
  ggplot2::ggplot(  
    ggplot2::aes(  
      x = .data$pillar_date,  
      y = 100 * .data$one_day_forward_rate  
    )  
  ) +  
  ggplot2::geom_line(linewidth = 0.7) +  
  ggplot2::geom_point(size = 1.5) +  
  ggplot2::scale_x_date(  
    date_breaks = "5 years",  
    date_labels = "%Y"  
  ) +  
  ggplot2::labs(  
    title = "EONIA 1営業日フォワードカーブ",  
    x = "開始日",  
    y = "フォワードレート (%)"  
  ) +  
  ggplot2::theme_minimal()  
  
print(spot_curve_plot)
```



```
print(discount_curve_plot)
```



```
print(forward_curve_plot)
```



1.2 マーケットコンベンション

債券評価では、価格や利回りの計算方法だけでなく、日付、利払頻度、休日および端数処理に関する市場慣行を確認する必要がある。同じ債券であっても、採用する日数計算規則や利回り表示方式が異なれば、経過利子、残存年数および計算価格も異なる。

1.2.1 一般的な市場慣行

日数計算規則 (Day Count Convention) は、二つの日付の間の期間を年数へ換算する規則である。主な方式は次のとおりである。

- **Actual/365 Fixed** 二つの日付間の実日数を 365 で除する。
- **Actual/360** 二つの日付間の実日数を 360 で除する。短期金融市場や金利商品で広く用いられる。
- **Actual/Actual ICMA** 実日数を、利払期間の実日数と年間利払回数に基づいて年換算する。固定利付債で用いられる代表的な方式である。
- **Actual/Actual ISDA** 対象期間を平年部分と閏年部分に分け、それぞれ 365 または 366 で除する。
- **30/360 Bond Basis** 1 か月を 30 日、1 年を 360 日として計算し、月末の日付には所定の調整を行う。
- **30E/360** 開始日または終了日が 31 日の場合に 30 日へ調整し、1 か月を 30 日、1 年を 360 日として計算する。

30/360 方式は手計算を容易にするために考案された方式であり、半年、四半期および 1 か月をそれぞれ 180 日、90 日および 30 日として扱える。一方、Actual 方式では暦上の実日数を用いるため、同じ利率でも計算期間によって利息額が異なることがある。日数計算規則の違いは、経過利子だけでなく、割引期間や利回りにも

影響する。詳細は [Day count convention](#) を参照されたい。ただし、日数計算規則はすべての計算に同じものを用いればよいわけではない。Actual/Actual ICMA や 30/360 Bond Basis は、規則的な利払期間を基準としてクーポン額や経過利子を求める用途に適している。一方、金利期間構造では、評価日から各将来日までの距離を一貫した時間軸へ変換する必要があるため、Actual/360 または Actual/365 Fixed のような単純な規則を用いることが多い。

とくに Actual/Actual ICMA は、基準となる利払期間（reference period）を必要とする。不規則な初回または最終利払期間では、同じ二つの日付であっても、基準期間の与え方によって年数が変わり得る。利払スケジュールを持たない金利カーブにこの規則をそのまま使用すると、割引期間や割引係数が不自然になる場合がある。したがって、債券のクーポン計算に用いる日数計算規則と、割引カーブの時間軸に用いる日数計算規則は区別して設定する必要がある。

受渡日や利払日が非営業日に当たる場合には、対象市場の休日カレンダーと営業日調整規則を用いる。代表的な規則には、次営業日へ移す Following、翌月へ越える場合には前営業日へ戻す Modified Following、前営業日へ戻す Preceding、および日付を調整しない Unadjusted がある。

1.2.2 日本の債券市場における慣行

日本の公社債市場では、単価と複利利回りに加えて、単利利回りが広く用いられてきた。日本証券業協会の公社債店頭売買参考統計値でも、原則として報告された単利利回りから単価を求め、その単価から複利利回りを計算する手順が採用されている。

利付債の経過利子に用いる経過日数は、直前利払期日から受渡日までの実日数を片端入れて数える。一方、最終利回りに用いる残存日数は、受渡日の翌日から償還日までを片端入れて数えるため、経過日数と残存日数を区別する必要がある。

残存日数を N 、残存年数を T とすると、残存年数は次式で求める。

$$T = \frac{N}{365}$$

日本市場の実務では、残存期間が 1 年以上の場合には、原則として期間中の 2 月 29 日を残存日数から除外する。残存期間が 1 年未満の場合には 2 月 29 日を含めるが、分母は 365 のままとする。

さらに、計算された残存年数は小数点以下第 8 位で切り捨て、小数点以下第 7 位までの値を以後の計算に用いる。四捨五入ではなく切り捨てである点が重要である。

額面 100 円、年間クーポン額を C 、償還価格を R 、単価を P 、残存年数を T とすると、単利の最終利回り Y は次式で表される。

$$Y = \frac{C + \frac{R - P}{T}}{P} \times 100$$

この単利利回りは、将来の各キャッシュフローを支払時点ごとに割り引く複利利回りとは異なる。クーポンと償還差損益を残存年数で年換算する日本市場独自の表示方法であり、キャッシュフローごとの時間価値を直接には反映しない。

利回りから単価を逆算する場合には、小数点以下第 7 位までに切り捨てた残存年数を使用する。算出された単価も、原則として小数点以下第 4 位を切り捨て、小数点以下第 3 位までとする。

単価で約定する取引では、計算途中の端数が約定価格を直接変更する場面は限られる。しかし、単利利回りから単価を逆算する場合には、残存年数の切り捨てが償還差損益の年換算額を変化させ、さらに単価の切り捨てによって価格差が生じる。このため、日本の債券計算では、残存日数、残存年数および単価の端数処理を正確に再現する必要がある。

なお、以下のコード例では一般的な債券評価の確認を目的として、30/360 Bond Basis、半年複利および Unadjusted を採用している。したがって、この設定は日本国内債の単利利回り慣行をそのまま再現するものではない。

以下では、日本の休日カレンダー、取引日から 2 営業日後の受渡日、30/360 Bond Basis、半年複利および年 2 回払いを設定する。

```
jp_calendar <- QuantLib::Japan()

dc_a365 <- QuantLib::Actual365Fixed()
dc_a360 <- QuantLib::Actual360()
dc_30 <- GaussQuant::day_counter_GQL(
  "Thirty360",
  convention = "BondBasis"
)

compd_compounded <- QuantLib::Compounding_Compounded_get()
compd_simple <- QuantLib::Compounding_Simple_get()

freq_annual <- QuantLib::Frequency_Annual_get()
freq_semiannual <- QuantLib::Frequency_Semiannual_get()

trade_date_chr <- "2022-08-19"
issue_date_chr <- "2022-07-28"
maturity_date_chr <- "2025-07-28"

trade_date <- GaussQuant::date_GQL(trade_date_chr)
issue_date_ql <- GaussQuant::date_GQL(issue_date_chr)
maturity_date_ql <- GaussQuant::date_GQL(maturity_date_chr)

settlement_days <- 2L

GaussQuant::set_eval_date_GQL(trade_date)

settlement_date <- GaussQuant::advance_days_GQL(
  calendar_obj = jp_calendar,
  date_obj = trade_date,
  n_days = settlement_days
```

```

)

settlement_date_chr <- as.character(settlement_date)
settlement_date_ql <- GaussQuant::date_GQL(settlement_date)

setup_tbl <- tibble::tibble(
  item = c(
    "trade_date",
    "settlement_date",
    "issue_date",
    "maturity_date",
    "settlement_days",
    "day_counter",
    "compounding",
    "frequency"
  ),
  value = c(
    trade_date_chr,
    settlement_date_chr,
    issue_date_chr,
    maturity_date_chr,
    as.character(settlement_days),
    "Thirty360(BondBasis)",
    "Compounded",
    "Semiannual"
  )
)

GaussQuant::show_tbl_GQH(setup_tbl, "Bond setup dates and conventions")
#> # A tibble: 8 x 2
#>   item          value
#>   <chr>         <chr>
#> 1 trade_date    2022-08-19
#> 2 settlement_date 2022-08-23
#> 3 issue_date    2022-07-28
#> 4 maturity_date 2025-07-28
#> 5 settlement_days 2
#> 6 day_counter    Thirty360(BondBasis)
#> 7 compounding    Compounded
#> 8 frequency      Semiannual

```

表示された表から、取引日、受渡日、発行日、満期日および評価に用いる市場慣行を確認する。受渡日は日本の休日カレンダーを用いて取引日から 2 営業日後に計算される。

1.3 固定利付債計算

額面 100、年率 0.37%、半年払い、満期 2025 年 7 月 28 日の固定利付債を作成する。利払スケジュールは満期日から発行日へ向かって 6 か月ごとに生成し、各利払日は Unadjusted とする。

```
face_amount <- 100
coupon_rate <- 0.00370
clean_price_input <- 97.0

bond_obj <- GaussQuant::fixed_rate_bond_GQL(
  issue_date = issue_date_chr,
  maturity_date = maturity_date_chr,
  face_amount = face_amount,
  coupon_rate = coupon_rate,
  settlement_days = settlement_days,
  calendar = jp_calendar,
  accrual_day_counter = dc_30,
  payment_convention = "Unadjusted",
  schedule_convention = "Unadjusted",
  maturity_convention = "Unadjusted",
  date_generation = "Backward",
  end_of_month = FALSE,
  schedule_frequency = GaussQuant::period_months_GQL(6)
)

bond_schedule <- QuantLib::Schedule(
  issue_date_ql,
  maturity_date_ql,
  GaussQuant::period_months_GQL(6),
  jp_calendar,
  "Unadjusted",
  "Unadjusted",
  "Backward",
  FALSE
)

schedule_tbl <- GaussQuant::schedule_dates_GQL(bond_schedule)

bond_setup_tbl <- tibble::tibble(
  metric = c(
    "bond_class",
    "face_amount",
    "coupon_rate",
```

```

    "clean_price_input"
  ),
  value = list(
    paste(class(bond_obj), collapse = ", "),
    face_amount,
    coupon_rate,
    clean_price_input
  )
)

GaussQuant::show_tbl_GQH(GaussQuant::metric_tbl_display_GQH(bond_setup_tbl), "Fixed-rate bond object")
#> # A tibble: 4 x 2
#>   metric      value
#>   <chr>      <chr>
#> 1 bond_class  _p_FixedRateBond
#> 2 face_amount 100.00000000
#> 3 coupon_rate 0.00370000
#> 4 clean_price_input 97.00000000
GaussQuant::show_tbl_GQH(schedule_tbl, "Bond schedule", n = 20)
#> # A tibble: 7 x 1
#>   schedule_date
#>   <date>
#> 1 2022-07-28
#> 2 2023-01-28
#> 3 2023-07-28
#> 4 2024-01-28
#> 5 2024-07-28
#> 6 2025-01-28
#> 7 2025-07-28

```

債券オブジェクトの条件と、発行日から満期日までの利払日を確認する。

1.3.1 クリーン価格から最終利回り

市場で提示されるクリーン価格 97 から、将来キャッシュフローの現在価値がこの価格と一致する最終利回りを逆算する。

```

price_to_yield <- GaussQuant::bond_yield_from_clean_safe_GQL(
  bond = bond_obj,
  clean_price = clean_price_input,
  day_counter = dc_30,
  compounding = cmpd_compounded,
  frequency = freq_semiannual
)

```

```

yield_tbl <- tibble::tibble(
  metric = c(
    "clean_price_input",
    "yield_from_clean_price",
    "yield_percent"
  ),
  value = list(
    clean_price_input,
    price_to_yield,
    100 * price_to_yield
  )
)

GaussQuant::show_tbl_GQH(GaussQuant::metric_tbl_display_GQH(yield_tbl), "Clean price -> yield")
#> # A tibble: 3 x 2
#>   metric          value
#>   <chr>          <chr>
#> 1 clean_price_input 97.00000000
#> 2 yield_from_clean_price 0.01418724
#> 3 yield_percent    1.41872370

```

債券価格が額面を下回っているため、算出される最終利回りはクーポンレートを上回る。

1.3.2 最終利回りから価格

前節で求めた最終利回りを使って、クリーン価格、ダーティ価格および経過利子を計算する。両価格の関係は次式で表される。

$$\text{Dirty Price} = \text{Clean Price} + \text{Accrued Interest}$$

```

price_tbl <- GaussQuant::bond_price_measures_GQL(
  bond = bond_obj,
  yield = price_to_yield,
  day_counter = dc_30,
  compounding = cmpd_compounded,
  frequency = freq_semiannual,
  settlement_date = settlement_date_chr
)

price_tbl <- GaussQuant::complete_accrual_metrics_GQL(
  price_tbl = price_tbl,
  bond_schedule = bond_schedule,
  settlement_date = settlement_date,

```

```

    day_counter = dc_30
  )

price_tbl_display <- GaussQuant::metric_tbl_display_GQH(price_tbl)

GaussQuant::show_tbl_GQH(price_tbl_display, "Yield -> price summary")
#> # A tibble: 6 x 2
#>   metric          value
#>   <chr>          <chr>
#> 1 settlement_date 2022-08-23
#> 2 previous_coupon_date 2022-07-28
#> 3 accrued_days    25.00000000
#> 4 accrued_amount  0.02569444
#> 5 clean_price     97.00000012
#> 6 dirty_price     97.02569456

dirty_price_from_yield <- GaussQuant::get_metric_num_GQH(price_tbl, "dirty_price")
clean_price_from_yield <- GaussQuant::get_metric_num_GQH(price_tbl, "clean_price")
accrued_amount <- GaussQuant::get_metric_num_GQH(price_tbl, "accrued_amount")

cat(
  "clean price:",
  sprintf("%.8f", clean_price_from_yield),
  "\n",
  "dirty price:",
  sprintf("%.8f", dirty_price_from_yield),
  "\n",
  "accrued:",
  sprintf("%.8f", accrued_amount),
  "\n"
)
#> clean price: 97.00000012
#> dirty price: 97.02569456
#> accrued: 0.02569444

```

再計算されたクリーン価格が入力価格 97 と一致することを確認する。ダーティ価格との差額は、前回利払日から受渡日まで発生した経過利子である。

1.3.3 金利リスク

修正デュレーションは、利回りの小さな変化に対する債券価格の一次感応度を表す。コンベクシティは価格と利回りの非線形な関係を補正する二次感応度である。

```

risk_tbl <- GaussQuant::bond_risk_measures_GQL(
  bond = bond_obj,
  yield = price_to_yield,
  day_counter = dc_30,
  compounding = cmpd_compounded,
  frequency = freq_semiannual
)

risk_tbl_display <- GaussQuant::metric_tbl_display_GQH(risk_tbl)

GaussQuant::show_tbl_GQH(risk_tbl_display, "Bond risk measures")
#> # A tibble: 4 x 2
#>   metric      value
#>   <chr>      <chr>
#> 1 modified_duration 2.89593215
#> 2 bpv              0.02809798
#> 3 dv01              0.02809798
#> 4 convexity         9.84952310

modified_duration <- GaussQuant::get_metric_num_GQH(risk_tbl, "modified_duration")
convexity_value <- GaussQuant::get_metric_num_GQH(risk_tbl, "convexity")

cat(
  "modified duration:",
  sprintf("%.8f", modified_duration),
  "\n",
  "convexity:",
  sprintf("%.8f", convexity_value),
  "\n"
)
#> modified duration: 2.89593215
#> convexity: 9.84952310

```

修正デュレーションが大きいほど、同じ利回り変化に対する価格変化も大きくなる。コンベクシティは、利回り変化が大きくなるほど重要になる。

1.3.4 デュレーションとコンベクシティによる価格変化の近似

利回り変化を Δy とすると、債券価格の相対変化は修正デュレーションとコンベクシティを使って近似できる。

$$\frac{\Delta P}{P} \approx -D_{\text{mod}} \Delta y + \frac{1}{2} C (\Delta y)^2$$

```

handcalc_tbl <- GaussQuant::bond_risk_handcalc_GQL(
  bond = bond_obj,
  yield = price_to_yield,
  dirty_price = dirty_price_from_yield,
  modified_duration = modified_duration,
  convexity = convexity_value,
  day_counter = dc_30,
  compounding = cmpd_compounded,
  frequency = freq_semiannual
)

handcalc_tbl_display <- GaussQuant::metric_tbl_display_GQH(handcalc_tbl)

GaussQuant::show_tbl_GQH(handcalc_tbl_display, "Risk hand calculations")
#> # A tibble: 5 x 2
#>   metric                value
#>   <chr>                <chr>
#> 1 bpv_hand             -0.02809798
#> 2 modified_duration_hand 0.02895932
#> 3 convexity_hand        0.00098495
#> 4 price_up_100bp        94.26306473
#> 5 price_approx_delta_gamma 94.26367912

```

一次近似と二次近似を比較し、コンベクシティを加えることで実際の価格変化に近づくことを確認する。

1.4 キャッシュフローによる検証

各利払日のクーポンと満期時の元本を最終利回りで割り引き、ダーティ価格を手計算する。そこから経過利子を差し引くことでクリーン価格を求める。

```

schedule_dates_chr <- schedule_tbl[[1]] |>
  as.character()

schedule_dates_chr <- schedule_dates_chr[!is.na(schedule_dates_chr)]

future_dates_chr <- schedule_dates_chr[schedule_dates_chr > settlement_date_chr]

coupon_per_period <- face_amount * coupon_rate / 2

manual_cf_tbl <- tibble::tibble(
  payment_date = future_dates_chr,
  period_no = seq_along(future_dates_chr),
  cashflow = coupon_per_period
) |>

```

```

dplyr::mutate(
  cashflow = ifelse(
    .data$payment_date == maturity_date_chr,
    .data$cashflow + face_amount,
    .data$cashflow
  ),
  ql_date = purrr::map(payment_date, GaussQuant::date_GQL),
  time = purrr::map_dbl(
    ql_date,
    ~ dc_30$yearFraction(settlement_date_ql, .x)
  ),
  discount_factor = 1 / (1 + price_to_yield / 2)^(2 * time),
  pv = cashflow * discount_factor
) |>
dplyr::select(-ql_date)

manual_dirty_price <- sum(manual_cf_tbl$pv, na.rm = TRUE)
manual_clean_price <- manual_dirty_price - accrued_amount

manual_summary_tbl <- tibble::tibble(
  metric = c(
    "manual_dirty_price",
    "manual_clean_price",
    "wrapper_dirty_price",
    "wrapper_clean_price",
    "dirty_price_difference",
    "clean_price_difference"
  ),
  value = list(
    manual_dirty_price,
    manual_clean_price,
    dirty_price_from_yield,
    clean_price_from_yield,
    manual_dirty_price - dirty_price_from_yield,
    manual_clean_price - clean_price_from_yield
  )
)

GaussQuant::show_tbl_GQH(manual_cf_tbl, "Manual cashflow PV table")
#> # A tibble: 6 x 6
#>   payment_date period_no cashflow  time discount_factor    pv
#>   <chr>          <int>    <dbl> <dbl>          <dbl> <dbl>
#> 1 2023-01-28         1    0.185 0.431          0.994 0.184

```

```
#> 2 2023-07-28      2    0.185 0.931      0.987 0.183
#> 3 2024-01-28      3    0.185 1.43      0.980 0.181
#> 4 2024-07-28      4    0.185 1.93      0.973 0.180
#> 5 2025-01-28      5    0.185 2.43      0.966 0.179
#> 6 2025-07-28      6   100.    2.93      0.959 96.1

GaussQuant::show_tbl_GQH(GaussQuant::metric_tbl_display_GQH(manual_summary_tbl), "Manual PV check")
#> # A tibble: 6 x 2
#>   metric      value
#>   <chr>      <chr>
#> 1 manual_dirty_price 97.02569456
#> 2 manual_clean_price 97.00000012
#> 3 wrapper_dirty_price 97.02569456
#> 4 wrapper_clean_price 97.00000012
#> 5 dirty_price_difference 0.00000000
#> 6 clean_price_difference 0.00000000
```

手計算と関数による価格との差が十分に小さいことを確認する。これにより、キャッシュフロー、割引期間および経過利子の関係を検算できる。

1.4.1 フラットな利回りによる価格評価

次に、最終利回りを一定とするフラットな割引曲線を構築し、割引エンジンから債券価格を計算する。

```
flat_yield_handle <- GaussQuant::bond_flat_forward_handle_GQL(
  settlement_date = settlement_date_chr,
  rate = price_to_yield,
  day_counter = dc_30,
  compounding = compd_compounded,
  frequency = freq_semiannual
)

flat_engine <- QuantLib::DiscountingBondEngine(flat_yield_handle)

QuantLib::Instrument_setPricingEngine(
  bond_obj,
  flat_engine
)
#> NULL

flat_dirty_price <- QuantLib::Instrument_NPV(bond_obj)

flat_yield_tbl <- tibble::tibble(
  metric = c(
    "flat_yield",
```



```

    "dirty_price_from_flat_engine",
    "dirty_price_from_yield",
    "difference"
  ),
  value = list(
    price_to_yield,
    flat_dirty_price,
    dirty_price_from_yield,
    flat_dirty_price - dirty_price_from_yield
  )
)

GaussQuant::show_tbl_GQH(GaussQuant::metric_tbl_display_GQH(flat_yield_tbl), "Flat yield pricing")
#> # A tibble: 4 x 2
#>   metric                                value
#>   <chr>                                <chr>
#> 1 flat_yield                          0.01418724
#> 2 dirty_price_from_flat_engine 97.02569456
#> 3 dirty_price_from_yield       97.02569456
#> 4 difference                     -0.00000000

```

フラットな利回りを使った割引価格と、最終利回りから直接求めたダーティ価格を比較する。### 1.4.2 Z-spread による価格調整

Z-spread は、基準となる割引カーブの各年限に一律に加えるスプレッドである。ここでは基準カーブに 50 ベーシスポイントを上乗せし、債券価格への影響を確認する。

```

z_spread <- 50 / 10000

zspread_result <- GaussQuant::bond_npv_with_zspread_GQL(
  bond = bond_obj,
  base_curve_handle = flat_yield_handle,
  z_spread = z_spread,
  compounding = compd_compounded,
  frequency = freq_semiannual,
  day_counter = dc_30
)

zspread_dirty_price <- zspread_result$npv

zspread_tbl <- tibble::tibble(
  metric = c(
    "base_yield",
    "z_spread_bp",
    "dirty_price_before_spread",

```

```

      "dirty_price_after_spread",
      "price_difference"
    ),
    value = list(
      price_to_yield,
      10000 * z_spread,
      flat_dirty_price,
      zspread_dirty_price,
      zspread_dirty_price - flat_dirty_price
    )
  )

GaussQuant::show_tbl_GQH(
  GaussQuant::metric_tbl_display_GQH(zspread_tbl),
  "Z-spread pricing"
)

#> # A tibble: 5 x 2
#>   metric                value
#>   <chr>                <chr>
#> 1 base_yield           0.01418724
#> 2 z_spread_bp          50.00000000
#> 3 dirty_price_before_spread 97.02569456
#> 4 dirty_price_after_spread  95.63266391
#> 5 price_difference      -1.39303065

```

正の Z-spread を加えると割引率が上昇するため、債券価格は低下する。Z-spread には発行体の信用リスクだけでなく、流動性、市場需給および基準カーブとの相違も含まれ得るため、純粋なデフォルト確率を直接表す指標ではない。ここでは全期間への一律なスプレッドだけを扱い、年限別の非平行シフトは金利カーブの章で扱う。### 1.4.3 債券キャッシュフロー

債券に含まれる将来のクーポンと元本償還を一覧で確認する。

```

bond_cf_tbl <- GaussQuant::bond_cashflow_table_GQL(
  bond = bond_obj
)

GaussQuant::show_tbl_GQH(bond_cf_tbl, "Bond cashflow table", n = 30)

#> # A tibble: 7 x 2
#>   date      amount
#>   <chr>    <dbl>
#> 1 2023-01-28  0.185
#> 2 2023-07-28  0.185
#> 3 2024-01-28  0.185
#> 4 2024-07-28  0.185
#> 5 2025-01-28  0.185

```

```
#> 6 2025-07-28 0.185
#> 7 2025-07-28 100
```

各行は支払日と支払額を表し、満期日のキャッシュフローには最終クーポンと元本償還が含まれる。

1.5 計算結果のまとめ

これまでに設定した日付、価格、利回りおよび金利リスク指標を一つの表にまとめる。

```
summary_tbl <- tibble::tibble(
  metric = c(
    "trade_date",
    "settlement_date",
    "issue_date",
    "maturity_date",
    "clean_price_input",
    "yield_from_clean_price",
    "clean_price_from_yield",
    "dirty_price_from_yield",
    "accrued_amount",
    "modified_duration",
    "convexity"
  ),
  value = c(
    GaussQuant::iso_GQL(trade_date),
    settlement_date_chr,
    issue_date_chr,
    maturity_date_chr,
    sprintf("%.8f", clean_price_input),
    sprintf("%.8f", price_to_yield),
    sprintf("%.8f", clean_price_from_yield),
    sprintf("%.8f", dirty_price_from_yield),
    sprintf("%.8f", accrued_amount),
    sprintf("%.8f", modified_duration),
    sprintf("%.8f", convexity_value)
  )
)

GaussQuant::show_tbl_GQH(summary_tbl, "Bond analysis summary", n = 20)
#> # A tibble: 11 x 2
#>   metric          value
#>   <chr>          <chr>
#> 1 trade_date    2022-08-19
#> 2 settlement_date 2022-08-23
```

```
#> 3 issue_date          2022-07-28
#> 4 maturity_date       2025-07-28
#> 5 clean_price_input    97.00000000
#> 6 yield_from_clean_price 0.01418724
#> 7 clean_price_from_yield 97.00000012
#> 8 dirty_price_from_yield 97.02569456
#> 9 accrued_amount      0.02569444
#> 10 modified_duration   2.89593215
#> 11 convexity           9.84952310

cat("\nchapter01 bonds stable rewrite completed successfully.\n")
#>
#> chapter01 bonds stable rewrite completed successfully.
```

第 II-2 章金利カーブ構築と債券先物 CTD、BPV

債券、金利スワップおよび金利オプションの評価では、将来キャッシュフローを現在価値へ換算するための金利期間構造が必要となる。金利期間構造は、満期ごとの金利を並べた単なる曲線ではない。市場で観測される預金金利、債券価格、FRA およびスワップレートなどから、各将来日の割引係数を整合的に推定した結果である。

同じ期間構造は、割引係数、ゼロ金利またはフォワード金利として表現できる。これらは相互に変換可能であるが、表示方法によって曲線の特徴の見え方が異なる。割引係数は現在価値計算に直接用いられ、ゼロ金利は満期ごとの平均的な金利水準を示し、フォワード金利は将来の区間ごとの限界的な金利を示す。

本章では、最初にゼロ金利ノードから単純なカーブを構築し、割引係数、ゼロ金利およびフォワード金利の関係を確認する。次に、補間方式による曲線形状の違いを比較する。その後、預金と債券、ならびに預金とスワップを用いたブートストラップを行い、最後に Implied Term Structure と平行シフトを確認する。

```
knitr::opts_chunk$set(
  collapse = TRUE,
  comment = "#>",
  warning = FALSE,
  message = FALSE
)

suppressPackageStartupMessages({
  library(tidyverse)
  library(QuantLib)
  library(GaussQuant)
})
```

2.1 金利カーブの基礎

評価日を 0、将来時点を t とし、時点 t に 1 を受け取るキャッシュフローの現在価値を $D(0, t)$ とする。 $D(0, t)$ は割引係数である。連続複利のゼロ金利を $z(0, t)$ とすると、両者の関係は次式で表される。

$$D(0, t) = \exp[-z(0, t)t]$$

したがって、割引係数からゼロ金利を求めると次式となる。

$$z(0, t) = -\frac{\log D(0, t)}{t}$$

二つの時点 t_1 と t_2 の間に適用される連続複利のフォワード金利を $f(t_1, t_2)$ とすると、次式で求められる。

$$f(t_1, t_2) = -\frac{\log [D(0, t_2)/D(0, t_1)]}{t_2 - t_1}$$

割引係数、ゼロ金利およびフォワード金利は同じ期間構造を異なる方法で表している。ただし、補間方法の違いは、とくにフォワード金利の形状に強く表れる。

2.1.1 ゼロ金利ノード

最初に、評価日と複数の将来日について連続複利のゼロ金利を設定する。ここで用いる数値は、カーブの構造を確認するための例示値である。

```
evaluation_date_chr <- "2022-08-19"

GaussQuant::set_eval_date_GQL(evaluation_date_chr)

zero_nodes <- tibble::tribble(
  ~tenor, ~date, ~zero_rate,
  "0D",   as.Date("2022-08-19"), 0.0005,
  "1M",   as.Date("2022-09-19"), 0.0006,
  "3M",   as.Date("2022-11-21"), 0.0008,
  "6M",   as.Date("2023-02-20"), 0.0011,
  "1Y",   as.Date("2023-08-21"), 0.0018,
  "2Y",   as.Date("2024-08-19"), 0.0032,
  "3Y",   as.Date("2025-08-19"), 0.0048,
  "5Y",   as.Date("2027-08-19"), 0.0075,
  "10Y",  as.Date("2032-08-19"), 0.0115
)

GaussQuant::show_tbl_GQH(
  zero_nodes,
  "Zero-rate nodes",
  n = 20
)

#> # A tibble: 9 x 3
#>   tenor date       zero_rate
#>   <chr> <date>         <dbl>
#> 1 0D    2022-08-19    0.0005
#> 2 1M    2022-09-19    0.0006
#> 3 3M    2022-11-21    0.0008
#> 4 6M    2023-02-20    0.0011
```

```
#> 5 1Y    2023-08-21    0.0018
#> 6 2Y    2024-08-19    0.0032
#> 7 3Y    2025-08-19    0.0048
#> 8 5Y    2027-08-19    0.0075
#> 9 10Y   2032-08-19    0.0115
```

2.1.2 ゼロカーブ

`build_zero_curve_GQL()` は、日付とゼロ金利の組から QuantLib の `ZeroCurve` を構築する。ここではカーブの時間軸に `Actual/365 Fixed` を用いる。

```
zero_curve <- GaussQuant::build_zero_curve_GQL(
  date_chr = as.character(zero_nodes$date),
  zero_rates = zero_nodes$zero_rate,
  day_counter = "Actual365Fixed"
)

zero_curve_handle <- GaussQuant::yield_curve_handle_GQL(
  zero_curve
)

zero_curve_tbl <- GaussQuant::curve_tbl_GQH(
  curve = zero_curve,
  tenors = c(
    "1D", "1W", "1M", "3M", "6M",
    "1Y", "2Y", "3Y", "5Y", "7Y", "10Y"
  )
)

GaussQuant::show_tbl_GQH(
  zero_curve_tbl,
  "Zero curve",
  n = 20
)

#> # A tibble: 11 x 4
#>   tenor date      discount zero_rate
#>   <chr> <date>      <dbl>     <dbl>
#> 1 1D    2022-08-20    1.000  0.000503
#> 2 1W    2022-08-26    1.000  0.000523
#> 3 1M    2022-09-19    1.000  0.000600
#> 4 3M    2022-11-19    1.000  0.000794
#> 5 6M    2023-02-19    0.999  0.00110
#> 6 1Y    2023-08-19    0.998  0.00179
#> 7 2Y    2024-08-19    0.994  0.00320
```

```
#> 8 3Y    2025-08-19    0.986  0.00480
#> 9 5Y    2027-08-19    0.963  0.0075
#> 10 7Y   2029-08-19    0.938  0.00910
#> 11 10Y  2032-08-19    0.891  0.0115
```

カーブから取得したゼロ金利は連続複利表示である。入力ノードの間では QuantLib の補間規則に従って金利が補間される。

2.1.3 カーブの表現

カーブを細かい時間間隔へ展開し、割引係数、ゼロ金利および隣接区間のフォワード金利を計算する。

```
zero_curve_grid <- GaussQuant::curve_grid_tbl_GQL(
  curve = zero_curve,
  n = 240L,
  extrapolate = TRUE
) |>
dplyr::mutate(
  next_time = dplyr::lead(.data$time),
  next_discount = dplyr::lead(.data$discount_factor),
  forward_rate = dplyr::if_else(
    !is.na(.data$next_time) &
    .data$next_time > .data$time &
    .data$discount_factor > 0 &
    .data$next_discount > 0,
    -log(.data$next_discount / .data$discount_factor) /
    (.data$next_time - .data$time),
    NA_real_
  )
)

grid_show_index <- unique(
  round(
    seq(
      from = 1,
      to = nrow(zero_curve_grid),
      length.out = 12
    )
  )
)

GaussQuant::show_tbl_GQH(
  zero_curve_grid |>
  dplyr::slice(grid_show_index) |>
```



```
dplyr::select(
  .data$curve_date,
  .data$time,
  .data$discount_factor,
  .data$zero_rate,
  .data$forward_rate
),
"Zero-curve grid",
n = 20
)
```

```
#> # A tibble: 12 x 5
#>   curve_date    time discount_factor zero_rate forward_rate
#>   <date>      <dbl>          <dbl>    <dbl>      <dbl>
#> 1 2022-08-19    0            1        0      0.000548
#> 2 2023-07-21  0.921          0.998    0.00168    0.00303
#> 3 2024-06-06  1.8            0.995    0.00292    0.00550
#> 4 2025-05-08  2.72            0.988    0.00435    0.00877
#> 5 2026-04-09  3.64            0.980    0.00566    0.0106
#> 6 2027-03-12  4.56            0.969    0.00691    0.0131
#> 7 2028-01-26  5.44            0.958    0.00785    0.0122
#> 8 2028-12-28  6.36            0.947    0.00859    0.0137
#> 9 2029-11-29  7.28            0.934    0.00932    0.0152
#> 10 2030-10-31  8.21            0.921    0.0101    0.0167
#> 11 2031-09-17  9.08            0.907    0.0108    0.0181
#> 12 2032-08-19 10.0            0.891    0.0115    NA
```

```
discount_factor_plot <- zero_curve_grid |>
```

```
ggplot2::ggplot(
  ggplot2::aes(
    x = .data$curve_date,
    y = .data$discount_factor
  )
) +
ggplot2::geom_line() +
ggplot2::labs(
  title = "Discount factor curve",
  x = NULL,
  y = "Discount factor"
) +
ggplot2::theme_minimal()
```


```
zero_rate_plot <- zero_curve_grid |>
```

```
ggplot2::ggplot(
  ggplot2::aes(
```


```
      x = .data$curve_date,
      y = 100 * .data$zero_rate
    )
  ) +
  ggplot2::geom_line() +
  ggplot2::labs(
    title = "Continuous zero-rate curve",
    x = NULL,
    y = "Zero rate (%)"
  ) +
  ggplot2::theme_minimal()

forward_rate_plot <- zero_curve_grid |>
  dplyr::filter(!is.na(.data$forward_rate)) |>
  ggplot2::ggplot(
    ggplot2::aes(
      x = .data$curve_date,
      y = 100 * .data$forward_rate
    )
  ) +
  ggplot2::geom_line() +
  ggplot2::labs(
    title = "One-step forward-rate curve",
    x = NULL,
    y = "Forward rate (%)"
  ) +
  ggplot2::theme_minimal()


print(discount_factor_plot)
```



```
print(zero_rate_plot)
```



```
print(forward_rate_plot)
```



割引係数は将来の 1 単位を現在価値へ換算する倍率である。正の金利環境では、満期が長くなるほど一般に小さくなる。ゼロ金利は評価日から各満期までの平均的な金利水準を示す。一方、フォワード金利は隣接する二時点間の金利を表すため、補間方法やノード配置の影響を強く受ける。

2.2 補間と参照日

2.2.1 補間方式とフォワード金利

市場では限られた満期の金利または価格しか観測できないため、ノード間の値を補間する必要がある。補間対象には、ゼロ金利、割引係数、対数割引係数またはフォワード金利などがある。

ここでは、同じゼロ金利ノードから次の二つのカーブを構築する。

- ZeroCurve：ゼロ金利を基礎とするカーブ
- DiscountCurve：ノードのゼロ金利を割引係数へ変換し、割引係数を基礎とするカーブ

```
discount_curve <- GaussQuant::build_discount_curve_GQL(
  nodes = zero_nodes |>
    dplyr::select(
      .data$date,
      .data$zero_rate
    ),
  day_counter = "Actual365Fixed"
)

discount_curve_handle <- GaussQuant::yield_curve_handle_GQL(
  discount_curve
)
```

```
comparison_max_time <- min(
  as.numeric(zero_curve$maxTime()),
  as.numeric(discount_curve$maxTime())
)

comparison_time_grid <- seq(
  from = 0,
  to = comparison_max_time,
  length.out = 300
)

comparison_reference_date <- as.Date(
  GaussQuant::iso_GQL(
    zero_curve$referenceDate()
  )
)

interpolation_tbl <- tibble::tibble(
  time = comparison_time_grid,
  date = comparison_reference_date +
    round(comparison_time_grid * 365)
) |>
dplyr::mutate(
  ql_date = purrr::map(
    as.character(.data$date),
    GaussQuant::date_GQL
  ),
  zero_curve_discount = purrr::map_dbl(
    .data$ql_date,
    ~ GaussQuant::curve_discount_safe_GQL(
      zero_curve,
      .x
    )
  ),
  discount_curve_discount = purrr::map_dbl(
    .data$ql_date,
    ~ GaussQuant::curve_discount_safe_GQL(
      discount_curve,
      .x
    )
  )
) |>
dplyr::select(
  -.data$ql_date
```

```
) |>
tidyr::pivot_longer(
  cols = c(
    zero_curve_discount,
    discount_curve_discount
  ),
  names_to = "interpolation",
  values_to = "discount_factor"
) |>
dplyr::mutate(
  interpolation = dplyr::recode(
    .data$interpolation,
    zero_curve_discount = "ZeroCurve",
    discount_curve_discount = "DiscountCurve"
  )
) |>
dplyr::group_by(
  .data$interpolation
) |>
dplyr::arrange(
  .data$interpolation,
  .data$time
) |>
dplyr::mutate(
  zero_rate = dplyr::if_else(
    .data$time > 0 &
    .data$discount_factor > 0,
    -log(.data$discount_factor) /
    .data$time,
    zero_nodes$zero_rate[[1]]
  ),
  next_time = dplyr::lead(
    .data$time
  ),
  next_discount = dplyr::lead(
    .data$discount_factor
  ),
  forward_rate = dplyr::if_else(
    !is.na(.data$next_time) &
    .data$next_time > .data$time &
    .data$discount_factor > 0 &
    .data$next_discount > 0,
    -log(
```

```

      .data$next_discount /
      .data$discount_factor
    ) / (
      .data$next_time -
      .data$time
    ),
    NA_real_
  )
) |>
dplyr::ungroup()

```

```


interpolation_zero_plot <- interpolation_tbl |>
ggplot2::ggplot(
  ggplot2::aes(
    x = .data$time,
    y = 100 * .data$zero_rate,
    linetype = .data$interpolation
  )
) +
ggplot2::geom_line() +
ggplot2::labs(
  title = "Zero rates under different interpolation targets",
  x = "Time from reference date",
  y = "Zero rate (%)",
  linetype = NULL
) +
ggplot2::theme_minimal()

interpolation_forward_plot <- interpolation_tbl |>
dplyr::filter(!is.na(.data$forward_rate)) |>
ggplot2::ggplot(
  ggplot2::aes(
    x = .data$time,
    y = 100 * .data$forward_rate,
    linetype = .data$interpolation
  )
) +
ggplot2::geom_line() +
ggplot2::labs(
  title = "Forward rates under different interpolation targets",
  x = "Time from reference date",
  y = "Forward rate (%)",
  linetype = NULL
) +


```

```
ggplot2::theme_minimal()

print(interpolation_zero_plot)
```



```
print(interpolation_forward_plot)
```



両カーブは入力ノードではほぼ同じ情報を再現するが、ノード間では異なる形状を示す。ゼロ金利のグラフでは差が小さく見えても、フォワード金利へ変換すると差が拡大することがある。したがって、カーブの妥当性はゼロ金利だけでなく、フォワード金利も確認する必要がある。

2.2.2 参照日と評価日

カーブの参照日は、割引係数が1となる時点であり、時間軸の起点である。日付ノードから構築したカーブでは、通常、最初のノード日が固定参照日となる。

次の確認では、QuantLib の評価日を変更した後も、すでに構築済みの ZeroCurve の参照日が変わらないことを確認する。

```
reference_date_before <- as.Date(
  GaussQuant::iso_GQL(
    zero_curve$referenceDate()
  )
)

GaussQuant::set_eval_date_GQL(
  "2022-09-19"
)

reference_date_after <- as.Date(
  GaussQuant::iso_GQL(
    zero_curve$referenceDate()
  )
)

reference_date_tbl <- tibble::tribble(
  ~item, ~value,
  "curve_reference_date_before", as.character(reference_date_before),
  "evaluation_date_after_change", "2022-09-19",
  "curve_reference_date_after", as.character(reference_date_after)
)

GaussQuant::show_tbl_GQH(
  reference_date_tbl,
  "Fixed reference date"
)

#> # A tibble: 3 x 2
#>   item                                value
#>   <chr>                               <chr>
#> 1 curve_reference_date_before 2022-08-19
#> 2 evaluation_date_after_change 2022-09-19
#> 3 curve_reference_date_after 2022-08-19

GaussQuant::set_eval_date_GQL(
  evaluation_date_chr
```

)

固定参照日のカーブは、評価日を変更しても参照日が変化しない。一方、決済日数と休日カレンダーから参照日を決定する Moving Reference Date 型のカーブでは、評価日の変更に応じて参照日も移動する。評価日を進めるシナリオ分析では、既存カーブを固定したまま使うのか、市場データから新しいカーブを再構築するのかを区別する必要がある。

2.3 ブートストラップ

2.3.1 預金と債券

市場ではゼロ金利を直接観測できる満期は限られている。そのため、短期預金、国債価格およびスワップレートなどから、割引係数を順次推定するブートストラップを行う。

短期部分では預金金利から最初の割引係数を求め、その先では固定利付債の市場価格と理論価格が一致するようにカーブを延長する。GaussQuant の `build_bond_discount_curve_GQL()` は、短期預金と複数の固定利付債を用いて PiecewiseFlatForward カーブを構築する。

```
GaussQuant::set_eval_date_GQL(
  "2008-09-15"
)

bond_curve <- GaussQuant::build_bond_discount_curve_GQL(
  settlement_date = "2008-09-18",
  fixing_days = 3,
  settlement_days = 3
)

bond_curve_tbl <- GaussQuant::curve_tbl_GQH(
  curve = bond_curve,
  tenors = c(
    "1M", "3M", "6M", "1Y",
    "2Y", "3Y", "5Y", "7Y",
    "10Y", "15Y", "20Y"
  )
)

GaussQuant::show_tbl_GQH(
  bond_curve_tbl,
  "Deposit and bond bootstrap curve",
  n = 30
)


#> # A tibble: 11 x 4
#>   tenor date          discount zero_rate
#>   <chr> <date>          <dbl>      <dbl>
```

```
#> 1 1M 2008-10-18 0.999 0.00961
#> 2 3M 2008-12-18 0.998 0.00961
#> 3 6M 2009-03-18 0.993 0.0145
#> 4 1Y 2009-09-18 0.981 0.0192
#> 5 2Y 2010-09-18 0.957 0.0218
#> 6 3Y 2011-09-18 0.929 0.0245
#> 7 5Y 2013-09-18 0.860 0.0302
#> 8 7Y 2015-09-18 0.782 0.0351
#> 9 10Y 2018-09-18 0.679 0.0388
#> 10 15Y 2023-09-18 0.532 0.0421
#> 11 20Y 2028-09-18 0.417 0.0438
```

```
bond_curve_grid <- GaussQuant::curve_grid_tbl_GQL(
  curve = bond_curve,
  n = 300L,
  extrapolate = TRUE
)

bond_curve_plot <- bond_curve_grid |>
  ggplot2::ggplot(
    ggplot2::aes(
      x = .data$curve_date,
      y = 100 * .data$zero_rate
    )
  ) +
  ggplot2::geom_line() +
  ggplot2::labs(
    title = "Deposit and bond bootstrap curve",
    x = NULL,
    y = "Continuous zero rate (%)"
  ) +
  ggplot2::theme_minimal()

print(bond_curve_plot)
```



債券価格を用いるブートストラップでは、各債券のクーポン日、満期日、経過利子および日数計算規則がカーブ構築に影響する。債券のクーポン計算には商品固有の日数計算規則を用いる一方、期間構造の時間軸には単純で加法的な日数計算規則を用いる必要がある。

2.3.2 預金とスワップ

次に、短期部分を預金金利、中長期部分を固定対変動金利スワップの市場レートから構築する。スワップの市場レートは、固定レグと変動レグの現在価値を等しくするパー・スワップレートである。

GaussQuant の `build_swap_curve_GQL()` は、短期預金と複数満期のスワップレートを用いて `PiecewiseFlatForward` カーブを構築する。

```
swap_curve <- GaussQuant::build_swap_curve_GQL(
  settlement_date = "2008-09-18",
  fixing_days = 3
)

swap_curve_handle <- GaussQuant::yield_curve_handle_GQL(
  swap_curve
)

swap_curve_tbl <- GaussQuant::curve_tbl_GQH(
  curve = swap_curve,
  tenors = c(
    "1W", "1M", "3M", "6M",
    "1Y", "2Y", "3Y", "5Y",
    "7Y", "10Y", "15Y"
  )
)
```

```
)

GaussQuant::show_tbl_GQH(
  swap_curve_tbl,
  "Deposit and swap bootstrap curve",
  n = 30
)

#> # A tibble: 11 x 4
#>   tenor date      discount zero_rate
#>   <chr> <date>      <dbl>    <dbl>
#> 1 1W    2008-09-25    0.999    0.0441
#> 2 1M    2008-10-18    0.997    0.0326
#> 3 3M    2008-12-18    0.992    0.0324
#> 4 6M    2009-03-18    0.983    0.0341
#> 5 1Y    2009-09-18    0.967    0.0334
#> 6 2Y    2010-09-18    0.944    0.0290
#> 7 3Y    2011-09-18    0.909    0.0318
#> 8 5Y    2013-09-18    0.837    0.0355
#> 9 7Y    2015-09-18    0.763    0.0387
#> 10 10Y   2018-09-18    0.663    0.0411
#> 11 15Y   2023-09-18    0.521    0.0434
```

```
comparison_tenors <- c(
  "1M", "3M", "6M", "1Y",
  "2Y", "3Y", "5Y", "7Y",
  "10Y", "15Y"
)

bootstrap_comparison_tbl <- dplyr::bind_rows(
  GaussQuant::curve_tbl_GQH(
    curve = bond_curve,
    tenors = comparison_tenors
  ) |>
  dplyr::mutate(
    curve = "Deposit + bond"
  ),
  GaussQuant::curve_tbl_GQH(
    curve = swap_curve,
    tenors = comparison_tenors
  ) |>
  dplyr::mutate(
    curve = "Deposit + swap"
  )
)
```

```


GaussQuant::show_tbl_GQH(
  bootstrap_comparison_tbl,
  "Bootstrap curve comparison",
  n = 30
)
#> # A tibble: 20 x 5
#>   tenor date      discount zero_rate curve
#>   <chr> <date>      <dbl>    <dbl> <chr>
#> 1 1M    2008-10-18    0.999    0.00961 Deposit + bond
#> 2 3M    2008-12-18    0.998    0.00961 Deposit + bond
#> 3 6M    2009-03-18    0.993    0.0145  Deposit + bond
#> 4 1Y    2009-09-18    0.981    0.0192  Deposit + bond
#> 5 2Y    2010-09-18    0.957    0.0218  Deposit + bond
#> 6 3Y    2011-09-18    0.929    0.0245  Deposit + bond
#> 7 5Y    2013-09-18    0.860    0.0302  Deposit + bond
#> 8 7Y    2015-09-18    0.782    0.0351  Deposit + bond
#> 9 10Y   2018-09-18    0.679    0.0388  Deposit + bond
#> 10 15Y  2023-09-18    0.532    0.0421  Deposit + bond
#> 11 1M    2008-10-18    0.997    0.0326  Deposit + swap
#> 12 3M    2008-12-18    0.992    0.0324  Deposit + swap
#> 13 6M    2009-03-18    0.983    0.0341  Deposit + swap
#> 14 1Y    2009-09-18    0.967    0.0334  Deposit + swap
#> 15 2Y    2010-09-18    0.944    0.0290  Deposit + swap
#> 16 3Y    2011-09-18    0.909    0.0318  Deposit + swap
#> 17 5Y    2013-09-18    0.837    0.0355  Deposit + swap
#> 18 7Y    2015-09-18    0.763    0.0387  Deposit + swap
#> 19 10Y   2018-09-18    0.663    0.0411  Deposit + swap
#> 20 15Y  2023-09-18    0.521    0.0434  Deposit + swap

bootstrap_zero_plot <- bootstrap_comparison_tbl |>
  ggplot2::ggplot(
    ggplot2::aes(
      x = .data$date,
      y = 100 * .data$zero_rate,
      linetype = .data$curve
    )
  ) +
  ggplot2::geom_line() +
  ggplot2::geom_point() +
  ggplot2::labs(
    title = "Bond-based and swap-based curves",
    x = NULL,
    y = "Continuous zero rate (%)",
  )

```

```
linetype = NULL
) +
ggplot2::theme_minimal()

print(bootstrap_zero_plot)
```



債券カーブとスワップカーブは、異なる市場商品から構築されるため一致するとは限らない。両者の差には、市場の流動性、商品固有の信用・担保条件、日数計算規則および観測時点の違いが含まれる。

FRA は、将来の一定期間に適用される金利を直接観測する商品として、預金とスワップの間を接続するために用いられる。本章の実装では預金とスワップを用いるが、FRA を追加する場合も、各市場商品の理論価格が市場価格と一致するように同じブートストラップの枠組みへ組み込む。

2.4 カーブ操作と検証

2.4.1 Implied Term Structure

Implied Term Structure は、既存カーブが示す将来の割引関係を保ったまま、参照日を将来へ移した期間構造である。元のカーブの参照日を t_0 、新しい参照日を t_1 、将来日を t_2 とすると、Implied Term Structure の割引係数は概念的に次式で表される。

$$D_{t_1}(t_2) = \frac{D_{t_0}(t_2)}{D_{t_0}(t_1)}$$

```
implied_reference_date <- GaussQuant::date_GQL(
  "2009-09-18"
)
```

```

implied_constructor <- get0(
  "ImpliedTermStructure",
  envir = asNamespace("QuantLib"),
  inherits = FALSE
)

implied_curve <- if (is.null(implied_constructor)) {
  NULL
} else {
  tryCatch(
    implied_constructor(
      swap_curve_handle,
      implied_reference_date
    ),
    error = function(e) NULL
  )
}

implied_curve_tbl <- if (is.null(implied_curve)) {
  tibble::tibble(
    status = "ImpliedTermStructure is not available in the installed QuantLib binding."
  )
} else {
  GaussQuant::curve_tbl_GQH(
    curve = implied_curve,
    tenors = c(
      "1M", "3M", "6M", "1Y",
      "2Y", "3Y", "5Y", "10Y"
    )
  )
}

GaussQuant::show_tbl_GQH(
  implied_curve_tbl,
  "Implied term structure",
  n = 20
)

#> # A tibble: 8 x 4
#>   tenor date      discount zero_rate
#>   <chr> <date>      <dbl>    <dbl>
#> 1 1M    2009-10-18    0.998    0.0245
#> 2 3M    2009-12-18    0.994    0.0245
#> 3 6M    2010-03-18    0.988    0.0245

```



```
#> 4 1Y    2010-09-18    0.976    0.0245
#> 5 2Y    2011-09-18    0.940    0.0310
#> 6 3Y    2012-09-18    0.902    0.0343
#> 7 5Y    2014-09-18    0.826    0.0381
#> 8 10Y   2019-09-18    0.653    0.0426
```

Implied Term Structure は、将来時点から見た割引係数を現在のカーブから機械的に導くものであり、将来の市場カーブを予測したものではない。評価日を将来へ進めたシナリオで市場リスクを評価する場合には、カーブの単純な時間経過と市場金利の変動を区別する必要がある。

2.4.2 カーブの平行シフト

金利リスク分析では、基準カーブに一定のスプレッドを加えたカーブを用いる。すべての満期へ同じスプレッドを加える変化を平行シフトという。

ここでは、預金・スワップカーブへ 50 ベーシスポイントを加え、ゼロ金利と割引係数の変化を確認する。

```
parallel_spread <- 50 / 10000

spreaded_curve_bundle <- GaussQuant::make_zero_spreaded_curve_GQL(
  base_curve_handle = swap_curve_handle,
  spread_rate = parallel_spread,
  day_counter = QuantLib::Actual365Fixed(),
  extrapolate = TRUE
)

spreaded_curve <- spreaded_curve_bundle$curve

parallel_shift_tbl <- dplyr::bind_rows(
  GaussQuant::curve_tbl_GQH(
    curve = swap_curve,
    tenors = comparison_tenors
  ) |>
  dplyr::mutate(
    curve = "Base curve"
  ),
  GaussQuant::curve_tbl_GQH(
    curve = spreaded_curve,
    tenors = comparison_tenors
  ) |>
  dplyr::mutate(
    curve = "Base curve + 50bp"
  )
)
```

```

parallel_shift_wide_tbl <- parallel_shift_tbl |>
  dplyr::select(
    .data$tenor,
    .data$date,
    .data$curve,
    .data$discount,
    .data$zero_rate
  ) |>
  tidyr::pivot_wider(
    names_from = curve,
    values_from = c(
      discount,
      zero_rate
    )
  ) |>
  dplyr::mutate(
    observed_zero_shift_bp =
      10000 * (
        .data$`zero_rate_Base curve + 50bp` -
        .data$`zero_rate_Base curve`
      )
  )


GaussQuant::show_tbl_GQH(
  parallel_shift_wide_tbl,
  "Parallel curve shift",
  n = 30
)

#> # A tibble: 10 x 7
#>   tenor date      `discount_Base curve` `discount_Base curve + 50bp`
#>   <chr> <date>          <dbl>          <dbl>
#> 1 1M      2008-10-18      0.997          0.997
#> 2 3M      2008-12-18      0.992          0.991
#> 3 6M      2009-03-18      0.983          0.981
#> 4 1Y      2009-09-18      0.967          0.962
#> 5 2Y      2010-09-18      0.944          0.935
#> 6 3Y      2011-09-18      0.909          0.897
#> 7 5Y      2013-09-18      0.837          0.820
#> 8 7Y      2015-09-18      0.763          0.743
#> 9 10Y     2018-09-18      0.663          0.642
#> 10 15Y    2023-09-18      0.521          0.502
#> # i 3 more variables: `zero_rate_Base curve` <dbl>,
#> #   `zero_rate_Base curve + 50bp` <dbl>, observed_zero_shift_bp <dbl>

```

```
parallel_shift_plot <- parallel_shift_tbl |>
  ggplot2::ggplot(
    ggplot2::aes(
      x = .data$date,
      y = 100 * .data$zero_rate,
      linetype = .data$curve
    )
  ) +
  ggplot2::geom_line() +
  ggplot2::geom_point() +
  ggplot2::labs(
    title = "Parallel shift of the zero curve",
    x = NULL,
    y = "Continuous zero rate (%)",
    linetype = NULL
  ) +
  ggplot2::theme_minimal()

print(parallel_shift_plot)
```



正の平行シフトでは割引率が上昇し、将来キャッシュフローの割引係数は低下する。そのため、通常の固定キャッシュフロー商品の現在価値も低下する。

実際の市場変動は完全な平行移動とは限らない。短期だけが動く変化、長期だけが動く変化、曲線の傾きが変わるスティーピングまたはフラットニングも生じる。年限別の Key Rate Shift では、特定年限のノードを動かし、周辺年限へ補間しながら再評価する。これらは平行シフトより細かなリスク分解である。

2.4.3 カーブの検証

構築したカーブについて、少なくとも次の点を確認する必要がある。

- 参照日と最終日が想定どおりであること
- 割引係数が正であること
- 欠損値や計算不能な区間がないこと
- ゼロ金利とフォワード金利に不自然な跳びがないこと
- 入力商品の理論価格または理論レートが市場値へ再現されること

まず、例示的なゼロ金利ノードが二つのカーブでどの程度再現されるかを確認する。

```
node_recovery_tbl <- zero_nodes |>
  dplyr::mutate(
    ql_date = purrr::map(
      as.character(.data$date),
      GaussQuant::date_GQL
    ),
    time = as.numeric(
      .data$date -
      as.Date(evaluation_date_chr)
    ) / 365,
    zero_curve_discount = purrr::map_dbl(
      .data$ql_date,
      ~ GaussQuant::curve_discount_safe_GQL(
        zero_curve,
        .x
      )
    ),
    discount_curve_discount = purrr::map_dbl(
      .data$ql_date,
      ~ GaussQuant::curve_discount_safe_GQL(
        discount_curve,
        .x
      )
    ),
    zero_curve_implied_rate = dplyr::if_else(
      .data$time > 0,
      -log(.data$zero_curve_discount) /
        .data$time,
      .data$zero_rate
    ),
    discount_curve_implied_rate = dplyr::if_else(
      .data$time > 0,
```

```

      -log(.data$discount_curve_discount) /
      .data$time,
      .data$zero_rate
    ),
    zero_curve_error =
      .data$zero_curve_implied_rate -
      .data$zero_rate,
    discount_curve_error =
      .data$discount_curve_implied_rate -
      .data$zero_rate
  ) |>
  dplyr::select(
    .data$tenor,
    .data$date,
    .data$zero_rate,
    .data$zero_curve_implied_rate,
    .data$discount_curve_implied_rate,
    .data$zero_curve_error,
    .data$discount_curve_error
  )

GaussQuant::show_tbl_GQH(
  node_recovery_tbl,
  "Node recovery check",
  n = 20
)

#> # A tibble: 9 x 7
#>   tenor date      zero_rate zero_curve_implied_rate discount_curve_implied_rate
#>   <chr> <date>      <dbl>          <dbl>          <dbl>
#> 1 0D    2022-08-19    0.0005          0.0005          0.0005
#> 2 1M    2022-09-19    0.0006          0.000600        0.000600
#> 3 3M    2022-11-21    0.0008          0.000800        0.000800
#> 4 6M    2023-02-20    0.0011          0.00110         0.00110
#> 5 1Y    2023-08-21    0.0018          0.00180         0.00180
#> 6 2Y    2024-08-19    0.0032          0.00320         0.00320
#> 7 3Y    2025-08-19    0.0048          0.00480         0.00480
#> 8 5Y    2027-08-19    0.0075          0.0075          0.0075
#> 9 10Y   2032-08-19    0.0115          0.0115          0.0115
#> # i 2 more variables: zero_curve_error <dbl>, discount_curve_error <dbl>

```

続いて、各カーブを密なグリッドへ展開し、割引係数の範囲と欠損値を確認する。

```

curve_validation_tbl <- dplyr::bind_rows(
  GaussQuant::curve_grid_tbl_GQL(

```

```

    zero_curve,
    n = 200L,
    extrapolate = TRUE
) |>
  dplyr::mutate(
    curve = "ZeroCurve"
  ),
GaussQuant::curve_grid_tbl_GQL(
  discount_curve,
  n = 200L,
  extrapolate = TRUE
) |>
  dplyr::mutate(
    curve = "DiscountCurve"
  ),
GaussQuant::curve_grid_tbl_GQL(
  bond_curve,
  n = 200L,
  extrapolate = TRUE
) |>
  dplyr::mutate(
    curve = "Deposit + bond"
  ),
GaussQuant::curve_grid_tbl_GQL(
  swap_curve,
  n = 200L,
  extrapolate = TRUE
) |>
  dplyr::mutate(
    curve = "Deposit + swap"
  ),
GaussQuant::curve_grid_tbl_GQL(
  spreaded_curve,
  n = 200L,
  extrapolate = TRUE
) |>
  dplyr::mutate(
    curve = "Deposit + swap + 50bp"
  )
) |>
dplyr::group_by(.data$curve) |>
dplyr::summarise(
  first_date = min(

```

```

    .data$curve_date,
    na.rm = TRUE
  ),
  last_date = max(
    .data$curve_date,
    na.rm = TRUE
  ),
  min_discount = min(
    .data$discount_factor,
    na.rm = TRUE
  ),
  max_discount = max(
    .data$discount_factor,
    na.rm = TRUE
  ),
  nonpositive_discount_count = sum(
    .data$discount_factor <= 0,
    na.rm = TRUE
  ),
  missing_discount_count = sum(
    is.na(.data$discount_factor)
  ),
  missing_zero_rate_count = sum(
    is.na(.data$zero_rate)
  ),
  .groups = "drop"
)

GaussQuant::show_tbl_GQH(
  curve_validation_tbl,
  "Curve validation summary",
  n = 20
)

#> # A tibble: 5 x 8
#>   curve   first_date last_date  min_discount max_discount nonpositive_discount~1
#>   <chr>   <date>      <date>      <dbl>         <dbl>              <int>
#> 1 Deposi~ 2008-09-18 2038-05-15      0.260           1                0
#> 2 Deposi~ 2008-09-18 2023-09-18      0.521           1                0
#> 3 Deposi~ 2008-09-18 2023-09-18      0.502           1                0
#> 4 Discou~ 2022-08-19 2032-08-19      0.891           1                0
#> 5 ZeroCu~ 2022-08-19 2032-08-19      0.891           1                0
#> # i abbreviated name: 1: nonpositive_discount_count
#> # i 2 more variables: missing_discount_count <int>,

```

```
#> # missing_zero_rate_count <int>
```

割引係数が正であることは、裁定のない期間構造を確認するための基本条件である。ただし、正の割引係数だけでは十分ではない。入力商品の再評価、補間区間のフォワード金利、外挿方法、日数計算規則および参照日の設定も確認する必要がある。

2.5 国債先物の基礎

株価指数先物では、指数そのものを受け渡すことができないため、満期時には差金決済が行われる。これに対し、国債先物では、満期まで保有された建玉について、受渡適格銘柄に指定された国債を用いた現物受渡しが行われる。現物受渡しを通じて、先物市場と現物国債市場の価格連関が保たれている。

国債先物の取引対象は、実際に発行された特定の国債ではなく、クーポンや償還期限を標準化した標準物である。この標準物は実在しないため、最終決済では、取引所が定めた複数の受渡適格銘柄のいずれかを用いて受渡しを行う。銘柄ごとにクーポン、残存期間および価格が異なるため、その価値の差は変換係数（Conversion Factor: CF）によって調整される。

受渡銘柄を選択する権利は、国債を受け取る買方ではなく、国債を引き渡す売方にある。したがって売方は、受渡適格銘柄の中から、現物価格だけでなく、変換係数、経過利子、クーポン収入および受渡日までの資金調達費用を考慮し、最も低い経済的費用で受け渡すことのできる銘柄を選択する。この銘柄を最割安銘柄（Cheapest-to-Deliver: CTD）という。

CTD は、単純に現物単価が最も低い債券ではない。先物価格に変換係数を乗じて求める受渡価値と、現物債を調達して受渡日まで保有する費用とを比較して決定される。

本章では、受渡適格銘柄ごとに現物価格、グロスベース、キャリー、ネットベースおよびインプライド・レボを計算する。これらの比較を通じて、どのような経済計算によって CTD が選定されるのかを確認し、最後に CTD を基礎とする国債先物の BPV を求める。

```
knitr::opts_chunk$set(
  collapse = TRUE,
  comment = "#>",
  warning = FALSE,
  message = FALSE
)

suppressPackageStartupMessages({
  library(tidyverse)
  library(QuantLib)
  library(GaussQuant)
})
```

2.5.1 計算条件と市場慣行

本章では、米国国債先物を例として計算する。現物国債には米国政府債カレンダーと Actual/Actual (Bond) を使用し、レボ期間には Actual/360 を使用する。現物債の受渡日は取引日の 1 営業日後とする。

米国国債先物の価格は、通常、額面 100 に対するポイントと 32 分の 1 で表示される。たとえば、コード中の $109 + 10 / 32$ は、相場表示では 109-10 に相当する。

```
cal_us_gov <- QuantLib::UnitedStates("GovernmentBond")

dc_act_act_bond <- GaussQuant::day_counter_GQL("ActualActual_Bond")
dc_act_360 <- GaussQuant::day_counter_GQL("Actual360")

compd_compounded <- QuantLib::Compounding_Compounded_get()
freq_semiannual <- QuantLib::Frequency_Semiannual_get()

settlement_days_t1 <- 1L
trade_date_chr <- "2023-04-20"
repo_end_date_chr <- "2023-07-06"

trade_date <- GaussQuant::date_GQL(trade_date_chr)
repo_end_date_ql <- GaussQuant::date_GQL(repo_end_date_chr)

GaussQuant::set_eval_date_GQL(trade_date)

settle_date <- GaussQuant::advance_days_GQL(
  calendar_obj = cal_us_gov,
  date_obj = trade_date,
  n_days = settlement_days_t1
)

settle_date_chr <- as.character(settle_date)
settle_date_ql <- GaussQuant::date_GQL(settle_date_chr)

setup_tbl <- tibble::tribble(
  ~item, ~value,
  "trade_date", trade_date_chr,
  "spot_settlement_date", settle_date_chr,
  "repo_end_date", repo_end_date_chr,
  "settlement_days", as.character(settlement_days_t1),
  "calendar", "UnitedStates(GovernmentBond)",
  "bond_day_counter", "ActualActual(Bond)",
  "repo_day_counter", "Actual360",
  "compounding", "Compounded",
  "frequency", "Semiannual"
)

GaussQuant::show_tbl_GQH(setup_tbl, "Treasury futures setup")
#> # A tibble: 9 x 2
```

```

#>   item                value
#>   <chr>                <chr>
#> 1 trade_date          2023-04-20
#> 2 spot_settlement_date 2023-04-21
#> 3 repo_end_date        2023-07-06
#> 4 settlement_days      1
#> 5 calendar             UnitedStates(GovernmentBond)
#> 6 bond_day_counter     ActualActual(Bond)
#> 7 repo_day_counter     Actual360
#> 8 compounding          Compounded
#> 9 frequency            Semiannual

```

2.5.2 受渡適格国債

最初に、受渡適格銘柄の例となる米国国債を作成する。発行日、償還日、クーポンおよび利払スケジュールは、現物価格、経過利子、キャリアおよび BPV を計算する基礎となる。

次のコードでは、年率 4.125%、年 2 回払いの米国国債を作成し、利払スケジュールを確認する。あわせて、利回り 6% を仮定した場合のクリーン価格を計算する。

```

bond_bundle <- GaussQuant::us_treasury_bond_GQL(
  effective_date = "2022-09-30",
  maturity_date = "2027-09-30",
  coupon_rate_pct = 4.125,
  face_amount = 100,
  settlement_days = settlement_days_t1,
  calendar = cal_us_gov,
  day_counter = dc_act_act_bond
)

bond_obj <- bond_bundle$bond

GaussQuant::show_tbl_GQH(
  GaussQuant::schedule_dates_GQL(bond_bundle$schedule),
  "US Treasury bond schedule",
  n = 20
)
#> # A tibble: 11 x 1
#>   schedule_date
#>   <date>
#> 1 2022-09-30
#> 2 2023-03-30
#> 3 2023-09-30
#> 4 2024-03-30

```

```
#> 5 2024-09-30
#> 6 2025-03-30
#> 7 2025-09-30
#> 8 2026-03-30
#> 9 2026-09-30
#> 10 2027-03-30
#> 11 2027-09-30

clean_price_at_six_percent <- GaussQuant::bond_clean_price_from_yield_safe_GQL(
  bond = bond_obj,
  yield_rate = 6 / 100,
  day_counter = dc_act_act_bond,
  compounding = compd_compounded,
  frequency = freq_semiannual,
  settlement_date = GaussQuant::date_GQL("2023-07-06")
)

cat(
  "Yield 6%, settle 2023-07-06 clean price:",
  GaussQuant::fmt_num_GQH(clean_price_at_six_percent, 4),
  "\n"
)
#> Yield 6%, settle 2023-07-06 clean price: 93.07
```

2.5.3 現物債評価

CTD 分析では、現物債を取得するために必要な資金を把握する必要がある。市場利回りからクリーン価格を求め、受渡日までの経過利子を加えると、実際の決済金額に対応するダーティ価格が得られる。

$$\text{ダーティ価格} = \text{クリーン価格} + \text{経過利子}$$

先物価格には 109-10、現物債の市場利回りには 3.70% を用いる。

```
bond_yield <- 3.70 / 100
futures_price <- 109 + 10 / 32

accrued_amount <- bond_obj$accruedAmount(settle_date_ql)
clean_price <- GaussQuant::bond_clean_price_from_yield_safe_GQL(
  bond = bond_obj,
  yield_rate = bond_yield,
  day_counter = dc_act_act_bond,
  compounding = compd_compounded,
  frequency = freq_semiannual,
```

```

    settlement_date = settle_date_ql
  )

dirty_price <- clean_price + accrued_amount

price_tbl <- tibble::tibble(
  trade_date = as.Date(trade_date_chr),
  settlement_date = as.Date(settle_date_chr),
  yield = bond_yield,
  accrued_amount = accrued_amount,
  clean_price = clean_price,
  dirty_price = dirty_price,
  futures_price = futures_price
)

GaussQuant::show_tbl_GQH(price_tbl, "Bond price from yield")
#> # A tibble: 1 x 7
#>   trade_date settlement_date yield accrued_amount clean_price dirty_price
#>   <date>      <date>      <dbl>         <dbl>         <dbl>      <dbl>
#> 1 2023-04-20 2023-04-21    0.037          0.247          102.       102.
#> # i 1 more variable: futures_price <dbl>

cat(
  "Yield:",
  sprintf("%.8f", bond_yield),
  "\nClean price:",
  sprintf("%.8f", clean_price),
  "\nDirty price:",
  sprintf("%.8f", dirty_price),
  "\nAccrued amount:",
  sprintf("%.8f", accrued_amount),
  "\n"
)
#> Yield: 0.03700000
#> Clean price: 101.72260614
#> Dirty price: 101.96920940
#> Accrued amount: 0.24660326

```

2.5.4 キャッシュフロー検証

次の計算では、各キャッシュフローへ一般的な割引係数を適用し、現在価値の合計と債券価格を比較する。

ただし、Actual/Actual (Bond) は利払参照期間を用いるため、ここで作成する一般的な割引係数は、QuantLib による債券利回り計算を完全には再現しない。この表は、債券価格が将来キャッシュフローの現在価値から構

成されることを確認するためのものであり、差額がゼロになることを目的とした検算ではない。

```
interest_rate_obj <- QuantLib::InterestRate(
  bond_yield,
  dc_act_act_bond,
  compd_compounded,
  freq_semiannual
)

settle_date_r <- as.Date(settle_date_chr)

bond_cf_tbl <- GaussQuant::bond_cashflow_table_GQL(bond_obj) |>
  dplyr::mutate(
    pay_date = as.Date(.data$date),
    discount_factor = purrr::map_dbl(
      as.character(.data$pay_date),
      function(x) {
        if (as.Date(x) < settle_date_r) {
          return(NA_real_)
        }

        tryCatch(
          interest_rate_obj$discountFactor(
            settle_date_ql,
            GaussQuant::date_GQL(x)
          ),
          error = function(e) NA_real_
        )
      }
    ),
    pv = .data$amount * .data$discount_factor
  ) |>
  dplyr::select(
    .data$pay_date,
    .data$amount,
    .data$discount_factor,
    .data$pv
  )

cashflow_pv <- sum(bond_cf_tbl$pv, na.rm = TRUE)

cashflow_check_tbl <- tibble::tribble(
  ~metric, ~value,
  "cashflow_present_value", cashflow_pv,
```

```

"dirty_price_from_yield", dirty_price,
"illustrative_difference", cashflow_pv - dirty_price
)

GaussQuant::show_tbl_GQH(bond_cf_tbl, "Bond cashflow present-value table", n = 20)
#> # A tibble: 11 x 4
#>   pay_date    amount discount_factor    pv
#>   <date>      <dbl>          <dbl> <dbl>
#> 1 2023-03-30    2.06             NA     NA
#> 2 2023-10-02    2.06             0.985  2.03
#> 3 2024-04-01    2.06             0.967  1.99
#> 4 2024-09-30    2.06             0.949  1.96
#> 5 2025-03-31    2.06             0.932  1.92
#> 6 2025-09-30    2.06             0.915  1.89
#> 7 2026-03-30    2.06             0.899  1.85
#> 8 2026-09-30    2.06             0.882  1.82
#> 9 2027-03-30    2.06             0.866  1.79
#> 10 2027-09-30    2.06             0.851  1.75
#> 11 2027-09-30  100             0.851 85.1

GaussQuant::show_tbl_GQH(
  GaussQuant::metric_tbl_display_GQH(cashflow_check_tbl),
  "Cashflow PV illustration"
)
#> # A tibble: 3 x 2
#>   metric                value
#>   <chr>                <chr>
#> 1 cashflow_present_value 102.05828711
#> 2 dirty_price_from_yield 101.96920940
#> 3 illustrative_difference 0.08907771

```

2.5.5 経過利子

経過利子は、直前利払日から受渡日までに発生したクーポンを日割りして求める。Actual/Actual (Bond) では、経過日数を利払期間の実日数で除してクーポンを按分する。

$$\text{経過利子} = 1 \text{ 回分のクーポン} \times \frac{\text{経過日数}}{\text{利払期間の日数}}$$

手計算結果と QuantLib の結果との差を確認する。

```

previous_coupon_date <- GaussQuant::date_GQL("2023-03-30")
next_coupon_date <- GaussQuant::date_GQL("2023-09-30")

accrued_days_hand <- dc_act_act_bond$dayCount(

```

```

previous_coupon_date,
settle_date_ql
)

coupon_period_days <- dc_act_act_bond$dayCount(
  previous_coupon_date,
  next_coupon_date
)

coupon_amount_semiannual <- 4.125 / 2

accrued_interest_hand <- coupon_amount_semiannual *
  accrued_days_hand /
  coupon_period_days

accrued_tbl <- tibble::tibble(
  previous_coupon_date = as.Date(GaussQuant::iso_GQL(previous_coupon_date)),
  settlement_date = as.Date(settle_date_chr),
  next_coupon_date = as.Date(GaussQuant::iso_GQL(next_coupon_date)),
  accrued_days = accrued_days_hand,
  coupon_period_days = coupon_period_days,
  coupon_amount = coupon_amount_semiannual,
  accrued_interest_hand = accrued_interest_hand,
  accrued_amount_quantlib = accrued_amount,
  difference = accrued_interest_hand - accrued_amount
)

GaussQuant::show_tbl_GQH(accrued_tbl, "Accrued interest hand calculation")
#> # A tibble: 1 x 9
#>   previous_coupon_date settlement_date next_coupon_date accrued_days
#>   <date>                <date>          <date>          <int>
#> 1 2023-03-30          2023-04-21      2023-09-30           22
#> # i 5 more variables: coupon_period_days <int>, coupon_amount <dbl>,
#> #   accrued_interest_hand <dbl>, accrued_amount_quantlib <dbl>,
#> #   difference <dbl>

```

2.6 CTD 分析と先物 BPV

2.6.1 受渡適格銘柄と変換係数

国債先物では、複数の受渡適格銘柄が存在する。各銘柄はクーポンや残存期間が異なるため、そのままでは同じ先物価格に対して比較できない。そこで、各銘柄へ変換係数を適用し、標準物に対する相対的な受渡価値を調整する。

受渡時に買方が売方へ支払う金額は、概念的には次式で表される。

$$\text{インボイス価格} = \text{先物価格} \times \text{変換係数} + \text{受渡時経過利子}$$

ここでいう CF は Conversion Factor の略であり、キャッシュフローを意味する CF とは区別する。

次の表では、3 銘柄の発行日、償還日、クーポン、変換係数および市場利回りを設定する。

```
deliverable_tbl <- tibble::tribble(
  ~issue_date, ~maturity_date, ~coupon_rate_pct, ~conversion_factor, ~market_yield_pct,
  "2022-09-30", "2027-09-30", 4.125, 0.9305, 3.70,
  "2022-08-31", "2027-08-31", 3.125, 0.8953, 3.69,
  "2023-01-31", "2028-01-31", 3.500, 0.9011, 3.65
)

GaussQuant::show_tbl_GQH(deliverable_tbl, "Treasury futures deliverable basket")
#> # A tibble: 3 x 5
#>   issue_date maturity_date coupon_rate_pct conversion_factor market_yield_pct
#>   <chr>         <chr>         <dbl>         <dbl>         <dbl>
#> 1 2022-09-30 2027-09-30         4.12         0.930         3.7
#> 2 2022-08-31 2027-08-31         3.12         0.895         3.69
#> 3 2023-01-31 2028-01-31         3.5         0.901         3.65
```

2.6.2 グロスベースス

グロスベーススは、現物債のクリーン価格と、変換係数で調整した先物価格との差である。

$$\text{グロスベースス} = \text{現物クリーン価格} - \text{先物価格} \times \text{変換係数}$$

グロスベーススが小さい銘柄ほど受渡しに有利に見えるが、この段階では受渡日までの資金調達費用、クーポン収入および経過利子の変化を考慮していない。

2.6.3 キャリーとネットベースス

現物債を購入して受渡日まで保有する場合、レポによる資金調達費用が発生する一方、保有期間中にはクーポン収入や経過利子の増加が得られる。これらをまとめたものがキャリーである。

概念的には、ネットベーススは次式で表される。

$$\text{ネットベースス} = \text{グロスベースス} - \text{キャリー}$$

同一の前提条件で比較した場合、一般にネットベーススが最も小さい銘柄が CTD となる。

2.6.4 インプライド・レポ

インプライド・レポは、現物債を購入し、レポで資金調達して受渡日まで保有し、先物契約へ受け渡す取引から得られる収益率である。

ネットベーススが受渡コストの大きさを表すのに対し、インプライド・レポは同じ取引を収益率として表す。通常、ネットベーススが最小となる銘柄と、インプライド・レポが最大となる銘柄は一致する。

次のコードでは、各受渡適格銘柄について現物価格、BPV、グロスベースス、キャリー、ネットベーススおよびインプライド・レポを計算し、CTD を選定する。

```
repo_rate <- 5.10 / 100

repo_days <- dc_act_360$dayCount(
  settle_date_ql,
  repo_end_date_ql
)

repo_year_fraction <- dc_act_360$yearFraction(
  settle_date_ql,
  repo_end_date_ql
)

ctd_result <- GaussQuant::bond_futures_ctd_table_GQL(
  deliverable_tbl = deliverable_tbl,
  settlement_date = settle_date_chr,
  futures_price = futures_price,
  repo_end_date = repo_end_date_chr,
  repo_rate = repo_rate,
  settlement_days = settlement_days_t1,
  calendar = cal_us_gov,
  day_counter = dc_act_act_bond,
  compounding = cmpd_compounded,
  frequency = freq_semiannual,
  repo_day_counter = dc_act_360,
  carry_day_counter = dc_act_360
)

basket_tbl <- ctd_result$basket

gross_basis_tbl <- basket_tbl |>
  dplyr::select(
    .data$issue_date,
    .data$maturity,
```

```

        .data$coupon,
        .data$yield_pct,
        .data$bpv,
        .data$clean_price,
        .data$dirty_price,
        .data$conversion_factor,
        .data$gross_basis
    )

net_basis_tbl <- basket_tbl |>
  dplyr::select(
    .data$maturity,
    .data$conversion_factor,
    .data$gross_basis,
    .data$accrued_start,
    .data$accrued_end,
    .data$coupon_income,
    .data$repo_cost,
    .data$carry,
    .data$net_basis,
    .data$forward_price,
    .data$implied_repo,
    .data$ctd
  )

basket_display_tbl <- basket_tbl |>
  dplyr::select(-dplyr::any_of("bond_obj"))

ctd_tbl <- ctd_result$ctd
ctd_display_tbl <- ctd_tbl |>
  dplyr::select(-dplyr::any_of("bond_obj"))

stopifnot(
  nrow(ctd_tbl) == 1L,
  isTRUE(ctd_tbl$ctd[[1L]])
)

cat(
  "Futures price:",
  sprintf("%.6f", futures_price),
  "\nRepo rate:",
  sprintf("%.6f", repo_rate),
  "\nRepo days:",

```

```

repo_days,
"\nRepo year fraction:",
sprintf("%.8f", repo_year_fraction),
"\n"
)
#> Futures price: 109.312500
#> Repo rate: 0.051000
#> Repo days: 76
#> Repo year fraction: 0.21111111

GaussQuant::show_tbl_GQH(gross_basis_tbl, "Gross basis table", n = 20)
#> # A tibble: 3 x 9
#>   issue_date maturity   coupon yield_pct   bpv clean_price dirty_price
#>   <chr>      <chr>      <dbl>   <dbl> <dbl>   <dbl>   <dbl>
#> 1 2022-09-30 2027-09-30 0.0412     3.7 0.0410     102.     102.
#> 2 2022-08-31 2027-08-31 0.0312     3.69 0.0394     97.7     98.2
#> 3 2023-01-31 2028-01-31 0.035      3.65 0.0433     99.3     100.
#> # i 2 more variables: conversion_factor <dbl>, gross_basis <dbl>
GaussQuant::show_tbl_GQH(net_basis_tbl, "Net basis and implied repo table", n = 20)
#> # A tibble: 3 x 12
#>   maturity conversion_factor gross_basis accrued_start accrued_end coupon_income
#>   <chr>          <dbl>      <dbl>      <dbl>      <dbl>      <dbl>
#> 1 2027-09~      0.930      0.00732      0.247      1.10      0.852
#> 2 2027-08~      0.895     -0.128      0.442      1.09      0.645
#> 3 2028-01~      0.901      0.841      0.773      1.51      0.735
#> # i 6 more variables: repo_cost <dbl>, carry <dbl>, net_basis <dbl>,
#> #   forward_price <dbl>, implied_repo <dbl>, ctd <lg1>
GaussQuant::show_tbl_GQH(basket_display_tbl, "Deliverable basket summary", n = 20)
#> # A tibble: 3 x 18
#>   issue_date maturity   coupon yield_pct   bpv clean_price dirty_price
#>   <chr>      <chr>      <dbl>   <dbl> <dbl>   <dbl>   <dbl>
#> 1 2022-09-30 2027-09-30 0.0412     3.7 0.0410     102.     102.
#> 2 2022-08-31 2027-08-31 0.0312     3.69 0.0394     97.7     98.2
#> 3 2023-01-31 2028-01-31 0.035      3.65 0.0433     99.3     100.
#> # i 11 more variables: conversion_factor <dbl>, gross_basis <dbl>,
#> #   accrued_start <dbl>, accrued_end <dbl>, coupon_income <dbl>,
#> #   repo_cost <dbl>, carry <dbl>, net_basis <dbl>, forward_price <dbl>,
#> #   implied_repo <dbl>, ctd <lg1>
GaussQuant::show_tbl_GQH(ctd_display_tbl, "Cheapest-to-deliver bond", n = 20)
#> # A tibble: 1 x 18
#>   issue_date maturity   coupon yield_pct   bpv clean_price dirty_price
#>   <chr>      <chr>      <dbl>   <dbl> <dbl>   <dbl>   <dbl>
#> 1 2022-09-30 2027-09-30 0.0412     3.7 0.0410     102.     102.

```

```
#> # i 11 more variables: conversion_factor <dbl>, gross_basis <dbl>,
#> #   accrued_start <dbl>, accrued_end <dbl>, coupon_income <dbl>,
#> #   repo_cost <dbl>, carry <dbl>, net_basis <dbl>, forward_price <dbl>,
#> #   implied_repo <dbl>, ctd <lgl>
```

結果では、現物価格だけでなく、変換係数とキャリーを反映したネットベーススを比較する。ctd が TRUE となった銘柄が、本章の条件における最割安銘柄である。インプライド・レポもあわせて確認し、CTD 選定と整合しているかを見る。

2.6.5 CTD 調整後の先物 BPV

国債先物の金利感応度は、CTD 債券の BPV を変換係数で調整して概算する。

$$\text{先物 BPV} \approx \frac{\text{CTD 債券の BPV}}{\text{変換係数}}$$

この計算は、金利が小幅に変化しても現在の CTD が変わらないことを前提とする。金利水準やイールドカーブの形状が大きく変化すると、別の受渡適格銘柄が CTD となる可能性がある。そのため、国債先物のリスクは、現在の CTD 債券の感応度だけでなく、CTD が切り替わる可能性にも依存する。

```
ctd_bond <- ctd_tbl$bond_obj[[1L]]
ctd_conversion_factor <- ctd_tbl$conversion_factor[[1L]]
ctd_yield <- ctd_tbl$yield_pct[[1L]] / 100

ctd_futures_bpv <- GaussQuant::bond_futures_bpv_GQL(
  bond = ctd_bond,
  conversion_factor = ctd_conversion_factor,
  contracts = 1,
  measure = "dv01",
  ytm = ctd_yield,
  day_counter = dc_act_act_bond,
  compounding = cmpd_compounded,
  frequency = freq_semiannual
)

ctd_summary_tbl <- tibble::tibble(
  metric = c(
    "ctd_maturity",
    "ctd_coupon",
    "ctd_yield_pct",
    "conversion_factor",
    "gross_basis",
    "net_basis",
    "implied_repo",
    "ctd_bond_bpv",
```

```

    "ctd_futures_bpv"
  ),
  value = list(
    as.character(ctd_tbl$maturity[[1L]]),
    ctd_tbl$coupon[[1L]],
    ctd_tbl$yield_pct[[1L]],
    ctd_conversion_factor,
    ctd_tbl$gross_basis[[1L]],
    ctd_tbl$net_basis[[1L]],
    ctd_tbl$implied_repo[[1L]],
    ctd_tbl$bpv[[1L]],
    ctd_futures_bpv
  )
)

GaussQuant::show_tbl_GQH(
  GaussQuant::metric_tbl_display_GQH(ctd_summary_tbl),
  "CTD and futures BPV summary"
)

#> # A tibble: 9 x 2
#>   metric      value
#>   <chr>      <chr>
#> 1 ctd_maturity 2027-09-30
#> 2 ctd_coupon  0.04125000
#> 3 ctd_yield_pct 3.70000000
#> 4 conversion_factor 0.93050000
#> 5 gross_basis  0.00732489
#> 6 net_basis    0.25329120
#> 7 implied_repo 0.03923370
#> 8 ctd_bond_bpv 0.04101840
#> 9 ctd_futures_bpv 0.04408210

```

2.7 まとめ

本章では、金利期間構造を割引係数、ゼロ金利およびフォワード金利の三つの表現から確認した。これらは同じカーブを表すが、補間方式の影響はフォワード金利に強く現れる。

また、ゼロ金利ノードから直接構築する方法に加え、預金と債券、ならびに預金とスワップを用いたブートストラップを確認した。市場商品から構築したカーブでは、各商品の価格計算、市場慣行および日数計算規則が期間構造へ組み込まれる。

さらに、固定参照日、Implied Term Structure および平行シフトを確認した。カーブを評価へ使用する際には、単にカーブオブジェクトを作成するだけでなく、参照日、補間方式、外挿、入力商品の再現性およびフォワード金利の形状を検証する必要がある。国債先物では、売方が複数の受渡適格銘柄から実際に引き渡す銘柄

を選択する。銘柄間のクーポンや残存期間の差は変換係数によって調整されるが、変換係数だけで経済価値の差が完全に解消されるわけではない。

そのため、CTD の選定では、現物価格と変換係数から求めるグロスベースに加え、レボ費用、クーポン収入および経過利子の変化を反映したキャリーを考慮する。ネットベースが最小、またはインプライド・レボが最大となる銘柄が、売方にとって最も有利な受渡銘柄となる。

国債先物の BPV は、CTD 債券の BPV と変換係数に依存する。ただし、市場環境の変化によって CTD が切り替わる可能性があるため、国債先物のリスク管理では受渡銘柄選択権も考慮する必要がある。

第 II-3 章 OIS スワップとマルチカーブ評価

3.1 IBOR 改革と OIS の基礎

3.1.1 IBOR 改革と歴史的背景

2007 年から 2009 年にかけての世界金融危機、とりわけ 2008 年 9 月のリーマン・ブラザーズ破綻は、金利デリバティブの評価方法を大きく変化させた。それ以前の市場では、LIBOR は信用リスクをほとんど含まない基準金利として扱われ、同一の LIBOR カーブから将来の変動金利を予測すると同時に、将来キャッシュフローの現在価値を計算するシングルカーブ評価が広く用いられていた。

しかし、LIBOR は銀行間の無担保資金調達金利である。したがって、LIBOR には将来の短期金利に対する市場予想だけでなく、借り手銀行の信用リスク、資金流動性リスクおよび借入期間に応じたプレミアムが含まれる。金融危機時に LIBOR と OIS 金利の差が急拡大したことにより、LIBOR を信用リスクのない割引金利として扱うことができないことが明らかになった。

この認識を背景として、デリバティブ市場では中央清算および担保契約の利用が拡大した。担保付取引では、担保に付される翌日物金利に近い OIS カーブを用いて将来キャッシュフローを割り引くことが経済的に整合的である。一方、LIBOR、TIBOR または EURIBOR などを参照する契約の将来変動金利は、それぞれの参照金利に対応するフォワードカーブから予測する必要がある。その結果、将来金利を予測するカーブと現在価値を求めるディスカウントカーブを分離するマルチカーブ評価が定着した。

ここで、「担保付取引への移行」と「翌日物指標の性質」は区別する必要がある。米ドルの SOFR は米国債レポ取引に基づく有担保翌日物金利であるのに対し、日本円の TONA は無担保コール市場の翌日物金利である。いずれも翌日物のリスク・フリー・レートに近い指標として用いられるが、基礎となる市場の担保性は同一ではない。

さらに、LIBOR の不正操作および虚偽報告が明らかになり、銀行の判断に大きく依存する金利指標の信頼性が損なわれた。金融安定理事会は 2014 年、既存 IBOR の強化と、実取引に基づく代替的なリスク・フリー・レートの育成を提言した。2017 年には、英国の金融行為規制機構である FCA が、2021 年末以降も銀行へ LIBOR の呈示を求め続けることはないとの方針を示した。

代表性のある円、ポンド、ユーロおよびスイスフラン LIBOR の多くは 2021 年末に終了し、米ドル LIBOR の銀行パネルも 2023 年 6 月 30 日に終了した。経過措置として残された合成 LIBOR も 2024 年 9 月 30 日に最終公表され、すべての LIBOR 設定が恒久的に終了した。

LIBOR に代わる主要な指標として、日本円では TONA、米ドルでは SOFR が採用された。これらの翌日物金利を参照する OIS では、通常、計算期間中の日次金利を後決めて複利計算する。そのため、LIBOR のように期間開始時点で適用金利が確定する取引とは異なり、期間全体の金利と利息額が確定するのは期末近くとなる。日次金利の公表時刻、Fixing が利用可能になるまでの時間差、計算終了日から支払日までの事務処理期間

は、新たなオペレーショナル・リスクとして管理する必要がある。

以上の IBOR 改革によって、金利デリバティブ評価は、単一の LIBOR カーブですべてを処理する方法から、翌日物金利を基礎とする OIS カーブを割引に用い、参照金利ごとに将来金利を予測する方法へ移行した。

本章では、この歴史的変化を踏まえ、日本円の TONA および米ドルの SOFR を参照する OIS を取り上げる。まず市場レートから OIS カーブを構築し、固定レグと翌日物変動レグを評価する。次に、変動レグを日次金利へ分解し、Fixing の確定前後で評価額がどのように変化するかを確認する。最後に、将来金利を予測するカーブとキャッシュフローを割引くカーブを分離し、マルチカーブ評価の基本構造を示す。

```
knitr::opts_chunk$set(
  collapse = TRUE,
  comment = "#>",
  warning = FALSE,
  message = FALSE
)

suppressPackageStartupMessages({
  library(tidyverse)
  library(ggthemes)
  library(QuantLib)
  library(GaussQuant)
  library(tidyverse)
  library(broom)
})
```

3.1.2 OIS と翌日物金利

OIS (Overnight Index Swap) は、あらかじめ定めた固定金利と、計算期間中の翌日物金利を複利で積み上げた変動金利を交換する金利スワップである。元本そのものは交換せず、通常は固定レグと変動レグの利息差額を決済する。

日次金利を r_i 、その金利が適用される日数を d_i 、日数計算の年間基準を B とすると、計算期間全体の複利収益率は概念的に次式で表される。

$$R_{\text{comp}} = \prod_{i=1}^n \left(1 + r_i \frac{d_i}{B} \right) - 1$$

元本を N とすると、変動レグの利息額は次式となる。

$$I_{\text{overnight}} = NR_{\text{comp}}$$

固定金利を K 、固定レグの年率換算期間を α とすると、固定レグの利息額は次式となる。

$$I_{\text{fixed}} = NK\alpha$$

固定金利を支払う OIS の価値は、変動レグの現在価値から固定レグの現在価値を差し引いて求める。

$$PV_{\text{OIS}} = PV_{\text{overnight}} - PV_{\text{fixed}}$$

契約締結時に両レグの現在価値を等しくする固定金利がフェア OIS レートである。

以下では、カーブを表形式で確認するための補助関数を定義する。これは計算ロジックを新たに実装するものではなく、QuantLib のカーブから割引係数と連続複利ゼロ金利を取り出す表示用関数である。

```
curve_tbl_local <- function(curve_obj, n = 200, extrapolate = TRUE) {
  if (extrapolate) {
    QuantLib::TermStructure_enableExtrapolation(curve_obj)
  }

  reference_date <- as.Date(
    GaussQuant::iso_GQL(curve_obj$referenceDate())
  )

  curve_times <- seq(
    from = 0,
    to = curve_obj$maxTime(),
    length.out = n
  )

  tibble::tibble(time = curve_times) |>
  dplyr::mutate(
    discount_factor = purrr::map_dbl(
      time,
      function(x) curve_obj$discount(x)
    ),
    zero_rate = dplyr::if_else(
      time > 0,
      -log(discount_factor) / time,
      0
    ),
    date = reference_date + round(time * 365)
  ) |>
  dplyr::select(
    date,
    time,
    discount_factor,
    zero_rate
  )
}
```

3.2 TONA カーブと短期 OIS 評価

TONA は、日本の無担保コール市場における翌日物金利を基礎とする円のリスク・フリー・レートである。本節では、2022 年 8 月 19 日の例示的な TONA および OIS 市場レートから、円 OIS カーブを構築する。

短期部分には翌日物金利や短期 OIS を使用し、中長期部分には各満期の OIS スワップレートを使用する。ブートストラップでは、各市場商品の理論価格が市場価格と一致するように、満期ごとの割引係数を順次決定する。

3.2.1 TONA 市場レート

```
trade_date_tona <- "2022-08-19"

GaussQuant::set_eval_date_GQL(trade_date_tona)

tona_quotes <- tibble::tribble(
  ~as_of_date, ~currency, ~instrument, ~kind, ~tenor, ~rate,
  as.Date(trade_date_tona), "JPY", "TONA", "depo", "1D", -0.0000900,
  as.Date(trade_date_tona), "JPY", "TONA", "ois", "1W", -0.0001261,
  as.Date(trade_date_tona), "JPY", "TONA", "ois", "2W", -0.0001469,
  as.Date(trade_date_tona), "JPY", "TONA", "ois", "1M", -0.0001807,
  as.Date(trade_date_tona), "JPY", "TONA", "ois", "3M", -0.0001919,
  as.Date(trade_date_tona), "JPY", "TONA", "ois", "6M", -0.0001043,
  as.Date(trade_date_tona), "JPY", "TONA", "ois", "9M", 0.0000022,
  as.Date(trade_date_tona), "JPY", "TONA", "ois", "12M", 0.0001250,
  as.Date(trade_date_tona), "JPY", "TONA", "ois", "18M", 0.0003125,
  as.Date(trade_date_tona), "JPY", "TONA", "ois", "2Y", 0.0004875,
  as.Date(trade_date_tona), "JPY", "TONA", "ois", "3Y", 0.0007375,
  as.Date(trade_date_tona), "JPY", "TONA", "ois", "4Y", 0.0009479,
  as.Date(trade_date_tona), "JPY", "TONA", "ois", "5Y", 0.0011854,
  as.Date(trade_date_tona), "JPY", "TONA", "ois", "7Y", 0.0019146
)

GaussQuant::show_tbl_GQH(
  tona_quotes,
  "TONA market quotes",
  n = 20
)

#> # A tibble: 14 x 6
#>   as_of_date currency instrument kind tenor      rate
#>   <date>      <chr>    <chr>    <chr> <chr>    <dbl>
#> 1 2022-08-19 JPY      TONA      depo  1D      -0.00009
#> 2 2022-08-19 JPY      TONA      ois    1W      -0.000126
```

```
#> 3 2022-08-19 JPY      TONA      ois  2W   -0.000147
#> 4 2022-08-19 JPY      TONA      ois  1M   -0.000181
#> 5 2022-08-19 JPY      TONA      ois  3M   -0.000192
#> 6 2022-08-19 JPY      TONA      ois  6M   -0.000104
#> 7 2022-08-19 JPY      TONA      ois  9M    0.0000022
#> 8 2022-08-19 JPY      TONA      ois 12M    0.000125
#> 9 2022-08-19 JPY      TONA      ois 18M    0.000312
#>10 2022-08-19 JPY      TONA      ois  2Y    0.000488
#>11 2022-08-19 JPY      TONA      ois  3Y    0.000738
#>12 2022-08-19 JPY      TONA      ois  4Y    0.000948
#>13 2022-08-19 JPY      TONA      ois  5Y    0.00119
#>14 2022-08-19 JPY      TONA      ois  7Y    0.00191
```

3.2.2 TONA OIS カーブの構築

```
tona_curve_envs <- GaussQuant::ir_build_ois_curve_envs_GQH(
  quotes = tona_quotes,
  trade_date = trade_date_tona,
  verbose = TRUE
)

tona_curve_env <- tona_curve_envs[["JPY::TONA"]]
tona_curve <- tona_curve_env$curve

tona_curve_display_tbl <- curve_tbl_local(
  curve_obj = tona_curve,
  n = 200
)

GaussQuant::show_tbl_GQH(
  tona_curve_display_tbl,
  "TONA OIS curve",
  n = 12
)

#> # A tibble: 12 x 4
#>   date          time discount_factor zero_rate
#>   <date>        <dbl>          <dbl>     <dbl>
#> 1 2022-08-23  0              1         0
#> 2 2022-09-05  0.0352          1.00 -0.000145
#> 3 2022-09-18  0.0704          1.00 -0.000173
#> 4 2022-10-01  0.106           1.00 -0.000183
#> 5 2022-10-13  0.141           1.00 -0.000187
#> 6 2022-10-26  0.176           1.00 -0.000189
```

```
#> 7 2022-11-08 0.211 1.00 -0.000191
#> 8 2022-11-21 0.246 1.00 -0.000192
#> 9 2022-12-04 0.282 1.00 -0.000175
#> 10 2022-12-17 0.317 1.00 -0.000157
#> 11 2022-12-29 0.352 1.00 -0.000143
#> 12 2023-01-11 0.387 1.00 -0.000132

tona_curve_check_tbl <- tibble::tibble(
  reference_date = GaussQuant::iso_GQL(
    tona_curve$referenceDate()
  ),
  discount_2022_08_23 = tona_curve$discount(
    GaussQuant::date_GQL("2022-08-23")
  )
)

GaussQuant::show_tbl_GQH(
  tona_curve_check_tbl,
  "TONA curve checks",
  n = 20
)

#> # A tibble: 1 x 2
#>   reference_date discount_2022_08_23
#>   <chr> <dbl>
#> 1 2022-08-23 1
```

割引係数 $P(0, T)$ は、将来時点 T の 1 円を評価日時点の価値へ換算する係数である。満期が長くなるほど、通常は割引係数が低下する。ゼロ金利は、各満期の割引係数を単一の金利として表したものである。

3.2.3 JPY 短期 OIS の評価

次に、TONA カーブを用いて短期円 OIS を評価する。評価対象は、2022 年 8 月 23 日から 8 月 30 日までの 7 日間、元本 1,000 万円、固定金利マイナス 0.015% の固定金利支払い OIS である。

OIS の固定レグと翌日物レグを確認し、NPV とフェアレートを表示する。

```
jpy_ois_short <- GaussQuant::trade_ois_swap_py_GQH(
  curve_env = tona_curve_env,
  effective = "2022-08-23",
  maturity = "2022-08-30",
  notional = 10000000,
  fixed_rate = -0.00015,
  pay_receive = "pay",
  verbose = TRUE
)
```

```

GaussQuant::ir_show_swap_summary_GQH(
  trade_env = jpy_ois_short,
  title = "JPY short OIS summary"
)

jpy_ois_fixed_cf_tbl <- GaussQuant::swap_fixed_leg_table_GQL(
  jpy_ois_short$swap
)

jpy_ois_overnight_cf_tbl <- GaussQuant::ois_overnight_leg_table_GQL(
  jpy_ois_short$swap
)

GaussQuant::show_tbl_GQH(
  jpy_ois_fixed_cf_tbl,
  "TONA fixed leg cashflows",
  n = 10
)
#> # A tibble: 1 x 2
#>   date      amount
#>   <chr>      <dbl>
#> 1 2022-08-30 -28.8

GaussQuant::show_tbl_GQH(
  jpy_ois_overnight_cf_tbl,
  "TONA overnight leg cashflows",
  n = 10
)
#> # A tibble: 1 x 2
#>   date      amount
#>   <chr>      <dbl>
#> 1 2022-08-30 -24.2

```

3.2.4 フェアレートの手計算

単一期間の OIS では、開始日の割引係数を $P(0, T_0)$ 、終了日の割引係数を $P(0, T_1)$ 、固定レグの支払日の割引係数を $P(0, T_p)$ 、固定レグの年率換算期間を α とすると、フェアレートは概念的に次式で求められる。

$$K_{\text{fair}} = \frac{P(0, T_0) - P(0, T_1)}{\alpha P(0, T_p)}$$

```

jpy_effective_df <- tona_curve$discount(
  GaussQuant::date_GQL("2022-08-23")
)

```

```

)

jpy_maturity_df <- tona_curve$discount(
  GaussQuant::date_GQL("2022-08-30")
)

jpy_payment_df <- tona_curve$discount(
  GaussQuant::date_GQL("2022-09-01")
)

jpy_annuity <- (7 / 365) * jpy_payment_df

jpy_swap_rate_hand <- (
  jpy_effective_df - jpy_maturity_df
) / jpy_annuity

jpy_fair_rate_check_tbl <- tibble::tibble(
  effective_discount_factor = jpy_effective_df,
  maturity_discount_factor = jpy_maturity_df,
  payment_discount_factor = jpy_payment_df,
  annuity = jpy_annuity,
  fair_swap_rate_hand = jpy_swap_rate_hand
)

GaussQuant::show_tbl_GQH(
  jpy_fair_rate_check_tbl,
  "TONA fair-rate hand check",
  n = 20
)

#> # A tibble: 1 x 5
#>   effective_discount_fac~1 maturity_discount_fa~2 payment_discount_fac~3 annuity
#>   <dbl> <dbl> <dbl> <dbl>
#> 1      1      1.00      1.00 0.0192
#> # i abbreviated names: 1: effective_discount_factor,
#> #   2: maturity_discount_factor, 3: payment_discount_factor
#> # i 1 more variable: fair_swap_rate_hand <dbl>

```

3.3 日次複利と Fixing

3.3.1 OIS 変動レグの日次複利

OIS の変動レグでは、計算期間中の翌日物金利を日ごとに複利で積み上げる。休日をまたぐ金利は、次の営業日まで複数日分に適用されるため、各行の適用日数を確認する必要がある。

次のコードでは、変動レグを日次単位に分解し、割引係数から日次フォワード金利を求める。

```
jpy_ois_daily <- GaussQuant::trade_ois_swap_py_GQH(
  curve_env = tona_curve_env,
  effective = "2022-08-23",
  maturity = "2022-08-30",
  notional = 10000000,
  fixed_rate = -0.00015,
  pay_receive = "pay",
  fixed_schedule_tenor = "1Y",
  floating_schedule_tenor = "1D",
  pay_lag = 0,
  verbose = TRUE
)

GaussQuant::set_eval_date_GQL(trade_date_tona)

jpy_daily_float_cf_tbl <- GaussQuant::ois_daily_forward_table_GQH(
  swap = jpy_ois_daily$swap,
  curve = tona_curve,
  index = jpy_ois_daily$index,
  eval_date = trade_date_tona,
  notional = 10000000
)

GaussQuant::show_tbl_GQH(
  jpy_daily_float_cf_tbl,
  "TONA daily forward leg",
  n = 20
)

#> # A tibble: 5 x 9
#>   fixing_date next_date   days fixing_before_eval fixing_on_eval fixing_value
#>   <chr>       <chr>   <int> <lgl>                <lgl>                <dbl>
#> 1 2022-08-23 2022-08-24     1 FALSE                FALSE                -0.0000900
#> 2 2022-08-24 2022-08-25     1 FALSE                FALSE                -0.000132
#> 3 2022-08-25 2022-08-26     1 FALSE                FALSE                -0.000132
#> 4 2022-08-26 2022-08-29     3 FALSE                FALSE                -0.000132
#> 5 2022-08-29 2022-08-30     1 FALSE                FALSE                -0.000132
#> # i 3 more variables: forward_rate_from_df <dbl>, applied_rate <dbl>,
#> #   amount <dbl>
```

各日の単利フォワード金利は、開始日の割引係数を $P(0, t_i)$ 、終了日の割引係数を $P(0, t_{i+1})$ 、年率換算期間を δ_i とすると、次式で求められる。

$$f_i = \frac{P(0, t_i)/P(0, t_{i+1}) - 1}{\delta_i}$$

日次フォワード金利を用いて複利収益率と利息額を確認する。

```
daily_compounding_result <- if (
  nrow(jpy_daily_float_cf_tbl) >= 2 &&
  all(c("days", "rate") %in% names(jpy_daily_float_cf_tbl))
) {
  daily_compounded_return <- (
    1 +
    jpy_daily_float_cf_tbl$days[-1] /
    365 *
    jpy_daily_float_cf_tbl$rate[-1]
  ) |>
  prod() -
  1

  tibble::tibble(
    compounded_return = daily_compounded_return,
    floating_interest = daily_compounded_return * 1000000,
    equivalent_annual_rate = daily_compounded_return * 365 / 7
  )
} else {
  tibble::tibble(
    compounded_return = NA_real_,
    floating_interest = NA_real_,
    equivalent_annual_rate = NA_real_
  )
}

GaussQuant::show_tbl_GQH(
  daily_compounding_result,
  "TONA daily compounding result",
  n = 20
)

#> # A tibble: 1 x 3
#>   compounded_return floating_interest equivalent_annual_rate
#>   <dbl>             <dbl>             <dbl>
#> 1             NA             NA             NA
```


3.3.2 Fixing の確定と再評価

評価日より前の翌日物金利には、実際に公表された Fixing を使用する。評価日より後の金利は、OIS カーブから推定したフォワード金利を使用する。

したがって、評価途中の OIS 変動レグは、次の二つから構成される。

- 評価日までに確定した日次 Fixing の複利部分
- 評価日より後のフォワード金利による予測部分

後決め複利では、期間終了まで変動レグ全体の利息額が確定しない。Fixing の公表時刻と支払処理の間に必要な時間を確保するため、実務では Lookback、Observation Shift、Lockout または Payment Delay などの規則が用いられることがある。

次の例では、2022 年 8 月 23 日および 24 日の TONA Fixing を登録し、2022 年 8 月 25 日時点で再評価する。

```
jpy_fixings_tbl <- tibble::tribble(
  ~date, ~currency, ~instrument, ~fixing,
  "2022-08-23", "JPY", "TONA", -0.000090,
  "2022-08-24", "JPY", "TONA", -0.000085
)

GaussQuant::set_eval_date_GQL(trade_date_tona)

jpy_overnight_before_tbl <- GaussQuant::ois_overnight_leg_table_GQL(
  jpy_ois_short$swap
)

GaussQuant::ir_apply_fixings_GQH(
  index_obj = jpy_ois_short$index,
  fixings_tbl = jpy_fixings_tbl,
  currency = "JPY",
  instrument = "TONA"
)

GaussQuant::set_eval_date_GQL("2022-08-25")

jpy_overnight_after_tbl <- GaussQuant::ois_overnight_leg_table_GQL(
  jpy_ois_short$swap
)

GaussQuant::ir_show_fixing_before_after_GQH(
  before_tbl = jpy_overnight_before_tbl,
  after_tbl = jpy_overnight_after_tbl,
  title = "TONA fixing before / after",
```

```

  n = 10
)
#> # A tibble: 1 x 3
#>   row_id amount_before amount_after
#>   <int>         <dbl>         <dbl>
#> 1     1             -24.2         -24.2

GaussQuant::ir_show_swap_summary_GQH(
  trade_env = jpy_ois_short,
  title = "TONA short OIS summary after fixings"
)

jpy_fixing_diag_tbl <- GaussQuant::ir_fixing_table_GQH(
  swap = jpy_ois_daily$swap,
  curve = tona_curve,
  index = jpy_ois_short$index
)

GaussQuant::show_tbl_GQH(
  jpy_fixing_diag_tbl,
  "TONA daily fixing decomposition",
  n = 20
)
#> # A tibble: 1 x 7
#>       i fixing_date fixing_value pay_date  amount    df    pv
#>   <int> <chr>         <dbl> <chr>         <dbl> <dbl> <dbl>
#> 1     1 2022-08-29      -0.000142 2022-08-30   -24.2    1.00 -24.2

```

3.4 SOFR とマルチカーブ評価

SOFR は、米国債を担保とする翌日物レポ取引に基づく米ドルのリスク・フリー・レートである。TONA が無担保翌日物市場に基づくのに対し、SOFR は有担保取引に基づく点が異なる。

OIS 評価の基本構造は TONA と同じであり、通貨、休日カレンダー、日数計算規則、市場クォートおよび翌日物指数が異なる。

3.4.1 SOFR 市場レートと OIS カーブ

```

trade_date_sofr <- "2023-09-26"

GaussQuant::set_eval_date_GQL(trade_date_sofr)

sofr_quotes <- tibble::tribble(

```

```

~as_of_date, ~currency, ~instrument, ~kind, ~tenor, ~rate,
as.Date(trade_date_sofr), "USD", "SOFR", "depo", "1D", 0.0531,
as.Date(trade_date_sofr), "USD", "SOFR", "ois", "1M", 0.0532,
as.Date(trade_date_sofr), "USD", "SOFR", "ois", "3M", 0.0538,
as.Date(trade_date_sofr), "USD", "SOFR", "ois", "6M", 0.0546,
as.Date(trade_date_sofr), "USD", "SOFR", "ois", "1Y", 0.0545,
as.Date(trade_date_sofr), "USD", "SOFR", "ois", "2Y", 0.0501,
as.Date(trade_date_sofr), "USD", "SOFR", "ois", "3Y", 0.0467
)

sofr_curve_envs <- GaussQuant::ir_build_ois_curve_envs_GQH(
  quotes = sofr_quotes,
  trade_date = trade_date_sofr,
  verbose = TRUE
)

sofr_curve_env <- sofr_curve_envs[["USD::SOFR"]]
sofr_curve <- sofr_curve_env$curve

GaussQuant::show_tbl_GQH(
  curve_tbl_local(sofr_curve),
  "SOFR OIS curve",
  n = 12
)

#> # A tibble: 12 x 4
#>   date          time discount_factor zero_rate
#>   <date>        <dbl>         <dbl>     <dbl>
#> 1 2023-09-28 0          1          0
#> 2 2023-10-04 0.0153     0.999     0.0531
#> 3 2023-10-09 0.0306     0.998     0.0531
#> 4 2023-10-15 0.0459     0.998     0.0531
#> 5 2023-10-20 0.0612     0.997     0.0531
#> 6 2023-10-26 0.0765     0.996     0.0531
#> 7 2023-11-01 0.0918     0.995     0.0531
#> 8 2023-11-06 0.107      0.994     0.0532
#> 9 2023-11-12 0.122      0.994     0.0532
#> 10 2023-11-17 0.138     0.993     0.0533
#> 11 2023-11-23 0.153     0.992     0.0533
#> 12 2023-11-28 0.168     0.991     0.0533

```

3.4.2 SOFR OIS の評価

```
sofr_ois_trade <- GaussQuant::trade_ois_swap_py_GQH(
  curve_env = sofr_curve_env,
  effective = "2023-09-28",
  maturity = "2025-09-28",
  notional = 10000000,
  fixed_rate = 0.05,
  pay_receive = "pay",
  verbose = TRUE
)

GaussQuant::ir_show_swap_summary_GQH(
  trade_env = sofr_ois_trade,
  title = "SOFR OIS summary"
)

sofr_overnight_cf_tbl <- GaussQuant::ois_overnight_leg_table_GQL(
  sofr_ois_trade$swap
)

GaussQuant::show_tbl_GQH(
  sofr_overnight_cf_tbl,
  "SOFR overnight leg cashflows",
  n = 20
)

#> # A tibble: 2 x 2
#>   date      amount
#>   <chr>      <dbl>
#> 1 2024-09-30 557111.
#> 2 2025-09-29 459522.
```

3.4.3 マルチカーブ評価

金融危機以前のシングルカーブ評価では、同一の金利カーブを用いて、将来変動金利の予測とキャッシュフローの割引を行っていた。

マルチカーブ評価では、二つの役割を分離する。

- フォワードカーブ参照金利の将来 Fixing または期間フォワード金利を予測する。
- ディスカウントカーブ担保契約に対応する金利を用いて、将来キャッシュフローを現在価値へ割り引く。

将来変動金利を F_j 、年率換算期間を α_j 、割引係数を D_j 、元本を N とすると、変動レグの現在価値は概念的

に次式で表される。

$$PV_{\text{floating}} = N \sum_{j=1}^m \alpha_j F_j D_j$$

ここで、 F_j はフォワードカーブから求め、 D_j はディスカウントカーブから求める。

以下では、マルチカーブの効果だけを明確にするため、EURIBOR 6 か月物を参照する一般的なバニラスワップを用いる。同じフォワードカーブを使用しながら、割引カーブを同一にした場合と分離した場合の NPV を比較する。

```
GaussQuant::set_eval_date_GQL("2023-09-26")

multi_curve_dates <- c(
  "2023-09-26",
  "2024-09-26",
  "2025-09-26",
  "2026-09-28",
  "2028-09-26"
)

forecast_zero_rates <- c(
  0.0450,
  0.0470,
  0.0460,
  0.0445,
  0.0420
)

discount_zero_rates <- c(
  0.0400,
  0.0415,
  0.0410,
  0.0400,
  0.0380
)

forecast_curve <- GaussQuant::build_zero_curve_GQL(
  date_chr = multi_curve_dates,
  zero_rates = forecast_zero_rates,
  day_counter = "Actual365Fixed"
)

discount_curve <- GaussQuant::build_zero_curve_GQL(
  date_chr = multi_curve_dates,
```

```

    zero_rates = discount_zero_rates,
    day_counter = "Actual365Fixed"
  )

QuantLib::TermStructure_enableExtrapolation(forecast_curve)
#> NULL
QuantLib::TermStructure_enableExtrapolation(discount_curve)
#> NULL

forecast_handle <- GaussQuant::yield_curve_handle_GQL(
  forecast_curve
)

discount_handle <- GaussQuant::yield_curve_handle_GQL(
  discount_curve
)

multi_curve_comparison_tbl <- tibble::tibble(
  date = as.Date(multi_curve_dates)
) |>
dplyr::mutate(
  forecast_discount_factor = purrr::map_dbl(
    as.character(date),
    function(x) {
      forecast_curve$discount(
        GaussQuant::date_GQL(x)
      )
    }
  ),
  ois_discount_factor = purrr::map_dbl(
    as.character(date),
    function(x) {
      discount_curve$discount(
        GaussQuant::date_GQL(x)
      )
    }
  )
)

GaussQuant::show_tbl_GQH(
  multi_curve_comparison_tbl,
  "Forecast and discount curves",
  n = 20

```

```
)
#> # A tibble: 5 x 3
#>   date          forecast_discount_factor ois_discount_factor
#>   <date>                <dbl>                <dbl>
#> 1 2023-09-26                1                1
#> 2 2024-09-26             0.954             0.959
#> 3 2025-09-26             0.912             0.921
#> 4 2026-09-28             0.875             0.887
#> 5 2028-09-26             0.810             0.827
```

3.4.4 シングルカーブ評価との比較

```
single_curve_swap <- GaussQuant::make_vanilla_swap_GQL(
  effective_date = "2023-09-28",
  maturity_date = "2025-09-28",
  fixed_rate = 0.045,
  notional = 10000000,
  forecast_handle = forecast_handle,
  discount_handle = forecast_handle,
  swap_type = "payer",
  index = "Euribor6M",
  fixed_tenor = GaussQuant::period_years_GQL(1),
  floating_tenor = GaussQuant::period_months_GQL(6),
  calendar = QuantLib::TARGET()
)

multi_curve_swap <- GaussQuant::make_vanilla_swap_GQL(
  effective_date = "2023-09-28",
  maturity_date = "2025-09-28",
  fixed_rate = 0.045,
  notional = 10000000,
  forecast_handle = forecast_handle,
  discount_handle = discount_handle,
  swap_type = "payer",
  index = "Euribor6M",
  fixed_tenor = GaussQuant::period_years_GQL(1),
  floating_tenor = GaussQuant::period_months_GQL(6),
  calendar = QuantLib::TARGET()
)

single_curve_summary <- GaussQuant::swap_summary_GQL(
  single_curve_swap
)
```

```

multi_curve_summary <- GaussQuant::swap_summary_GQL(
  multi_curve_swap
)

curve_valuation_comparison_tbl <- dplyr::bind_rows(
  single_curve_summary |>
    dplyr::mutate(valuation_method = "single_curve"),
  multi_curve_summary |>
    dplyr::mutate(valuation_method = "multi_curve")
) |>
  dplyr::relocate(valuation_method)

GaussQuant::show_tbl_GQH(
  curve_valuation_comparison_tbl,
  "Single-curve and multi-curve valuation",
  n = 20
)

#> # A tibble: 2 x 6
#>   valuation_method    npv fixed_leg_npv floating_leg_npv fair_rate fair_spread
#>   <chr>             <dbl>      <dbl>          <dbl>      <dbl>      <dbl>
#> 1 single_curve     40292.    -840562.      880855.    0.0472    -0.00210
#> 2 multi_curve     39436.    -847103.      886539.    0.0471    -0.00204

```

両方のスワップは同じフォワードカーブから将来 EURIBOR を予測するが、シングルカーブ評価ではそのカーブを割引にも使用し、マルチカーブ評価では別のディスカウントカーブを使用する。割引係数が異なるため、同じ将来キャッシュフローであっても NPV およびフェアレートが変化する。

3.5 ケーススタディ 1：EONIA カーブと OIS 評価

本ケーススタディでは、2012 年 12 月 11 日の EONIA 市場データから OIS カーブを構築する。短期部分には翌日物預金と短期 OIS を用い、その先には日付指定 OIS と長期 OIS を用いる。

カーブ構築後、年末をまたぐ市場金利に含まれる流動性効果を分離し、年末ジャンプを組み込んだ最終的な EONIA カーブを作成する。さらに、カーブ構築に使用した 5 年 OIS の市場レートを契約固定金利として OIS を構築し、NPV とフェアレートを確認する。

3.5.1 評価日と EONIA 市場データ

評価日は 2012 年 12 月 11 日とする。市場データには、翌日物預金、短期 OIS、日付指定 OIS および長期 OIS を使用する。

```

case_evaluation_date <- "2012-12-11"

GaussQuant::set_eval_date_GQL(

```



```

    case_evaluation_date
  )

case_eonia_quotes <- GaussQuant::ametrano_bianchetti_eonia_quotes_GQL()

GaussQuant::show_tbl_GQH(
  case_eonia_quotes,
  "EONIA market quotes",
  n = 40
)

#> # A tibble: 30 x 9
#>   quote_id instrument_type rate_pct    rate fixing_days tenor_n tenor_unit
#>   <chr>      <chr>          <dbl>  <dbl>    <int>  <int> <chr>
#> 1 DEP-ON-0D deposit         0.04   0.0004      0      1 Days
#> 2 DEP-ON-1D deposit         0.04   0.0004      1      1 Days
#> 3 DEP-ON-2D deposit         0.04   0.0004      2      1 Days
#> 4 OIS-1W    spot_ois        0.07   0.0007      2      1 Weeks
#> 5 OIS-2W    spot_ois        0.069  0.00069     2      2 Weeks
#> 6 OIS-3W    spot_ois        0.078  0.00078     2      3 Weeks
#> 7 OIS-1M    spot_ois        0.074  0.00074     2      1 Months
#> 8 OIS-ECB-1 dated_ois       0.046  0.00046     NA     NA <NA>
#> 9 OIS-ECB-2 dated_ois       0.016  0.00016     NA     NA <NA>
#> 10 OIS-ECB-3 dated_ois      -0.007 -0.00007     NA     NA <NA>
#> # i 20 more rows
#> # i 2 more variables: start_date <chr>, end_date <chr>

```

`rate_pct` はパーセント表示の市場レートであり、`rate` は QuantLib へ渡す小数表示の金利である。

預金には 1 日の期間を設定し、評価日からスポット日までを接続するため、Fixing 日数を 0 日、1 日および 2 日とした。短期 OIS と長期 OIS にはスポット日から満期までの期間を指定し、日付指定 OIS には開始日と終了日を直接指定する。

3.5.2 EONIA カーブの構築

次に、市場レートから EONIA カーブを構築する。

最初に対数割引係数を 3 次補間するカーブと、区分的に一定のフォワード金利を用いるカーブを構築する。後者を用いて年末部分のフォワード金利を確認し、年末ジャンプを推定する。

```

case_eonia_benchmark <- GaussQuant::eonia_curve_benchmark_GQL(
  quotes = case_eonia_quotes,
  evaluation_date = case_evaluation_date
)

case_eonia_curve <- case_eonia_benchmark$final$curve

```

```

case_eonia_handle <- case_eonia_benchmark$final$curve_handle

case_jump_summary <- case_eonia_benchmark$jump_summary

GaussQuant::show_tbl_GQH(
  case_jump_summary,
  "EONIA year-end jump",
  n = 20
)
#> # A tibble: 1 x 7
#>   original_forward clean_forward   t12 jump_time jump_rate jump_discount_factor
#>   <dbl>           <dbl> <dbl>   <dbl>     <dbl>           <dbl>
#> 1      0.000815      0.000671 0.0384  0.00548   0.00101           1.000
#> # i 1 more variable: jump_date <date>

```

年末ジャンプの推定では、2012 年 12 月 24 日から 2013 年 1 月 7 日までのフォワード金利を確認する。次に、2013 年 1 月 3 日の区分フォワード金利を前後のノードの平均へ置き換え、年末要因を含まないフォワードカーブを作成する。

元のフォワード金利と調整後のフォワード金利の差を、2012 年 12 月 31 日から 2013 年 1 月 2 日までの期間へ換算し、年末ジャンプを求める。

3.5.3 ベンチマーク値の確認

年末ジャンプを推定する過程で得られたフォワード金利を確認する。

```

case_benchmark_check_tbl <- tibble::tribble(
  ~metric, ~reference_value_pct, ~r_value_pct,
  "Original two-week forward", 0.082,
  100 * case_jump_summary$original_forward[[1L]],
  "Adjusted two-week forward", 0.067,
  100 * case_jump_summary$clean_forward[[1L]],
  "Year-end jump", 0.101,
  100 * case_jump_summary$jump_rate[[1L]]
) |>
dplyr::mutate(
  difference_pct =
    r_value_pct -
    reference_value_pct
)

GaussQuant::show_tbl_GQH(
  case_benchmark_check_tbl,
  "EONIA benchmark comparison",
  n = 20
)

```

```

)
#> # A tibble: 3 x 4
#>   metric                reference_value_pct r_value_pct difference_pct
#>   <chr>                <dbl>         <dbl>         <dbl>
#> 1 Original two-week forward      0.082      0.0815      -0.000469
#> 2 Adjusted two-week forward      0.067      0.0671       0.000122
#> 3 Year-end jump                  0.101      0.101      -0.000137

stopifnot(
  all(
    abs(case_benchmark_check_tbl$difference_pct) <= 0.0005
  )
)

```

基準値はパーセント単位で小数第 3 位まで表示されている。そのため、照合では表示桁の半分に相当する 0.0005 パーセントポイントを許容範囲とする。

3.5.4 市場レートの再現性

構築した最終カーブを用いて、各 Rate Helper のインプライド・レートを求める。

```

case_eonia_validation <- case_eonia_benchmark$final_validation

case_eonia_repricing_tbl <- case_eonia_validation$quote_repricing |>
  dplyr::mutate(
    quote_error_bp = 10000 * quote_error
  )

GaussQuant::show_tbl_GQH(
  case_eonia_repricing_tbl,
  "EONIA quote repricing",
  n = 40
)
#> # A tibble: 30 x 10
#>   quote_id instrument_type market_quote implied_quote quote_error pillar_date
#>   <chr>      <chr>          <dbl>         <dbl>         <dbl> <date>
#> 1 DEP-ON-0D deposit          0.0004      0.000400      2.62e-15 2012-12-12
#> 2 DEP-ON-1D deposit          0.0004      0.000400      2.62e-15 2012-12-13
#> 3 DEP-ON-2D deposit          0.0004      0.000400      2.62e-15 2012-12-14
#> 4 OIS-1W    spot_ois          0.0007      0.000700      4.56e-13 2012-12-20
#> 5 OIS-2W    spot_ois          0.00069     0.000690      1.08e-14 2012-12-27
#> 6 OIS-3W    spot_ois          0.00078     0.000780     -1.36e-15 2013-01-03
#> 7 OIS-1M    spot_ois          0.00074     0.000740      1.85e-15 2013-01-14
#> 8 OIS-ECB-1 dated_ois        0.00046     0.000460      6.52e-12 2013-02-13

```

```
#> 9 OIS-ECB-2 dated_ois          0.00016      0.000160      8.46e-12 2013-03-13
#> 10 OIS-ECB-3 dated_ois        -0.00007      -0.0000700     9.13e-12 2013-04-10
#> # i 20 more rows
#> # i 4 more variables: discount_factor <dbl>, zero_rate <dbl>,
#> #   one_day_forward_rate <dbl>, quote_error_bp <dbl>

stopifnot(
  max(
    abs(case_eonia_repricing_tbl$quote_error),
    na.rm = TRUE
  ) < 1e-8
)
```

各商品のインプライド・レートと市場レートが一致することにより、預金、短期 OIS、日付指定 OIS および長期 OIS が同じ期間構造上で再現されていることを確認できる。

3.5.5 5 年 OIS の構築

市場データに含まれる 5 年 OIS を取り上げる。契約固定金利には、カーブ構築に用いた 5 年 OIS の市場レートを使用する。

```
case_ois_tenor <- QuantLib::Period(
  5,
  "Years"
)

case_ois_fixed_rate <- case_eonia_quotes |>
  dplyr::filter(
    quote_id == "OIS-5Y"
  ) |>
  dplyr::pull(
    rate
  )

case_eonia_index <- QuantLib::Eonia(
  case_eonia_handle
)

case_ois_contract_tbl <- tibble::tibble(
  evaluation_date = as.Date(case_evaluation_date),
  index = "EONIA",
  tenor = "5Y",
  settlement_days = 2L,
  contract_fixed_rate = case_ois_fixed_rate
)
```

```
)

GaussQuant::show_tbl_GQH(
  case_ois_contract_tbl,
  "Five-year EONIA OIS contract",
  n = 20
)

#> # A tibble: 1 x 5
#>   evaluation_date index tenor settlement_days contract_fixed_rate
#>   <date>          <chr> <chr>          <int>          <dbl>
#> 1 2012-12-11      EONIA 5Y              2          0.00456
```

3.5.6 OIS の構築と計算結果の照合

最初に、QuantLib の MakeOIS を直接使用して OIS を構築する。

```
case_ois_builder_quantlib <- QuantLib::MakeOIS(
  swapTenor = case_ois_tenor,
  overnightIndex = case_eonia_index,
  fixedRate = case_ois_fixed_rate
)

case_ois_quantlib <- QuantLib::MakeOIS_makeOIS(
  case_ois_builder_quantlib
)
```

次に、同じ期間、同じ EONIA インデックスおよび同じ固定金利を用いて OIS を構築する。

```
case_ois_gaussquant <- GaussQuant::build_ois_GQL(
  swap_tenor = case_ois_tenor,
  overnight_index = case_eonia_index,
  fixed_rate = case_ois_fixed_rate
)
```

両方の OIS について、NPV、固定レグの現在価値、翌日物レグの現在価値、フェアレートおよびフェアスプレッドを確認する。

```
case_ois_quantlib_summary <- GaussQuant::swap_summary_GQL(
  case_ois_quantlib
)

case_ois_gaussquant_summary <- GaussQuant::swap_summary_GQL(
  case_ois_gaussquant
)

case_ois_comparison_tbl <- dplyr::bind_rows(
```

```

case_ois_quantlib_summary |>
  dplyr::mutate(
    calculation_route = "QuantLib"
  ),
case_ois_gaussquant_summary |>
  dplyr::mutate(
    calculation_route = "GaussQuant"
  )
) |>
dplyr::relocate(
  calculation_route
)

GaussQuant::show_tbl_GQH(
  case_ois_comparison_tbl,
  "Five-year EONIA OIS valuation",
  n = 20
)
#> # A tibble: 2 x 6
#>   calculation_route      npv fixed_leg_npv floating_leg_npv fair_rate
#>   <chr>              <dbl>      <dbl>          <dbl>      <dbl>
#> 1 QuantLib          -1.65e-13    -0.0230        0.0230    0.00456
#> 2 GaussQuant        -1.65e-13    -0.0230        0.0230    0.00456
#> # i 1 more variable: fair_spread <dbl>

case_ois_metrics <- c(
  "npv",
  "fixed_leg_npv",
  "floating_leg_npv",
  "fair_rate",
  "fair_spread"
)

case_quantlib_values <- unlist(
  case_ois_quantlib_summary |>
    dplyr::select(
      dplyr::all_of(case_ois_metrics)
    ),
  use.names = FALSE
)

case_gaussquant_values <- unlist(
  case_ois_gaussquant_summary |>

```

```

    dplyr::select(
      dplyr::all_of(case_ois_metrics)
    ),
    use.names = FALSE
  )

stopifnot(
  isTRUE(
    all.equal(
      case_quantlib_values,
      case_gaussquant_values,
      tolerance = 1e-12
    )
  )
)

```

3.5.7 市場固定金利とフェアレート

カーブ構築に使用した 5 年 OIS の市場レートと、構築後のカーブから求めたフェアレートを比較する。

```

case_ois_rate_check_tbl <- tibble::tibble(
  market_fixed_rate = case_ois_fixed_rate,
  calculated_fair_rate =
    case_ois_gaussquant_summary$fair_rate[[1L]],
  difference_bp = 10000 * (
    case_ois_gaussquant_summary$fair_rate[[1L]] -
    case_ois_fixed_rate
  ),
  npv = case_ois_gaussquant_summary$npv[[1L]]
)

GaussQuant::show_tbl_GQH(
  case_ois_rate_check_tbl,
  "Five-year EONIA OIS rate check",
  n = 20
)

#> # A tibble: 1 x 4
#>   market_fixed_rate calculated_fair_rate difference_bp      npv
#>   <dbl>             <dbl>             <dbl>    <dbl>
#> 1      0.00456         0.00456      -3.29e-10 -1.65e-13

stopifnot(
  abs(
    case_ois_gaussquant_summary$fair_rate[[1L]] -

```

```

    case_ois_fixed_rate
  ) < 1e-8
)

```

5 年 OIS はカーブ構築に使用した商品の一つであるため、市場固定金利とカーブから再計算したフェアレートは一致し、NPV はゼロに近い値となる。

3.5.8 固定レグと翌日物レグ

最後に、5 年 OIS の固定レグと翌日物レグのキャッシュフローを確認する。

```

case_ois_fixed_leg_tbl <- GaussQuant::leg_to_cashflow_tbl_GQL(
  case_ois_gaussquant$fixedLeg()
)

case_ois_overnight_leg_tbl <- GaussQuant::leg_to_cashflow_tbl_GQL(
  case_ois_gaussquant$overnightLeg()
)

GaussQuant::show_tbl_GQH(
  case_ois_fixed_leg_tbl,
  "Five-year EONIA OIS fixed leg",
  n = 20
)

#> # A tibble: 5 x 2
#>   date          amount
#>   <chr>         <dbl>
#> 1 2013-12-13 0.00462
#> 2 2014-12-15 0.00465
#> 3 2015-12-14 0.00461
#> 4 2016-12-13 0.00462
#> 5 2017-12-13 0.00462

GaussQuant::show_tbl_GQH(
  case_ois_overnight_leg_tbl,
  "Five-year EONIA OIS overnight leg",
  n = 20
)

#> # A tibble: 5 x 2
#>   date          amount
#>   <chr>         <dbl>
#> 1 2013-12-13 0.0000146
#> 2 2014-12-15 0.000718
#> 3 2015-12-14 0.00314

```



```
#> 4 2016-12-13 0.00730
#> 5 2017-12-13 0.0122
```

固定レグと翌日物レグは反対方向のキャッシュフローを持ち、市場固定金利がフェアレートと一致する場合には、両レグの現在価値が相殺される。

3.6 ケーススタディ 2：市場レート変動と評価損益

第 9 節では、2012 年 12 月 11 日の EONIA 市場データから期間構造を構築し、5 年 OIS の市場固定金利とフェアレートが一致することを確認した。

本ケーススタディでは、評価日と OIS の約定条件を変更せず、カーブ構築に使用する市場レートだけを上下へ 10 ベーシスポイント変化させる。各シナリオについて EONIA カーブを再構築し、第 9 節と同じ 5 年 OIS を再評価する。

比較するシナリオは、次の三つである。

- EONIA 市場レートを一律に 10 ベーシスポイント低下
- 第 9 節と同じ基準市場レート
- EONIA 市場レートを一律に 10 ベーシスポイント上昇

契約固定金利には、第 9 節で設定した 5 年 OIS の市場レート 0.456% を引き続き使用する。したがって、各シナリオの NPV の差は、市場レートの変化による評価損益を表す。

3.6.1 市場レートシナリオ

最初に、基準となる EONIA 市場レートへ、マイナス 10 ベーシスポイント、ゼロおよびプラス 10 ベーシスポイントのシフトを加える。

ここでは構築済みのゼロカーブを直接動かすのではなく、預金、短期 OIS、日付指定 OIS および長期 OIS の市場レートを変化させる。その後、それぞれの市場データから EONIA カーブを改めて構築する。

```
case_rate_scenario_tbl <- tibble::tribble(
  ~scenario, ~shift_bp,
  "10bp低下", -10,
  "基準",      0,
  "10bp上昇", 10
) |>
dplyr::mutate(
  quotes = purrr::map(
    shift_bp,
    function(shift_bp) {
      case_eonia_quotes |>
        dplyr::mutate(
          rate = rate + shift_bp / 10000,
          rate_pct = 100 * rate
        )
    }
  )
)
```

```

    )
  }
)
)

```

10 ベーシスポイントは、小数表示の金利では 0.001、パーセント表示では 0.1 パーセントポイントに相当する。

市場レートの変化を確認するため、翌日物預金、1 か月 OIS、5 年 OIS および 30 年 OIS を取り出す。

```

case_rate_scenario_quote_tbl <- purrr::map2_dfr(
  case_rate_scenario_tbl$scenario,
  case_rate_scenario_tbl$quotes,
  function(scenario, quotes) {
    quotes |>
      dplyr::filter(
        quote_id %in% c(
          "DEP-ON-OD",
          "OIS-1M",
          "OIS-5Y",
          "OIS-30Y"
        )
      ) |>
      dplyr::transmute(
        scenario = scenario,
        quote_id = quote_id,
        instrument_type = instrument_type,
        rate_pct = rate_pct,
        rate = rate
      )
  }
)

GaussQuant::show_tbl_GQH(
  case_rate_scenario_quote_tbl,
  "EONIA market-rate scenarios",
  n = 20
)

#> # A tibble: 12 x 5
#>   scenario quote_id instrument_type rate_pct   rate
#>   <chr>    <chr>    <chr>          <dbl>  <dbl>
#> 1 10bp低下 DEP-ON-OD deposit        -0.06  -0.0006
#> 2 10bp低下 OIS-1M   spot_ois        -0.026 -0.00026
#> 3 10bp低下 OIS-5Y   spot_ois         0.356  0.00356
#> 4 10bp低下 OIS-30Y  spot_ois         1.94   0.0194
#> 5 基準     DEP-ON-OD deposit         0.04   0.0004

```

```
#> 6 基準      OIS-1M      spot_ois      0.074 0.00074
#> 7 基準      OIS-5Y      spot_ois      0.456 0.00456
#> 8 基準      OIS-30Y     spot_ois      2.04  0.0204
#> 9 10bp上昇 DEP-0N-0D deposit      0.14  0.0014
#> 10 10bp上昇 OIS-1M      spot_ois      0.174 0.00174
#> 11 10bp上昇 OIS-5Y      spot_ois      0.556 0.00556
#> 12 10bp上昇 OIS-30Y     spot_ois      2.14  0.0214
```

各商品のレートは、基準値から一律に 10 ベーシスポイント低下または上昇している。評価日、Fixing 日数、期間、開始日および終了日などの市場慣行は変更しない。

3.6.2 シナリオ別 EONIA カーブ

各シナリオの市場データから、年末ジャンプを含む EONIA カーブを再構築する。

```
case_rate_scenario_tbl <- case_rate_scenario_tbl |>
  dplyr::mutate(
    benchmark = purrr::map(
      quotes,
      function(quotes) {
        GaussQuant::eonia_curve_benchmark_GQL(
          quotes = quotes,
          evaluation_date = case_evaluation_date
        )
      }
    ),
    curve = purrr::map(
      benchmark,
      ~ .x$final$curve
    ),
    curve_handle = purrr::map(
      benchmark,
      ~ .x$final$curve_handle
    ),
    max_quote_error = purrr::map_dbl(
      benchmark,
      function(benchmark) {
        max(
          abs(
            benchmark$final_validation$
              quote_repricing$
              quote_error
          ),
          na.rm = TRUE
        )
      }
    )
  )
```

```

    )
  }
)
)

case_curve_validation_tbl <- case_rate_scenario_tbl |>
  dplyr::select(
    scenario,
    shift_bp,
    max_quote_error
  )

GaussQuant::show_tbl_GQH(
  case_curve_validation_tbl,
  "EONIA scenario-curve validation",
  n = 20
)

#> # A tibble: 3 x 3
#>   scenario shift_bp max_quote_error
#>   <chr>      <dbl>      <dbl>
#> 1 10bp低下    -10      9.84e-12
#> 2 基準         0      9.86e-12
#> 3 10bp上昇     10      9.87e-12

stopifnot(
  all(
    case_curve_validation_tbl$max_quote_error < 1e-8
  )
)

```

すべてのシナリオについて、Rate Helper のインプライド・レートが入力した市場レートと一致することを確認する。これにより、評価損益の比較に使用する各カーブが、それぞれの市場データを再現していることが分かる。

3.6.3 同一 OIS の再評価

第9節と同じ5年 OIS を、各シナリオの EONIA カーブへ接続する。

契約期間は5年、契約固定金利は0.456%のままとし、市場カーブだけを変更する。

```

case_rate_scenario_tbl <- case_rate_scenario_tbl |>
  dplyr::mutate(
    eonia_index = purrr::map(
      curve_handle,
      QuantLib::Eonia
    )
  )

```

```

    ),
    ois = purrr::map(
      eonia_index,
      function(eonia_index) {
        GaussQuant::build_ois_GQL(
          swap_tenor = case_ois_tenor,
          overnight_index = eonia_index,
          fixed_rate = case_ois_fixed_rate
        )
      }
    ),
    valuation = purrr::map(
      ois,
      GaussQuant::swap_summary_GQL
    )
  )
)

```

各シナリオの評価結果を一つの表へまとめる。

```

case_ois_scenario_result_tbl <- case_rate_scenario_tbl |>
  dplyr::select(
    scenario,
    shift_bp,
    valuation
  ) |>
  tidyr::unnest(
    cols = valuation
  )

case_base_fair_rate <- case_ois_scenario_result_tbl |>
  dplyr::filter(
    scenario == "基準"
  ) |>
  dplyr::pull(
    fair_rate
  )

case_base_npv <- case_ois_scenario_result_tbl |>
  dplyr::filter(
    scenario == "基準"
  ) |>
  dplyr::pull(
    npv
  )

```

```

case_ois_scenario_result_tbl <- case_ois_scenario_result_tbl |>
  dplyr::mutate(
    contract_fixed_rate = case_ois_fixed_rate,
    fair_rate_change_bp = 10000 * (
      fair_rate -
      case_base_fair_rate
    ),
    payer_valuation_change =
      npv -
      case_base_npv,
    receiver_npv = -npv,
    receiver_valuation_change =
      -(
        npv -
        case_base_npv
      )
  ) |>
  dplyr::select(
    scenario,
    shift_bp,
    contract_fixed_rate,
    fair_rate,
    fair_rate_change_bp,
    payer_npv = npv,
    payer_valuation_change,
    receiver_npv,
    receiver_valuation_change
  )

GaussQuant::show_tbl_GQH(
  case_ois_scenario_result_tbl,
  "Five-year EONIA OIS scenario valuation",
  n = 20
)

#> # A tibble: 3 x 9
#>   scenario shift_bp contract_fixed_rate fair_rate fair_rate_change_bp payer_npv
#>   <chr>      <dbl>          <dbl>      <dbl>          <dbl>      <dbl>
#> 1 10bp低下    -10            0.00456    0.00356          -10.0    -5.05e- 3
#> 2 基準         0            0.00456    0.00456           0      -1.65e-13
#> 3 10bp上昇     10            0.00456    0.00556          10.00    5.02e- 3
#> # i 3 more variables: payer_valuation_change <dbl>, receiver_npv <dbl>,
#> #   receiver_valuation_change <dbl>

```

`payer_npv` は固定金利を支払うポジションの NPV であり、`receiver_npv` は固定金利を受け取る反対ポジションの NPV である。

`payer_valuation_change` と `receiver_valuation_change` は、それぞれのシナリオの NPV から基準シナリオの NPV を差し引いた評価損益である。

3.6.4 基準シナリオの照合

基準シナリオは、第 9 節で使用した市場データと約定条件をそのまま使用している。そのため、基準シナリオの NPV とフェアレートは、第 9 節の計算結果と一致する。

```
case_base_scenario_tbl <- case_ois_scenario_result_tbl |>
  dplyr::filter(
    scenario == "基準"
  )

case_base_check_tbl <- tibble::tibble(
  metric = c(
    "NPV",
    "Fair rate"
  ),
  chapter9_value = c(
    case_ois_gaussquant_summary$npv[[1L]],
    case_ois_gaussquant_summary$fair_rate[[1L]]
  ),
  chapter10_value = c(
    case_base_scenario_tbl$payer_npv[[1L]],
    case_base_scenario_tbl$fair_rate[[1L]]
  )
) |>
  dplyr::mutate(
    difference =
      chapter10_value -
      chapter9_value
  )

GaussQuant::show_tbl_GQH(
  case_base_check_tbl,
  "Base-scenario consistency check",
  n = 20
)

#> # A tibble: 2 x 4
#>   metric      chapter9_value chapter10_value difference
#>   <chr>          <dbl>          <dbl>          <dbl>
#> 1 NPV          -1.65e-13        -1.65e-13          0
```

```
#> 2 Fair rate      4.56e- 3      4.56e- 3      0

stopifnot(
  isTRUE(
    all.equal(
      case_base_check_tbl$chapter9_value,
      case_base_check_tbl$chapter10_value,
      tolerance = 1e-12
    )
  )
)
```

この照合により、第 9 節の基準評価と、第 10 節の基準シナリオが同じ市場データ、評価日および約定条件に基づいていることを確認できる。

3.6.5 市場レート変動と評価損益

市場レートが低下すると、5 年 OIS のフェアレートも低下する。この場合、固定金利支払側は、低下後の市場水準より高い 0.456% を支払うため、既存契約の価値は低下する。

一方、市場レートが上昇すると、固定金利支払側は市場水準より低い 0.456% を支払う契約を保有することになるため、既存契約の価値は上昇する。

固定金利受取側では、この関係が逆になる。固定金利支払側の利益は固定金利受取側の損失となり、両者の NPV と評価損益は符号が反対になる。

3.6.6 1 ベーシスポイント当たりの評価変化

上下 10 ベーシスポイントの結果から、固定金利支払側について、1 ベーシスポイント当たりの平均的な NPV 変化を求める。

```
case_npv_down <- case_ois_scenario_result_tbl |>
  dplyr::filter(
    scenario == "10bp低下"
  ) |>
  dplyr::pull(
    payer_npv
  )

case_npv_up <- case_ois_scenario_result_tbl |>
  dplyr::filter(
    scenario == "10bp上昇"
  ) |>
  dplyr::pull(
    payer_npv
  )
```



```

)

case_ois_bpv_tbl <- tibble::tibble(
  position = "Fixed-rate payer",
  npv_10bp_down = case_npv_down,
  npv_base = case_base_npv,
  npv_10bp_up = case_npv_up,
  average_npv_change_per_bp =
    (
      case_npv_up -
      case_npv_down
    ) / 20
)

GaussQuant::show_tbl_GQH(
  case_ois_bpv_tbl,
  "Five-year EONIA OIS rate sensitivity",
  n = 20
)

#> # A tibble: 1 x 5
#>   position      npv_10bp_down npv_base npv_10bp_up average_npv_change_per_bp
#>   <chr>          <dbl>      <dbl>      <dbl>          <dbl>
#> 1 Fixed-rate payer      -0.00505 -1.65e-13      0.00502          0.000503

```

average_npv_change_per_bp は、マイナス 10 ベーシスポイントからプラス 10 ベーシスポイントまでの NPV 変化を 20 で除した値である。

本ケーススタディでは名目元本を 1 として OIS を構築しているため、この値も単位元本当たりの評価変化を表す。実際の取引では、これに取引元本を乗じることによって、ポジション全体の金利感応度を求めることができる。

3.7 まとめ

本章では、世界金融危機と IBOR 改革を背景として、金利デリバティブの評価がシングルカーブ方式からマルチカーブ方式へ移行した経緯を確認した。LIBOR などの IBOR には銀行の信用リスクや資金流動性リスクが含まれるため、担保付取引の割引金利としてそのまま使用することは適切ではない。そこで、担保契約に対応する OIS カーブを割引に用い、参照金利ごとのフォワードカーブから将来金利を予測する評価方法が定着した。

OIS では、固定金利と、計算期間中の日々の翌日物金利を複利で積み上げた変動金利を交換する。評価日以前の翌日物金利には確定した Fixing を使用し、評価日以後の金利には期間構造から求めた予測値を使用する。TONA と SOFR はいずれも翌日物金利であるが、その基礎となる市場や担保性は異なるため、対象通貨の市場慣行を正しく設定する必要がある。

マルチカーブ評価では、将来の変動金利を求めるフォワードカーブと、将来キャッシュフローを現在価値へ変

換するディスカウントカーブを分離する。同じ将来キャッシュフローであっても、使用する割引カーブが異なれば NPV やフェアレートも変化する。したがって、金利スワップの評価では、参照インデックスがどのカーブへ接続され、価格計算エンジンがどのカーブを割引に使用しているかを明確にする必要がある。

ケーススタディでは、期間構造ハンドルを翌日物金利インデックスへ接続し、MakeOIS を用いて OIS を構築した。さらに、NPV、フェアレート、固定レグおよび翌日物レグのキャッシュフローを確認し、OIS の契約条件と市場カーブが評価結果へどのように反映されるかを示した。

また、契約固定金利を変更せずに市場カーブを上下へ平行シフトし、OIS の評価損益を比較した。契約締結後も固定金利は変化しないが、市場カーブの変動によって将来の翌日物金利予測と割引係数が変化するため、OIS の NPV は日々変動する。固定金利支払側と固定金利受取側では、同じ市場変動に対する評価損益の符号が反対になる。

実際のリスク管理では、カーブ全体の平行シフトだけでなく、短期、中期および長期の金利を個別に変化させる必要がある。また、Fixing の確定、休日カレンダー、日数計算規則、支払ラグ、予測カーブおよび割引カーブの設定を総合的に確認することが、OIS と金利スワップを正しく評価するための基本となる。

参考資料

- Financial Conduct Authority, [The future of LIBOR](#), 27 July 2017.
- Financial Conduct Authority, [The end of LIBOR](#), 1 October 2024.
- Financial Stability Board, [Reforming Major Interest Rate Benchmarks](#), 22 July 2014.
- Bank of Japan, [Uncollateralized Overnight Call Rate](#).

第 II-4 章 Black モデル

1973 年に公表された Black–Scholes–Merton モデルは、株式オプションの理論価格を求めるための基本モデルとして、金融工学の発展に大きな影響を与えた。このモデルでは、株価が幾何ブラウン運動に従い、将来の株価が対数正規分布に従うと仮定する。

一方、金利先物、債券先物、商品先物およびフォワード金利を原資産とするオプションでは、現物価格よりも満期に対応する先物価格またはフォワード価格を直接扱う方が自然である。Black は 1976 年、Black–Scholes–Merton モデルの考え方を先物オプションへ適用した。現在、この評価方法は Black-76 モデルまたは単に Black モデルと呼ばれている。

Black–Scholes–Merton モデルでは、現物価格、無リスク金利および配当利回りから将来のフォワード価格を求める。これに対し Black-76 モデルでは、観測されたフォワード価格または先物価格を直接入力し、満期時の Payoff を割り引いて現在価値を求める。

したがって、Black-76 と Black–Scholes–Merton は無関係な別のモデルではない。両者は、原資産価格が正の値を取り、その変化率が正規分布に従うという共通の仮定を持つ。現物価格を出発点とするか、フォワード価格を出発点とするかが異なる。

本章では、まず Black-76 による先物・フォワードオプションの解析評価を行い、オプション価格と Greeks を確認する。次に、同じ確率過程から Monte Carlo パスを生成し、満期 Payoff の割引期待値が解析解へ近づくことを確認する。

その後、Black–Scholes–Merton モデルによる株式オプション評価へ戻り、European オプションの解析解と二項 Tree を比較する。さらに、American オプションの早期行使価値を、近似解、二項 Tree および Longstaff–Schwartz 法によって評価する。

Black モデルは、原資産価格を正の値に限定する対数正規モデルである。この性質は株式や先物価格の評価には都合がよい一方、金利がゼロまたはマイナスとなる市場では制約となる。次章では、この制約を持たない Normal モデルを取り上げ、Black モデルとの違いを確認する。

```
knitr::opts_chunk$set(
  collapse = TRUE,
  comment = "#>",
  warning = FALSE,
  message = FALSE
)

suppressPackageStartupMessages({
  library(tidyverse)
```

```
library(QuantLib)
library(GaussQuant)
})
```

4.1 Black–Scholes–Merton と Black-76

4.1.1 Black–Scholes–Merton モデル

リスク中立測度の下で、株価 S_t は次の確率微分方程式に従うと仮定する。

$$dS_t = (r - q)S_t dt + \sigma S_t dW_t$$

ここで、 r は無リスク金利、 q は配当利回り、 σ はボラティリティ、 W_t はブラウン運動である。

満期 T のフォワード価格は次式となる。

$$F_0 = S_0 e^{(r-q)T}$$

したがって、Black–Scholes–Merton モデルは現物価格を出発点として、金利と配当を通じてフォワード価格を内生的に求めるモデルとみることができる。

4.1.2 Black-76 モデル

Black-76 では、フォワード価格 F_0 を直接入力する。European call の価格は次式で与えられる。

$$C = D(0, T) [F_0 N(d_1) - K N(d_2)]$$

European put の価格は次式となる。

$$P = D(0, T) [K N(-d_2) - F_0 N(-d_1)]$$

ここで、

$$d_1 = \frac{\log(F_0/K) + \frac{1}{2}\sigma^2 T}{\sigma\sqrt{T}}$$

$$d_2 = d_1 - \sigma\sqrt{T}$$

であり、 K は行使価格、 $D(0, T)$ は満期までの割引係数、 $N(\cdot)$ は標準正規分布の累積分布関数である。

金利が決定論的である場合、同一満期の先物価格とフォワード価格は一致するため、Black-76 は先物オプションとフォワードオプションの双方に用いられる。

4.1.3 Black-76 の入力条件

本節では、債券先物オプションを意識した価格表示を使用する。フォワード価格は 107 と 32 分の 6.75、行使価格は 107.5、ボラティリティは 5.2%、無リスク金利は 5% とする。

Black-76 では、現物価格ではなく、オプション満期に対応するフォワード価格または先物価格を原資産として使用する。

```
black_input_tbl <- tibble::tribble(
  ~input,      ~value,
  "trade_date", "2023-07-21",
  "maturity_date", "2023-08-26",
  "forward_price", as.character(107 + 6.75 / 32),
  "strike_price",  as.character(107.5),
  "volatility",    as.character(0.052),
  "risk_free_rate", as.character(0.05)
)

trade_date <- GaussQuant::date_GQL("2023-07-21")
maturity_date <- GaussQuant::date_GQL("2023-08-26")
forward_price <- 107 + 6.75 / 32
strike_price <- 107.5
volatility <- 0.052
risk_free_rate <- 0.05
day_counter <- QuantLib::Actual365Fixed()

call_payoff <- QuantLib::PlainVanillaPayoff(
  QuantLib::Option_Call_get(),
  strike_price
)

GaussQuant::set_eval_date_GQL(trade_date)

maturity <- day_counter$yearFraction(
  trade_date,
  maturity_date
)

GaussQuant::show_tbl_GQH(
  black_input_tbl,
  "Black-76 input assumptions",
  n = 20
)

#> # A tibble: 6 x 2
```

```
#>   input      value
#>   <chr>      <chr>
#> 1 trade_date 2023-07-21
#> 2 maturity_date 2023-08-26
#> 3 forward_price 107.2109375
#> 4 strike_price 107.5
#> 5 volatility 0.052
#> 6 risk_free_rate 0.05
```

4.2 Black-76 による解析評価

4.2.1 Black 公式による価格と Greeks

BlackCalculator は、フォワード価格、行使価格、総標準偏差および割引係数から、オプション価格と Greeks を直接計算する。

QuantLib へ渡される総標準偏差は、単なる年率ボラティリティではなく、

$$\sigma\sqrt{T}$$

である。

本節では、次の Greeks を確認する。

- **Delta**：フォワード価格の変化に対するオプション価格の感応度
- **Gamma**：フォワード価格の変化に対する Delta の感応度
- **Vega**：ボラティリティの変化に対するオプション価格の感応度
- **Theta**：時間経過に対するオプション価格の感応度

Black-76 の Delta はフォワード価格に対する Delta であり、株式オプションの Spot Delta とは区別する必要がある。

```
black_bundle <- GaussQuant::black_process_bundle_GQL(
  valuation_date = trade_date,
  forward = forward_price,
  risk_free_rate = risk_free_rate,
  volatility = volatility,
  day_counter = day_counter
)

discount_factor <- black_bundle$discount_curve$discount(
  maturity_date
)

black_calculator_tbl <- GaussQuant::black_calculator_table_GQL(
  payoff = call_payoff,
```

```

    forward = forward_price,
    volatility = volatility,
    maturity = maturity,
    discount_factor = discount_factor
)

GaussQuant::show_tbl_GQH(
  black_calculator_tbl,
  "Black calculator summary",
  n = 20
)

#> # A tibble: 6 x 2
#>   metric      value
#>   <chr>      <dbl>
#> 1 npv        0.562
#> 2 delta       0.436
#> 3 gamma       0.224
#> 4 vega       13.2
#> 5 theta      -3.45
#> 6 theta_per_day -0.00946

```

4.2.2 Black 過程による European option 評価

前節では Black 公式を直接使用した。本節では、同じ入力条件から Black process を構築し、European option へ解析的 Pricing Engine を設定する。

数式を直接評価する方法と、確率過程および Pricing Engine を通じて評価する方法が、同一の理論価格を与えることを確認する。

```

european_call <- QuantLib::VanillaOption(
  call_payoff,
  QuantLib::EuropeanExercise(maturity_date)
)

analytic_engine <- QuantLib::AnalyticEuropeanEngine(
  black_bundle$process
)

european_call$setPricingEngine(
  analytic_engine
)

#> NULL

analytic_european_tbl <- GaussQuant::option_metric_table_GQL(

```

```

    option = european_call,
    process = black_bundle$process
  )

analytic_npv <- analytic_european_tbl |>
  dplyr::filter(.data$metric == "npv") |>
  dplyr::pull(.data$value)

GaussQuant::show_tbl_GQH(
  analytic_european_tbl,
  "Analytic European call",
  n = 20
)

#> # A tibble: 7 x 2
#>   metric      value
#>   <chr>      <dbl>
#> 1 npv        0.562
#> 2 delta      0.436
#> 3 gamma      0.224
#> 4 vega      13.2
#> 5 theta     -3.45
#> 6 theta_per_day -0.00946
#> 7 implied_volatility 0.0520

```

4.3 Black–Scholes–Merton と European option

4.3.1 Black–Scholes–Merton モデルの入力条件

ここからは現物株価を原資産とする Black–Scholes–Merton モデルを扱う。現物価格 100、行使価格 100、満期 1 年、ボラティリティ 20%、無リスク金利 5%、配当利回り 0% とする。

Black–Scholes–Merton process では、現物価格に加えて、無リスク金利カーブ、配当利回りカーブおよびボラティリティカーブを設定する。

```

bsm_input_tbl <- tibble::tribble(
  ~input,      ~value,
  "trade_date", "2024-03-01",
  "maturity",   "1Y",
  "spot_price", as.character(100),
  "strike_price", as.character(100),
  "volatility",  as.character(0.20),
  "risk_free_rate", as.character(0.05),
  "dividend_rate", as.character(0)
)

```



```

trade_date_bsm <- GaussQuant::date_GQL("2024-03-01")
calendar_bsm <- QuantLib::TARGET()

maturity_date_bsm <- calendar_bsm$advance(
  trade_date_bsm,
  1L,
  "Years"
)

spot_price_bsm <- 100
strike_price_bsm <- 100
volatility_bsm <- 0.20
risk_free_rate_bsm <- 0.05
dividend_rate_bsm <- 0

GaussQuant::set_eval_date_GQL(
  trade_date_bsm
)

bsm_bundle <- GaussQuant::bsm_process_bundle_GQL(
  valuation_date = trade_date_bsm,
  spot = spot_price_bsm,
  risk_free_rate = risk_free_rate_bsm,
  dividend_rate = dividend_rate_bsm,
  volatility = volatility_bsm,
  day_counter = day_counter,
  calendar = calendar_bsm
)

GaussQuant::show_tbl_GQH(
  bsm_input_tbl,
  "Black-Scholes-Merton assumptions",
  n = 20
)

#> # A tibble: 7 x 2
#>   input      value
#>   <chr>      <chr>
#> 1 trade_date 2024-03-01
#> 2 maturity   1Y
#> 3 spot_price 100
#> 4 strike_price 100
#> 5 volatility  0.2
#> 6 risk_free_rate 0.05

```

```
#> 7 dividend_rate 0
```

4.3.2 European put の解析解と二項 Tree

European オプションは満期時にのみ行使できるため、Black–Scholes–Merton モデルの解析解を利用できる。

二項 Tree では、連続時間の価格過程を有限個の時間ステップへ分割する。ステップ数を増やすほど、理論上は連続時間モデルの解析値へ近づく。

ここでは、25、100 および 500 ステップの Cox–Ross–Rubinstein Tree を解析解と比較する。

```

european_put <- GaussQuant::make_european_option_GQL(
  spot = spot_price_bsm,
  strike = strike_price_bsm,
  maturity_date = maturity_date_bsm,
  option_type = "put",
  valuation_date = trade_date_bsm,
  risk_free_rate = risk_free_rate_bsm,
  dividend_yield = dividend_rate_bsm,
  volatility = volatility_bsm,
  day_counter = day_counter,
  calendar = calendar_bsm
)

european_engines <- list(
  crr_25 = QuantLib::BinomialCRRVanillaEngine(
    bsm_bundle$process,
    25L
  ),
  analytic = QuantLib::AnalyticEuropeanEngine(
    bsm_bundle$process
  ),
  crr_100 = QuantLib::BinomialCRRVanillaEngine(
    bsm_bundle$process,
    100L
  ),
  crr_500 = QuantLib::BinomialCRRVanillaEngine(
    bsm_bundle$process,
    500L
  )
)

european_comparison_tbl <- purrr::imap_dfr(
  european_engines,
  function(engine, method) {

```

```

european_put$setPricingEngine(engine)

tibble::tibble(
  method = method,
  npv = european_put$NPV()
)
}
)

analytic_put_npv <- european_comparison_tbl |>
  dplyr::filter(.data$method == "analytic") |>
  dplyr::pull(.data$npv)

european_comparison_tbl <- european_comparison_tbl |>
  dplyr::mutate(
    difference_from_analytic = .data$npv - analytic_put_npv
  )

GaussQuant::show_tbl_GQH(
  european_comparison_tbl,
  "European put engine comparison",
  n = 20
)

#> # A tibble: 4 x 3
#>   method      npv difference_from_analytic
#>   <chr>      <dbl>                <dbl>
#> 1 crr_25    5.65                0.0720
#> 2 analytic  5.58                  0
#> 3 crr_100   5.56               -0.0197
#> 4 crr_500   5.58               -0.00394

```

4.4 Monte Carlo 評価

4.4.1 擬似乱数 Monte Carlo 評価

リスク中立評価では、オプション価格は満期 Payoff の割引期待値として表される。

$$V_0 = D(0, T) E^Q [\max(F_T - K, 0)]$$

Monte Carlo 法では、多数の将来パスを生成し、各パスの満期 Payoff を求め、その平均値を割り引く。

European call には解析解があるため、ここで Monte Carlo 法を使う目的は、解析解に代わる高度な方法を示すことではない。確率過程から生成したパスの期待値が Black 公式の価格へ近づくことを確認し、後に解析解を持たない商品へ応用する準備をすることにある。

```

mc_setting_tbl <- tibble::tribble(
  ~setting, ~value,
  "steps", 12,
  "paths", 20000,
  "seed", 1
)

mc_path_tbl <- GaussQuant::generate_path_table_GQL(
  process = black_bundle$process,
  maturity = maturity,
  n_steps = 12L,
  n_paths = 20000L,
  seed = 1L,
  sequence = "pseudo"
)

mc_result <- GaussQuant::terminal_option_mc_GQL(
  path_tbl = mc_path_tbl,
  strike = strike_price,
  discount_factor = discount_factor,
  option_type = "call"
)

mc_comparison_tbl <- tibble::tribble(
  ~method, ~npv, ~standard_error,
  "Black analytic", analytic_npv, NA_real_,
  "Pseudo-random Monte Carlo", mc_result$summary$npv[[1]], mc_result$summary$standard_error[[1]]
) |>
  dplyr::mutate(
    difference_from_analytic = .data$npv - analytic_npv
  )

GaussQuant::show_tbl_GQH(
  mc_setting_tbl,
  "Monte Carlo settings",
  n = 20
)

#> # A tibble: 3 x 2
#>   setting value
#>   <chr>   <dbl>
#> 1 steps      12
#> 2 paths    20000
#> 3 seed         1

```

```
GaussQuant::show_tbl_GQH(
  mc_comparison_tbl,
  "Analytic and Monte Carlo comparison",
  n = 20
)
#> # A tibble: 2 x 4
#>   method          npv standard_error difference_from_analytic
#>   <chr>          <dbl>         <dbl>          <dbl>
#> 1 Black analytic    0.562           NA              0
#> 2 Pseudo-random Monte Carlo 0.560       0.00654      -0.00163
```

標準誤差は、有限本数のパスを用いたことによる Monte Carlo 推定値の不確実性を表す。解析値との差が標準誤差と同程度であれば、シミュレーション結果は統計的に整合的と判断できる。

4.4.2 Monte Carlo パスの可視化

Black process では、フォワード価格は対数正規分布に従う。したがって、各パスの価格は常に正であり、満期価格の分布は左右対称にはならない。

次のグラフでは、前節と同じオプション満期までの 120 本のパスと、その満期価格分布を表示する。

```
path_plot_tbl <- GaussQuant::generate_path_table_GQL(
  process = black_bundle$process,
  maturity = maturity,
  n_steps = 12L,
  n_paths = 120L,
  seed = 1L,
  sequence = "pseudo"
)

path_plot <- ggplot2::ggplot(
  path_plot_tbl,
  ggplot2::aes(
    x = .data$time,
    y = .data$price,
    group = .data$path_id
  )
) +
  ggplot2::geom_line(
    alpha = 0.45,
    linewidth = 0.4
  ) +
  ggplot2::labs(
    title = "Black model Monte Carlo paths",


```

```
x = "Year",
y = "Forward price"
) +
ggplot2::theme_minimal()


terminal_plot_tbl <- path_plot_tbl |>
  dplyr::group_by(.data$path_id) |>
  dplyr::slice_max(
    order_by = .data$step,
    n = 1L,
    with_ties = FALSE
  ) |>
  dplyr::ungroup()

terminal_plot <- ggplot2::ggplot(
  terminal_plot_tbl,
  ggplot2::aes(x = .data$price)
) +
  ggplot2::geom_histogram(
    bins = 24
  ) +
  ggplot2::labs(
    title = "Terminal forward-price distribution",
    x = "Terminal price",
    y = "Count"
  ) +
  ggplot2::theme_minimal()

print(path_plot)
```



```
print(terminal_plot)
```



4.4.3 Black 過程の 1 パス

Black process のフォワード価格は、時間幅 Δt ごとに次式で更新できる。

$$F_{t+\Delta t} = F_t \exp \left[-\frac{1}{2} \sigma^2 \Delta t + \sigma \sqrt{\Delta t} Z \right]$$

ここで、 Z は標準正規乱数である。フォワード測度の下ではフォワード価格のドリフトがゼロであるため、指数部には Ito 補正項である $-\frac{1}{2} \sigma^2 \Delta t$ が現れる。

QuantLib の PathGenerator が使用する Gaussian increment を取り出し、同じ乱数から手計算したパスと比較する。

```
n_steps_check <- 3L
seed_check <- 1L

generated_path_tbl <- GaussQuant::generate_path_table_GQL(
  process = black_bundle$process,
  maturity = maturity,
  n_steps = n_steps_check,
  n_paths = 1L,
  seed = seed_check,
  sequence = "pseudo"
)

gaussian_rng_check <- QuantLib::GaussianRandomSequenceGenerator(
  QuantLib::UniformRandomSequenceGenerator(
    n_steps_check,
    QuantLib::UniformRandomGenerator(seed_check)
  )
)

gaussian_increment <- gaussian_rng_check$nextSequence()$value() |>
  as.numeric()

time_grid_check <- generated_path_tbl |>
  dplyr::arrange(.data$step) |>
  dplyr::pull(.data$time)

dt_check <- diff(time_grid_check)

growth_factor <- exp(
  -0.5 * volatility^2 * dt_check +
  volatility * sqrt(dt_check) * gaussian_increment
)

hand_price <- forward_price * c(
  1,
  cumprod(growth_factor)
)

one_path_check_tbl <- generated_path_tbl |>
  dplyr::arrange(.data$step) |>
  dplyr::transmute(
```



```

    step = .data$step,
    time = .data$time,
    generated_price = .data$price,
    hand_price = hand_price,
    difference = .data$price - hand_price
  )

GaussQuant::show_tbl_GQH(
  one_path_check_tbl,
  "One-path hand calculation",
  n = 20
)

#> # A tibble: 4 x 5
#>   step   time generated_price hand_price difference
#>   <int> <dbl>         <dbl>      <dbl>      <dbl>
#> 1     0  0          107.        107.        0
#> 2     1 0.0329        107.        107.        0
#> 3     2 0.0658        110.        110.        0
#> 4     3 0.0986        110.        110.   -1.42e-14

```

差が数値誤差の範囲に収まれば、PathGenerator が Black 過程の離散化式に従っていることを確認できる。

4.5 American put の早期行使価値

American オプションは満期までの任意の時点で行使できる。したがって、その価値は同じ条件の European オプション以上となる。

$$V_{\text{American}} \geq V_{\text{European}}$$

両者の差は早期行使権の価値である。

American put には一般的な閉形式の解析解がないため、二項 Tree または近似法を用いる。本節では、次の方法を比較する。

- 25 ステップ CRR Tree
- Barone-Adesi-Whaley 近似
- Bjerksund-Stensland 近似
- 500 ステップ CRR Tree

500 ステップ CRR Tree を比較基準とする。

```

american_put <- GaussQuant::make_american_option_GQL(
  spot = spot_price_bsm,
  strike = strike_price_bsm,
  maturity_date = maturity_date_bsm,

```

```

option_type = "put",
valuation_date = trade_date_bsm,
risk_free_rate = risk_free_rate_bsm,
dividend_yield = dividend_rate_bsm,
volatility = volatility_bsm,
day_counter = day_counter,
calendar = calendar_bsm,
steps = 500L
)

american_engines <- list(
  crr_25 = QuantLib::BinomialCRRVanillaEngine(
    bsm_bundle$process,
    25L
  ),
  barone_adesi_whaley = QuantLib::BaroneAdesiWhaleyApproximationEngine(
    bsm_bundle$process
  ),
  bjerksund_stensland = QuantLib::BjerksundStenslandApproximationEngine(
    bsm_bundle$process
  ),
  crr_500 = QuantLib::BinomialCRRVanillaEngine(
    bsm_bundle$process,
    500L
  )
)

american_comparison_tbl <- purrr::imap_dfr(
  american_engines,
  function(engine, method) {
    american_put$setPricingEngine(engine)

    tibble::tibble(
      method = method,
      npv = american_put$NPV()
    )
  }
)

crr_500_american_npv <- american_comparison_tbl |>
  dplyr::filter(.data$method == "crr_500") |>
  dplyr::pull(.data$npv)

```

```
american_comparison_tbl <- american_comparison_tbl |>
  dplyr::mutate(
    difference_from_crr_500 = .data$npv - crr_500_american_npv
  )

GaussQuant::show_tbl_GQH(
  american_comparison_tbl,
  "American put engine comparison",
  n = 20
)

#> # A tibble: 4 x 3
#>   method                npv difference_from_crr_500
#>   <chr>                <dbl>                <dbl>
#> 1 crr_25                6.16                0.0584
#> 2 barone_adesi_whaley  6.11                0.00892
#> 3 bjerksund_stensland  6.00               -0.106
#> 4 crr_500              6.10                0
```

4.6 準 Monte Carlo と Longstaff–Schwartz 法

4.6.1 Sobol 系列によるパス生成

擬似乱数は乱数生成器によって確率的な点列を作る。これに対し Sobol 系列は、積分領域をできるだけ均等に覆うように構成された低乖離列である。

Sobol 系列を用いる準 Monte Carlo 法では、通常の擬似乱数より少ないパスで安定した数値積分が得られる場合がある。ただし、パス同士は独立な確率標本ではないため、通常の標準誤差の解釈をそのまま適用できない点に注意する。

次のコードでは、Black–Scholes–Merton process から 64 本の Sobol パスを生成する。

```
maturity_bsm <- day_counter$yearFraction(
  trade_date_bsm,
  maturity_date_bsm
)

sobol_display_tbl <- GaussQuant::generate_path_table_GQL(
  process = bsm_bundle$process,
  maturity = maturity_bsm,
  n_steps = 12L,
  n_paths = 64L,
  seed = 1L,
  sequence = "sobol"
)
```

```
sobol_plot <- ggplot2::ggplot(
  sobol_display_tbl,
  ggplot2::aes(
    x = .data$time,
    y = .data$price,
    group = .data$path_id
  )
) +
  ggplot2::geom_line(
    alpha = 0.5,
    linewidth = 0.4
  ) +
  ggplot2::labs(
    title = "Black-Scholes-Merton Sobol paths",
    x = "Year",
    y = "Stock price"
  ) +
  ggplot2::theme_minimal()
```

```
GaussQuant::show_tbl_GQH(
```


```
  sobol_display_tbl,
  "Sobol path table",
  n = 20
)
```

```
#> # A tibble: 20 x 4
```

```
#>   path_id  step  time price
#>   <int> <int> <dbl> <dbl>
#> 1      1     0  0     100
#> 2      1     1 0.0838 100.
#> 3      1     2 0.168  101.
#> 4      1     3 0.251  101.
#> 5      1     4 0.335  101.
#> 6      1     5 0.419  101.
#> 7      1     6 0.503  102.
#> 8      1     7 0.587  102.
#> 9      1     8 0.670  102.
#> 10     1     9 0.754  102.
#> 11     1    10 0.838  103.
#> 12     1    11 0.922  103.
#> 13     1    12 1.01   103.
#> 14     2     0  0     100
#> 15     2     1 0.0838 104.
#> 16     2     2 0.168  101.
```

```
#> 17      2      3 0.251  105.
#> 18      2      4 0.335  101.
#> 19      2      5 0.419  105.
#> 20      2      6 0.503  102.
```

```
print(sobol_plot)
```



4.6.2 Longstaff-Schwartz 法

American オプションでは、各行使可能時点において、即時行使価値と保有を継続する価値を比較する必要がある。

put の即時行使価値は次式である。

$$I(S_t) = \max(K - S_t, 0)$$

Longstaff-Schwartz 法では、将来受け取る割引 Cashflow を原資産価格の関数として回帰し、条件付き継続価値を推定する。本章では、次の 2 次多項式を使用する。

$$\widehat{C}(S_t) = \beta_0 + \beta_1 S_t + \beta_2 S_t^2$$

即時行使価値が推定継続価値を上回る場合、その時点で行使する。

本節では、2,048 本の Sobol パスから American put を評価し、500 ステップ CRR Tree と比較する。

```
lsm_path_tbl <- GaussQuant::generate_path_table_GQL(
  process = bsm_bundle$process,
  maturity = maturity_bsm,
```

```

n_steps = 12L,
n_paths = 2048L,
seed = 1L,
sequence = "sobol"
)

lsm_result <- GaussQuant::lsm_american_put_GQL(
  path_tbl = lsm_path_tbl,
  strike = strike_price_bsm,
  risk_free_rate = risk_free_rate_bsm
)

lsm_npv <- lsm_result$summary |>
  dplyr::filter(.data$metric == "lsm_npv") |>
  dplyr::pull(.data$value)

lsm_comparison_tbl <- tibble::tribble(
  ~method, ~npv,
  "Longstaff-Schwartz Sobol", lsm_npv,
  "CRR Tree 500 steps", crr_500_american_npv
) |>
  dplyr::mutate(
    difference_from_crr_500 = .data$npv - crr_500_american_npv
  )

exercise_summary_tbl <- lsm_result$exercise |>
  dplyr::count(
    .data$exercise_step,
    .data$exercise_time,
    name = "paths"
  ) |>
  dplyr::arrange(.data$exercise_step)

GaussQuant::show_tbl_GQH(
  lsm_result$summary,
  "Longstaff-Schwartz summary",
  n = 20
)

#> # A tibble: 4 x 2
#>   metric      value
#>   <chr>      <dbl>
#> 1 lsm_npv      6.29
#> 2 standard_error 0.167

```

```

#> 3 paths          2048
#> 4 steps           12

GaussQuant::show_tbl_GQH(
  lsm_comparison_tbl,
  "Longstaff-Schwartz and CRR comparison",
  n = 20
)
#> # A tibble: 2 x 3
#>   method          npv difference_from_crr_500
#>   <chr>          <dbl>          <dbl>
#> 1 Longstaff-Schwartz Sobol  6.29          0.191
#> 2 CRR Tree 500 steps      6.10           0

GaussQuant::show_tbl_GQH(
  exercise_summary_tbl,
  "Longstaff-Schwartz exercise timing",
  n = 20
)
#> # A tibble: 11 x 3
#>   exercise_step exercise_time paths
#>   <int>          <dbl> <int>
#> 1           2      0.168    28
#> 2           3      0.251    52
#> 3           4      0.335    57
#> 4           5      0.419   109
#> 5           6      0.503   107
#> 6           7      0.587   100
#> 7           8      0.670    87
#> 8           9      0.754    38
#> 9          10      0.838    78
#> 10          11      0.922    96
#> 11          12      1.01   1296

GaussQuant::show_tbl_GQH(
  lsm_result$diagnostics,
  "Longstaff-Schwartz diagnostics",
  n = 20
)
#> # A tibble: 11 x 6
#>   step   time in_the_money_paths exercised_paths mean_immediate_value
#>   <int> <dbl>          <int>          <int>          <dbl>
#> 1     11 0.922            931            575            5.68

```

```
#> 2 10 0.838 918 459 5.53
#> 3 9 0.754 932 355 5.28
#> 4 8 0.670 937 392 5.08
#> 5 7 0.587 945 338 4.82
#> 6 6 0.503 946 282 4.55
#> 7 5 0.419 939 193 4.25
#> 8 4 0.335 959 105 3.85
#> 9 3 0.251 970 69 3.41
#> 10 2 0.168 963 28 2.88
#> 11 1 0.0838 989 0 2.11
#> # i 1 more variable: mean_realized_continuation <dbl>
```

Longstaff–Schwartz 法の価格は、パス数、時間ステップ、基底関数および回帰誤差に依存する。したがって、二項 Tree との差が完全にゼロになることを目的とするのではなく、早期行使判断を Monte Carlo パス上でのように近似するかを確認する。

4.7 まとめ

Black-76 と Black–Scholes–Merton は、原資産が対数正規分布に従うという共通の仮定を持つ。Black–Scholes–Merton は現物価格から出発し、Black-76 はフォワード価格または先物価格を直接入力する。

Black-76 では、Black 公式による直接計算と、Black process を用いた解析的 Pricing Engine が同じ価格を与えることを確認した。さらに、Monte Carlo 法によって満期 Payoff の割引期待値を求め、解析値と比較した。

Black–Scholes–Merton モデルでは、European put の解析解と CRR Tree を比較した。American put では、早期行使権を評価するため、近似 Engine、CRR Tree および Longstaff–Schwartz 法を比較した。

解析解、Tree、Monte Carlo および回帰法は、互いに競合する単純な代替手法ではない。Payoff の構造、早期行使の有無、モデルの次元および必要な計算精度に応じて使い分ける必要がある。

Black モデルの対数正規仮定は、価格が正である市場では扱いやすい。一方、金利がゼロまたはマイナスとなる場合には直接適用できない。この問題が、Normal モデルや Shifted Black モデルを用いる理由となる。

```
chapter04_summary_tbl <- tibble::tribble(
  ~section, ~main_result,
  "Black-76", "Black calculator and analytic European pricing",
  "Pseudo-random Monte Carlo", "Discounted terminal payoff and standard error",
  "European put", "Analytic and CRR Tree comparison",
  "American put", "Approximation engines and CRR Tree comparison",
  "Sobol", "Low-discrepancy path generation",
  "Longstaff-Schwartz", "Regression-based early-exercise approximation"
)

GaussQuant::show_tbl_GQH(
  chapter04_summary_tbl,
  "Chapter II-4 summary",
```



```
n = 20
)
#> # A tibble: 6 x 2
#>   section          main_result
#>   <chr>          <chr>
#> 1 Black-76      Black calculator and analytic European pricing
#> 2 Pseudo-random Monte Carlo Discounted terminal payoff and standard error
#> 3 European put  Analytic and CRR Tree comparison
#> 4 American put  Approximation engines and CRR Tree comparison
#> 5 Sobol         Low-discrepancy path generation
#> 6 Longstaff-Schwartz Regression-based early-exercise approximation
```

第 II-5 章 Normal (Bachelier) モデル

前章では、株価や為替レートのように、価格の変化率をウィーナー過程によって表現する対象について、Black モデルを検討した。Black モデルでは、原資産の変動幅がその時点の価格水準に比例する幾何ブラウン運動を仮定するため、原資産価格は常に正の値を取る。

これに対して、本章では金利を原資産とするオプションを検討する。金利は株価や為替レートとは異なり、満期ごとに異なる期間構造を持ち、ゼロまたはマイナスの値を取る可能性もある。このため、金利を単一の幾何ブラウン運動によって表現することには限界がある。

本章では、金利期間構造全体を確率モデルとして記述するのではなく、特定の将来期間に対応するフォワード金利を直接モデル化する。適切なフォワード測度の下では、フォワード金利をマルチンゲールとして扱うことができる。

Black モデルでは、フォワード金利の変化幅がその金利水準に比例すると仮定する。

$$dF_t = \sigma_B F_t dW_t$$

この場合、フォワード金利は理論上常に正の値を取り、ゼロまたはマイナスの金利を直接扱うことができない。

そこで本章では、フォワード金利の変化額がウィーナー過程に従う Normal モデルを検討する。

$$dF_t = \sigma_N dW_t$$

このモデルでは、将来のフォワード金利は次のように表される。

$$F_T = F_0 + \sigma_N \sqrt{T} Z$$

ここで、 Z は標準正規分布に従う確率変数である。フォワード金利の変化幅は現在の金利水準に依存しないため、将来金利はゼロまたはマイナスの値も取り得る。

本章では、あえて金利期間構造全体の動学モデルを導入せず、各商品の評価に必要なフォワード金利を、それぞれに対応する測度の下でマルチンゲールとして直接モデル化する。この枠組みに基づき、金利先物オプション、Caplet、Cap および Swaption を Normal モデルによって評価する。

```
knitr::opts_chunk$set(
  collapse = TRUE,
  comment = "#>",
  warning = FALSE,
```

```

    message = FALSE
  )

suppressPackageStartupMessages({
  library(tidyverse)
  library(QuantLib)
  library(GaussQuant)
})

```

5.1 Normal モデルの基礎

5.1.1 金利モデルと測度

金利デリバティブでは、すべてのフォワード金利を一つの確率過程で表現するとは限らない。単一の Caplet を評価する場合、その Caplet が参照する期間のフォワード金利を、支払日を満期とするゼロクーポン債を Numeraire としたフォワード測度の下で扱う。

期間 $[T_1, T_2]$ のフォワード金利を $L_t(T_1, T_2)$ とすると、 T_2 -forward measure の下で、これをマルチンゲールとして次のように置く。

$$dL_t(T_1, T_2) = \sigma_N dW_t^{T_2}$$

一方、Swaption では、原資産は単一期間のフォワード金利ではなく、複数期間から構成されるフォワードスワップレートである。この場合は、固定レグのアンニュイティを Numeraire とする swap measure の下で、フォワードスワップレートをマルチンゲールとして扱う。

したがって本章では、期間構造全体を確率的に生成する HJM、LMM または短期金利モデルへ進むのではなく、各商品の自然なフォワード変数に対して局所的な Normal モデルを適用する。

現在価値を計算するためには割引係数が必要であるが、割引カーブ自体の動学はモデル化しない。本章では、与えられた割引係数または簡単な決定論的割引率を使用する。

5.1.2 Bachelier 価格公式

Normal モデルの下で、満期時のフォワード金利は次の正規分布に従う。

$$F_T \sim N(F_0, \sigma_N^2 T)$$

European call の価格は次式で与えられる。

$$C_N = D(0, T) \left[(F_0 - K)N(d) + \sigma_N \sqrt{T} \phi(d) \right]$$

European put の価格は次式となる。

$$P_N = D(0, T) \left[(K - F_0)N(-d) + \sigma_N \sqrt{T} \phi(d) \right]$$

ここで、

$$d = \frac{F_0 - K}{\sigma_N \sqrt{T}}$$

であり、 $D(0, T)$ は割引係数、 $N(\cdot)$ は標準正規分布の累積分布関数、 $\phi(\cdot)$ は標準正規分布の密度関数である。

Black 公式には $\log(F_0/K)$ が含まれるが、Normal 公式では差額 $F_0 - K$ だけを使用する。このため、フォワード金利または行使金利がゼロ以下であっても計算できる。

5.1.3 Normal volatility の単位

Black volatility は原資産価格に対する相対的な変化率であり、通常は百分率で表示される。

これに対して Normal volatility は、原資産と同じ単位を持つ。金利を小数で表す場合、Normal volatility 50bp は次の値である。

$$50 \text{ bp} = \frac{50}{10000} = 0.0050$$

したがって、 $\text{vol} = 0.0050$ は「0.5% の Black volatility」ではなく、**年率 50bp の Normal volatility** を意味する。

Normal モデルでは、

$$F_T - F_0 = \sigma_N \sqrt{T} Z$$

であるため、 $\sigma_N \sqrt{T}$ は満期までの金利変化額の標準偏差となる。

```
normal_volatility_bp <- 50
normal_volatility <- normal_volatility_bp / 10000

normal_volatility_tbl <- tibble::tribble(
  ~metric,          ~value,
  "normal_volatility_bp",    normal_volatility_bp,
  "normal_volatility_decimal",  normal_volatility,
  "one_standard_deviation_1y_bp", normal_volatility * 10000
)

GaussQuant::show_tbl_GQH(
  normal_volatility_tbl,
  "Normal volatility units",
  n = 20
)
```

```
#> # A tibble: 3 x 2
#>   metric          value
#>   <chr>          <dbl>
#> 1 normal_volatility_bp      50
#> 2 normal_volatility_decimal 0.005
#> 3 one_standard_deviation_1y_bp 50
```

5.2 SOFR 先物オプション

5.2.1 先物価格から金利への変換

短期金利先物は、一般に金利と反対方向に動く価格表示を使用する。本例では次の関係を用いる。

$$\text{Futures Price} = 100 - 100 \times \text{Rate}$$

したがって、先物価格 94.54 は金利 5.46% に対応する。

$$F_0 = \frac{100 - 94.54}{100} = 0.0546$$

行使価格 94.50 は行使金利 5.50% に対応する。

$$K = \frac{100 - 94.50}{100} = 0.0550$$

先物価格の call は、金利が低下して先物価格が上昇したときに価値を持つ。金利を原資産として表現すると、これは put に相当する。そのため、Normal 公式では `option_sign = -1` を使用する。

```
trade_date <- as.Date("2023-09-26")
maturity_date <- as.Date("2023-12-15")

futures_price <- 94.54
strike_futures_price <- 94.50

forward_rate <- (100 - futures_price) / 100
strike_rate <- (100 - strike_futures_price) / 100

normal_volatility <- 50 / 10000
risk_free_rate <- 5.4 / 100

maturity_year_fraction <- as.numeric(
  maturity_date - trade_date
) / 365

maturity_discount_factor <- exp(
```

```

    -risk_free_rate * maturity_year_fraction
  )

option_sign <- -1

futures_option_input_tbl <- tibble::tribble(
  ~input,          ~value,
  "trade_date",    as.character(trade_date),
  "maturity_date", as.character(maturity_date),
  "futures_price", as.character(futures_price),
  "strike_futures_price", as.character(strike_futures_price),
  "forward_rate",  as.character(forward_rate),
  "strike_rate",   as.character(strike_rate),
  "normal_volatility", as.character(normal_volatility),
  "maturity_year_fraction", as.character(maturity_year_fraction),
  "discount_factor",   as.character(maturity_discount_factor)
)

GaussQuant::show_tbl_GQH(
  futures_option_input_tbl,
  "Normal futures-option assumptions",
  n = 20
)

#> # A tibble: 9 x 2
#>   input          value
#>   <chr>          <chr>
#> 1 trade_date    2023-09-26
#> 2 maturity_date 2023-12-15
#> 3 futures_price 94.54
#> 4 strike_futures_price 94.5
#> 5 forward_rate  0.05459999999999999
#> 6 strike_rate   0.055
#> 7 normal_volatility 0.005
#> 8 maturity_year_fraction 0.219178082191781
#> 9 discount_factor 0.988234148959797

```

5.2.2 価格と Greeks

Normal モデルによる価格と Greeks を計算する。

```

normal_greeks_tbl <- GaussQuant::normal_option_greeks_GQL(
  option_sign = option_sign,
  forward = forward_rate,
  strike = strike_rate,

```

```

    vol = normal_volatility,
    maturity = maturity_year_fraction,
    discount_factor = maturity_discount_factor,
    risk_free_rate = risk_free_rate
  )

normal_npv <- normal_greeks_tbl |>
  dplyr::filter(.data$metric == "npv") |>
  dplyr::pull(.data$value)

contract_value_multiplier <- 100 * 2500

normal_summary_tbl <- dplyr::bind_rows(
  tibble::tibble(
    metric = c(
      "option_npv_rate_unit",
      "contract_value_multiplier",
      "delivery_amount"
    ),
    value = c(
      normal_npv,
      contract_value_multiplier,
      normal_npv * contract_value_multiplier
    )
  ),
  normal_greeks_tbl |>
    dplyr::filter(.data$metric != "npv")
)

GaussQuant::show_tbl_GQH(
  normal_summary_tbl,
  "Normal futures-option summary",
  n = 20
)

#> # A tibble: 7 x 2
#>   metric                                value
#>   <chr>                                <dbl>
#> 1 option_npv_rate_unit                0.00113
#> 2 contract_value_multiplier 250000
#> 3 delivery_amount                283.
#> 4 delta                            -0.561
#> 5 gamma                           166.
#> 6 vega                             0.182

```

```
#> 7 theta -0.00201
```

`option_npv_rate_unit` は金利を小数表示した単位でのオプション価値である。金額換算は商品ごとの契約乗数に依存する。本例では、原章と同じ換算係数 $100 * 2500$ を使用する。

5.3 マイナス金利とボラティリティ分析

5.3.1 ゼロ金利とマイナス金利

Normal モデルの重要な特徴は、フォワード金利がゼロまたはマイナスの場合でも価格公式を変更する必要がないことである。

次の例では、フォワード金利をマイナス 0.20%、行使金利を 0%、Normal volatility を 60bp とする。

```
negative_rate_example_tbl <- tibble::tribble(
  ~option_type, ~option_sign, ~forward, ~strike,
  "call",      1,             -0.0020,  0.0000,
  "put",       -1,             -0.0020,  0.0000
) |>
dplyr::mutate(
  normal_volatility = 60 / 10000,
  maturity = 1,
  discount_factor = exp(-0.01),
  npv = purrr::pmap_dbl(
    list(
      .data$option_sign,
      .data$forward,
      .data$strike,
      .data$normal_volatility,
      .data$maturity,
      .data$discount_factor
    ),
    function(
      option_sign,
      forward,
      strike,
      normal_volatility,
      maturity,
      discount_factor
    ) {
      GaussQuant::normal_option_price_GQL(
        option_sign = option_sign,
        forward = forward,
        strike = strike,
        vol = normal_volatility,
```



```

        maturity = maturity,
        discount_factor = discount_factor
    )
}
)
)

GaussQuant::show_tbl_GQH(
  negative_rate_example_tbl,
  "Normal pricing with a negative forward rate",
  n = 20
)

#> # A tibble: 2 x 8
#>   option_type option_sign forward strike normal_volatility maturity
#>   <chr>         <dbl>   <dbl>  <dbl>         <dbl>      <dbl>
#> 1 call           1 -0.002    0           0.006        1
#> 2 put          -1 -0.002    0           0.006        1
#> # i 2 more variables: discount_factor <dbl>, npv <dbl>

```

Normal 分布は下方に限界を持たないため、極端なマイナス金利も正の確率で許容する。これは計算上の柔軟性である一方、経済的には常に現実的とは限らない。

5.3.2 インプライド Normal ボラティリティ

市場で観測されるオプション価格から、Normal モデルと整合するボラティリティを逆算したものがインプライド Normal ボラティリティである。

市場価格を V_{mkt} とすると、次式を満たす σ_N を求める。

$$V_N(F_0, K, T, D, \sigma_N) = V_{\text{mkt}}$$

GaussQuant には、Normal 価格からボラティリティを直接逆算する関数が用意されている。

```

target_npv <- 0.1133 / 100

implied_normal_volatility <- GaussQuant::normal_vol_from_price_GQL(
  option_sign = option_sign,
  strike = strike_rate,
  forward = forward_rate,
  maturity = maturity_year_fraction,
  option_npv = target_npv,
  discount_factor = maturity_discount_factor
)

```

```

repriced_target <- GaussQuant::normal_option_price_GQL(
  option_sign = option_sign,
  forward = forward_rate,
  strike = strike_rate,
  vol = implied_normal_volatility,
  maturity = maturity_year_fraction,
  discount_factor = maturity_discount_factor
)

implied_volatility_tbl <- tibble::tribble(
  ~metric,          ~value,
  "target_npv",     target_npv,
  "implied_normal_volatility", implied_normal_volatility,
  "implied_normal_volatility_bp", implied_normal_volatility * 10000,
  "repriced_npv",   repriced_target,
  "repricing_difference", repriced_target - target_npv
)

GaussQuant::show_tbl_GQH(
  implied_volatility_tbl,
  "Implied normal volatility",
  n = 20
)

#> # A tibble: 5 x 2
#>   metric          value
#>   <chr>          <dbl>
#> 1 target_npv      0.00113
#> 2 implied_normal_volatility 0.00499
#> 3 implied_normal_volatility_bp 49.9
#> 4 repriced_npv    0.00113
#> 5 repricing_difference      0

```

再評価値と市場価格の差が数値誤差の範囲に収まれば、逆算結果が正しいことを確認できる。

5.3.3 金利・ボラティリティ・時間シナリオ

Normal モデルでは、フォワード金利と Normal volatility がいずれも絶対変化量で表される。このため、シナリオも 1bp 単位の加算として設定する方が分かりやすい。

```

normal_calculator_function <- GaussQuant::make_normal_calculator_GQL(
  option_sign = option_sign,
  strike = strike_rate,
  maturity = maturity_year_fraction,
  discount_factor = maturity_discount_factor,

```

```

    forward = forward_rate,
    vol = normal_volatility
  )

normal_calculator_object <- GaussQuant::normal_calculator_GQL(
  option_sign = option_sign,
  strike = strike_rate,
  maturity = maturity_year_fraction,
  discount_factor = maturity_discount_factor,
  forward = forward_rate,
  vol = normal_volatility
)

forward_up_1bp <- forward_rate + 1 / 10000
volatility_up_1bp <- normal_volatility + 1 / 10000

maturity_after_one_day <- max(
  maturity_year_fraction - 1 / 365,
  0
)

discount_factor_after_one_day <- exp(
  -risk_free_rate * maturity_after_one_day
)

closure_scenario_tbl <- tibble::tribble(
  ~scenario,      ~npv,
  "base",         normal_calculator_function(),
  "forward_up_1bp", normal_calculator_function(
    forward_new = forward_up_1bp
  ),
  "normal_vol_up_1bp", normal_calculator_function(
    vol_new = volatility_up_1bp
  ),
  "one_day_passed",   normal_calculator_function(
    maturity_new = maturity_after_one_day,
    discount_factor_new = discount_factor_after_one_day
  )
) |>
dplyr::mutate(
  difference_from_base = .data$npv -
    .data$npv[.data$scenario == "base"]
)

```

```

class_style_tbl <- tibble::tribble(
  ~scenario,      ~npv,
  "base",         normal_calculator_object$npv(),
  "forward_up_1bp", normal_calculator_object$npv(
    forward_new = forward_up_1bp
  ),
  "normal_vol_up_1bp", normal_calculator_object$npv(
    vol_new = volatility_up_1bp
  ),
  "one_day_passed", normal_calculator_object$npv(
    maturity_new = maturity_after_one_day,
    discount_factor_new = discount_factor_after_one_day
  )
)

GaussQuant::show_tbl_GQH(
  closure_scenario_tbl,
  "Normal-model scenarios",
  n = 20
)

#> # A tibble: 4 x 3
#>   scenario      npv difference_from_base
#>   <chr>      <dbl>          <dbl>
#> 1 base      0.00113            0
#> 2 forward_up_1bp 0.00108        -0.0000553
#> 3 normal_vol_up_1bp 0.00115        0.0000182
#> 4 one_day_passed 0.00113        -0.00000553

GaussQuant::show_tbl_GQH(
  class_style_tbl,
  "Class-like normal calculator",
  n = 20
)

#> # A tibble: 4 x 2
#>   scenario      npv
#>   <chr>      <dbl>
#> 1 base      0.00113
#> 2 forward_up_1bp 0.00108
#> 3 normal_vol_up_1bp 0.00115
#> 4 one_day_passed 0.00113

```

先物価格の call を金利 put として評価しているため、金利が 1bp 上昇するとオプション価値は低下する。Normal volatility が上昇すると、選択権の時間価値が増加する。

5.4 Caplet と Cap

Caplet は、将来の単一期間のフォワード金利に対する call option である。期間 $[T_{i-1}, T_i]$ のフォワード金利を F_i 、行使金利を K 、年率換算期間を α_i 、支払日の割引係数を $P(0, T_i)$ とする。

Caplet の価格は次式となる。

$$V_i^{\text{caplet}} = N\alpha_i P(0, T_i) [(F_i - K)N(d_i) + \sigma_{N,i} \sqrt{\tau_i} \phi(d_i)]$$

ここで、

$$d_i = \frac{F_i - K}{\sigma_{N,i} \sqrt{\tau_i}}$$

である。Cap は複数の Caplet の合計として評価される。

$$V^{\text{cap}} = \sum_i V_i^{\text{caplet}}$$

本節では、期間構造モデルを構築せず、各 Caplet のフォワード金利、Fixing までの時間および割引係数を外生的に与える。

```
cap_notional <- 10000000
cap_strike <- 0.05
flat_discount_rate <- 0.045

caplet_input_tbl <- tibble::tribble(
  ~caplet, ~fixing_time, ~payment_time, ~accrual_fraction, ~forward_rate, ~normal_vol_bp,
  1L,      0.25,      0.50,      0.25,      0.0510,      80,
  2L,      0.50,      0.75,      0.25,      0.0505,      82,
  3L,      0.75,      1.00,      0.25,      0.0495,      84,
  4L,      1.00,      1.25,      0.25,      0.0485,      86
) |>
dplyr::mutate(
  normal_volatility = .data$normal_vol_bp / 10000,
  discount_factor = exp(
    -flat_discount_rate * .data$payment_time
  ),
  option_value_per_rate_unit = purrr::pmap_dbl(
    list(
      .data$forward_rate,
      .data$normal_volatility,
      .data$fixing_time,
      .data$discount_factor
```

```

    ),
    function(
      forward_rate,
      normal_volatility,
      fixing_time,
      discount_factor
    ) {
      GaussQuant::normal_option_price_GQL(
        option_sign = 1,
        forward = forward_rate,
        strike = cap_strike,
        vol = normal_volatility,
        maturity = fixing_time,
        discount_factor = discount_factor
      )
    }
  ),
  caplet_npv = cap_notional *
    .data$accrual_fraction *
    .data$option_value_per_rate_unit
)

cap_summary_tbl <- tibble::tribble(
  ~metric,      ~value,
  "cap_notional", cap_notional,
  "cap_strike",   cap_strike,
  "cap_npv",      sum(caplet_input_tbl$caplet_npv)
)

GaussQuant::show_tbl_GQH(
  caplet_input_tbl,
  "Bachelier caplet decomposition",
  n = 20
)

#> # A tibble: 4 x 10
#>   caplet fixing_time payment_time accrual_fraction forward_rate normal_vol_bp
#>   <int>      <dbl>      <dbl>          <dbl>         <dbl>      <dbl>
#> 1     1         0.25         0.5            0.25         0.051        80
#> 2     2         0.5         0.75            0.25         0.0505       82
#> 3     3         0.75         1              0.25         0.0495       84
#> 4     4         1         1.25            0.25         0.0485       86
#> # i 4 more variables: normal_volatility <dbl>, discount_factor <dbl>,
#> #   option_value_per_rate_unit <dbl>, caplet_npv <dbl>

```

```
GaussQuant::show_tbl_GQH(
  cap_summary_tbl,
  "Bachelier cap summary",
  n = 20
)
#> # A tibble: 3 x 2
#>   metric      value
#>   <chr>      <dbl>
#> 1 cap_notional 10000000
#> 2 cap_strike    0.05
#> 3 cap_npv      24274.
```

各 Caplet は異なる Fixing 時点とフォワード金利を持つ。ここでは期間構造を動的に生成せず、各フォワード金利をそれぞれの支払日フォワード測度の下で直接評価している。

5.5 Swaption 評価

5.5.1 フォワードスワップレートとアニュイティ

Swaption の原資産は、将来開始する金利スワップのフォワードスワップレートである。

固定レグ支払日を $T_1, \dots, T_n$ 、年率換算期間を α_i とすると、スワップアニュイティは次式である。

$$A(0) = \sum_{i=1}^n \alpha_i P(0, T_i)$$

スワップ開始日を T_0 、満期を T_n とすると、単一カーブの簡略化されたフォワードスワップレートは次式となる。

$$S_0 = \frac{P(0, T_0) - P(0, T_n)}{A(0)}$$

本節では決定論的な割引係数を与え、フォワードスワップレートとアニュイティを計算する。

```
swap_exercise_time <- 1
swap_start_time <- 1
fixed_payment_times <- c(2, 3, 4)
fixed_accrual_fractions <- rep(
  1,
  length(fixed_payment_times)
)
swap_flat_discount_rate <- 0.035

swap_discount_tbl <- tibble::tibble(
  payment_time = fixed_payment_times,
```

```

accrual_fraction = fixed_accrual_fractions,
discount_factor = exp(
  -swap_flat_discount_rate * fixed_payment_times
)
)

swap_annuity <- sum(
  swap_discount_tbl$accrual_fraction *
  swap_discount_tbl$discount_factor
)

swap_start_discount_factor <- exp(
  -swap_flat_discount_rate * swap_start_time
)

swap_end_discount_factor <- exp(
  -swap_flat_discount_rate *
  max(fixed_payment_times)
)

forward_swap_rate <- (
  swap_start_discount_factor -
  swap_end_discount_factor
) / swap_annuity

forward_swap_tbl <- tibble::tribble(
  ~metric,          ~value,
  "swap_start_discount_factor", swap_start_discount_factor,
  "swap_end_discount_factor",   swap_end_discount_factor,
  "swap_annuity",               swap_annuity,
  "forward_swap_rate",          forward_swap_rate
)

GaussQuant::show_tbl_GQH(
  swap_discount_tbl,
  "Underlying swap fixed-leg schedule",
  n = 20
)

#> # A tibble: 3 x 3
#>   payment_time accrual_fraction discount_factor
#>   <dbl>         <dbl>         <dbl>
#> 1           2           1           0.932
#> 2           3           1           0.900

```



```
#> 3          4          1      0.869

GaussQuant::show_tbl_GQH(
  forward_swap_tbl,
  "Forward swap rate and annuity",
  n = 20
)
#> # A tibble: 4 x 2
#>   metric          value
#>   <chr>          <dbl>
#> 1 swap_start_discount_factor 0.966
#> 2 swap_end_discount_factor   0.869
#> 3 swap_annuity              2.70
#> 4 forward_swap_rate         0.0356
```

5.5.2 Bachelier Swaption

payer swaption は、将来の固定金利支払いスワップへ入る権利である。フォワードスワップレートが行使金利を上回ると価値を持つため、フォワードスワップレートに対する call option として評価できる。

swap measure の下でフォワードスワップレートをマルチンゲールとし、Normal モデルを仮定する。

$$dS_t = \sigma_S dW_t^A$$

payer swaption の価格は次式となる。

$$V_{\text{payer}} = NA(0) \left[(S_0 - K)N(d) + \sigma_S \sqrt{T_e} \phi(d) \right]$$

ここで、

$$d = \frac{S_0 - K}{\sigma_S \sqrt{T_e}}$$

である。receiver swaption は put option として評価する。

```
swaption_notional <- 10000000
swaption_strike <- 0.034
swaption_normal_volatility <- 100 / 10000

payer_option_value_per_annuity <- GaussQuant::normal_option_price_GQL(
  option_sign = 1,
  forward = forward_swap_rate,
  strike = swaption_strike,
  vol = swaption_normal_volatility,
```

```

    maturity = swap_exercise_time,
    discount_factor = 1
  )

receiver_option_value_per_annuity <- GaussQuant::normal_option_price_GQL(
  option_sign = -1,
  forward = forward_swap_rate,
  strike = swaption_strike,
  vol = swaption_normal_volatility,
  maturity = swap_exercise_time,
  discount_factor = 1
)

swaption_tbl <- tibble::tribble(
  ~option_type, ~option_sign, ~npv,
  "payer",      1,             swaption_notional *
                                swap_annuity *
                                payer_option_value_per_annuity,
  "receiver",   -1,             swaption_notional *
                                swap_annuity *
                                receiver_option_value_per_annuity
) |>
  dplyr::mutate(
    forward_swap_rate = forward_swap_rate,
    strike = swaption_strike,
    annuity = swap_annuity,
    normal_volatility = swaption_normal_volatility
  ) |>
  dplyr::relocate(
    .data$option_type,
    .data$forward_swap_rate,
    .data$strike,
    .data$annuity,
    .data$normal_volatility,
    .data$npv
  )

GaussQuant::show_tbl_GQH(
  swaption_tbl,
  "Bachelier swaption summary",
  n = 20
)

#> # A tibble: 2 x 7

```

```
#>   option_type forward_swap_rate strike annuity normal_volatility      npv
#>   <chr>          <dbl>   <dbl>   <dbl>          <dbl>   <dbl>
#> 1 payer          0.0356  0.034    2.70          0.01 131091.
#> 2 receiver       0.0356  0.034    2.70          0.01  87325.
#> # i 1 more variable: option_sign <dbl>
```

アニュイティ $A(0)$ はすでに将来の固定レグ支払いを現在価値へ割り引いた量である。そのため、Normal 公式側では割引係数を 1 とし、結果へ元本とアニュイティを掛けている。

5.6 Black volatility と Normal volatility

Black モデルでは、ATM 付近のオプション価値は概ね次式に比例する。

$$V_{\text{Black,ATM}} \approx D(0, T) F_0 \sigma_B \sqrt{T} \phi(0)$$

Normal モデルでは次式となる。

$$V_{\text{Normal,ATM}} \approx D(0, T) \sigma_N \sqrt{T} \phi(0)$$

したがって、ATM 付近では両モデルのボラティリティに次の近似関係がある。

$$\sigma_N \approx F_0 \sigma_B$$

Normal volatility は金利水準と同じ単位を持つため、同じ Black volatility であっても、金利水準が低下すると対応する Normal volatility は小さくなる。

```
black_volatility <- 0.20

black_normal_comparison_tbl <- tibble::tribble(
  ~forward_rate, ~black_volatility,
  0.0500,        black_volatility,
  0.0200,        black_volatility,
  0.0050,        black_volatility
) |>
dplyr::mutate(
  approximate_normal_volatility =
    .data$forward_rate *
    .data$black_volatility,
  approximate_normal_volatility_bp =
    .data$approximate_normal_volatility *
    10000
)
```

```
GaussQuant::show_tbl_GQH(
  black_normal_comparison_tbl,
  "Approximate ATM Black-to-Normal volatility conversion",
  n = 20
)
#> # A tibble: 3 x 4
#>   forward_rate black_volatility approximate_normal_vola~1 approximate_normal_v~2
#>   <dbl>         <dbl>         <dbl>         <dbl>
#> 1      0.05         0.2         0.01         100
#> 2      0.02         0.2         0.004         40
#> 3      0.005        0.2         0.001         10
#> # i abbreviated names: 1: approximate_normal_volatility,
#> #   2: approximate_normal_volatility_bp
```

この関係は ATM 近似であり、Strike が ATM から離れる場合やボラティリティスマイルが存在する場合には、単純な換算だけでは十分でない。

5.7 まとめ

本章では、金利期間構造全体の確率モデルを与えず、各商品の評価に必要なフォワード金利またはフォワードスワップレートを、適切な測度の下でマルチングールとして直接モデル化した。

Normal モデルでは、フォワード金利の変化額が正規分布に従う。

$$dF_t = \sigma_N dW_t$$

このため、フォワード金利がゼロまたはマイナスとなる場合でも、価格公式を変更せずに評価できる。

Normal volatility は相対変化率ではなく、金利と同じ単位を持つ。金利市場では通常、ベースポイント単位で表示される。Normal volatility 50bp は小数表示で 0.0050 である。

金利先物オプションでは、先物価格から金利へ変換すると Payoff の向きが反転する。先物価格の call は、金利を原資産とした場合には put として評価される。

Cap は複数の Caplet の合計であり、各 Caplet は対応するフォワード金利を原資産とする。Swaption はフォワードスワップレートを原資産とし、スワップアニュイティを価格倍率として使用する。

Normal モデルはマイナス金利を扱える一方、金利水準にかかわらず同じ絶対変動幅を仮定し、極端な負の金利も許容する。実際の市場では、Black、Shifted Black、Normal および SABR などを、金利水準とボラティリティ市場の慣行に応じて使い分ける。

```
chapter05_summary_tbl <- tibble::tribble(
  ~section,          ~main_result,
  "Normal dynamics",  "Additive forward-rate process",
  "Futures option",   "Rate conversion, price, and Greeks",
  "Implied normal volatility", "Volatility inversion and repricing",
```

```

    "Negative rates",      "Pricing without a logarithmic restriction",
    "Cap",                "Sum of Bachelier caplets",
    "Swaption",           "Forward swap rate times annuity"
  )

GaussQuant::show_tbl_GQH(
  chapter05_summary_tbl,
  "Chapter II-5 summary",
  n = 20
)

#> # A tibble: 6 x 2
#>   section                main_result
#>   <chr>                 <chr>
#> 1 Normal dynamics      Additive forward-rate process
#> 2 Futures option       Rate conversion, price, and Greeks
#> 3 Implied normal volatility Volatility inversion and repricing
#> 4 Negative rates       Pricing without a logarithmic restriction
#> 5 Cap                  Sum of Bachelier caplets
#> 6 Swaption             Forward swap rate times annuity

cat(
  "\nChapter II-5 Normal Bachelier model completed successfully.\n"
)
#>
#> Chapter II-5 Normal Bachelier model completed successfully.

```

第 II-6 章 SABR モデル

前章までの Black モデルと Normal モデルでは、満期と Strike が同じオプションに対して、一つのボラティリティを与えた。しかし、実際のオプション市場では、同じ満期であっても Strike ごとに異なるインプライド・ボラティリティが観測される。この Strike 方向の形状をボラティリティ・スマイルまたはスキューと呼ぶ。

SABR モデルは、フォワード価格またはフォワード金利と、そのボラティリティを同時に確率変数として扱う。モデル名は、Stochastic Alpha Beta Rho の頭文字に由来する。

フォワード F_t とボラティリティ係数 α_t の動学を、概念的に次のように表す。

$$dF_t = \alpha_t F_t^\beta dW_t^{(1)}$$

$$d\alpha_t = \nu \alpha_t dW_t^{(2)}$$

$$dW_t^{(1)} dW_t^{(2)} = \rho dt$$

SABR モデルには、 α 、 β 、 ν 、 ρ の 4 パラメータがある。

- α はボラティリティ水準を主に決定する。
- β はフォワード水準に対する変動幅の依存度を表す。
- ν はボラティリティ自体の変動性であり、スマイルの曲率に強く影響する。
- ρ はフォワードとボラティリティの相関であり、スマイルの左右非対称性に影響する。

$\beta = 1$ は対数正規型に近く、 $\beta = 0$ は Normal 型に近い。実務では 4 パラメータを同時推定すると不安定になりやすいため、 β をあらかじめ固定し、 α 、 ν 、 ρ を市場ボラティリティへカリブレーションすることが多い。

本章では、まず Black volatility のスマイルへ SABR モデルを適合させる。次に各パラメータがスマイルの形状へ与える影響を確認する。最後に、負の Strike を含む Normal volatility の市場データに対して Shifted SABR を適用する。

```
knitr::opts_chunk$set(
  collapse = TRUE,
  comment = "#>",
  warning = FALSE,
  message = FALSE
)
```

```
suppressPackageStartupMessages({
  library(tidyverse)
  library(ggthemes)
  library(QuantLib)
  library(GaussQuant)
  library(tidyverse)
  library(broom)
})
```

6.1 SABR モデルとパラメータ

6.1.1 SABR パラメータの役割

SABR の各パラメータは完全に独立してスマイルを動かすわけではないが、主な役割は次のように整理できる。

6.1.2 Alpha

α は初期ボラティリティ水準である。他の条件を固定して α を上げると、スマイル全体が概ね上方へ移動する。

6.1.3 Beta

β はフォワード水準に対する弾性を表す。

$$\text{instantaneous volatility} = \alpha_t F_t^\beta$$

$\beta = 1$ では変動幅がフォワード水準に比例し、Black モデルに近い。 $\beta = 0$ では変動幅がフォワード水準に依存せず、Normal モデルに近い。

6.1.4 Volatility of volatility

ν は volatility of volatility、すなわち vol-of-vol である。 ν が大きいほど、ボラティリティが将来大きく変化する可能性が高まり、一般にスマイルの曲率が強くなる。

本章のコードでは、変数名として `volvol` を使用する。

6.1.5 Rho

ρ はフォワード変化とボラティリティ変化の相関である。負の ρ は、フォワード低下時にボラティリティが上昇しやすい構造を表し、低 Strike 側のボラティリティを相対的に高くする。

6.1.6 Hagan 近似とカリブレーション

SABR モデルの市場利用では、Hagan らによる近似式を用いて、SABR パラメータから Black volatility または Normal volatility を計算することが多い。

市場 Strike を K_i 、市場ボラティリティを σ_i^{mkt} 、SABR 近似値を σ_i^{SABR} とする。本章では、適合度を次の RMSE で測定する。

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\sigma_i^{\text{mkt}} - \sigma_i^{\text{SABR}})^2}$$

β を固定し、RMSE が最小となる α 、 ν 、 ρ を数値的に求める。

6.2 Black SABR のカリブレーション

6.2.1 市場データ

フォワードを 0.56%、満期を 2 年、 $\beta = 0.5$ とする。市場 Black volatility は Strike ごとに異なり、明確なスマイルを形成している。

```
black_market_data <- tibble::tribble(
  ~strike_pct, ~market_vol_pct,
  0.06,        90.78,
  0.31,        46.09,
  0.56,        45.30,
  0.81,        50.17,
  1.06,        53.85,
  1.56,        58.42,
  2.56,        62.72
) |>
dplyr::mutate(
  strike = .data$strike_pct / 100,
  market_vol = .data$market_vol_pct / 100
)

forward_black <- 0.0056
maturity_black <- 2
beta_black <- 0.5

black_model_inputs <- tibble::tribble(
  ~input,      ~value,
  "forward",   forward_black,
  "maturity",  maturity_black,
  "fixed_beta", beta_black
```



```

)

initial_parameters_black <- c(
  alpha = 0.1,
  volvol = 0.1,
  rho = 0.1
)

GaussQuant::show_tbl_GQH(
  black_market_data |>
  dplyr::select(
    .data$strike,
    .data$market_vol
  ),
  "Black SABR market data",
  n = 20
)

#> # A tibble: 7 x 2
#>   strike market_vol
#>   <dbl>     <dbl>
#> 1 0.0006     0.908
#> 2 0.0031     0.461
#> 3 0.0056     0.453
#> 4 0.0081     0.502
#> 5 0.0106     0.538
#> 6 0.0156     0.584
#> 7 0.0256     0.627

GaussQuant::show_tbl_GQH(
  black_model_inputs,
  "Black SABR model inputs",
  n = 20
)

#> # A tibble: 3 x 2
#>   input      value
#>   <chr>     <dbl>
#> 1 forward  0.0056
#> 2 maturity  2
#> 3 fixed_beta 0.5

```

ATM に近い Strike は 0.56% であり、フォワード 0.56% と一致する。ATM 付近の水準は主に α に影響し、両翼の形状が ν と ρ の推定に影響する。

6.2.2 パラメータ・カリブレーション

目的関数では、各 Strike における QuantLib の SABR Black volatility と市場 Black volatility の RMSE を計算する。

```
objective_sabr_black <- function(parameters) {
  alpha <- parameters[[1]]
  volvol <- parameters[[2]]
  rho <- parameters[[3]]

  if (
    alpha <= 0 ||
    volvol < 0 ||
    rho <= -0.9999 ||
    rho >= 0.9999
  ) {
    return(1e6)
  }

  calculated_volatility <- purrr::map_dbl(
    black_market_data$strike,
    function(strike_value) {
      GaussQuant::safe_sabr_vol_GQL(
        strike = strike_value,
        forward = forward_black,
        maturity = maturity_black,
        alpha = alpha,
        beta = beta_black,
        volvol = volvol,
        rho = rho
      )
    }
  )

  if (
    any(is.na(calculated_volatility)) ||
    any(!is.finite(calculated_volatility))
  ) {
    return(1e6)
  }

  GaussQuant::rmse_GQH(
    actual = black_market_data$market_vol,
```

```

    fitted = calculated_volatility
  )
}

black_fit <- stats::optim(
  par = initial_parameters_black,
  fn = objective_sabr_black,
  method = "L-BFGS-B",
  lower = c(
    0.0001,
    0,
    -0.9999
  ),
  upper = c(
    Inf,
    Inf,
    0.9999
  )
)

black_parameters <- black_fit$par

black_calculated_volatility <- purrr::map_dbl(
  black_market_data$strike,
  function(strike_value) {
    GaussQuant::safe_sabr_vol_GQL(
      strike = strike_value,
      forward = forward_black,
      maturity = maturity_black,
      alpha = black_parameters[[1]],
      beta = beta_black,
      volvol = black_parameters[[2]],
      rho = black_parameters[[3]]
    )
  }
)

black_calibration_tbl <- tibble::tribble(
  ~parameter,      ~value,
  "alpha",         black_parameters[[1]],
  "beta",          beta_black,
  "volvol",        black_parameters[[2]],
  "rho",           black_parameters[[3]],

```

```

    "rmse",          black_fit$value,
    "convergence_code", black_fit$convergence
  )

GaussQuant::show_tbl_GQH(
  black_calibration_tbl,
  "Black SABR calibration summary",
  n = 20
)

#> # A tibble: 6 x 2
#>   parameter      value
#>   <chr>         <dbl>
#> 1 alpha         0.0306
#> 2 beta          0.5
#> 3 volvol        0.728
#> 4 rho           0.449
#> 5 rmse          0.0139
#> 6 convergence_code 0

```

`convergence_code` が 0 であれば、`optim()` は通常の収束条件を満たして終了している。RMSE は市場ボラティリティとモデル値の平均的な誤差を表す。

6.2.3 ボラティリティ・スマイル

```

black_smile_tbl <- black_market_data |>
  dplyr::transmute(
    strike = .data$strike,
    market_vol = .data$market_vol,
    sabr_vol = black_calculated_volatility,
    residual = .data$market_vol -
      black_calculated_volatility
  )

black_smile_plot_tbl <- black_smile_tbl |>
  dplyr::select(
    .data$strike,
    .data$market_vol,
    .data$sabr_vol
  ) |>
  tidyr::pivot_longer(
    cols = c(
      market_vol,
      sabr_vol
    )
  )

```

```

    ),
    names_to = "series",
    values_to = "volatility"
  )

black_smile_plot <- ggplot2::ggplot(
  black_smile_plot_tbl,
  ggplot2::aes(
    x = .data$strike,
    y = .data$volatility,
    group = .data$series,
    linetype = .data$series,
    shape = .data$series
  )
) +
  ggplot2::geom_line(
    linewidth = 0.6
  ) +
  ggplot2::geom_point(
    size = 2.2
  ) +
  ggplot2::scale_x_continuous(
    labels = function(x) sprintf("%.2f%%", 100 * x)
  ) +
  ggplot2::scale_y_continuous(
    labels = function(x) sprintf("%.0f%%", 100 * x)
  ) +
  ggplot2::labs(
    title = "Black SABR calibration",
    subtitle = paste0(
      "alpha=",
      sprintf("%.5f", black_parameters[[1]]),
      ", beta=",
      sprintf("%.3f", beta_black),
      ", volvol=",
      sprintf("%.5f", black_parameters[[2]]),
      ", rho=",
      sprintf("%.5f", black_parameters[[3]])
    ),
    x = "Strike",
    y = "Black volatility",
    linetype = "Series",
    shape = "Series"
  )

```

```

) +
  ggplot2::theme_minimal()

GaussQuant::show_tbl_GQH(
  black_smile_tbl,
  "Black SABR smile table",
  n = 20
)


#> # A tibble: 7 x 4
#>   strike market_vol sabr_vol  residual
#>   <dbl>      <dbl>    <dbl>    <dbl>
#> 1 0.0006      0.908      0.897  0.0108
#> 2 0.0031      0.461      0.485 -0.0240
#> 3 0.0056      0.453      0.449  0.00402
#> 4 0.0081      0.502      0.489  0.0125
#> 5 0.0106      0.538      0.528  0.0106
#> 6 0.0156      0.584      0.583  0.000924
#> 7 0.0256      0.627      0.646 -0.0193

print(black_smile_plot)

```

Black SABR calibration

$\alpha=0.03058$, $\beta=0.500$, $\text{volvol}=0.72848$, $\rho=0.44933$



SABR はすべての市場点を完全に通過する補間法ではなく、少数のパラメータでスマイル全体の形状を表現するモデルである。残差が完全にゼロでなくても、Strike 方向に滑らかなボラティリティを与えられる点に意味がある。

6.3 SABR パラメータの感応度

推定結果を基準として、一つのパラメータだけを上下させた場合のスマイルを確認する。パラメータ間には相互作用があるため、これは厳密なリスク分解ではなく、形状を理解するための比較である。

```
base_parameter_tbl <- tibble::tribble(
  ~parameter, ~base_value,      ~shift,
  "alpha",    black_parameters[[1]], 0.02,
  "beta",     beta_black,           0.20,
  "volvol",   black_parameters[[2]], 0.40,
  "rho",      black_parameters[[3]], 0.44
)

base_parameters <- stats::setNames(
  base_parameter_tbl$base_value,
  base_parameter_tbl$parameter
)

parameter_shifts <- stats::setNames(
  base_parameter_tbl$shift,
  base_parameter_tbl$parameter
)

sabr_sensitivity_tbl <- purrr::map_dfr(
  names(base_parameters),
  function(parameter_name) {
    parameters_up <- base_parameters
    parameters_down <- base_parameters

    parameters_up[[parameter_name]] <-
      parameters_up[[parameter_name]] +
      parameter_shifts[[parameter_name]]

    parameters_down[[parameter_name]] <-
      parameters_down[[parameter_name]] -
      parameter_shifts[[parameter_name]]

    parameters_up[["alpha"]] <- max(
      parameters_up[["alpha"]],
      1e-6
    )
    parameters_down[["alpha"]] <- max(
      parameters_down[["alpha"]],

```

```

1e-6
)
parameters_up[["beta"]] <- min(
  max(parameters_up[["beta"]], 0),
  1
)
parameters_down[["beta"]] <- min(
  max(parameters_down[["beta"]], 0),
  1
)
parameters_up[["volvol"]] <- max(
  parameters_up[["volvol"]],
  0
)
parameters_down[["volvol"]] <- max(
  parameters_down[["volvol"]],
  0
)
parameters_up[["rho"]] <- min(
  max(parameters_up[["rho"]], -0.95),
  0.95
)
parameters_down[["rho"]] <- min(
  max(parameters_down[["rho"]], -0.95),
  0.95
)

scenario_parameter_tbl <- tibble::tribble(
  ~scenario, ~alpha, ~beta, ~volvol,
  "base",    base_parameters[["alpha"]], base_parameters[["beta"]], base_parameters[["volvol"]],
  "up",      parameters_up[["alpha"]],   parameters_up[["beta"]],   parameters_up[["volvol"]],
  "down",    parameters_down[["alpha"]], parameters_down[["beta"]], parameters_down[["volvol"]]
)

purrr::pmap_dfr(
  scenario_parameter_tbl,
  function(
    scenario,
    alpha,
    beta,
    volvol,
    rho
  ) {

```



```

    tibble::tibble(
      strike = black_market_data$strike,
      volatility = purrr::map_dbl(
        black_market_data$strike,
        function(strike_value) {
          GaussQuant::safe_sabr_vol_GQL(
            strike = strike_value,
            forward = forward_black,
            maturity = maturity_black,
            alpha = alpha,
            beta = beta,
            volvol = volvol,
            rho = rho
          )
        }
      ),
      scenario = scenario,
      parameter = parameter_name
    )
  }
)

sabr_sensitivity_plot <- ggplot2::ggplot(
  sabr_sensitivity_tbl,
  ggplot2::aes(
    x = .data$strike,
    y = .data$volatility,
    group = .data$scenario,
    linetype = .data$scenario
  )
) +
  ggplot2::geom_line(
    linewidth = 0.6
  ) +
  ggplot2::facet_wrap(
    ~parameter,
    scales = "free_y"
  ) +
  ggplot2::scale_x_continuous(
    labels = function(x) sprintf("%.2f%%", 100 * x)
  ) +

```

```


ggplot2::scale_y_continuous(
  labels = function(x) sprintf("%.0f%%", 100 * x)
) +
ggplot2::labs(
  title = "SABR parameter sensitivity",
  x = "Strike",
  y = "Black volatility",
  linetype = "Scenario"
) +
ggplot2::theme_minimal()

GaussQuant::show_tbl_GQH(
  base_parameter_tbl,
  "SABR sensitivity settings",
  n = 20
)

#> # A tibble: 4 x 3
#>   parameter base_value shift
#>   <chr>         <dbl> <dbl>
#> 1 alpha         0.0306  0.02
#> 2 beta          0.5     0.2
#> 3 volvol        0.728   0.4
#> 4 rho           0.449   0.44

print(sabr_sensitivity_plot)

```



一般に、 α はスマイルの水準、 ν は曲率、 ρ は傾きと左右非対称性に強く影響する。 β も水準と傾きの双方へ影

響するため、他のパラメータとの識別が難しい。このため、 β を市場慣行や過去推定値に基づいて固定することが多い。

6.4 Shifted SABR と負の金利

通常の Black SABR 近似では、フォワードと Strike が正である必要がある。負の金利を含む市場では、フォワードと Strike へ同じ Shift s を加える。

$$\tilde{F} = F + s$$

$$\tilde{K} = K + s$$

Shift 後の値が正であれば、対数やべき乗を含む SABR 近似を適用できる。

本章では、Normal volatility の市場データに対して、Shift を加えた Hagan 近似を使用する。出力は Normal volatility であるが、内部では Shift 後のフォワードと Strike を使ってスマイルを表現する。

Shift は負の金利を消してしまう調整ではない。モデル計算上の座標を移動するだけであり、実際の Strike とフォワードは元の水準のまま解釈する。

6.5 Shifted SABR Normal のカリブレーション

6.5.1 市場データ

フォワードを 0.05%、満期を 2 年、 $\beta = 0.5$ 、Shift を 2.5% とする。市場データにはマイナス 0.95% の Strike が含まれる。

```
normal_market_data <- tibble::tribble(
  ~strike_pct, ~market_vol_bp,
  -0.95,      41.94,
  -0.45,      38.64,
  -0.20,      37.71,
  0.05,       37.80,
  0.30,       39.05,
  0.55,       41.37,
  1.05,       47.81
) |>
dplyr::mutate(
  strike = .data$strike_pct / 100,
  market_vol = .data$market_vol_bp / 10000
)

forward_normal <- 0.0005
maturity_normal <- 2
```

```

beta_normal <- 0.5
shift_normal <- 0.025

normal_model_inputs <- tibble::tribble(
  ~input,      ~value,
  "forward",   forward_normal,
  "maturity",  maturity_normal,
  "fixed_beta", beta_normal,
  "shift",     shift_normal
)

```

```

initial_parameters_normal <- c(
  alpha = 0.1,
  volvol = 0.1,
  rho = 0.1
)

```

```

GaussQuant::show_tbl_GQH(
  normal_market_data |>
    dplyr::select(
      .data$strike,
      .data$market_vol
    ),
  "Shifted SABR normal market data",
  n = 20
)

```

```

#> # A tibble: 7 x 2
#>   strike market_vol
#>   <dbl>      <dbl>
#> 1 -0.0095  0.00419
#> 2 -0.0045  0.00386
#> 3 -0.002   0.00377
#> 4  0.0005  0.00378
#> 5  0.003   0.00390
#> 6  0.0055  0.00414
#> 7  0.0105  0.00478

```

```

GaussQuant::show_tbl_GQH(
  normal_model_inputs,
  "Shifted SABR normal model inputs",
  n = 20
)
#> # A tibble: 4 x 2

```

```
#>   input      value
#>   <chr>     <dbl>
#> 1 forward    0.0005
#> 2 maturity    2
#> 3 fixed_beta 0.5
#> 4 shift      0.025
```

すべての市場 Strike について、

$$K + s > 0$$

が必要である。本例の最小 Strike はマイナス 0.95%、Shift は 2.5% であるため、Shift 後の Strike は正となる。

6.5.2 パラメータ・カリブレーション

Black SABR と同様に β を固定し、 α 、 ν 、 ρ を推定する。目的関数は Normal volatility 単位の RMSE である。

```
objective_sabr_normal <- function(parameters) {
  alpha <- parameters[[1]]
  volvol <- parameters[[2]]
  rho <- parameters[[3]]

  if (
    alpha <= 0.001 ||
    volvol < 0 ||
    rho <= -0.999 ||
    rho >= 0.999
  ) {
    return(1e6)
  }

  calculated_volatility <- purrr::map_dbl(
    normal_market_data$strike,
    function(strike_value) {
      GaussQuant::shifted_normal_vol_hagan_GQL(
        strike = strike_value,
        forward = forward_normal,
        maturity = maturity_normal,
        beta = beta_normal,
        alpha = alpha,
        volvol = volvol,
        rho = rho,
        shift = shift_normal
      )
    }
  )
}
```

```

    }
  )

  if (
    any(is.na(calculated_volatility)) ||
    any(!is.finite(calculated_volatility))
  ) {
    return(1e6)
  }

  GaussQuant::rmse_GQH(
    actual = normal_market_data$market_vol,
    fitted = calculated_volatility
  )
}

normal_fit <- stats::optim(
  par = initial_parameters_normal,
  fn = objective_sabr_normal,
  method = "L-BFGS-B",
  lower = c(
    0.001,
    0,
    -0.999
  ),
  upper = c(
    Inf,
    Inf,
    0.999
  )
)

normal_parameters <- normal_fit$par

normal_calculated_volatility <- purrr::map_dbl(
  normal_market_data$strike,
  function(strike_value) {
    GaussQuant::shifted_normal_vol_hagan_GQL(
      strike = strike_value,
      forward = forward_normal,
      maturity = maturity_normal,
      beta = beta_normal,
      alpha = normal_parameters[[1]],

```

```

    volvol = normal_parameters[[2]],
    rho = normal_parameters[[3]],
    shift = shift_normal
  )
}
)

normal_calibration_tbl <- tibble::tribble(
  ~parameter,      ~value,
  "alpha",          normal_parameters[[1]],
  "beta",           beta_normal,
  "volvol",         normal_parameters[[2]],
  "rho",            normal_parameters[[3]],
  "shift",          shift_normal,
  "rmse",           normal_fit$value,
  "convergence_code", normal_fit$convergence
)

GaussQuant::show_tbl_GQH(
  normal_calibration_tbl,
  "Shifted SABR normal calibration summary",
  n = 20
)

#> # A tibble: 7 x 2
#>   parameter      value
#>   <chr>          <dbl>
#> 1 alpha          0.0254
#> 2 beta           0.5
#> 3 volvol         0.0994
#> 4 rho            0.0998
#> 5 shift          0.025
#> 6 rmse           0.000298
#> 7 convergence_code 0

```

6.5.3 Normal ボラティリティ・スマイル

```

normal_smile_tbl <- normal_market_data |>
  dplyr::transmute(
    strike = .data$strike,
    market_vol = .data$market_vol,
    sabr_vol = normal_calculated_volatility,
    residual = .data$market_vol -
      normal_calculated_volatility
  )

```

```

)

normal_smile_plot_tbl <- normal_smile_tbl |>
  dplyr::select(
    .data$strike,
    .data$market_vol,
    .data$sabr_vol
  ) |>
  tidyr::pivot_longer(
    cols = c(
      market_vol,
      sabr_vol
    ),
    names_to = "series",
    values_to = "volatility"
  )

normal_smile_plot <- ggplot2::ggplot(
  normal_smile_plot_tbl,
  ggplot2::aes(
    x = .data$strike,
    y = .data$volatility,
    group = .data$series,
    linetype = .data$series,
    shape = .data$series
  )
) +
  ggplot2::geom_line(
    linewidth = 0.6
  ) +
  ggplot2::geom_point(
    size = 2.2
  ) +
  ggplot2::scale_x_continuous(
    labels = function(x) sprintf("%.2f%%", 100 * x)
  ) +
  ggplot2::scale_y_continuous(
    labels = function(x) sprintf("%.1f bp", 10000 * x)
  ) +
  ggplot2::labs(
    title = "Shifted SABR normal calibration",
    subtitle = paste0(
      "alpha=",

```



```


    sprintf("%.5f", normal_parameters[[1]]),
    ", beta=",
    sprintf("%.3f", beta_normal),
    ", volvol=",
    sprintf("%.5f", normal_parameters[[2]]),
    ", rho=",
    sprintf("%.5f", normal_parameters[[3]]),
    ", shift=",
    sprintf("%.2f%%", 100 * shift_normal)
  ),
  x = "Strike",
  y = "Normal volatility",
  linetype = "Series",
  shape = "Series"
) +
ggplot2::theme_minimal()

GaussQuant::show_tbl_GQH(
  normal_smile_tbl |>
  dplyr::mutate(
    market_vol_bp = 10000 * .data$market_vol,
    sabr_vol_bp = 10000 * .data$sabr_vol,
    residual_bp = 10000 * .data$residual
  ),
  "Shifted SABR normal smile table",
  n = 20
)

#> # A tibble: 7 x 7
#>   strike market_vol sabr_vol   residual market_vol_bp sabr_vol_bp residual_bp
#>   <dbl>     <dbl>    <dbl>     <dbl>         <dbl>     <dbl>     <dbl>
#> 1 -0.0095  0.00419  0.00360  0.000593         41.9        36.0        5.93
#> 2 -0.0045  0.00386  0.00383  0.0000348        38.6        38.3         0.348
#> 3 -0.002   0.00377  0.00394 -0.000170        37.7        39.4       -1.70
#> 4  0.0005   0.00378  0.00405 -0.000273        37.8        40.5       -2.73
#> 5  0.003    0.00390  0.00417 -0.000261        39.0        41.7       -2.61
#> 6  0.0055   0.00414  0.00428 -0.000141        41.4        42.8       -1.41
#> 7  0.0105   0.00478  0.00450  0.000277        47.8        45.0        2.77

print(normal_smile_plot)

```



Black volatility と Normal volatility は単位が異なるため、Black SABR の RMSE と Shifted SABR Normal の RMSE を数値の大きさだけで直接比較してはならない。Black 側は相対ボラティリティ、Normal 側は金利の絶対変化幅である。

6.6 外挿とモデル比較

6.6.1 カリブレーション範囲外の Strike

SABR モデルは、市場点の間を滑らかにつなぐだけでなく、市場点の外側にもボラティリティを与える。ただし、外挿結果は観測データによる制約が弱く、パラメータの影響を強く受ける。

次のコードでは、市場データの外側にある二つの Strike について Normal volatility を確認する。

```
outer_strike_input_tbl <- tibble::tribble(
  ~label,      ~strike,
  "lower_wing", -0.0195,
  "upper_wing", 0.0205
)

outer_strike_tbl <- outer_strike_input_tbl |>
  dplyr::mutate(
    shifted_strike = .data$strike +
      shift_normal,
    normal_volatility = purrr::map_dbl(
      .data$strike,
      function(strike_value) {
        GaussQuant::shifted_normal_vol_hagan_GQL(
          strike = strike_value,
```

```

    forward = forward_normal,
    maturity = maturity_normal,
    beta = beta_normal,
    alpha = normal_parameters[[1]],
    volvol = normal_parameters[[2]],
    rho = normal_parameters[[3]],
    shift = shift_normal
  )
}
),
normal_volatility_bp = 10000 *
  .data$normal_volatility
)

GaussQuant::show_tbl_GQH(
  outer_strike_tbl,
  "Shifted SABR outer-strike check",
  n = 20
)
#> # A tibble: 2 x 5
#>   label      strike shifted_strike normal_volatility normal_volatility_bp
#>   <chr>      <dbl>         <dbl>          <dbl>          <dbl>
#> 1 lower_wing -0.0195         0.0055          0.00307          30.7
#> 2 upper_wing  0.0205         0.0455          0.00496          49.6

```

Shift 後の Strike がゼロ以下となる領域では、この近似式を使用できない。また、数式上計算できる場合でも、カリブレーション範囲から遠い外挿値には注意が必要である。

6.6.2 Black SABR と Shifted SABR Normal

二つのカリブレーション結果を一覧にする。

```

calibration_comparison_tbl <- tibble::tribble(
  ~model,          ~alpha,          ~beta,      ~volvol,          ~rho,
  "Black SABR",    black_parameters[[1]], beta_black, black_parameters[[2]], black_param
  "Shifted SABR Normal", normal_parameters[[1]], beta_normal, normal_parameters[[2]], normal_param
)

GaussQuant::show_tbl_GQH(
  calibration_comparison_tbl,
  "SABR calibration comparison",
  n = 20
)
#> # A tibble: 2 x 8

```

```
#>   model                alpha  beta volvol      rho shift      rmse convergence_code
#>   <chr>                <dbl> <dbl> <dbl> <dbl> <dbl>    <dbl>             <int>
#> 1 Black SABR          0.0306  0.5 0.728  0.449  0      0.0139             0
#> 2 Shifted SABR Normal 0.0254  0.5 0.0994 0.0998 0.025 0.000298             0
```

Black SABR では、正のフォワードと Strike から Black volatility を計算した。Shifted SABR Normal では、フォワードと Strike へ Shift を加え、負の Strike を含む市場データへ Normal volatility を適合させた。

どちらも同じ 4 つの SABR パラメータを用いるが、出力するインプライド・ボラティリティの定義と単位が異なる。したがって、パラメータ値や RMSE を異なるボラティリティ表現の間で単純比較するのではなく、それぞれの市場表示におけるスマイル適合度を確認する。

6.7 まとめ

SABR モデルは、フォワードとそのボラティリティを同時に確率変数として扱い、Strike ごとに異なるインプライド・ボラティリティを少数のパラメータで表現する。

α は主にボラティリティ水準、 ν はスマイルの曲率、 ρ は傾きと左右非対称性へ影響する。 β はフォワード水準に対する変動幅の弾性を表し、他のパラメータとの識別が難しいため、本章では固定してカリブレーションした。

Black SABR では、正のフォワードと Strike を前提として Black volatility のスマイルを評価した。負の金利を含む Normal volatility 市場では、フォワードと Strike へ共通の Shift を加える Shifted SABR を使用した。

SABR は市場ボラティリティを完全に補間することだけを目的とするものではない。Strike 方向に滑らかで、パラメータによる解釈が可能なスマイルを構築し、観測されていない Strike の評価やリスク管理へ利用する。

```
chapter06_summary_tbl <- tibble::tribble(
  ~section,          ~main_result,
  "Black SABR",      "Calibration to a Black-volatility smile",
  "Parameter sensitivity", "Alpha, beta, vol-of-vol, and rho effects",
  "Shifted SABR Normal", "Normal-volatility smile with negative strikes",
  "Outer strikes",     "Extrapolation outside calibration points"
)

GaussQuant::show_tbl_GQH(
  chapter06_summary_tbl,
  "Chapter II-6 summary",
  n = 20
)

#> # A tibble: 4 x 2
#>   section                main_result
#>   <chr>                  <chr>
#> 1 Black SABR            Calibration to a Black-volatility smile
#> 2 Parameter sensitivity Alpha, beta, vol-of-vol, and rho effects
#> 3 Shifted SABR Normal   Normal-volatility smile with negative strikes
```

```
#> 4 Outer strikes          Extrapolation outside calibration points

cat(
  "\nChapter II-6 SABR model completed successfully.\n"
)
#>
#> Chapter II-6 SABR model completed successfully.
```

第 II-7 章 Callable Bond と Hull–White モデル

Callable Bond は、発行体があらかじめ定められた日と価格で期限前償還できる債券である。市場金利が低下すると、発行体は既存の高いクーポンを支払い続けるよりも、債券を期限前償還して低い金利で資金を再調達する誘因を持つ。

したがって、コール条項は発行体にとって価値を持つ一方、投資家にとっては不利な権利である。同じクーポン、満期および信用条件を持つ場合、Callable Bond の価格はオプションを含まない Bullet Bond の価格以下となる。

概念的には、次の関係で表される。

$$V_{\text{callable}} = V_{\text{bullet}} - V_{\text{issuer call}}$$

発行体のコール権は、金利低下時に価値が上昇する。この性質は、固定金利を受け取り変動金利を支払う Receiver Swaption に近い。複数のコール可能日がある場合、その権利は Bermudan Receiver Swaption に対応する。

ただし、Callable Bond と Swaption では、元本交換、クーポンと固定レグ、決済、経過利子、行使価格および支払日の調整が必ずしも完全には一致しない。このため、本章では、

$$V_{\text{callable}} \approx V_{\text{bullet}} - V_{\text{Bermudan receiver swaption}}$$

をモデル構造の比較として確認する。

期限前償還権を評価するためには、将来の金利変動と各行使日における継続価値を扱う必要がある。本章では、初期金利期間構造へ適合できる Hull–White 1-factor モデルと金利 Tree を使用する。

```
knitr::opts_chunk$set(
  collapse = TRUE,
  comment = "#>",
  warning = FALSE,
  message = FALSE
)

suppressPackageStartupMessages({
  library(tidyverse)
  library(ggthemes)
```

```
library(QuantLib)
library(GaussQuant)
library(tidyverse)
library(broom)
})
```

7.1 Hull–White モデルと債券条件

7.1.1 Hull–White 1-factor モデル

Hull–White モデルでは、短期金利 r_t を次の Gaussian 過程で表す。

$$dr_t = [\theta(t) - ar_t] dt + \sigma dW_t$$

ここで、 a は平均回帰速度、 σ は短期金利のボラティリティ、 $\theta(t)$ は時間依存のドリフトである。

a が大きいほど、金利ショックの影響は速く減衰する。 σ が大きいほど将来金利の分布が広がり、金利オプションの価値は一般に高くなる。

Hull–White モデルの重要な特徴は、 $\theta(t)$ を調整することによって、評価時点で観測された初期イールドカーブを再現できることである。モデルの確率部分を状態変数 x_t として分離すると、次の Ornstein–Uhlenbeck 過程として表せる。

$$dx_t = -ax_t dt + \sigma dW_t$$

短期金利は、初期期間構造を表す決定論的な部分と状態変数の和として解釈できる。

$$r_t = \phi(t) + x_t$$

Hull–White モデルは Gaussian モデルであるため、短期金利が負になる可能性を持つ。前章までの Normal モデルと同様、ゼロ金利近傍を扱いやすい一方、極端な負の金利も理論上許容する。

7.1.2 債券条件

5年満期、年率3%、半年払いの固定利付債を考える。市場利回りも3%とし、オプションを含まない Bullet Bond の価格がおおむね額面付近となる条件を設定する。

最初の1年間をノンコール期間とし、その後の各クーポン日に額面100で期限前償還できるものとする。満期日は通常の元本償還日であるため、コール可能日から除外する。

```
trade_date <- GaussQuant::date_GQL("2024-04-15")
issue_date <- GaussQuant::date_GQL("2024-04-17")
maturity_date <- GaussQuant::date_GQL("2029-04-17")

GaussQuant::set_eval_date_GQL(trade_date)
```

```

coupon_rate <- 0.03
market_yield <- 0.03
settlement_days <- 2L
face_amount <- 100
call_price_clean <- 100
non_call_periods <- 2L

bond_calendar <- QuantLib::WeekendsOnly()
bond_day_counter <- QuantLib::ActualActual("Bond")
model_day_counter <- QuantLib::Actual365Fixed()
bond_compounding <- QuantLib::Compounding_Compounded_get()
bond_frequency <- QuantLib::Frequency_Semiannual_get()

bond_input_tbl <- tibble::tribble(
  ~input,      ~value,
  "trade_date", "2024-04-15",
  "issue_date", "2024-04-17",
  "maturity_date", "2029-04-17",
  "coupon_rate", as.character(coupon_rate),
  "market_yield", as.character(market_yield),
  "settlement_days", as.character(settlement_days),
  "face_amount", as.character(face_amount),
  "call_price", as.character(call_price_clean),
  "non_call_periods", as.character(non_call_periods)
)

GaussQuant::show_tbl_GQH(
  bond_input_tbl,
  "Callable bond input assumptions",
  n = 20
)

#> # A tibble: 9 x 2
#>   input      value
#>   <chr>      <chr>
#> 1 trade_date 2024-04-15
#> 2 issue_date 2024-04-17
#> 3 maturity_date 2029-04-17
#> 4 coupon_rate 0.03
#> 5 market_yield 0.03
#> 6 settlement_days 2
#> 7 face_amount 100
#> 8 call_price 100
#> 9 non_call_periods 2

```


7.1.3 Bullet Bond

クーポンスケジュールを作成し、コール条項を含まない固定利付債を評価する。

```
bond_schedule <- QuantLib::Schedule(  
  issue_date,  
  maturity_date,  
  GaussQuant::period_months_GQL(6),  
  bond_calendar,  
  "Unadjusted",  
  "Unadjusted",  
  "Backward",  
  FALSE  
)  
  
bond_schedule_tbl <- GaussQuant::schedule_table_GQL(  
  bond_schedule  
)  
  
bullet_bond <- QuantLib::FixedRateBond(  
  settlement_days,  
  face_amount,  
  bond_schedule,  
  c(coupon_rate),  
  bond_day_counter  
)  
  
bullet_settlement_date <- tryCatch(  
  bullet_bond$settlementDate(),  
  error = function(e) NULL  
)  
  
bullet_clean_price <- GaussQuant::bond_clean_price_from_yield_safe_GQL(  
  bond = bullet_bond,  
  yield_rate = market_yield,  
  day_counter = bond_day_counter,  
  compounding = bond_compounding,  
  frequency = bond_frequency,  
  settlement_date = bullet_settlement_date  
)  
  
bullet_summary_tbl <- tibble::tribble(  
  ~bullet_bond, bullet_clean_price, bullet_settlement_date, bullet_summary_tbl
```

```

~metric,                                ~value,
"coupon_rate",                          coupon_rate,
"market_yield",                         market_yield,
"clean_price_from_yield",               bullet_clean_price,
"face_amount",                          face_amount
)

GaussQuant::show_tbl_GQH(
  bond_schedule_tbl,
  "Bullet bond schedule",
  n = 20
)

#> # A tibble: 11 x 2
#>   period schedule_date
#>   <int> <date>
#> 1     1 2024-04-17
#> 2     2 2024-10-17
#> 3     3 2025-04-17
#> 4     4 2025-10-17
#> 5     5 2026-04-17
#> 6     6 2026-10-17
#> 7     7 2027-04-17
#> 8     8 2027-10-17
#> 9     9 2028-04-17
#> 10    10 2028-10-17
#> 11    11 2029-04-17

GaussQuant::show_tbl_GQH(
  bullet_summary_tbl,
  "Bullet bond summary",
  n = 20
)

#> # A tibble: 4 x 2
#>   metric          value
#>   <chr>          <dbl>
#> 1 coupon_rate      0.03
#> 2 market_yield      0.03
#> 3 clean_price_from_yield 100.0
#> 4 face_amount      100

```

7.1.4 初期カーブと Hull-White モデル

Callable Bond と Swaption を同じ初期カーブと Hull-White パラメータで評価する。

本節では、年率 3% のフラットカーブを使用する。Callable Bond の主目的はオプション構造と Tree 評価を確認することであり、複雑な市場カーブ構築は行わない。

```
hull_white_a <- 0.03
hull_white_sigma <- 0.01
tree_steps <- 120L

flat_curve <- GaussQuant::flat_curve_GQL(
  reference_date = trade_date,
  rate = market_yield,
  day_counter = model_day_counter,
  compounding = "Continuous"
)

flat_curve_handle <- QuantLib::YieldTermStructureHandle(
  flat_curve
)

hull_white_model <- GaussQuant::hull_white_model_GQL(
  term_structure = flat_curve_handle,
  a = hull_white_a,
  sigma = hull_white_sigma
)

hull_white_input_tbl <- tibble::tribble(
  ~parameter,      ~value,
  "mean_reversion_a", hull_white_a,
  "sigma",          hull_white_sigma,
  "tree_steps",     tree_steps,
  "flat_curve_rate", market_yield
)

GaussQuant::show_tbl_GQH(
  hull_white_input_tbl,
  "Hull-White model assumptions",
  n = 20
)

#> # A tibble: 4 x 2
#>   parameter      value
#>   <chr>          <dbl>
#> 1 mean_reversion_a 0.03
#> 2 sigma            0.01
#> 3 tree_steps       120
#> 4 flat_curve_rate 0.03
```

7.2 Callable Bond の構築と Tree 評価

7.2.1 コールスケジュール

スケジュールには発行日と満期日も含まれる。最初の 2 クーポン期間をノンコールとし、満期日を除く残りのクーポン日をコール可能日とする。

```
bond_schedule_dates <- GaussQuant::schedule_date_vector_GQL(
  bond_schedule
)

first_call_position <- non_call_periods + 1L

call_dates <- bond_schedule_dates[
  first_call_position:
    (length(bond_schedule_dates) - 1L)
]

call_schedule <- GaussQuant::make_callability_schedule_GQL(
  call_dates = call_dates,
  call_price_clean = call_price_clean
)

call_schedule_tbl <- tibble::tibble(
  call_number = seq_along(call_dates),
  call_date = call_dates,
  call_price = rep(
    call_price_clean,
    length(call_dates)
  )
)

GaussQuant::show_tbl_GQH(
  call_schedule_tbl,
  "Callable bond exercise schedule",
  n = 20
)

#> # A tibble: 8 x 3
#>   call_number call_date  call_price
#>       <int> <date>         <dbl>
#> 1         1 2025-04-17         100
#> 2         2 2025-10-17         100
#> 3         3 2026-04-17         100
```

```
#> 4      4 2026-10-17      100
#> 5      5 2027-04-17      100
#> 6      6 2027-10-17      100
#> 7      7 2028-04-17      100
#> 8      8 2028-10-17      100
```

7.2.2 Callable Bond の Tree 評価

Callable Bond を作成し、Hull-White モデルに基づく金利 Tree を Pricing Engine として設定する。

各 Tree node では、発行体はその時点でコールする価値と、債券を存続させる価値が比較される。発行体にとってコールが有利であれば期限前償還が選択される。

```
callable_bond <- QuantLib::CallableFixedRateBond(
  settlement_days,
  face_amount,
  bond_schedule,
  c(coupon_rate),
  bond_day_counter,
  "Unadjusted",
  call_price_clean,
  issue_date,
  call_schedule
)

callable_bond_engine <- QuantLib::TreeCallableFixedRateBondEngine(
  hull_white_model,
  tree_steps
)

callable_bond$setPricingEngine(
  callable_bond_engine
)
#> NULL

callable_clean_price <- GaussQuant::callable_bond_clean_price_safe_GQL(
  callable_bond
)

callable_dirty_price <- GaussQuant::callable_bond_dirty_price_safe_GQL(
  callable_bond
)

callable_settlement_value <- GaussQuant::callable_bond_settlement_value_safe_GQL(
```

```

callable_bond
)

embedded_call_value <- bullet_clean_price -
  callable_clean_price

callable_summary_tbl <- tibble::tribble(
  ~metric,          ~value,
  "bullet_clean_price",    bullet_clean_price,
  "callable_clean_price",  callable_clean_price,
  "callable_dirty_price",  callable_dirty_price,
  "callable_settlement_value", callable_settlement_value,
  "embedded_call_value",   embedded_call_value
)

GaussQuant::show_tbl_GQH(
  callable_summary_tbl,
  "Callable bond summary",
  n = 20
)

#> # A tibble: 5 x 2
#>   metric          value
#>   <chr>          <dbl>
#> 1 bullet_clean_price    100.0
#> 2 callable_clean_price    98.0
#> 3 callable_dirty_price    98.0
#> 4 callable_settlement_value 98.0
#> 5 embedded_call_value     2.00

```

Callable Bond 価格が Bullet Bond 価格を下回る差額は、投資家が発行体へ与えている期限前償還権の価値と解釈できる。

7.3 Hull-White パラメータ感応度

短期金利のボラティリティが高いほど、将来金利が大きく低下する可能性も高くなる。したがって、発行体のコール権は一般に高くなり、Callable Bond 価格は低下する。

平均回帰速度 a は、金利ショックがどの程度の速さで消滅するかを決める。平均回帰が速い場合、長い期間にわたる金利ショックの影響は小さくなる。

```

callable_sensitivity_input_tbl <- tibble::tribble(
  ~scenario,      ~mean_reversion, ~sigma,
  "low_sigma",    0.03,            0.005,
  "base",         0.03,            0.010,

```

```

    "high_sigma",      0.03,      0.020,
    "slow_reversion",  0.01,      0.010,
    "fast_reversion",  0.10,      0.010
  )

callable_sensitivity_tbl <- purrr::pmap_dfr(
  callable_sensitivity_input_tbl,
  function(
    scenario,
    mean_reversion,
    sigma
  ) {
    model_i <- GaussQuant::hull_white_model_GQL(
      term_structure = flat_curve_handle,
      a = mean_reversion,
      sigma = sigma
    )

    engine_i <- QuantLib::TreeCallableFixedRateBondEngine(
      model_i,
      tree_steps
    )

    callable_bond$setPricingEngine(
      engine_i
    )

    callable_price_i <- GaussQuant::callable_bond_clean_price_safe_GQL(
      callable_bond
    )

    tibble::tibble(
      scenario = scenario,
      mean_reversion = mean_reversion,
      sigma = sigma,
      callable_clean_price = callable_price_i,
      embedded_call_value = bullet_clean_price -
        callable_price_i
    )
  }
)

callable_bond$setPricingEngine(

```

```

    callable_bond_engine
  )
#> NULL

GaussQuant::show_tbl_GQH(
  callable_sensitivity_tbl,
  "Callable bond Hull-White sensitivity",
  n = 20
)
#> # A tibble: 5 x 5
#>   scenario      mean_reversion sigma callable_clean_price embedded_call_value
#>   <chr>          <dbl> <dbl>          <dbl>          <dbl>
#> 1 low_sigma      0.03 0.005            99.0            1.04
#> 2 base           0.03 0.01             98.0            2.00
#> 3 high_sigma     0.03 0.02             96.1            3.91
#> 4 slow_reversion 0.01 0.01             97.9            2.08
#> 5 fast_reversion 0.1  0.01             98.2            1.76

```

パラメータ感応度は他の条件を固定した比較である。市場カリブレーション後のパラメータは互いに独立ではないため、実務上のリスク分析ではカーブとボラティリティ市場を同時に考慮する必要がある。

7.4 Bermudan Receiver Swaption との比較

発行体が債券をコールする誘因は、市場金利がクーポン金利を下回ったときに強くなる。これは固定金利を受け取る Receiver Swap の価値が、金利低下時に上昇する性質と対応する。

そこで、債券のクーポンスケジュールを固定レグとする Receiver Swap を作成し、Callable Bond と同じ行使日を持つ Bermudan Receiver Swaption を評価する。

```

floating_index <- QuantLib::JPYLibor(
  GaussQuant::period_months_GQL(6),
  flat_curve_handle
)

tryCatch(
  floating_index$addFixing(
    trade_date,
    market_yield,
    TRUE
  ),
  error = function(e) NULL
)
#> NULL

```



```

underlying_receiver_swap <- QuantLib::VanillaSwap(
  QuantLib::Swap_Receiver_get(),
  face_amount,
  bond_schedule,
  coupon_rate,
  bond_day_counter,
  bond_schedule,
  floating_index,
  0,
  bond_day_counter
)

bermudan_receiver_engine <- GaussQuant::hull_white_swaption_engine_GQL(
  term_structure = flat_curve_handle,
  a = hull_white_a,
  sigma = hull_white_sigma,
  method = "tree",
  time_steps = tree_steps
)

bermudan_receiver_swaption <- GaussQuant::make_bermudan_swaption_GQL(
  underlying_swap = underlying_receiver_swap,
  exercise_dates = call_dates,
  pricing_engine = bermudan_receiver_engine
)

bermudan_receiver_npv <- GaussQuant::swaption_npv_GQL(
  bermudan_receiver_swaption
)

receiver_swaption_value_per_100 <- bermudan_receiver_npv /
  face_amount *
  100

bullet_minus_receiver_swaption <- bullet_clean_price -
  receiver_swaption_value_per_100

callable_comparison_tbl <- tibble::tribble(
  ~valuation, ~value,
  "bullet_bond_clean_price", bullet_clean_price,
  "callable_bond_clean_price", callable_clean_price,
  "receiver_swaption_value_per_100", receiver_swaption_value_per_100,
  "bullet_minus_receiver_swaption", bullet_minus_receiver_swaption,

```

```

    "pricing_difference",          callable_clean_price -
                                   bullet_minus_receiver_swaption
  )

GaussQuant::show_tbl_GQH(
  callable_comparison_tbl,
  "Callable bond and Bermudan receiver swaption comparison",
  n = 20
)

#> # A tibble: 5 x 2
#>   valuation          value
#>   <chr>             <dbl>
#> 1 bullet_bond_clean_price      100.0
#> 2 callable_bond_clean_price     98.0
#> 3 receiver_swaption_value_per_100  1.89
#> 4 bullet_minus_receiver_swaption  98.1
#> 5 pricing_difference          -0.112

```

Callable Bond と Bermudan Receiver Swaption は、同じ Hull-White モデルと行使日を使用している。しかし、次の条件は完全には一致していない。

- 債券の元本償還と Swap の元本交換
- Clean price と Swaption NPV の決済単位
- 経過利子
- コール価格
- 固定クーポンと Swap 固定レグ
- 浮動レグの Fixing および支払条件

したがって、pricing_difference が厳密にゼロとなることは要求しない。この比較の目的は、Callable Bond に埋め込まれた金利低下時のオプション価値を、Receiver Swaption との関係から理解することである。

7.5 Vasicek モデルと Hull-White モデル

7.5.1 Vasicek モデルとの違い

Vasicek モデルは、短期金利が一定の長期平均へ回帰する Gaussian モデルである。

$$dr_t = a(b - r_t)dt + \sigma dW_t$$

ここで、 b は長期平均金利である。

Hull-White モデルも Gaussian 平均回帰モデルであるが、時間依存ドリフト $\theta(t)$ を導入することによって、評価時点のイールドカーブへ適合できる。

項目	Vasicek	Hull-White
平均回帰先	一定の長期平均 b	時間依存ドリフトで調整
初期カーブ	一般には完全適合しない	初期カーブへ適合可能
主な入力	a, b, σ, r_0	初期カーブ、 a, σ
金利分布	Gaussian	Gaussian
負の金利	許容	許容

Vasicek モデルは金利期間構造の長期的な形状をモデルパラメータから生成する。Hull-White モデルは、観測カーブを出発点として、その周りの確率的変動を表現する。

7.5.2 Vasicek と Hull-White のゼロ金利曲線

Vasicek では初期短期金利を変えると、モデルが生成する期間構造全体が変化する。Hull-White では状態変数がゼロであれば初期カーブを再現し、状態変数のショックが平均回帰しながら期間構造へ影響する。

```
maturity_grid <- seq(
  0.25,
  10,
  by = 0.25
)

vasicek_scenario_tbl <- tibble::tribble(
  ~scenario,      ~short_rate,
  "r0 = 1%",      0.01,
  "r0 = 3%",      0.03,
  "r0 = 5%",      0.05
)

vasicek_curve_tbl <- purrr::pmap_dfr(
  vasicek_scenario_tbl,
  function(
    scenario,
    short_rate
  ) {
    tibble::tibble(
      maturity = maturity_grid,
      zero_rate = purrr::map_dbl(
        maturity_grid,
        function(maturity_value) {
          GaussQuant::vasicek_zero_rate_GQL(
            time = 0,
            maturity = maturity_value,
            mean_reversion = 0.30,
```

```

        sigma = 0.01,
        long_run_rate = 0.03,
        short_rate = short_rate
      )
    }
  ),
  model = "Vasicek",
  scenario = scenario
)
}
)

hull_white_scenario_tbl <- tibble::tribble(
  ~scenario,      ~state_variable,
  "x0 = -0.3%",   -0.003,
  "base curve",   0.000,
  "x0 = 0.3%",    0.003
)

hull_white_curve_tbl <- purrr::pmap_dfr(
  hull_white_scenario_tbl,
  function(
    scenario,
    state_variable
  ) {
    tibble::tibble(
      maturity = maturity_grid,
      zero_rate = purrr::map_dbl(
        maturity_grid,
        function(maturity_value) {
          GaussQuant::hull_white_zero_rate_GQL(
            time = 0,
            maturity = maturity_value,
            curve = flat_curve,
            mean_reversion = 0.30,
            sigma = 0.01,
            state_variable = state_variable
          )
        }
      ),
      model = "Hull-White",
      scenario = scenario
    )
  }
)

```

```

}
)

short_rate_curve_tbl <- dplyr::bind_rows(
  vasicek_curve_tbl,
  hull_white_curve_tbl
)

short_rate_curve_plot <- ggplot2::ggplot(
  short_rate_curve_tbl,
  ggplot2::aes(
    x = .data$maturity,
    y = .data$zero_rate,
    group = .data$scenario,
    linetype = .data$scenario
  )
) +
  ggplot2::geom_line(
    linewidth = 0.7
  ) +
  ggplot2::facet_wrap(
    ~model,
    scales = "free_y"
  ) +
  ggplot2::scale_y_continuous(
    labels = function(x) sprintf("%.2f%%", 100 * x)
  ) +
  ggplot2::labs(
    title = "Vasicek and Hull-White zero-rate curves",
    x = "Residual maturity (years)",
    y = "Continuously compounded zero rate",
    linetype = "Scenario"
  ) +
  ggplot2::theme_minimal()


GaussQuant::show_tbl_GQH(
  short_rate_curve_tbl,
  "Short-rate model zero-rate curves",
  n = 30
)

#> # A tibble: 30 x 4
#>   maturity zero_rate model    scenario
#>   <dbl>     <dbl> <chr>    <chr>

```

```
#> 1      0.25      0.0107 Vasicek r0 = 1%
#> 2      0.5      0.0114 Vasicek r0 = 1%
#> 3      0.75      0.0121 Vasicek r0 = 1%
#> 4      1        0.0127 Vasicek r0 = 1%
#> 5      1.25      0.0133 Vasicek r0 = 1%
#> 6      1.5      0.0139 Vasicek r0 = 1%
#> 7      1.75      0.0144 Vasicek r0 = 1%
#> 8      2        0.0149 Vasicek r0 = 1%
#> 9      2.25      0.0154 Vasicek r0 = 1%
#> 10     2.5      0.0159 Vasicek r0 = 1%
#> # i 20 more rows
```

```
print(short_rate_curve_plot)
```



Hull-White の `base curve` が初期フラットカーブ付近に位置することが、初期期間構造へ適合する性質を表している。状態変数のショックは短期側で大きく、満期が長くなるほど平均回帰によって影響が小さくなる。

7.6 カリブレーションと数値検証

7.6.1 Hull-White モデルのカリブレーション

Hull-White モデルのパラメータ a と σ は、Swaption 市場の価格またはインプライド・ボラティリティへ適合させる。

本節では、1 年後に開始して 5 年間継続する 1Y×5Y ATM Swaption を使用する。市場 Normal volatility を 36.06bp とし、平均回帰速度 $a = 0.03$ を固定して、短期金利ボラティリティ σ だけを推定する。

単一の市場商品から a と σ の双方を安定して識別することはできない。複数満期の Swaption を利用する場合

には、複数の Calibration Helper を同時に用いて両パラメータを推定する。

7.6.2 1Y×5Y ATM Swap

```
GaussQuant::set_eval_date_GQL(trade_date)

calibration_calendar <- QuantLib::Japan()
calibration_day_counter <- QuantLib::Actual365Fixed()

swaption_expiry_date <- calibration_calendar$advance(
  trade_date,
  1L,
  "Years"
)

swap_effective_date <- calibration_calendar$advance(
  swaption_expiry_date,
  2L,
  "Days"
)

swap_maturity_date <- calibration_calendar$advance(
  swap_effective_date,
  5L,
  "Years"
)

calibration_schedule <- QuantLib::Schedule(
  swap_effective_date,
  swap_maturity_date,
  GaussQuant::period_months_GQL(6),
  calibration_calendar,
  "ModifiedFollowing",
  "ModifiedFollowing",
  "Backward",
  FALSE
)

calibration_index <- QuantLib::JPYLibor(
  GaussQuant::period_months_GQL(6),
  flat_curve_handle
)
```

```

calibration_annuity <- GaussQuant::swap_annuity_from_schedule_GQL(
  schedule = calibration_schedule,
  curve = flat_curve,
  day_counter = calibration_day_counter
)

calibration_forward_swap_rate <- GaussQuant::forward_swap_rate_from_schedule_GQL(
  schedule = calibration_schedule,
  curve = flat_curve,
  day_counter = calibration_day_counter
)

calibration_swap_tbl <- tibble::tribble(
  ~metric,          ~value,
  "expiry_date",    GaussQuant::iso_GQL(swaption_expiry_date),
  "swap_effective_date", GaussQuant::iso_GQL(swap_effective_date),
  "swap_maturity_date", GaussQuant::iso_GQL(swap_maturity_date),
  "annuity",        as.character(calibration_annuity),
  "forward_swap_rate", as.character(calibration_forward_swap_rate)
)

GaussQuant::show_tbl_GQH(
  GaussQuant::schedule_table_GQL(
    calibration_schedule
  ),
  "1Yx5Y fixed-leg schedule",
  n = 20
)

#> # A tibble: 11 x 2
#>   period schedule_date
#>   <int> <date>
#> 1     1 2025-04-17
#> 2     2 2025-10-17
#> 3     3 2026-04-17
#> 4     4 2026-10-19
#> 5     5 2027-04-19
#> 6     6 2027-10-18
#> 7     7 2028-04-17
#> 8     8 2028-10-17
#> 9     9 2029-04-17
#> 10    10 2029-10-17
#> 11    11 2030-04-17

GaussQuant::show_tbl_GQH(

```



```

calibration_swap_tbl,
"1Yx5Y forward swap summary",
n = 20
)
#> # A tibble: 5 x 2
#>   metric      value
#>   <chr>      <chr>
#> 1 expiry_date 2025-04-15
#> 2 swap_effective_date 2025-04-17
#> 3 swap_maturity_date 2030-04-17
#> 4 annuity      4.47364922408499
#> 5 forward_swap_rate 0.0302262727429665

```

7.6.3 One-helper calibration

```

market_normal_volatility <- 36.06 / 10000
fixed_mean_reversion <- 0.03
initial_sigma <- 0.0001

calibration_model <- GaussQuant::hull_white_model_GQL(
  term_structure = flat_curve_handle,
  a = fixed_mean_reversion,
  sigma = initial_sigma
)

calibration_jamshidian_engine <- QuantLib::JamshidianSwaptionEngine(
  calibration_model
)

swaption_helper <- QuantLib::SwaptionHelper(
  swaption_expiry_date,
  GaussQuant::period_years_GQL(5),
  QuantLib::QuoteHandle(
    QuantLib::SimpleQuote(
      market_normal_volatility
    )
  ),
  calibration_index,
  GaussQuant::period_months_GQL(6),
  calibration_day_counter,
  calibration_day_counter,
  flat_curve_handle,
  QuantLib::BlackCalibrationHelper_RelativePriceError_get(),

```

```

    calibration_forward_swap_rate,
    1,
    QuantLib::VolatilityType_Normal_get()
)

swaption_helper$setPricingEngine(
    calibration_jamshidian_engine
)
#> NULL

calibration_helper_vector <- GaussQuant::push_calibration_helpers_GQL(
    list(swaption_helper)
)

calibration_end_criteria <- QuantLib::EndCriteria(
    10000L,
    100L,
    1e-6,
    1e-8,
    1e-8
)

calibration_model$calibrate(
    calibration_helper_vector,
    QuantLib::LevenbergMarquardt(),
    calibration_end_criteria,
    QuantLib::NoConstraint(),
    numeric(),
    c(
        TRUE,
        FALSE
    )
)
#> NULL

calibration_parameter_array <- calibration_model$params()

calibrated_parameters <- c(
    as.numeric(calibration_parameter_array[1]),
    as.numeric(calibration_parameter_array[2])
)

calibration_result_tbl <- tibble::tribble(

```

```

~parameter,      ~value,
"a_fixed",        calibrated_parameters[[1]],
"sigma_calibrated", calibrated_parameters[[2]],
"market_normal_vol", market_normal_volatility
)

GaussQuant::show_tbl_GQH(
  calibration_result_tbl,
  "Hull-White one-helper calibration",
  n = 20
)

#> # A tibble: 3 x 2
#>   parameter      value
#>   <chr>          <dbl>
#> 1 a_fixed        0.03
#> 2 sigma_calibrated 0.00334
#> 3 market_normal_vol 0.00361
calibration_parameter_array <- calibration_model$params()

calibration_result_tbl <- tibble::tribble(
  ~parameter,      ~value,
  "a_fixed",        calibrated_parameters[[1]],
  "sigma_calibrated", calibrated_parameters[[2]],
  "market_normal_vol", market_normal_volatility
)

GaussQuant::show_tbl_GQH(
  calibration_result_tbl,
  "Hull-White one-helper calibration",
  n = 20
)

#> # A tibble: 3 x 2
#>   parameter      value
#>   <chr>          <dbl>
#> 1 a_fixed        0.03
#> 2 sigma_calibrated 0.00334
#> 3 market_normal_vol 0.00361

```

`c(TRUE, FALSE)` は、最初のパラメータ a を固定し、2 番目のパラメータ σ だけを最適化する指定である。

7.6.4 European Swaption の Engine 比較

カリブレーションに用いた 1Y×5Y ATM Swap を原資産とする European Payer Swaption を作成し、次の 3 つの方法で評価する。

- Jamshidian decomposition
- Hull-White Tree
- Bachelier analytic engine

Jamshidian と Tree は同じカリブレーション後の Hull-White モデルを使用する。Bachelier Engine は市場 Normal volatility を直接使用する。

```
calibration_underlying_swap <- QuantLib::VanillaSwap(
  QuantLib::Swap_Payer_get(),
  1,
  calibration_schedule,
  calibration_forward_swap_rate,
  calibration_day_counter,
  calibration_schedule,
  calibration_index,
  0,
  calibration_day_counter
)

calibration_european_swaption <- QuantLib::Swaption(
  calibration_underlying_swap,
  QuantLib::EuropeanExercise(
    swaption_expiry_date
  )
)

jamshidian_engine <- QuantLib::JamshidianSwaptionEngine(
  calibration_model
)

calibration_european_swaption$setPricingEngine(
  jamshidian_engine
)
#> NULL

npv_jamshidian <- GaussQuant::instrument_npv_safe_GQL(
  calibration_european_swaption
)

tree_engine_500 <- QuantLib::TreeSwaptionEngine(
  calibration_model,
  500L
)

calibration_european_swaption$setPricingEngine(
```

```

    tree_engine_500
  )
#> NULL

npv_tree_500 <- GaussQuant::instrument_npv_safe_GQL(
  calibration_european_swaption
)

bachelier_engine <- QuantLib::BachelierSwaptionEngine(
  flat_curve_handle,
  QuantLib::QuoteHandle(
    QuantLib::SimpleQuote(
      market_normal_volatility
    )
  )
)

calibration_european_swaption$setPricingEngine(
  bachelier_engine
)
#> NULL

npv_bachelier <- GaussQuant::instrument_npv_safe_GQL(
  calibration_european_swaption
)

engine_comparison_tbl <- tibble::tribble(
  ~engine,          ~npv,
  "Jamshidian",     npv_jamshidian,
  "Hull-White tree 500", npv_tree_500,
  "Bachelier",      npv_bachelier
) |>
  dplyr::mutate(
    difference_vs_bachelier = .data$npv -
      npv_bachelier,
    difference_vs_jamshidian = .data$npv -
      npv_jamshidian
  )

GaussQuant::show_tbl_GQH(
  engine_comparison_tbl,
  "1Yx5Y swaption engine comparison",
  n = 20

```

```

)
#> # A tibble: 3 x 4
#>   engine      npv difference_vs_bachelier difference_vs_jamshidian
#>   <chr>      <dbl>          <dbl>          <dbl>
#> 1 Jamshidian 0.00555      -0.0000000580      0
#> 2 Hull-White tree 500 0.00555      -0.00000395     -0.00000390
#> 3 Bachelier 0.00555      0                0.0000000580

```

カリブレーション対象と同じ ATM Swaption であるため、Hull-White 価格と Bachelier 市場価格は近い値になることが期待される。Jamshidian と十分に細かい Tree の差は、主に Tree 離散化誤差を表す。

7.6.5 Tree step の収束

Hull-White Tree では、時間軸と金利状態を有限個の node へ離散化する。Tree step が少ない場合、金利分布とオプション Payoff の非線形性を粗くしか表現できない。

同じ European Swaption を異なる Tree step で評価し、Jamshidian 価格への収束を確認する。

```

tree_step_grid <- c(
  6L,
  12L,
  24L,
  60L,
  120L,
  240L,
  500L
)

tree_convergence_tbl <- purrr::map_dfr(
  tree_step_grid,
  function(tree_step) {
    tree_engine_i <- QuantLib::TreeSwaptionEngine(
      calibration_model,
      tree_step
    )

    calibration_european_swaption$setPricingEngine(
      tree_engine_i
    )

    tree_npv_i <- GaussQuant::instrument_npv_safe_GQL(
      calibration_european_swaption
    )

    tibble::tibble(

```

```

    tree_steps = tree_step,
    npv = tree_npv_i,
    difference_vs_jamshidian = tree_npv_i -
      npv_jamshidian,
    difference_vs_bachelier = tree_npv_i -
      npv_bachelier
  )
}
)

tree_convergence_plot <- ggplot2::ggplot(
  tree_convergence_tbl,
  ggplot2::aes(
    x = .data$tree_steps,
    y = .data$npv
  )
) +
  ggplot2::geom_line(
    linewidth = 0.7
  ) +
  ggplot2::geom_point(
    size = 2.2
  ) +
  ggplot2::geom_hline(
    yintercept = npv_jamshidian,
    linetype = "dashed"
  ) +
  ggplot2::labs(
    title = "Hull-White tree-step convergence",
    subtitle = "Dashed line: Jamshidian price",
    x = "Tree steps",
    y = "Swaption NPV"
  ) +
  ggplot2::theme_minimal()


GaussQuant::show_tbl_GQH(
  tree_convergence_tbl,
  "Hull-White tree convergence",
  n = 20
)

#> # A tibble: 7 x 4
#>   tree_steps      npv difference_vs_jamshidian difference_vs_bachelier
#>   <int>      <dbl>                <dbl>                <dbl>

```

```
#> 1      6 0.00409      -0.00146      -0.00146
#> 2     12 0.00480      -0.000753     -0.000753
#> 3     24 0.00521      -0.000340     -0.000340
#> 4     60 0.00543      -0.000117     -0.000117
#> 5    120 0.00550      -0.0000508    -0.0000509
#> 6    240 0.00553      -0.0000194    -0.0000194
#> 7    500 0.00555      -0.00000390   -0.00000395
```

```
print(tree_convergence_plot)
```



Tree step を増やすほど、Tree 価格が Jamshidian 価格へ近づくことを確認する。Bermudan Swaption や Callable Bond には一般的な Jamshidian 解析解を利用できないため、European Swaption で Tree 精度を検証してから、早期行使商品へ同じ Tree 設定を適用することが重要である。

7.7 まとめ

Callable Bond は、Bullet Bond から発行体の期限前償還権を差し引いた商品として理解できる。金利が低下すると発行体のコール権は価値を持ち、投資家が保有する Callable Bond の価格上昇は抑制される。

発行体のコール権は、金利低下時に価値が上昇する Receiver Swaption と同じ方向の金利オプション性を持つ。複数のコール日がある場合には Bermudan Receiver Swaption に近い。ただし、債券と Swap では元本、決済およびキャッシュフロー条件が完全には一致しないため、価格関係は近似として解釈する必要がある。

Hull-White モデルは Gaussian 平均回帰型の短期金利モデルであり、時間依存ドリフトによって初期イールドカーブへ適合できる。Vasicek モデルがパラメータから期間構造を生成するのにに対し、Hull-White モデルは観測カーブを出発点として、その周りの確率変動を表現する。

Hull-White の平均回帰速度 a は金利ショックの持続性を、 σ は短期金利変動の大きさを表す。本章では、

1Y×5Y ATM Swaption の Normal volatility を使い、 a を固定して σ をカリブレーションした。

European Swaption では、Jamshidian decomposition、Hull-White Tree および Bachelier Engine を比較した。Tree step を増やすと Tree 価格は Jamshidian 価格へ近づく。Callable Bond や Bermudan Swaption のような早期行使商品では、この Tree 精度を確認したうえで評価する必要がある。

```
chapter07_summary_tbl <- tibble::tribble(
  ~section,          ~main_result,
  "Callable Bond",   "Bullet bond minus issuer call option",
  "Receiver Swaption", "Interest-rate direction of the issuer call",
  "Vasicek and Hull-White", "Initial-curve fit and mean reversion",
  "Calibration",     "Fixed a and calibrated sigma",
  "Tree convergence", "Convergence toward Jamshidian pricing"
)

GaussQuant::show_tbl_GQH(
  chapter07_summary_tbl,
  "Chapter II-7 summary",
  n = 20
)

#> # A tibble: 5 x 2
#>   section          main_result
#>   <chr>          <chr>
#> 1 Callable Bond    Bullet bond minus issuer call option
#> 2 Receiver Swaption Interest-rate direction of the issuer call
#> 3 Vasicek and Hull-White Initial-curve fit and mean reversion
#> 4 Calibration      Fixed a and calibrated sigma
#> 5 Tree convergence Convergence toward Jamshidian pricing

cat(
  "\nChapter II-7 Callable Bond and Hull-White model completed successfully.\n"
)

#>
#> Chapter II-7 Callable Bond and Hull-White model completed successfully.
```

第 II-8 章信用リスクと CDS

前章までの評価では、将来の市場価格、金利またはボラティリティの変動を扱った。本章では、契約相手または参照企業が債務を履行できなくなる信用リスクを検討する。

Credit Default Swap (CDS) は、参照企業などに信用事由が発生した場合に、プロテクションの売り手が買い手へ損失補償を支払う契約である。プロテクションの買い手は、その対価として契約期間中に定期的な Premium を支払う。

したがって、CDS は二つのレグから構成される。

- Premium Leg：プロテクション買い手が定期的な Spread を支払う。
- Protection Leg：信用事由が発生した場合に、プロテクション売り手が損失を補償する。

プロテクション買い手から見た CDS 価値は、次のように表される。

$$V_{\text{CDS}} = V_{\text{protection}} + V_{\text{premium}}$$

Premium Leg は支払いであるため通常は負、Protection Leg は受取りであるため正となる。

CDS 評価には、割引カーブだけでなく、将来のデフォルト確率を表す Default Probability Curve が必要である。本章では、Hazard Rate から生存確率とデフォルト確率を求め、Premium Leg と Protection Leg を評価する。

まず、フラット割引率とフラット Hazard Rate を使用して、MidPoint 法による CDS 評価と手計算を比較する。次に、標準 CDS2015 契約を ISDA CDS Engine で評価し、Fair spread、Fair upfront および Accrual rebateを確認する。

```
knitr::opts_chunk$set(
  collapse = TRUE,
  comment = "#>",
  warning = FALSE,
  message = FALSE
)

suppressPackageStartupMessages({
  library(tidyverse)
  library(ggthemes)
  library(QuantLib)
```

```
library(GaussQuant)
library(tidyverse)
library(broom)
})
```

8.1 信用リスクと CDS の基礎

8.1.1 デフォルト時刻と生存確率

デフォルトが発生する確率時刻を τ とする。時点 t まで企業がデフォルトせずに存続する確率を、生存確率と呼ぶ。

$$Q(t) = P(\tau > t)$$

時点 0 から t までの累積デフォルト確率は、

$$P(\tau \leq t) = 1 - Q(t)$$

である。

Hazard Rate $\lambda(t)$ は、時点 t まで存続しているという条件の下で、その直後にデフォルトする瞬間的な強度を表す。

$$\lambda(t) = \lim_{\Delta t \rightarrow 0} \frac{P(t < \tau \leq t + \Delta t \mid \tau > t)}{\Delta t}$$

Hazard Rate が一定のフラットモデルでは、生存確率は次式となる。

$$Q(t) = \exp(-\lambda t)$$

累積デフォルト確率は、

$$1 - Q(t) = 1 - \exp(-\lambda t)$$

である。

Hazard Rate は、通常の意味での「一年間のデフォルト確率」そのものではない。たとえば Hazard Rate が 2% であっても、1 年累積デフォルト確率は、

$$1 - e^{-0.02}$$

であり、厳密には 2% と一致しない。

8.1.2 Recovery Rate と Loss Given Default

デフォルトが発生した場合でも、債権価値のすべてが失われるとは限らない。デフォルト後に回収できる元本比率を Recovery Rate R とする。

損失率 Loss Given Default は、

$$LGD = 1 - R$$

である。

Notional を N とすると、Protection Leg が補償する損失額は概ね、

$$N(1 - R)$$

となる。

Recovery Rate が高いほどデフォルト時の損失は小さくなり、同じデフォルト確率であれば CDS Spread は低くなる。

8.1.3 CDS Spread と Hazard Rate の近似

連続的な Premium 支払い、一定 Hazard Rate、一定 Recovery Rate および単純な割引を仮定すると、CDS Spread s と Hazard Rate λ には次の近似関係がある。

$$s \approx (1 - R)\lambda$$

したがって、

$$\lambda \approx \frac{s}{1 - R}$$

となる。

この近似は CDS の信用水準を理解するために有用である。ただし、実際の評価では、四半期ごとの支払い、Accrual on default、割引、標準日付およびカーブ補間が影響するため、厳密な Hazard Rate とは一致しない。

8.2 フラットカーブによる CDS 評価

8.2.1 フラットカーブによる 1 年物 CDS

1 年物 CDS を考える。

- 評価日：2022 年 9 月 19 日
- 満期：2023 年 9 月 20 日

- Notional : 10,000,000
- 割引率 : 10%
- 市場 Spread : 130bp
- 契約 Coupon : 100bp
- Recovery Rate : 40%

市場 Spread は 130bp であるが、契約 Coupon は 100bp である。このため、契約時点の CDS 価値はゼロにならない。

```
trade_date_flat <- GaussQuant::date_GQL("2022-09-19")
maturity_date_flat <- GaussQuant::date_GQL("2023-09-20")

GaussQuant::set_eval_date_GQL(trade_date_flat)

notional_flat <- 10000000
risk_free_rate_flat <- 0.10
market_spread_flat <- 130 / 10000
contract_coupon_flat <- 100 / 10000
recovery_rate_flat <- 0.40

actual_365 <- QuantLib::Actual365Fixed()
actual_360 <- QuantLib::Actual360()
weekend_calendar <- QuantLib::WeekendsOnly()

flat_cds_input_tbl <- tibble::tribble(
  ~input,      ~value,
  "trade_date", "2022-09-19",
  "maturity_date", "2023-09-20",
  "notional",     as.character(notional_flat),
  "risk_free_rate", as.character(risk_free_rate_flat),
  "market_spread", as.character(market_spread_flat),
  "contract_coupon", as.character(contract_coupon_flat),
  "recovery_rate",  as.character(recovery_rate_flat)
)

GaussQuant::show_tbl_GQH(
  flat_cds_input_tbl,
  "Flat CDS input assumptions",
  n = 20
)

#> # A tibble: 7 x 2
#>   input      value
#>   <chr>      <chr>
#> 1 trade_date 2022-09-19
#> 2 maturity_date 2023-09-20
```

```
#> 3 notional      1e+07
#> 4 risk_free_rate 0.1
#> 5 market_spread  0.013
#> 6 contract_coupon 0.01
#> 7 recovery_rate  0.4
```

8.2.2 Hazard Rate 近似と確率曲線

市場 Spread 130bp と Recovery Rate 40% から、フラット Hazard Rate を近似する。

```
hazard_rate_approximation <- market_spread_flat /
  (1 - recovery_rate_flat)

hazard_approximation_tbl <- tibble::tribble(
  ~metric,          ~value,
  "market_spread",  market_spread_flat,
  "recovery_rate",  recovery_rate_flat,
  "loss_given_default", 1 - recovery_rate_flat,
  "hazard_rate_approx", hazard_rate_approximation
)

probability_time_grid <- seq(
  0,
  5,
  by = 0.25
)

flat_probability_tbl <- tibble::tibble(
  time = probability_time_grid
) |>
  dplyr::mutate(
    survival_probability = exp(
      -hazard_rate_approximation * .data$time
    ),
    cumulative_default_probability = 1 -
      .data$survival_probability
  )

flat_probability_plot_tbl <- flat_probability_tbl |>
  tidyr::pivot_longer(
    cols = c(
      survival_probability,
      cumulative_default_probability
    ),
```

```

    names_to = "probability_type",
    values_to = "probability"
  )

flat_probability_plot <- ggplot2::ggplot(
  flat_probability_plot_tbl,
  ggplot2::aes(
    x = .data$time,
    y = .data$probability,
    linetype = .data$probability_type
  )
) +
  ggplot2::geom_line(
    linewidth = 0.7
  ) +
  ggplot2::scale_y_continuous(
    labels = scales::percent_format(
      accuracy = 0.1
    )
  ) +
  ggplot2::labs(
    title = "Flat-hazard survival and default probabilities",
    x = "Time (years)",
    y = "Probability",
    linetype = "Probability"
  ) +
  ggplot2::theme_minimal()

GaussQuant::show_tbl_GQH(
  hazard_approximation_tbl,
  "Flat hazard-rate approximation",
  n = 20
)

#> # A tibble: 4 x 2
#>   metric          value
#>   <chr>          <dbl>
#> 1 market_spread    0.013
#> 2 recovery_rate    0.4
#> 3 loss_given_default 0.6
#> 4 hazard_rate_approx 0.0217

GaussQuant::show_tbl_GQH(
  flat_probability_tbl,


```

```

"Flat-hazard probability curve",
  n = 30
)
#> # A tibble: 21 x 3
#>   time survival_probability cumulative_default_probability
#>   <dbl>          <dbl>          <dbl>
#> 1  0          1          0
#> 2  0.25      0.995      0.00540
#> 3  0.5       0.989      0.0108
#> 4  0.75      0.984      0.0161
#> 5  1         0.979      0.0214
#> 6  1.25      0.973      0.0267
#> 7  1.5       0.968      0.0320
#> 8  1.75      0.963      0.0372
#> 9  2         0.958      0.0424
#> 10 2.25      0.952      0.0476
#> # i 11 more rows

print(flat_probability_plot)

```



8.2.3 CDS Schedule とカーブ

Premium は四半期ごとに支払われるものとする。単純な教育用例として、評価日の翌日から満期までの Forward Schedule を作成する。

```

cds_schedule_flat <- QuantLib::Schedule(
  trade_date_flat + 1L,

```



```

maturity_date_flat,
GaussQuant::period_months_GQL(3),
weekend_calendar,
"Following",
"Unadjusted",
"Forward",
FALSE
)

discount_curve_flat <- GaussQuant::flat_curve_GQL(
  reference_date = trade_date_flat,
  rate = risk_free_rate_flat,
  day_counter = actual_365,
  compounding = "Continuous"
)

discount_curve_handle_flat <- QuantLib::YieldTermStructureHandle(
  discount_curve_flat
)

hazard_curve_flat <- QuantLib::FlatHazardRate(
  trade_date_flat,
  GaussQuant::quote_handle_GQL(
    hazard_rate_approximation
  ),
  actual_365
)

hazard_curve_handle_flat <- QuantLib::DefaultProbabilityTermStructureHandle(
  hazard_curve_flat
)

flat_curve_check_tbl <- tibble::tribble(
  ~metric, ~value,
  "discount_factor_at_maturity", discount_curve_flat$discount(
    maturity_date_flat
  ),
  "survival_probability_at_maturity", hazard_curve_flat$survivalProbability(
    maturity_date_flat
  ),
  "default_probability_to_maturity", 1 -
    hazard_curve_flat$survivalProbability(
      maturity_date_flat
    )
)

```

```

    ),
    "hazard_rate_at_maturity", hazard_curve_flat$hazardRate(
      maturity_date_flat
    )
  )

GaussQuant::show_tbl_GQH(
  GaussQuant::schedule_table_GQL(
    cds_schedule_flat
  ),
  "CDS schedule: flat-curve example",
  n = 20
)

#> # A tibble: 5 x 2
#>   period schedule_date
#>   <int> <date>
#> 1     1 2022-09-20
#> 2     2 2022-12-20
#> 3     3 2023-03-20
#> 4     4 2023-06-20
#> 5     5 2023-09-20

GaussQuant::show_tbl_GQH(
  flat_curve_check_tbl,
  "Flat discount and hazard-curve check",
  n = 20
)

#> # A tibble: 4 x 2
#>   metric value
#>   <chr>   <dbl>
#> 1 discount_factor_at_maturity 0.905
#> 2 survival_probability_at_maturity 0.979
#> 3 default_probability_to_maturity 0.0215
#> 4 hazard_rate_at_maturity 0.0217

```

8.2.4 MidPoint CDS Engine

MidPoint 法では、各 Premium 期間中に発生するデフォルトを、その期間の midpoint で発生したものとして近似する。

100bp Coupon の CDS を作成し、GaussQuant の MidPoint CDS Engine で評価する。

```

cds_flat <- QuantLib::CreditDefaultSwap(
  GaussQuant::cds_buyer_side_GQL(),

```

```

    notional_flat,
    contract_coupon_flat,
    cds_schedule_flat,
    "Following",
    actual_360
)

midpoint_engine_flat <- GaussQuant::cds_midpoint_engine_GQL(
  probability_handle = hazard_curve_handle_flat,
  recovery_rate = recovery_rate_flat,
  discount_handle = discount_curve_handle_flat
)

cds_flat$setPricingEngine(
  midpoint_engine_flat
)
#> NULL

cds_flat_summary_tbl <- GaussQuant::cds_summary_GQL(
  cds_flat
)

cds_flat_leg_check_tbl <- tibble::tribble(
  ~metric,          ~value,
  "coupon_leg_npv",  cds_flat$couponLegNPV(),
  "default_leg_npv", cds_flat$defaultLegNPV(),
  "sum_of_two_legs", cds_flat$couponLegNPV() +
    cds_flat$defaultLegNPV(),
  "reported_npv",    GaussQuant::cds_npv_GQL(
    cds_flat
  ),
  "difference",      GaussQuant::cds_npv_GQL(
    cds_flat
  ) -
    (
      cds_flat$couponLegNPV() +
      cds_flat$defaultLegNPV()
    )
)

GaussQuant::show_tbl_GQH(
  cds_flat_summary_tbl,
  "CDS summary: MidPoint engine with flat curves",

```

```

  n = 20
)
#> # A tibble: 4 x 2
#>   metric      value
#>   <chr>      <dbl>
#> 1 npv      28116.
#> 2 fair_spread 0.0130
#> 3 coupon_leg_npv -94246.
#> 4 default_leg_npv 122362.

GaussQuant::show_tbl_GQH(
  cds_flat_leg_check_tbl,
  "CDS two-leg NPV check",
  n = 20
)
#> # A tibble: 5 x 2
#>   metric      value
#>   <chr>      <dbl>
#> 1 coupon_leg_npv -94246.
#> 2 default_leg_npv 122362.
#> 3 sum_of_two_legs 28116.
#> 4 reported_npv 28116.
#> 5 difference      0

```

プロテクション買い手から見て、Premium Leg は負、Protection Leg は正となる。契約 Coupon が Fair Spread より低ければ、プロテクション買い手に有利となり、CDS NPV は一般に正となる。

8.2.5 CDS キャッシュフローと確率表

GaussQuant の `cds_cashflow_table_GQL()` を利用し、各 Premium 期間の割引係数、生存確率、デフォルト確率および期間中点の情報を確認する。

```

cds_cashflow_flat_tbl <- GaussQuant::cds_cashflow_table_GQL(
  cds_schedule = cds_schedule_flat,
  protection_start_date = cds_flat$protectionStartDate(),
  coupon_rate = contract_coupon_flat,
  hazard_curve = hazard_curve_flat,
  discount_curve = discount_curve_flat,
  trade_date = trade_date_flat,
  notional = notional_flat
)

GaussQuant::show_tbl_GQH(
  cds_cashflow_flat_tbl,

```

```
"CDS cash-flow and probability table",
  n = 20
)
#> # A tibble: 5 x 13
#>   payment_date coupon_rate accrual_start accrual_end accrual_days
#>   <chr>          <dbl> <chr>          <chr>          <dbl>
#> 1 2022-09-20      NA    <NA>          2022-09-20      NA
#> 2 2022-12-20      0.01 2022-09-20    2022-12-20      91
#> 3 2023-03-20      0.01 2022-12-20    2023-03-20      90
#> 4 2023-06-20      0.01 2023-03-20    2023-06-20      92
#> 5 2023-09-20      0.01 2023-06-20    2023-09-20      92
#> # i 8 more variables: accrual_year_fraction_365 <dbl>, coupon_amount <dbl>,
#> #   discount_factor <dbl>, survival_probability <dbl>,
#> #   default_probability <dbl>, midpoint_date <chr>,
#> #   midpoint_discount_factor <dbl>, midpoint_survival_probability <dbl>
```

8.3 Premium Leg と Protection Leg

8.3.1 Premium Leg の手計算

Premium Leg は、参照企業が各支払日まで存続した場合に支払われる。

単純化した現在価値は次式で表される。

$$V_{\text{premium}} \approx -Ns \sum_i \alpha_i D(0, t_i) Q(t_i)$$

ここで、 N は Notional、 s は契約 Coupon、 α_i は利息計算期間、 $D(0, t_i)$ は割引係数、 $Q(t_i)$ は生存確率である。

```
premium_leg_hand_flat <- -sum(
  cds_cashflow_flat_tbl$coupon_amount *
  cds_cashflow_flat_tbl$discount_factor *
  cds_cashflow_flat_tbl$midpoint_survival_probability,
  na.rm = TRUE
)
```

この近似では期間中点の生存確率を使用している。実際の CDS では、期間中にデフォルトした場合の経過 Premium である Accrual on default も考慮される。

8.3.2 Protection Leg の手計算

期間 $(t_{i-1}, t_i]$ にデフォルトする確率を、

$$\Delta PD_i = Q(t_{i-1}) - Q(t_i)$$

とする。

Protection Leg は、各期間の中点 m_i で損失補償が支払われると近似する。

$$V_{\text{protection}} \approx N(1 - R) \sum_i D(0, m_i) \Delta P D_i$$

```
protection_leg_per_unit_hand_flat <- (
  1 - recovery_rate_flat
) *
sum(
  cds_cashflow_flat_tbl$midpoint_discount_factor *
  cds_cashflow_flat_tbl$default_probability,
  na.rm = TRUE
)

protection_leg_hand_flat <- notional_flat *
  protection_leg_per_unit_hand_flat
```

8.3.3 Risky PV01 と Fair Spread

Risky PV01 は、CDS Spread を 1 単位支払う Premium Leg の現在価値に相当する。

$$RPV01 \approx \sum_i \alpha_i D(0, t_i) Q(t_i)$$

Fair Spread は、Premium Leg と Protection Leg の価値を等しくし、Upfront なしの CDS NPV をゼロにする Running Spread である。

$$s_{\text{fair}} = \frac{V_{\text{protection}}/N}{RPV01}$$

```
risky_pv01_hand_flat <- sum(
  (
    cds_cashflow_flat_tbl$accrual_days /
    360
  ) *
  cds_cashflow_flat_tbl$discount_factor *
  cds_cashflow_flat_tbl$midpoint_survival_probability,
  na.rm = TRUE
)

fair_spread_hand_flat <- protection_leg_per_unit_hand_flat /
  risky_pv01_hand_flat

cds_npv_hand_flat <- premium_leg_hand_flat +
```

```

protection_leg_hand_flat

flat_hand_check_tbl <- tibble::tribble(
  ~metric,          ~hand_value,          ~quantlib_value,
  "coupon_leg_npv", premium_leg_hand_flat,  cds_flat$couponLegNPV(),
  "default_leg_npv", protection_leg_hand_flat, cds_flat$defaultLegNPV(),
  "cds_npv",        cds_npv_hand_flat,    GaussQuant::cds_npv_GQL(
                                cds_flat
                                ),
  "fair_spread",    fair_spread_hand_flat,  GaussQuant::cds_fair_spread_GQL(
                                cds_flat
                                )
) |>
dplyr::mutate(
  difference = .data$hand_value -
    .data$quantlib_value
)

flat_hand_summary_tbl <- tibble::tribble(
  ~metric,          ~value,
  "risky_pv01",     risky_pv01_hand_flat,
  "protection_leg_per_unit", protection_leg_per_unit_hand_flat,
  "hand_fair_spread", fair_spread_hand_flat,
  "quantlib_fair_spread", GaussQuant::cds_fair_spread_GQL(
                                cds_flat
                                ),
  "fair_spread_difference", fair_spread_hand_flat -
                                GaussQuant::cds_fair_spread_GQL(
                                    cds_flat
                                )
)

GaussQuant::show_tbl_GQH(
  flat_hand_check_tbl,
  "CDS hand calculation and MidPoint engine comparison",
  n = 20
)

#> # A tibble: 4 x 4
#>   metric          hand_value quantlib_value difference
#>   <chr>          <dbl>          <dbl>          <dbl>
#> 1 coupon_leg_npv -94244.          -94246.          2.10
#> 2 default_leg_npv 122362.          122362.           0
#> 3 cds_npv        28118.           28116.          2.10

```

```
#> 4 fair_spread          0.0130          0.0130 0.000000289

GaussQuant::show_tbl_GQH(
  flat_hand_summary_tbl,
  "CDS hand-calculation summary",
  n = 20
)
#> # A tibble: 5 x 2
#>   metric                value
#>   <chr>                <dbl>
#> 1 risky_pv01            0.942
#> 2 protection_leg_per_unit 0.0122
#> 3 hand_fair_spread       0.0130
#> 4 quantlib_fair_spread   0.0130
#> 5 fair_spread_difference 0.000000289
```

手計算と MidPoint Engine は近い値となるが、厳密には一致しない。差には Accrual on default、日付規則、Protection 開始日および QuantLib 内部の計算規約が含まれる。

8.4 Hazard Rate 推定と感応度

8.4.1 Zero-NPV CDS から Hazard Rate を推定する

市場 Spread を契約 Coupon として設定した CDS は、契約開始時点で NPV がゼロとなるように Hazard Rate を調整できる。

ここでは、市場 Spread 130bp の CDS について、MidPoint Engine の NPV がゼロとなるフラット Hazard Rate を `uniroot()` で推定する。

```
cds_market_flat <- QuantLib::CreditDefaultSwap(
  GaussQuant::cds_buyer_side_GQL(),
  notional_flat,
  market_spread_flat,
  cds_schedule_flat,
  "Following",
  actual_360
)

cds_market_npv_at_hazard <- function(hazard_rate) {
  engine <- GaussQuant::cds_midpoint_engine_GQL(
    recovery_rate = recovery_rate_flat,
    hazard_rate = hazard_rate,
    discount_rate = risk_free_rate_flat,
    reference_date = trade_date_flat,
    day_counter = "Actual365Fixed"
  )
}
```



```

)

cds_market_flat$setPricingEngine(
  engine
)

GaussQuant::cds_npv_GQL(
  cds_market_flat
)
}

hazard_calibration_result <- stats::uniroot(
  cds_market_npv_at_hazard,
  interval = c(
    1e-8,
    0.50
  ),
  tol = 1e-10
)

hazard_rate_calibrated <- hazard_calibration_result$root

calibrated_midpoint_engine <- GaussQuant::cds_midpoint_engine_GQL(
  recovery_rate = recovery_rate_flat,
  hazard_rate = hazard_rate_calibrated,
  discount_rate = risk_free_rate_flat,
  reference_date = trade_date_flat,
  day_counter = "Actual365Fixed"
)

cds_market_flat$setPricingEngine(
  calibrated_midpoint_engine
)
#> NULL

hazard_calibration_tbl <- tibble::tribble(
  ~metric, ~value,
  "market_spread", market_spread_flat,
  "simple_hazard_approximation", hazard_rate_approximation,
  "calibrated_hazard_rate", hazard_rate_calibrated,
  "zero_npv_check", GaussQuant::cds_npv_GQL(
    cds_market_flat
  ),

```

```

    "fair_spread_check",          GaussQuant::cds_fair_spread_GQL(
                                   cds_market_flat
                                   )
  )

GaussQuant::show_tbl_GQH(
  hazard_calibration_tbl,
  "Flat hazard calibration from a zero-NPV CDS",
  n = 20
)

#> # A tibble: 5 x 2
#>   metric                                value
#>   <chr>                                <dbl>
#> 1 market_spread                        0.013
#> 2 simple_hazard_approximation 0.0217
#> 3 calibrated_hazard_rate           0.0217
#> 4 zero_npv_check                    0.000000367
#> 5 fair_spread_check                  0.0130

```

単純近似 $\lambda \approx s/(1 - R)$ とカリブレーション結果は近いが、支払頻度と割引の影響により差が生じる。

8.4.2 Spread と Recovery Rate の感応度

単純近似の下では、Spread が高いほど Hazard Rate は高くなる。また、同じ Spread で Recovery Rate を高く仮定すると、デフォルト時損失が小さくなるため、その Spread を説明するために必要な Hazard Rate は高くなる。

```

credit_sensitivity_input_tbl <- tidyr::crossing(
  market_spread_bp = c(
    50,
    100,
    200
  ),
  recovery_rate = c(
    0.20,
    0.40,
    0.60
  )
)

credit_sensitivity_tbl <- credit_sensitivity_input_tbl |>
  dplyr::mutate(
    market_spread = .data$market_spread_bp /
      10000,

```

```

    loss_given_default = 1 -
      .data$recovery_rate,
    hazard_rate_approx = .data$market_spread /
      .data$loss_given_default,
    survival_probability_5y = exp(
      -5 * .data$hazard_rate_approx
    ),
    cumulative_default_probability_5y = 1 -
      .data$survival_probability_5y
  )

GaussQuant::show_tbl_GQH(
  credit_sensitivity_tbl,
  "Spread and recovery-rate sensitivity",
  n = 30
)

#> # A tibble: 9 x 7
#>   market_spread_bp recovery_rate market_spread loss_given_default
#>   <dbl>           <dbl>         <dbl>           <dbl>
#> 1             50         0.2         0.005           0.8
#> 2             50         0.4         0.005           0.6
#> 3             50         0.6         0.005           0.4
#> 4            100         0.2         0.01            0.8
#> 5            100         0.4         0.01            0.6
#> 6            100         0.6         0.01            0.4
#> 7            200         0.2         0.02            0.8
#> 8            200         0.4         0.02            0.6
#> 9            200         0.6         0.02            0.4
#> # i 3 more variables: hazard_rate_approx <dbl>, survival_probability_5y <dbl>,
#> #   cumulative_default_probability_5y <dbl>

```

Recovery Rate と Hazard Rate は、CDS Spread だけから完全に独立して識別できない。実務では Recovery Rate を外生的に仮定し、その仮定の下で Default Probability Curve を構築することが多い。

8.5 標準 CDS2015 と ISDA カーブ

8.5.1 標準 CDS と CDS2015 満期

標準 CDS では、満期を単純に取引日から 5 年後とするのではなく、CDS IMM 日と CDS2015 ルールに従って決定する。

次の 5 年物 CDS を考える。

- 取引日：2022 年 8 月 19 日
- 市場 Spread：30.426bp

- 契約 Coupon : 100bp
- Notional : 10,000,000
- Recovery Rate : 40%
- 外生的な OIS 割引率 : 0.25%

第 II-3 章では OIS カーブの構築を扱った。本章の目的は信用カーブと CDS 評価であるため、割引カーブの動学やブートストラップを繰り返さず、フラット OIS 割引率を外生的に与える。

```
trade_date_isda <- GaussQuant::date_GQL(
  "2022-08-19"
)

GaussQuant::set_eval_date_GQL(
  trade_date_isda
)

cds_tenor_isda <- GaussQuant::period_years_GQL(
  5L
)

maturity_date_isda <- QuantLib::cdsMaturity(
  trade_date_isda,
  cds_tenor_isda,
  "CDS2015"
)

market_spread_isda <- 30.426 / 10000
contract_coupon_isda <- 100 / 10000
notional_isda <- 10000000
recovery_rate_isda <- 0.40
ois_discount_rate_isda <- 0.0025

isda_cds_input_tbl <- tibble::tribble(
  ~input,          ~value,
  "trade_date",    "2022-08-19",
  "cds_tenor",     "5Y",
  "maturity_date", GaussQuant::iso_GQL(
    maturity_date_isda
  ),
  "market_spread_bp", as.character(
    market_spread_isda *
    10000
  ),
  "contract_coupon_bp", as.character(
    contract_coupon_isda *
```

```

                                10000
                                ),
  "notional",                    as.character(
                                notional_isda
                                ),
  "recovery_rate",              as.character(
                                recovery_rate_isda
                                ),
  "ois_discount_rate",          as.character(
                                ois_discount_rate_isda
                                )
)

GaussQuant::show_tbl_GQH(
  isda_cds_input_tbl,
  "ISDA CDS input assumptions",
  n = 20
)

#> # A tibble: 8 x 2
#>   input      value
#>   <chr>      <chr>
#> 1 trade_date 2022-08-19
#> 2 cds_tenor  5Y
#> 3 maturity_date 2027-06-20
#> 4 market_spread_bp 30.426
#> 5 contract_coupon_bp 100
#> 6 notional    1e+07
#> 7 recovery_rate 0.4
#> 8 ois_discount_rate 0.0025

```

8.5.2 標準 CDS2015 Schedule

CDS2015 ルールにより、Premium 支払日は標準化された四半期日へ調整される。

```

cds_calendar_isda <- QuantLib::WeekendsOnly()

cds_schedule_isda <- QuantLib::Schedule(
  trade_date_isda,
  maturity_date_isda,
  GaussQuant::period_months_GQL(3),
  cds_calendar_isda,
  "Following",
  "Unadjusted",
  "CDS2015",

```

```

FALSE
)

GaussQuant::show_tbl_GQH(
  GaussQuant::schedule_table_GQL(
    cds_schedule_isda
  ),
  "CDS schedule: 5Y CDS2015 example",
  n = 30
)

#> # A tibble: 21 x 2
#>   period schedule_date
#>   <int> <date>
#> 1     1 2022-06-20
#> 2     2 2022-09-20
#> 3     3 2022-12-20
#> 4     4 2023-03-20
#> 5     5 2023-06-20
#> 6     6 2023-09-20
#> 7     7 2023-12-20
#> 8     8 2024-03-20
#> 9     9 2024-06-20
#> 10    10 2024-09-20
#> # i 11 more rows

```

8.5.3 ISDA 用割引カーブ

```

discount_curve_isda <- GaussQuant::flat_curve_GQL(
  reference_date = trade_date_isda,
  rate = ois_discount_rate_isda,
  day_counter = actual_365,
  compounding = "Continuous"
)

discount_curve_handle_isda <- QuantLib::YieldTermStructureHandle(
  discount_curve_isda
)

isda_discount_check_tbl <- tibble::tribble(
  ~metric, ~value,
  "ois_discount_rate", ois_discount_rate_isda,
  "discount_factor_at_maturity", discount_curve_isda$discount(
    maturity_date_isda
  )
)

```

```

    )
)

GaussQuant::show_tbl_GQH(
  isda_discount_check_tbl,
  "ISDA discount-curve check",
  n = 20
)

#> # A tibble: 2 x 2
#>   metric                                value
#>   <chr>                                <dbl>
#> 1 ois_discount_rate                    0.0025
#> 2 discount_factor_at_maturity 0.988

```

8.5.4 ISDA 整合 Hazard Rate の推定

市場 Spread 30.426bp を Running Spread とする標準 CDS を作成し、ISDA Engine の NPV がゼロとなるフラット Hazard Rate を推定する。

```

market_cds_isda <- GaussQuant::make_cds_GQL(
  maturity_date = maturity_date_isda,
  running_spread = market_spread_isda,
  notional = notional_isda,
  side = "buyer",
  trade_date = trade_date_isda,
  coupon_tenor = "3M",
  day_counter = "Actual360",
  date_generation_rule = "CDS2015"
)

isda_market_npv_at_hazard <- function(hazard_rate) {
  probability_handle <- GaussQuant::flat_hazard_rate_GQL(
    hazard_rate = hazard_rate,
    reference_date = trade_date_isda,
    day_counter = "Actual365Fixed"
  )

  engine <- GaussQuant::cds_isda_engine_GQL(
    hazard_curve_handle = probability_handle,
    recovery_rate = recovery_rate_isda,
    discount_curve_handle = discount_curve_handle_isda
  )

  market_cds_isda$setPricingEngine(

```

```

    engine
  )

  GaussQuant::cds_npv_GQL(
    market_cds_isda
  )
}

isda_hazard_calibration_result <- stats::uniroot(
  isda_market_npv_at_hazard,
  interval = c(
    1e-8,
    0.50
  ),
  tol = 1e-10
)

hazard_rate_isda <- isda_hazard_calibration_result$root

hazard_curve_isda <- QuantLib::FlatHazardRate(
  trade_date_isda,
  GaussQuant::quote_handle_GQL(
    hazard_rate_isda
  ),
  actual_365
)

hazard_curve_handle_isda <- QuantLib::DefaultProbabilityTermStructureHandle(
  hazard_curve_isda
)

isda_hazard_check_tbl <- tibble::tribble(
  ~metric,                ~value,
  "market_spread",        market_spread_isda,
  "recovery_rate",        recovery_rate_isda,
  "implied_hazard_rate",  hazard_rate_isda,
  "simple_hazard_approximation", market_spread_isda /
    (
      1 -
      recovery_rate_isda
    ),
  "survival_probability_at_maturity",
  hazard_curve_isda$survivalProbability(

```



```

    maturity_date_isda
  ),
  "default_probability_to_maturity",
  1 -
    hazard_curve_isda$survivalProbability(
      maturity_date_isda
    )
)

GaussQuant::show_tbl_GQH(
  isda_hazard_check_tbl,
  "ISDA implied hazard-rate check",
  n = 20
)

#> # A tibble: 6 x 2
#>   metric                                value
#>   <chr>                                <dbl>
#> 1 market_spread                      0.00304
#> 2 recovery_rate                      0.4
#> 3 implied_hazard_rate                0.00514
#> 4 simple_hazard_approximation        0.00507
#> 5 survival_probability_at_maturity 0.975
#> 6 default_probability_to_maturity 0.0246

```

市場 Spread と Recovery Rate から得られる単純近似と、ISDA Engine でゼロ NPV となる Hazard Rate には差が生じる。標準 CDS の日付、Accrual on default、割引および数値積分が評価へ反映されるためである。

8.6 ISDA Engine と評価比較

8.6.1 ISDA CDS Engine

契約 Coupon を標準 Coupon 100bp へ固定した 5 年物 CDS を評価する。

市場 Spread は 30.426bp であり、契約 Coupon 100bp より低い。プロテクション買い手は市場水準より高い Premium を支払うため、Running Coupon だけで評価すると一般に負の NPV となる。

```

isda_engine <- GaussQuant::cds_isda_engine_GQL(
  hazard_curve_handle = hazard_curve_handle_isda,
  recovery_rate = recovery_rate_isda,
  discount_curve_handle = discount_curve_handle_isda
)

cds_isda <- GaussQuant::make_cds_GQL(
  maturity_date = maturity_date_isda,
  running_spread = contract_coupon_isda,

```

```

    notional = notional_isda,
    side = "buyer",
    trade_date = trade_date_isda,
    coupon_tenor = "3M",
    day_counter = "Actual360",
    date_generation_rule = "CDS2015",
    pricing_engine = isda_engine
)

cds_isda_summary_base_tbl <- GaussQuant::cds_summary_GQL(
  cds_isda
)

GaussQuant::show_tbl_GQH(
  cds_isda_summary_base_tbl,
  "ISDA CDS base summary",
  n = 20
)

#> # A tibble: 4 x 2
#>   metric          value
#>   <chr>          <dbl>
#> 1 npv          -334963.
#> 2 fair_spread    0.00304
#> 3 coupon_leg_npv -498392.
#> 4 default_leg_npv 146485.

```

8.6.2 Accrual rebate と NPV 分解

標準 CDS では、取引日が前回の標準 Coupon 日と次回 Coupon 日の間にある場合、契約開始時に Accrual rebate が発生することがある。

この場合、プロテクション買い手から見た NPV は、

$$V_{\text{CDS}} = V_{\text{coupon}} + V_{\text{default}} + V_{\text{accrual rebate}}$$

となる。

```

coupon_leg_npv_isda <- cds_isda$couponLegNPV()
default_leg_npv_isda <- cds_isda$defaultLegNPV()

accrual_rebate_npv_isda <- tryCatch(
  as.numeric(
    cds_isda$accrualRebateNPV()
  ),

```

```

error = function(e) NA_real_
)

three_component_sum_isda <- coupon_leg_npv_isda +
  default_leg_npv_isda +
  accrual_rebate_npv_isda

isda_leg_check_tbl <- tibble::tribble(
  ~metric,          ~value,
  "coupon_leg_npv", coupon_leg_npv_isda,
  "default_leg_npv", default_leg_npv_isda,
  "accrual_rebate_npv", accrual_rebate_npv_isda,
  "three_component_sum", three_component_sum_isda,
  "reported_npv",      GaussQuant::cds_npv_GQL(
                        cds_isda
                        ),
  "difference",        GaussQuant::cds_npv_GQL(
                        cds_isda
                        ) -
                        three_component_sum_isda
)

GaussQuant::show_tbl_GQH(
  isda_leg_check_tbl,
  "ISDA CDS NPV decomposition",
  n = 20
)

#> # A tibble: 6 x 2
#>   metric          value
#>   <chr>          <dbl>
#> 1 coupon_leg_npv -498392.
#> 2 default_leg_npv 146485.
#> 3 accrual_rebate_npv 16944.
#> 4 three_component_sum -334963.
#> 5 reported_npv      -334963.
#> 6 difference        0

```

8.6.3 Fair Spread と Fair Upfront

Fair Spread は、Upfront を授受せずに CDS NPV をゼロとする Running Spread である。

Fair Upfront は、契約 Coupon を標準 Coupon へ固定したまま、契約価値を調整するために開始時点で授受する Notional 比率である。

```

fair_spread_isda <- GaussQuant::cds_fair_spread_GQL(
  cds_isda
)

fair_upfront_isda <- tryCatch(
  as.numeric(
    cds_isda$fairUpfront()
  ),
  error = function(e) NA_real_
)

fair_upfront_amount_isda <- fair_upfront_isda *
  notional_isda

isda_cds_summary_tbl <- tibble::tribble(
  ~metric,          ~value,
  "coupon_leg_npv", coupon_leg_npv_isda,
  "default_leg_npv", default_leg_npv_isda,
  "accrual_rebate_npv", accrual_rebate_npv_isda,
  "cds_npv",        GaussQuant::cds_npv_GQL(
    cds_isda
  ),
  "market_spread",  market_spread_isda,
  "contract_coupon", contract_coupon_isda,
  "fair_spread",    fair_spread_isda,
  "fair_upfront",   fair_upfront_isda,
  "fair_upfront_amount", fair_upfront_amount_isda,
  "hazard_rate",    hazard_rate_isda
)

GaussQuant::show_tbl_GQH(
  isda_cds_summary_tbl,
  "CDS summary: ISDA engine",
  n = 30
)

#> # A tibble: 10 x 2
#>   metric          value
#>   <chr>          <dbl>
#> 1 coupon_leg_npv -498392.
#> 2 default_leg_npv 146485.
#> 3 accrual_rebate_npv 16944.
#> 4 cds_npv        -334963.
#> 5 market_spread    0.00304

```

```
#> 6 contract_coupon      0.01
#> 7 fair_spread          0.00304
#> 8 fair_upfront         -0.0335
#> 9 fair_upfront_amount -334974.
#> 10 hazard_rate         0.00514
```

この例では、契約 Coupon が市場 Spread より高いため、プロテクション買い手は市場より多くの Premium を支払う。したがって、契約開始時の価値を調整する Upfront が必要となる。

Fair Upfront の正負は、QuantLib における Buyer / Seller の符号規約と契約設定に依存する。符号だけで判断せず、CDS NPV、契約 Coupon、Fair Spread および Upfront 金額を一緒に確認する必要がある。

8.6.4 ISDA 用キャッシュフロー表

標準 CDS2015 Schedule、ISDA 整合 Hazard Curve および割引カーブから、Premium 期間ごとの確率情報を作成する。

```
cds_cashflow_isda_tbl <- GaussQuant::cds_cashflow_table_GQL(
  cds_schedule = cds_schedule_isda,
  protection_start_date = cds_isda$protectionStartDate(),
  coupon_rate = contract_coupon_isda,
  hazard_curve = hazard_curve_isda,
  discount_curve = discount_curve_isda,
  trade_date = trade_date_isda,
  notional = notional_isda
)

GaussQuant::show_tbl_GQH(
  cds_cashflow_isda_tbl,
  "CDS cash-flow table: CDS2015 example",
  n = 30
)

#> # A tibble: 21 x 13
#>   payment_date coupon_rate accrual_start accrual_end accrual_days
#>   <chr>          <dbl> <chr>          <chr>          <dbl>
#> 1 2022-08-19      NA    <NA>          2022-08-19      NA
#> 2 2022-09-20      0.01 2022-06-20    2022-09-20      92
#> 3 2022-12-20      0.01 2022-09-20    2022-12-20      91
#> 4 2023-03-20      0.01 2022-12-20    2023-03-20      90
#> 5 2023-06-20      0.01 2023-03-20    2023-06-20      92
#> 6 2023-09-20      0.01 2023-06-20    2023-09-20      92
#> 7 2023-12-20      0.01 2023-09-20    2023-12-20      91
#> 8 2024-03-20      0.01 2023-12-20    2024-03-20      91
#> 9 2024-06-20      0.01 2024-03-20    2024-06-20      92
#> 10 2024-09-20     0.01 2024-06-20    2024-09-20      92
```

```
#> # i 11 more rows
#> # i 8 more variables: accrual_year_fraction_365 <dbl>, coupon_amount <dbl>,
#> #   discount_factor <dbl>, survival_probability <dbl>,
#> #   default_probability <dbl>, midpoint_date <chr>,
#> #   midpoint_discount_factor <dbl>, midpoint_survival_probability <dbl>
```

この表は CDS の経済構造を理解するための MidPoint 型分解である。ISDA Engine は、標準日付、Accrual on default、数値積分および曲線補間をより厳密に扱うため、この表から得られる単純近似と完全には一致しない。

8.6.5 MidPoint 型近似と ISDA Engine

ISDA 用キャッシュフロー表から、Premium Leg、Protection Leg、RPV01 および Fair Spread を簡易計算する。

```
premium_leg_hand_isda <- -sum(
  cds_cashflow_isda_tbl$coupon_amount *
  cds_cashflow_isda_tbl$discount_factor *
  cds_cashflow_isda_tbl$midpoint_survival_probability,
  na.rm = TRUE
)

protection_leg_per_unit_hand_isda <- (
  1 -
  recovery_rate_isda
) *
sum(
  cds_cashflow_isda_tbl$midpoint_discount_factor *
  cds_cashflow_isda_tbl$default_probability,
  na.rm = TRUE
)

protection_leg_hand_isda <- notional_isda *
  protection_leg_per_unit_hand_isda

risky_pv01_hand_isda <- sum(
  (
    cds_cashflow_isda_tbl$accrual_days /
    360
  ) *
  cds_cashflow_isda_tbl$discount_factor *
  cds_cashflow_isda_tbl$midpoint_survival_probability,
  na.rm = TRUE
)
```

```

fair_spread_hand_isda <- protection_leg_per_unit_hand_isda /
  risky_pv01_hand_isda

cds_npv_hand_isda <- premium_leg_hand_isda +
  protection_leg_hand_isda +
  accrual_rebate_npv_isda

isda_hand_check_tbl <- tibble::tribble(
  ~metric,          ~hand_value,          ~isda_value,
  "coupon_leg_npv", premium_leg_hand_isda, coupon_leg_npv_isda,
  "default_leg_npv", protection_leg_hand_isda, default_leg_npv_isda,
  "cds_npv",        cds_npv_hand_isda,    GaussQuant::cds_npv_GQL(
                                     cds_isda
                                     ),
  "fair_spread",    fair_spread_hand_isda, fair_spread_isda
) |>
  dplyr::mutate(
    difference = .data$hand_value -
      .data$isda_value
  )

GaussQuant::show_tbl_GQH(
  isda_hand_check_tbl,
  "MidPoint-style approximation and ISDA comparison",
  n = 20
)

#> # A tibble: 4 x 4
#>   metric          hand_value    isda_value difference
#>   <chr>              <dbl>        <dbl>      <dbl>
#> 1 coupon_leg_npv -498112.    -498392.      280.
#> 2 default_leg_npv 146486.    146485.       0.194
#> 3 cds_npv        -334682.    -334963.      280.
#> 4 fair_spread      0.00294     0.00304    -0.000102

```

8.6.6 MidPoint Engine と ISDA Engine の比較

同じ Hazard Curve、Recovery Rate、割引カーブおよび標準 Coupon を使用し、MidPoint Engine と ISDA Engine の評価差を確認する。

```

midpoint_engine_isda_inputs <- GaussQuant::cds_midpoint_engine_GQL(
  probability_handle = hazard_curve_handle_isda,
  recovery_rate = recovery_rate_isda,
  discount_handle = discount_curve_handle_isda
)

```

```

)

cds_midpoint_standard <- GaussQuant::make_cds_GQL(
  maturity_date = maturity_date_isda,
  running_spread = contract_coupon_isda,
  notional = notional_isda,
  side = "buyer",
  trade_date = trade_date_isda,
  coupon_tenor = "3M",
  day_counter = "Actual360",
  date_generation_rule = "CDS2015",
  pricing_engine = midpoint_engine_isda_inputs
)

midpoint_standard_summary_tbl <- GaussQuant::cds_summary_GQL(
  cds_midpoint_standard
) |>
  dplyr::mutate(
    engine = "MidPoint"
  )

isda_standard_summary_tbl <- GaussQuant::cds_summary_GQL(
  cds_isda
) |>
  dplyr::mutate(
    engine = "ISDA"
  )

engine_comparison_tbl <- dplyr::bind_rows(
  midpoint_standard_summary_tbl,
  isda_standard_summary_tbl
) |>
  dplyr::relocate(
    .data$engine
  ) |>
  tidyr::pivot_wider(
    names_from = engine,
    values_from = value
  ) |>
  dplyr::mutate(
    difference_isda_minus_midpoint = .data$ISDA -
      .data$MidPoint
  )

```



```
GaussQuant::show_tbl_GQH(
  engine_comparison_tbl,
  "MidPoint and ISDA CDS engine comparison",
  n = 20
)
#> # A tibble: 4 x 4
#>   metric           MidPoint      ISDA difference_isda_minus_midpoint
#>   <chr>           <dbl>         <dbl>                                <dbl>
#> 1 npv            -334951.      -334963.                        -1.17e+1
#> 2 fair_spread      0.00304        0.00304                        -7.66e-8
#> 3 coupon_leg_npv -498380.      -498392.                        -1.15e+1
#> 4 default_leg_npv 146486.        146485.                        -1.94e-1
```

MidPoint 法は、各 Premium 期間内のデフォルト時点を期間中点へ集約する。ISDA Engine は標準市場規約に合わせて、より詳細な日付処理と積分を行う。そのため、同じカーブを用いても Leg NPV と Fair Spread に差が生じる。

8.7 まとめ

CDS は、Premium Leg と Protection Leg から構成される。プロテクション買い手は Premium を支払い、信用事由が発生した場合に損失補償を受け取る。

Hazard Rate は、企業がその時点まで存続しているという条件の下での瞬時的なデフォルト強度である。フラット Hazard Rate では、生存確率は次式で表される。

$$Q(t) = e^{-\lambda t}$$

Recovery Rate R を仮定すると、CDS Spread と Hazard Rate には、

$$\lambda \approx \frac{s}{1-R}$$

という近似関係がある。ただし、厳密な Hazard Rate は、Premium 支払日、割引、Accrual on default および標準 CDS 規約を反映して推定する。

Premium Leg の単位 Spread 当たり現在価値が Risky PV01 であり、Fair Spread は Protection Leg の単位 Notional 価値を Risky PV01 で割って求められる。

MidPoint Engine は、デフォルト時点を各期間の中点で近似するため、CDS 評価の構造を理解しやすい。ISDA Engine は、標準 CDS2015 の日付、Accrual rebate、Accrual on default および市場規約をより厳密に扱う。

標準 Coupon と市場 Spread が異なる場合、Running Coupon だけでは契約価値がゼロにならない。この差を契約開始時に調整するものが Fair Upfront である。

```

chapter08_summary_tbl <- tibble::tribble(
  ~section,          ~main_result,
  "Hazard Rate",     "Survival and cumulative default probabilities",
  "MidPoint CDS",    "Premium and protection leg decomposition",
  "Hazard calibration", "Zero-NPV market CDS",
  "CDS2015",         "Standard maturity and coupon schedule",
  "ISDA CDS",        "Fair spread, upfront, and accrual rebate",
  "Engine comparison", "MidPoint approximation versus ISDA pricing"
)

GaussQuant::show_tbl_GQH(
  chapter08_summary_tbl,
  "Chapter II-8 summary",
  n = 20
)

#> # A tibble: 6 x 2
#>   section          main_result
#>   <chr>           <chr>
#> 1 Hazard Rate     Survival and cumulative default probabilities
#> 2 MidPoint CDS    Premium and protection leg decomposition
#> 3 Hazard calibration Zero-NPV market CDS
#> 4 CDS2015        Standard maturity and coupon schedule
#> 5 ISDA CDS       Fair spread, upfront, and accrual rebate
#> 6 Engine comparison MidPoint approximation versus ISDA pricing

cat(
  "\nChapter II-8 Credit risk and CDS completed successfully.\n"
)

#>
#> Chapter II-8 Credit risk and CDS completed successfully.

```

第 II-9 章エキゾチック・デリバティブと PRDC

これまでの章では、債券、金利先物、Swap、Option、Callable Bond および CDS を、それぞれの主要なリスク要因に基づいて評価した。本章では、第 II 部の締めくくりとして、金利と為替を組み合わせたエキゾチック・デリバティブである PRDC を検討する。

PRDC (Power Reverse Dual Currency Note) は、為替レートに連動する Coupon を支払う長期の仕組債である。典型的な Coupon rate は、次の形で表される。

$$C(S_t) = \min \left[C_{\max}, \max \left(a \frac{S_t}{S_0} - b, C_{\min} \right) \right]$$

ここで、

- S_t は Coupon 決定日における為替レート
- S_0 は Coupon 計算上の基準為替レート
- a は為替連動係数
- b は固定控除率
- $C_{\min}$ は Coupon Floor
- $C_{\max}$ は Coupon Cap

である。

為替レートが上昇すると Coupon rate は増加するが、Floor と Cap によって下限と上限が制限される。したがって、PRDC Coupon は FX Spot に対して区分線形である一方、将来価値は為替分布に依存する非線形商品となる。

本章では、Domestic 金利、Foreign 金利および FX volatility を一定とする Garman–Kohlhagen モデルを用いて、将来の Coupon 日ごとに FX パスを生成する。各パスで Coupon を計算し、その平均値から Coupon Leg と Redemption Leg の現在価値を求める。

実際の PRDC には、発行体の期限前償還権を含むことが多い。本章では商品の基本構造を明確にするため、**発行体コール権を含まない非 Callable PRDC** を評価する。Callable PRDC には、金利・為替の複数因子モデル、相関構造および Least-Squares Monte Carlo などが追加が必要となる。

```
knitr::opts_chunk$set(  
  collapse = TRUE,  
  comment = "#>",  
  warning = FALSE,  
  message = FALSE  
)  
  
suppressPackageStartupMessages({  
  library(tidyverse)  
  library(ggthemes)  
  library(QuantLib)  
  library(GaussQuant)  
  library(tidyverse)  
  library(broom)  
})
```

9.1 PRDC の商品構造と市場条件

9.1.1 商品条件

2015 年 9 月 3 日から 2041 年 9 月 3 日まで、半年ごとに Coupon を支払う PRDC を考える。最初の 1 年間は固定 Coupon とし、その後は FX 連動 Coupon へ移行する。

評価日は 2023 年 4 月 11 日であるため、固定 Intro Coupon 期間はすでに終了している。ただし、GaussQuant の PRDC 評価関数が Intro Coupon を扱えることを確認するため、契約条件として残す。

本章では、計算時間を抑えながら Monte Carlo 評価を確認するため、基準評価のパス数を 3,000 本、感応度評価を 1,000 本とする。

```
valuation_date_prdc <- as.Date("2023-04-11")  
effective_date_prdc <- as.Date("2015-09-03")  
termination_date_prdc <- as.Date("2041-09-03")  
intro_coupon_end_date_prdc <- as.Date("2016-09-03")  
  
notional_prdc <- 300000000  
intro_coupon_rate_prdc <- 0.022  
coupon_frequency_months_prdc <- 6L  
  
domestic_rate_prdc <- 0.01  
foreign_rate_prdc <- 0.03  
discount_rate_prdc <- 0.005  
  
fx_spot_prdc <- 133.2681  
fx_volatility_prdc <- 0.10
```

```

coupon_fx_base_prdc <- 120
coupon_leverage_prdc <- 0.122
coupon_subtraction_prdc <- 0.10
coupon_floor_prdc <- 0
coupon_cap_prdc <- 0.022

number_of_paths_prdc <- 3000L
sensitivity_paths_prdc <- 1000L
random_seed_prdc <- 123L

GaussQuant::set_eval_date_GQL(
  valuation_date_prdc
)

prdc_input_tbl <- tibble::tribble(
  ~input,          ~value,
  "valuation_date", as.character(valuation_date_prdc),
  "effective_date", as.character(effective_date_prdc),
  "termination_date", as.character(termination_date_prdc),
  "intro_coupon_end_date", as.character(intro_coupon_end_date_prdc),
  "notional_jpy", as.character(notional_prdc),
  "intro_coupon_rate", as.character(intro_coupon_rate_prdc),
  "coupon_frequency_months", as.character(coupon_frequency_months_prdc),
  "domestic_rate", as.character(domestic_rate_prdc),
  "foreign_rate", as.character(foreign_rate_prdc),
  "discount_rate", as.character(discount_rate_prdc),
  "fx_spot", as.character(fx_spot_prdc),
  "fx_volatility", as.character(fx_volatility_prdc),
  "coupon_fx_base", as.character(coupon_fx_base_prdc),
  "coupon_leverage", as.character(coupon_leverage_prdc),
  "coupon_subtraction", as.character(coupon_subtraction_prdc),
  "coupon_floor", as.character(coupon_floor_prdc),
  "coupon_cap", as.character(coupon_cap_prdc),
  "valuation_paths", as.character(number_of_paths_prdc),
  "sensitivity_paths", as.character(sensitivity_paths_prdc),
  "random_seed", as.character(random_seed_prdc)
)

GaussQuant::show_tbl_GQH(
  prdc_input_tbl,
  "PRDC product and model assumptions",
  n = 30
)

```

```

#> # A tibble: 20 x 2
#>   input          value
#>   <chr>         <chr>
#> 1 valuation_date 2023-04-11
#> 2 effective_date 2015-09-03
#> 3 termination_date 2041-09-03
#> 4 intro_coupon_end_date 2016-09-03
#> 5 notional_jpy 3e+08
#> 6 intro_coupon_rate 0.022
#> 7 coupon_frequency_months 6
#> 8 domestic_rate 0.01
#> 9 foreign_rate 0.03
#> 10 discount_rate 0.005
#> 11 fx_spot 133.2681
#> 12 fx_volatility 0.1
#> 13 coupon_fx_base 120
#> 14 coupon_leverage 0.122
#> 15 coupon_subtraction 0.1
#> 16 coupon_floor 0
#> 17 coupon_cap 0.022
#> 18 valuation_paths 3000
#> 19 sensitivity_paths 1000
#> 20 random_seed 123

```

9.1.2 Coupon Schedule

契約開始日から満期までの全 Coupon Schedule と、固定 Intro Coupon 期間の Schedule を作成する。

```

valuation_date_ql_prdc <- GaussQuant::date_GQL(
  valuation_date_prdc
)

effective_date_ql_prdc <- GaussQuant::date_GQL(
  effective_date_prdc
)

termination_date_ql_prdc <- GaussQuant::date_GQL(
  termination_date_prdc
)

intro_coupon_end_date_ql_prdc <- GaussQuant::date_GQL(
  intro_coupon_end_date_prdc
)

```

```

coupon_schedule_prdc <- QuantLib::Schedule(
  effective_date_ql_prdc,
  termination_date_ql_prdc,
  GaussQuant::period_months_GQL(
    coupon_frequency_months_prdc
  ),
  QuantLib::TARGET(),
  "ModifiedFollowing",
  "ModifiedFollowing",
  "Backward",
  FALSE
)

intro_coupon_schedule_prdc <- QuantLib::Schedule(
  effective_date_ql_prdc,
  intro_coupon_end_date_ql_prdc,
  GaussQuant::period_months_GQL(
    coupon_frequency_months_prdc
  ),
  QuantLib::TARGET(),
  "ModifiedFollowing",
  "ModifiedFollowing",
  "Backward",
  FALSE
)

coupon_schedule_tbl <- GaussQuant::schedule_table_GQL(
  coupon_schedule_prdc
)

intro_coupon_dates_prdc <- GaussQuant::schedule_date_vector_GQL(
  intro_coupon_schedule_prdc
)

remaining_intro_coupon_dates_prdc <- intro_coupon_dates_prdc[
  intro_coupon_dates_prdc >
  valuation_date_prdc
]

intro_coupon_status_tbl <- tibble::tribble(
  ~metric, ~value,
  "intro_coupon_rate", intro_coupon_rate_prdc,
  "total_intro_schedule_dates", length(intro_coupon_dates_prdc),

```

```

    "remaining_intro_coupon_dates", length(remaining_intro_coupon_dates_prdc),
    "has_remaining_intro_coupon",   as.numeric(
                                      length(
                                          remaining_intro_coupon_dates_prdc
                                      ) > 0
                                )
)

GaussQuant::show_tbl_GQH(
  coupon_schedule_tbl,
  "PRDC full coupon schedule",
  n = 60
)

#> # A tibble: 53 x 2
#>   period schedule_date
#>   <int> <date>
#> 1     1 2015-09-03
#> 2     2 2016-03-03
#> 3     3 2016-09-05
#> 4     4 2017-03-03
#> 5     5 2017-09-04
#> 6     6 2018-03-05
#> 7     7 2018-09-03
#> 8     8 2019-03-04
#> 9     9 2019-09-03
#> 10    10 2020-03-03
#> # i 43 more rows

GaussQuant::show_tbl_GQH(
  intro_coupon_status_tbl,
  "PRDC introductory coupon status",
  n = 20
)

#> # A tibble: 4 x 2
#>   metric                                value
#>   <chr>                                <dbl>
#> 1 intro_coupon_rate                    0.022
#> 2 total_intro_schedule_dates            3
#> 3 remaining_intro_coupon_dates          0
#> 4 has_remaining_intro_coupon            0

```


9.1.3 Domestic、Foreign および Discount Curve

FX Quote を、外国通貨 1 単位当たりの円貨額として表す。

$$S_t = \text{JPY per unit of foreign currency}$$

このとき、

- Domestic Curve は JPY 金利
- Foreign Curve は外国通貨金利

である。

Garman–Kohlhagen モデルのリスク中立ドリフトには、Domestic 金利と Foreign 金利の差を使用する。

$$\frac{dS_t}{S_t} = (r_d - r_f)dt + \sigma_{FX}dW_t$$

本例では、Domestic 金利を 1%、Foreign 金利を 3% とする。そのため、リスク中立測度の下での FX ドリフトは年率マイナス 2% となる。

Coupon と元本の現在価値には、担保またはファンディング条件を表す外生的な割引率 0.5% を使用する。これは簡略化した設定であり、本格的な評価では Domestic OIS Curve と Collateral 条件を整合させる必要がある。

```
fx_day_counter_prdc <- QuantLib::Actual360()

domestic_curve_prdc <- GaussQuant::flat_curve_GQL(
  reference_date = valuation_date_ql_prdc,
  rate = domestic_rate_prdc,
  day_counter = fx_day_counter_prdc,
  compounding = "Continuous"
)

foreign_curve_prdc <- GaussQuant::flat_curve_GQL(
  reference_date = valuation_date_ql_prdc,
  rate = foreign_rate_prdc,
  day_counter = fx_day_counter_prdc,
  compounding = "Continuous"
)

discount_curve_prdc <- GaussQuant::flat_curve_GQL(
  reference_date = valuation_date_ql_prdc,
  rate = discount_rate_prdc,
  day_counter = fx_day_counter_prdc,
```

```

    compounding = "Continuous"
  )

  domestic_curve_handle_prdc <- QuantLib::YieldTermStructureHandle(
    domestic_curve_prdc
  )

  foreign_curve_handle_prdc <- QuantLib::YieldTermStructureHandle(
    foreign_curve_prdc
  )

  discount_curve_handle_prdc <- QuantLib::YieldTermStructureHandle(
    discount_curve_prdc
  )

  curve_summary_tbl <- tibble::tribble(
    ~curve,          ~flat_rate,
    "Domestic FX curve", domestic_rate_prdc,
    "Foreign FX curve", foreign_rate_prdc,
    "PRDC discount curve", discount_rate_prdc,
    "FX risk-neutral drift", domestic_rate_prdc -
      foreign_rate_prdc
  )

  GaussQuant::show_tbl_GQH(
    curve_summary_tbl,
    "PRDC flat-curve assumptions",
    n = 20
  )

#> # A tibble: 4 x 2
#>   curve          flat_rate
#>   <chr>          <dbl>
#> 1 Domestic FX curve      0.01
#> 2 Foreign FX curve      0.03
#> 3 PRDC discount curve   0.005
#> 4 FX risk-neutral drift -0.02

```

9.2 FX プロセスと Coupon Payoff

9.2.1 FX Process

FX volatility を 10% とし、Garman–Kohlhagen Process を作成する。

```

fx_volatility_curve_prdc <- QuantLib::BlackConstantVol(
  valuation_date_ql_prdc,
  QuantLib::NullCalendar(),
  GaussQuant::quote_handle_GQL(
    fx_volatility_prdc
  ),
  fx_day_counter_prdc
)

fx_volatility_handle_prdc <- QuantLib::BlackVolTermStructureHandle(
  fx_volatility_curve_prdc
)

fx_process_prdc <- GaussQuant::fx_process_GQL(
  spot = fx_spot_prdc,
  foreign_curve_handle = foreign_curve_handle_prdc,
  domestic_curve_handle = domestic_curve_handle_prdc,
  volatility_handle = fx_volatility_handle_prdc
)

fx_market_summary_tbl <- tibble::tribble(
  ~metric,          ~value,
  "fx_spot",        fx_spot_prdc,
  "fx_volatility",   fx_volatility_prdc,
  "domestic_rate",   domestic_rate_prdc,
  "foreign_rate",    foreign_rate_prdc,
  "risk_neutral_drift", domestic_rate_prdc -
                      foreign_rate_prdc
)

GaussQuant::show_tbl_GQH(
  fx_market_summary_tbl,
  "PRDC FX market assumptions",
  n = 20
)

#> # A tibble: 5 x 2
#>   metric          value
#>   <chr>          <dbl>
#> 1 fx_spot        133.
#> 2 fx_volatility    0.1
#> 3 domestic_rate    0.01
#> 4 foreign_rate     0.03
#> 5 risk_neutral_drift -0.02

```

9.2.2 Coupon Payoff

本例の FX 連動 Coupon は次式である。

$$C(S) = \min \left[2.2\%, \max \left(12.2\% \frac{S}{120} - 10\%, 0 \right) \right]$$

Floor に到達する FX 水準は、

$$S_{\text{floor}} = S_0 \frac{b + C_{\min}}{a}$$

Cap に到達する FX 水準は、

$$S_{\text{cap}} = S_0 \frac{b + C_{\max}}{a}$$

である。

```
fx_floor_threshold_prdc <- coupon_fx_base_prdc *
(
  coupon_subtraction_prdc +
  coupon_floor_prdc
) /
coupon_leverage_prdc

fx_cap_threshold_prdc <- coupon_fx_base_prdc *
(
  coupon_subtraction_prdc +
  coupon_cap_prdc
) /
coupon_leverage_prdc

fx_payoff_grid_tbl <- tibble::tibble(
  fx_rate = seq(
    70,
    180,
    by = 2
  )
) |>
dplyr::mutate(
  uncapped_coupon = coupon_leverage_prdc *
    .data$fx_rate /
    coupon_fx_base_prdc -
    coupon_subtraction_prdc,
```

```

    coupon_rate = GaussQuant::prdc_coupon_GQL(
      fx_rate = .data$fx_rate,
      fx_base = coupon_fx_base_prdc,
      leverage = coupon_leverage_prdc,
      subtraction = coupon_subtraction_prdc,
      floor_rate = coupon_floor_prdc,
      cap_rate = coupon_cap_prdc
    )
  )

coupon_threshold_tbl <- tibble::tribble(
  ~threshold,      ~fx_rate,
  "floor_threshold", fx_floor_threshold_prdc,
  "cap_threshold",  fx_cap_threshold_prdc,
  "current_spot",   fx_spot_prdc
)

prdc_payoff_plot <- ggplot2::ggplot(
  fx_payoff_grid_tbl,
  ggplot2::aes(
    x = .data$fx_rate,
    y = .data$coupon_rate
  )
) +
  ggplot2::geom_line(
    linewidth = 0.8
  ) +
  ggplot2::geom_vline(
    xintercept = c(
      fx_floor_threshold_prdc,
      fx_cap_threshold_prdc
    ),
    linetype = "dashed"
  ) +
  ggplot2::scale_y_continuous(
    labels = scales::percent_format(
      accuracy = 0.1
    )
  ) +
  ggplot2::labs(
    title = "PRDC coupon payoff",
    subtitle = "Floored and capped FX-linked coupon",
    x = "FX rate",

```

```


    y = "Coupon rate"
  ) +
  ggplot2::theme_minimal()

GaussQuant::show_tbl_GQH(
  coupon_threshold_tbl,
  "PRDC coupon FX thresholds",
  n = 20
)
#> # A tibble: 3 x 2
#>   threshold      fx_rate
#>   <chr>          <dbl>
#> 1 floor_threshold    98.4
#> 2 cap_threshold     120
#> 3 current_spot      133.

GaussQuant::show_tbl_GQH(
  fx_payoff_grid_tbl,
  "PRDC coupon payoff table",
  n = 60
)
#> # A tibble: 56 x 3
#>   fx_rate uncapped_coupon coupon_rate
#>   <dbl>      <dbl>      <dbl>
#> 1     70      -0.0288         0
#> 2     72      -0.0268         0
#> 3     74      -0.0248         0
#> 4     76      -0.0227         0
#> 5     78      -0.0207         0
#> 6     80      -0.0187         0
#> 7     82      -0.0166         0
#> 8     84      -0.0146         0
#> 9     86      -0.0126         0
#> 10    88      -0.0105         0
#> # i 46 more rows

print(prdc_payoff_plot)

```



現在の FX Spot は Cap 到達水準を上回っているため、評価時点の Coupon 式だけを見れば Cap に張り付いている。しかし、満期までの FX 分布には Floor、Linear 領域および Cap 領域のすべてが含まれ得る。

9.3 Monte Carlo による PRDC 評価

9.3.1 Coupon 日ベースの FX 時間グリッド

PRDC 評価に必要なのは、評価日より後に到来する Coupon 日である。GaussQuant の `fx_path_generator_GQL()` は、実際の Coupon 日を用いて不均一な時間間隔を保持する。

```
fx_path_generator_prdc <- GaussQuant::fx_path_generator_GQL(
  valuation_date = valuation_date_prdc,
  coupon_schedule = coupon_schedule_prdc,
  day_counter = fx_day_counter_prdc,
  process = fx_process_prdc
)

time_grid_tbl <- tibble::tibble(
  coupon_number = seq_along(
    fx_path_generator_prdc$remaining_coupon_dates
  ),
  coupon_date = fx_path_generator_prdc$remaining_coupon_dates,
  time_from_valuation = fx_path_generator_prdc$coupon_times,
  time_step = fx_path_generator_prdc$time_steps
)

path_generator_summary_tbl <- tibble::tribble(
  ~metric,
  ~value,
```

```

    "remaining_coupon_dates", length(
      fx_path_generator_prdc$remaining_coupon_dates
    ),
    "number_of_steps",      fx_path_generator_prdc$number_of_steps,
    "first_coupon_time",    min(
      fx_path_generator_prdc$coupon_times
    ),
    "final_coupon_time",    max(
      fx_path_generator_prdc$coupon_times
    )
  )

```

```

GaussQuant::show_tbl_GQH(
  path_generator_summary_tbl,
  "PRDC FX path-generator summary",
  n = 20
)

```

```

#> # A tibble: 4 x 2
#>   metric      value
#>   <chr>      <dbl>
#> 1 remaining_coupon_dates 37
#> 2 number_of_steps      37
#> 3 first_coupon_time     0.406
#> 4 final_coupon_time    18.7

```

```

GaussQuant::show_tbl_GQH(
  time_grid_tbl,
  "PRDC remaining coupon-date time grid",
  n = 60
)

```

```

#> # A tibble: 37 x 4
#>   coupon_number coupon_date time_from_valuation time_step
#>   <int> <date>          <dbl>      <dbl>
#> 1      1 2023-09-04      0.406      0.406
#> 2      2 2024-03-04      0.911      0.506
#> 3      3 2024-09-03      1.42       0.508
#> 4      4 2025-03-03      1.92       0.503
#> 5      5 2025-09-03      2.43       0.511
#> 6      6 2026-03-03      2.94       0.503
#> 7      7 2026-09-03      3.45       0.511
#> 8      8 2027-03-03      3.95       0.503
#> 9      9 2027-09-03      4.46       0.511
#> 10     10 2028-03-03      4.97       0.506

```



```
#> # i 27 more rows
```

QuantLib の `StochasticProcess1D$evolve()` へは標準正規変量を渡す。Brownian increment を外側で二重に時間調整してはならない。GaussQuant の Path Generator では、標準正規乱数と各 Coupon 間の実際の時間差を分けて処理している。

9.3.2 サンプル FX パス

Monte Carlo 評価へ進む前に、20 本の FX パスを生成し、将来の FX 分布と Coupon の動きを確認する。

```
sample_path_count_prdc <- 20L

sample_fx_path_matrix_prdc <- GaussQuant::prdc_path_matrix_GQL(
  path_generator = fx_path_generator_prdc,
  n_paths = sample_path_count_prdc,
  seed = random_seed_prdc
)

sample_fx_path_tbl <- purrr::map_dfr(
  seq_len(
    ncol(sample_fx_path_matrix_prdc)
  ),
  function(path_id) {
    path_values <- sample_fx_path_matrix_prdc[
      ,
      path_id
    ]

    tibble::tibble(
      path_id = path_id,
      coupon_number = seq_along(
        path_values
      ),
      coupon_date = fx_path_generator_prdc$remaining_coupon_dates,
      time = fx_path_generator_prdc$coupon_times,
      fx_rate = path_values,
      coupon_rate = GaussQuant::prdc_coupon_GQL(
        fx_rate = path_values,
        fx_base = coupon_fx_base_prdc,
        leverage = coupon_leverage_prdc,
        subtraction = coupon_subtraction_prdc,
        floor_rate = coupon_floor_prdc,
        cap_rate = coupon_cap_prdc
      )
    )
  }
)
```

```

    )
  }
)


sample_fx_path_plot <- ggplot2::ggplot(
  sample_fx_path_tbl,
  ggplot2::aes(
    x = .data$time,
    y = .data$fx_rate,
    group = .data$path_id
  )
) +
  ggplot2::geom_line(
    linewidth = 0.5,
    alpha = 0.7
  ) +
  ggplot2::labs(
    title = "Sample FX paths for PRDC valuation",
    x = "Time from valuation date (years)",
    y = "FX rate"
  ) +
  ggplot2::theme_minimal()

GaussQuant::show_tbl_GQH(
  sample_fx_path_tbl,
  "Sample PRDC FX and coupon paths",
  n = 40
)

#> # A tibble: 40 x 6
#>   path_id coupon_number coupon_date   time fx_rate coupon_rate
#>   <int>         <int> <date>     <dbl>   <dbl>         <dbl>
#> 1         1           1 2023-09-04 0.406    127.          0.022
#> 2         1           2 2024-03-04 0.911    124.          0.022
#> 3         1           3 2024-09-03 1.42     136.          0.022
#> 4         1           4 2025-03-03 1.92     135.          0.022
#> 5         1           5 2025-09-03 2.43     135.          0.022
#> 6         1           6 2026-03-03 2.94     150.          0.022
#> 7         1           7 2026-09-03 3.45     154.          0.022
#> 8         1           8 2027-03-03 3.95     139.          0.022
#> 9         1           9 2027-09-03 4.46     130.          0.022
#> 10        1          10 2028-03-03 4.97     125.          0.022
#> # i 30 more rows

```

```
print(sample_fx_path_plot)
```



9.3.3 PRDC の現在価値

各 Coupon 日の期待 Coupon rate は、Monte Carlo によって次のように近似する。

$$E[C(S_{t_i})] \approx \frac{1}{M} \sum_{j=1}^M C(S_{t_i}^{(j)})$$

ここで、 M はパス数、 $S_{t_i}^{(j)}$ はパス j における Coupon 日 t_i の FX Rate である。

各 Coupon cash flow は、

$$CF_i = N_0 \alpha_i E[C(S_{t_i})]$$

であり、PRDC 現在価値は、

$$PV_{\text{PRDC}} = \sum_i D(0, t_i) CF_i + D(0, T) N_0$$

となる。

```
prdc_result <- GaussQuant::prdc_npv_GQL(
  valuation_date = valuation_date_prdc,
  coupon_schedule = coupon_schedule_prdc,
  process = fx_process_prdc,
  discount_curve = discount_curve_prdc,
  notional = notional_prdc,
```

```

fx_base = coupon_fx_base_prdc,
leverage = coupon_leverage_prdc,
subtraction = coupon_subtraction_prdc,
floor_rate = coupon_floor_prdc,
cap_rate = coupon_cap_prdc,
day_counter = fx_day_counter_prdc,
intro_coupon_dates = intro_coupon_dates_prdc,
intro_coupon_rate = intro_coupon_rate_prdc,
n_paths = number_of_paths_prdc,
seed = random_seed_prdc,
redemption_amount = notional_prdc,
return_details = TRUE
)

fx_path_matrix_prdc <- prdc_result$path_matrix
expected_coupon_tbl <- prdc_result$expected_coupon
prdc_cashflow_tbl <- prdc_result$cashflows

coupon_leg_present_value_prdc <- prdc_result$summary |>
  dplyr::filter(
    .data$metric == "coupon_leg_npv"
  ) |>
  dplyr::pull(
    value
  )

redemption_present_value_prdc <- prdc_result$summary |>
  dplyr::filter(
    .data$metric == "redemption_leg_npv"
  ) |>
  dplyr::pull(
    value
  )

prdc_present_value_jpy <- prdc_result$npv

prdc_valuation_summary_tbl <- tibble::tribble(
  ~metric,                ~value,
  "coupon_leg_pv_jpy",    coupon_leg_present_value_prdc,
  "redemption_leg_pv_jpy", redemption_present_value_prdc,
  "total_pv_jpy",        prdc_present_value_jpy,
  "pv_as_percent_of_notional", prdc_present_value_jpy /
    notional_prdc,

```

```

    "number_of_paths",      number_of_paths_prdc,
    "number_of_coupon_steps", nrow(
                                fx_path_matrix_prdc
                                )
  )

GaussQuant::show_tbl_GQH(
  prdc_valuation_summary_tbl,
  "PRDC Monte Carlo valuation summary",
  n = 20
)

#> # A tibble: 6 x 2
#>   metric                                value
#>   <chr>                                <dbl>
#> 1 coupon_leg_pv_jpy                    61290348.
#> 2 redemption_leg_pv_jpy                273266946.
#> 3 total_pv_jpy                         334557294.
#> 4 pv_as_percent_of_notional            1.12
#> 5 number_of_paths                       3000
#> 6 number_of_coupon_steps                37

```

本章の元本償還額は固定されているため、Redemption Leg は割引率に依存するが FX には依存しない。FX Spot と FX volatility の影響は、主に Coupon Leg を通じて現れる。

9.3.4 期待 Coupon とキャッシュフロー

```

expected_coupon_display_tbl <- expected_coupon_tbl |>
  dplyr::select(
    coupon_number,
    coupon_date,
    time,
    expected_fx,
    expected_coupon_rate,
    is_intro_coupon,
    final_coupon_rate
  )

prdc_cashflow_display_tbl <- prdc_cashflow_tbl |>
  dplyr::select(
    coupon_number,
    accrual_start,
    accrual_end,
    final_coupon_rate,

```

```

    accrual_fraction,
    coupon_amount,
    redemption_amount,
    total_amount,
    discount_factor,
    total_present_value
)

GaussQuant::show_tbl_GQH(
  expected_coupon_display_tbl,
  "PRDC expected FX and coupon rates",
  n = 60
)

#> # A tibble: 37 x 7
#>   coupon_number coupon_date   time expected_fx expected_coupon_rate
#>       <int> <date>       <dbl>      <dbl>              <dbl>
#> 1           1 2023-09-04  0.406      132.              0.0218
#> 2           2 2024-03-04  0.911      131.              0.0208
#> 3           3 2024-09-03  1.42       130.              0.0196
#> 4           4 2025-03-03  1.92       128.              0.0185
#> 5           5 2025-09-03  2.43       127.              0.0176
#> 6           6 2026-03-03  2.94       126.              0.0168
#> 7           7 2026-09-03  3.45       124.              0.0161
#> 8           8 2027-03-03  3.95       123.              0.0153
#> 9           9 2027-09-03  4.46       122.              0.0147
#> 10          10 2028-03-03  4.97       121.              0.0140
#> # i 27 more rows
#> # i 2 more variables: is_intro_coupon <lgl>, final_coupon_rate <dbl>

GaussQuant::show_tbl_GQH(
  prdc_cashflow_display_tbl,
  "PRDC expected cash-flow table",
  n = 60
)

#> # A tibble: 37 x 10
#>   coupon_number accrual_start accrual_end final_coupon_rate accrual_fraction
#>       <int> <date>       <date>      <dbl>              <dbl>
#> 1           1 2023-03-03   2023-09-04      0.0218              0.514
#> 2           2 2023-09-04   2024-03-04      0.0208              0.506
#> 3           3 2024-03-04   2024-09-03      0.0196              0.508
#> 4           4 2024-09-03   2025-03-03      0.0185              0.503
#> 5           5 2025-03-03   2025-09-03      0.0176              0.511
#> 6           6 2025-09-03   2026-03-03      0.0168              0.503

```

```
#> 7          7 2026-03-03    2026-09-03          0.0161          0.511
#> 8          8 2026-09-03    2027-03-03          0.0153          0.503
#> 9          9 2027-03-03    2027-09-03          0.0147          0.511
#> 10         10 2027-09-03    2028-03-03          0.0140          0.506
#> # i 27 more rows
#> # i 5 more variables: coupon_amount <dbl>, redemption_amount <dbl>,
#> #   total_amount <dbl>, discount_factor <dbl>, total_present_value <dbl>
```


長期の FX 期待値は Domestic 金利と Foreign 金利の差の影響を受ける。本例では Foreign 金利が Domestic 金利より高いため、リスク中立測度の下では FX Rate に下向きのドリフトが働く。その結果、満期が長くなるほど Cap 領域から Linear 領域または Floor 領域へ移る確率が高くなる。

9.4 Coupon の期間構造と分布

9.4.1 期待 Coupon の期間構造

```
expected_coupon_plot <- ggplot2::ggplot(
  expected_coupon_tbl,
  ggplot2::aes(
    x = .data$time,
    y = .data$final_coupon_rate
  )
) +
  ggplot2::geom_line(
    linewidth = 0.8
  ) +
  ggplot2::geom_point(
    size = 1.8
  ) +
  ggplot2::scale_y_continuous(
    labels = scales::percent_format(
      accuracy = 0.1
    )
  ) +
  ggplot2::labs(
    title = "Expected PRDC coupon rates",
    subtitle = "Monte Carlo expectation at each future coupon date",
    x = "Time from valuation date (years)",
    y = "Expected coupon rate"
  ) +
  ggplot2::theme_minimal()

print(expected_coupon_plot)
```



期待 Coupon は、単に期待 FX を Coupon 式へ代入した値とは一般に一致しない。

$$E[C(S_t)] \neq C(E[S_t])$$

Cap と Floor を含む非線形 Payoff では、FX 分布全体を考慮する必要がある。

9.4.2 Coupon Cap / Floor 到達確率

各 Coupon 日について、シミュレーションされた Coupon が Floor または Cap に到達する確率を計算する。

```
coupon_cap_floor_probability_tbl <- GaussQuant::prdc_cap_floor_probability_GQL(
  path_matrix = fx_path_matrix_prdc,
  fx_base = coupon_fx_base_prdc,
  leverage = coupon_leverage_prdc,
  subtraction = coupon_subtraction_prdc,
  floor_rate = coupon_floor_prdc,
  cap_rate = coupon_cap_prdc,
  coupon_dates = fx_path_generator_prdc$remaining_coupon_dates,
  coupon_times = fx_path_generator_prdc$coupon_times
)

GaussQuant::show_tbl_GQH(
  coupon_cap_floor_probability_tbl,
  "PRDC coupon floor and cap probabilities",
  n = 60
)

#> # A tibble: 37 x 6
```



```
#> coupon_number floor_probability cap_probability interior_probability
#>      <int>          <dbl>          <dbl>          <dbl>
#>  1         1          0          0.931          0.0687
#>  2         2      0.000667          0.803          0.197
#>  3         3      0.0137          0.722          0.265
#>  4         4      0.0347          0.653          0.312
#>  5         5      0.0633          0.615          0.322
#>  6         6      0.0917          0.581          0.327
#>  7         7      0.118          0.546          0.336
#>  8         8      0.150          0.523          0.327
#>  9         9      0.175          0.493          0.332
#> 10        10      0.205          0.465          0.330
#> # i 27 more rows
#> # i 2 more variables: coupon_date <date>, time <dbl>
```

Cap 確率、Linear 領域の確率および Floor 確率は、長期的な Coupon の性質を直接示す。現在の Spot が Cap 水準を上回っていても、長期 Coupon が常に Cap へ固定されるとは限らない。

9.4.3 Coupon 分布

短期、中期、長期の代表的な Coupon 日について、Coupon rate の分布を比較する。

```
coupon_path_matrix_prdc <- GaussQuant::prdc_coupon_GQL(
  fx_rate = fx_path_matrix_prdc,
  fx_base = coupon_fx_base_prdc,
  leverage = coupon_leverage_prdc,
  subtraction = coupon_subtraction_prdc,
  floor_rate = coupon_floor_prdc,
  cap_rate = coupon_cap_prdc
)

number_of_coupon_steps_prdc <- nrow(
  coupon_path_matrix_prdc
)

distribution_coupon_ids <- unique(
  pmax(
    1L,
    pmin(
      number_of_coupon_steps_prdc,
      c(
        1L,
        round(
          number_of_coupon_steps_prdc /
```

```

      2
    ),
    number_of_coupon_steps_prdc
  )
)
)
)

coupon_distribution_tbl <- purrr::map_dfr(
  distribution_coupon_ids,
  function(coupon_id) {
    tibble::tibble(
      coupon_number = coupon_id,
      coupon_date = as.character(
        fx_path_generator_prdc$remaining_coupon_dates[
          coupon_id
        ]
      ),
      coupon_rate = coupon_path_matrix_prdc[
        coupon_id,
      ]
    )
  }
)

coupon_distribution_plot <- ggplot2::ggplot(
  coupon_distribution_tbl,
  ggplot2::aes(
    x = .data$coupon_rate
  )
) +
  ggplot2::geom_histogram(
    bins = 30,
    linewidth = 0.3
  ) +
  ggplot2::facet_wrap(
    ~coupon_date,
    scales = "free_y"
  ) +
  ggplot2::scale_x_continuous(
    labels = scales::percent_format(
      accuracy = 0.1
    )
  )


```

```

) +
  ggplot2::labs(
    title = "Simulated PRDC coupon distributions",
    x = "Coupon rate",
    y = "Path count"
  ) +
  ggplot2::theme_minimal()

print(coupon_distribution_plot)

```



Coupon 分布は連続的な正規分布または対数正規分布ではない。Floor と Cap に確率質量が集まり、その間に Linear 領域の連続分布が存在する。

9.5 FX 感応度と Monte Carlo 誤差

9.5.1 FX Spot 感応度

PRDC Coupon は FX Spot へ直接依存する。Spot を上下させたシナリオを比較する。

各シナリオで同じ乱数 Seed を使用することにより、Monte Carlo ノイズを抑えた Common Random Numbers 型の比較となる。

```

spot_scenario_input_tbl <- tibble::tribble(
  ~scenario,      ~fx_spot,
  "spot_minus_10", fx_spot_prdc * 0.90,
  "spot_minus_5",  fx_spot_prdc * 0.95,
  "base",          fx_spot_prdc,
  "spot_plus_5",   fx_spot_prdc * 1.05,

```

```

    "spot_plus_10",    fx_spot_prdc * 1.10
  )

spot_sensitivity_tbl <- GaussQuant::prdc_spot_sensitivity_GQL(
  spot_scenarios = spot_scenario_input_tbl,
  valuation_date = valuation_date_prdc,
  coupon_schedule = coupon_schedule_prdc,
  foreign_curve_handle = foreign_curve_handle_prdc,
  domestic_curve_handle = domestic_curve_handle_prdc,
  volatility_handle = fx_volatility_handle_prdc,
  discount_curve = discount_curve_prdc,
  notional = notional_prdc,
  fx_base = coupon_fx_base_prdc,
  leverage = coupon_leverage_prdc,
  subtraction = coupon_subtraction_prdc,
  floor_rate = coupon_floor_prdc,
  cap_rate = coupon_cap_prdc,
  day_counter = fx_day_counter_prdc,
  intro_coupon_dates = intro_coupon_dates_prdc,
  intro_coupon_rate = intro_coupon_rate_prdc,
  n_paths = sensitivity_paths_prdc,
  seed = random_seed_prdc,
  redemption_amount = notional_prdc,
  base_scenario = "base"
)

spot_sensitivity_plot <- ggplot2::ggplot(
  spot_sensitivity_tbl,
  ggplot2::aes(
    x = .data$fx_spot,
    y = .data$prdc_npv
  )
) +
  ggplot2::geom_line(
    linewidth = 0.7
  ) +
  ggplot2::geom_point(
    size = 2.2
  ) +
  ggplot2::labs(
    title = "PRDC FX spot sensitivity",
    x = "FX spot",
    y = "PRDC NPV"
  )

```

```


) +
  ggplot2::theme_minimal()

GaussQuant::show_tbl_GQH(
  spot_sensitivity_tbl,
  "PRDC FX spot sensitivity",
  n = 20
)

#> # A tibble: 5 x 4
#>   scenario      fx_spot  prdc_npv npv_difference_from_base
#>   <chr>         <dbl>    <dbl>          <dbl>
#> 1 spot_minus_10  120. 317016976.        -16325124.
#> 2 spot_minus_5   127. 325687168.        -7654931.
#> 3 base           133. 333342099.             0
#> 4 spot_plus_5    140. 340136016.         6793916.
#> 5 spot_plus_10   147. 346121967.        12779868.

print(spot_sensitivity_plot)

```



Spot 上昇は Coupon を上昇させる方向に働くが、Cap へ到達した後の限界効果は小さくなる。Spot 低下時も、Floor へ到達すると Coupon の低下は止まる。このため、PRDC 価値の Spot 感応度は全域で一定ではない。

9.5.2 FX Volatility 感応度

PRDC Coupon は、Floor と Cap を持つ非線形 Payoff である。そのため、FX volatility の変化は将来の FX 分布だけでなく、Floor、Linear 領域および Cap へ入る確率を変化させる。

```

volatility_scenario_input_tbl <- tibble::tribble(
  ~scenario,      ~fx_volatility,
  "vol_5pct",     0.05,
  "vol_7_5pct",   0.075,
  "base",         fx_volatility_prdc,
  "vol_12_5pct",  0.125,
  "vol_15pct",    0.15
)

volatility_sensitivity_tbl <- GaussQuant::prdc_volatility_sensitivity_GQL(
  volatility_scenarios = volatility_scenario_input_tbl,
  valuation_date = valuation_date_prdc,
  coupon_schedule = coupon_schedule_prdc,
  spot = fx_spot_prdc,
  foreign_curve_handle = foreign_curve_handle_prdc,
  domestic_curve_handle = domestic_curve_handle_prdc,
  discount_curve = discount_curve_prdc,
  notional = notional_prdc,
  fx_base = coupon_fx_base_prdc,
  leverage = coupon_leverage_prdc,
  subtraction = coupon_subtraction_prdc,
  floor_rate = coupon_floor_prdc,
  cap_rate = coupon_cap_prdc,
  day_counter = fx_day_counter_prdc,
  calendar = QuantLib::NullCalendar(),
  intro_coupon_dates = intro_coupon_dates_prdc,
  intro_coupon_rate = intro_coupon_rate_prdc,
  n_paths = sensitivity_paths_prdc,
  seed = random_seed_prdc,
  redemption_amount = notional_prdc,
  base_scenario = "base"
)

volatility_sensitivity_plot <- ggplot2::ggplot(
  volatility_sensitivity_tbl,
  ggplot2::aes(
    x = .data$fx_volatility,
    y = .data$prdc_npv
  )
) +
  ggplot2::geom_line(
    linewidth = 0.7
  ) +

```

```


ggplot2::geom_point(
  size = 2.2
) +
ggplot2::scale_x_continuous(
  labels = scales::percent_format(
    accuracy = 0.1
  )
) +
ggplot2::labs(
  title = "PRDC FX volatility sensitivity",
  x = "FX volatility",
  y = "PRDC NPV"
) +
ggplot2::theme_minimal()

GaussQuant::show_tbl_GQH(
  volatility_sensitivity_tbl,
  "PRDC FX volatility sensitivity",
  n = 20
)

#> # A tibble: 5 x 4
#>   scenario    fx_volatility  prdc_npv npv_difference_from_base
#>   <chr>          <dbl>      <dbl>          <dbl>
#> 1 vol_5pct      0.05  337897654.      4555555.
#> 2 vol_7_5pct    0.075 335766964.      2424865.
#> 3 base          0.1   333342099.         0
#> 4 vol_12_5pct   0.125 330911366.     -2430733.
#> 5 vol_15pct     0.15  328542072.     -4800028.

print(volatility_sensitivity_plot)

```



通常の Option のように「Volatility 上昇は必ず価値上昇」と単純には言えない。PRDC Coupon は Cap 付きの上昇 Payoff であると同時に Floor を持ち、現在の Spot、金利差、満期および各境界への到達確率によって Volatility 感応度が変わる。

9.5.3 Monte Carlo 標準誤差

Monte Carlo 推定値には統計誤差が存在する。各パスについて全 Coupon と Redemption の現在価値を計算し、標本平均、標準偏差、標準誤差および信頼区間を求める。

標準誤差は、パス現在価値の標準偏差を $\hat{\sigma}_{PV}$ 、パス数を M とすると、

$$SE = \frac{\hat{\sigma}_{PV}}{\sqrt{M}}$$

である。

```
monte_carlo_error_result <- GaussQuant::prdc_monte_carlo_error_GQL(
  path_matrix = fx_path_matrix_prdc,
  cashflow_tbl = prdc_cashflow_tbl,
  notional = notional_prdc,
  fx_base = coupon_fx_base_prdc,
  leverage = coupon_leverage_prdc,
  subtraction = coupon_subtraction_prdc,
  floor_rate = coupon_floor_prdc,
  cap_rate = coupon_cap_prdc,
  intro_coupon_dates = intro_coupon_dates_prdc,
  intro_coupon_rate = intro_coupon_rate_prdc,
  confidence_level = 0.95
)
```



```

path_present_value_tbl <- monte_carlo_error_result$path_present_values
monte_carlo_error_tbl <- monte_carlo_error_result$summary

GaussQuant::show_tbl_GQH(
  monte_carlo_error_tbl,
  "PRDC Monte Carlo error estimate",
  n = 20
)
#> # A tibble: 7 x 2
#>   metric                                value
#>   <chr>                                <dbl>
#> 1 number_of_paths                      3000
#> 2 mean_present_value                  334557294.
#> 3 present_value_sd                    36143296.
#> 4 standard_error                      659883.
#> 5 lower_confidence_bound              333263946.
#> 6 upper_confidence_bound              335850641.
#> 7 confidence_level                    0.95

```

パス数を 4 倍にすると、他の条件が同じであれば標準誤差は概ね半分になる。ただし、計算量も増加する。実務では、パス数を増やすだけでなく、Antithetic Variates、Control Variates、Quasi-Monte Carlo などの分散削減法を併用する。

9.6 モデルの限界と Part II 総括

9.6.1 PRDC 評価の限界

本章のモデルは、PRDC の基本的な非線形 Coupon と Monte Carlo 評価を理解するための簡略モデルである。主な制約は次のとおりである。

9.6.2 金利を決定論的とした

Domestic、Foreign および Discount Curve をフラットかつ決定論的とした。実際の長期 PRDC では、Domestic 金利と Foreign 金利の変動が、FX Forward、割引係数および Coupon 価値へ影響する。

9.6.3 FX volatility を一定とした

一定の Black volatility を使用した。実際の FX Option 市場には、満期方向と Strike 方向の Volatility Surface が存在する。長期 PRDC では、Smile、Skew および Volatility term structure の影響が重要となる。

9.6.4 相関を明示的に扱っていない

本格的な PRDC モデルでは、Domestic 金利、Foreign 金利および FX の間の相関を扱う必要がある。金利と FX を別々に評価して単純に合成するだけでは、長期の Cross-currency リスクを十分に表現できない。

9.6.5 発行体コール権を含めていない

実際の PRDC には、発行体が Coupon 日に商品を期限前償還できる Callable 条項が含まれることが多い。

発行体は各行使日で、

Call value と Continuation value

を比較する。将来の Continuation value は Closed-form では求めにくいため、Least-Squares Monte Carlo または Backward Induction を使用する。

本章の評価結果は、非 Callable PRDC の Coupon Leg と Redemption Leg の価値である。Callable PRDC の投資家価値は、概念的には次式となる。

$$V_{\text{callable PRDC}} = V_{\text{noncallable PRDC}} - V_{\text{issuer call}}$$

9.6.6 Part II のまとめ

第 II 部では、金融商品のキャッシュフロー、マーケットコンベンション、確率モデルおよび数値計算を段階的に扱った。

```
part2_chapter_summary_tbl <- tibble::tribble(
  ~chapter, ~subject, ~main_method,
  "II-1", "Bonds and market conventions", "Yield, price, duration, and convexity",
  "II-2", "Treasury futures and CTD", "Basis, carry, implied repo, and futures BPV",
  "II-3", "OIS and multi-curve valuation", "Discount and forecast curve separation",
  "II-4", "Black model", "Lognormal forward-option pricing",
  "II-5", "Normal model", "Bachelier pricing for zero and negative rates",
  "II-6", "SABR model", "Volatility-smile calibration",
  "II-7", "Callable Bond and Hull-White", "Short-rate tree and early exercise",
  "II-8", "Credit risk and CDS", "Hazard curve, MidPoint, and ISDA valuation",
  "II-9", "Exotic derivatives and PRDC", "FX-linked coupon Monte Carlo valuation"
)

GaussQuant::show_tbl_GQH(
  part2_chapter_summary_tbl,
  "Part II chapter summary",
  n = 20
)
```

```

)
#> # A tibble: 9 x 3
#>   chapter subject                                main_method
#>   <chr>    <chr>                                <chr>
#> 1 II-1    Bonds and market conventions Yield, price, duration, and convexity
#> 2 II-2    Treasury futures and CTD      Basis, carry, implied repo, and futures~
#> 3 II-3    OIS and multi-curve valuation Discount and forecast curve separation
#> 4 II-4    Black model                    Lognormal forward-option pricing
#> 5 II-5    Normal model                   Bachelier pricing for zero and negative~
#> 6 II-6    SABR model                     Volatility-smile calibration
#> 7 II-7    Callable Bond and Hull-White   Short-rate tree and early exercise
#> 8 II-8    Credit risk and CDS            Hazard curve, MidPoint, and ISDA valuat~
#> 9 II-9    Exotic derivatives and PRDC    FX-linked coupon Monte Carlo valuation

```

債券評価から始まり、金利先物、OIS、Option、Volatility Smile、短期金利モデル、信用リスク、そして複数の市場要因を持つエキゾチック商品へ進んだ。

Part II を通じた共通原則は、商品ごとに異なる数式を暗記することではない。次の要素を分離し、再利用可能な計算層へ落とすことである。

- 契約条件と Schedule
- 市場データと Curve
- リスク中立測度と確率過程
- Cash flow と Payoff
- Pricing Engine または数値計算法
- NPV、Risk および Calibration
- 表示と検証

GaussQuant は、QuantLib SWIG の低水準オブジェクトを金融商品の計算層へまとめる。LagrangeFinance の章側は、商品構造、数式、入力条件、表、グラフおよび金融的解釈に集中する。

9.7 まとめ

PRDC は、将来の FX Rate に連動する Coupon を持つ長期の仕組債である。

Coupon rate は、

$$C(S) = \min \left[C_{\max}, \max \left(a \frac{S}{S_0} - b, C_{\min} \right) \right]$$

という Floor 付き・Cap 付きの非線形 Payoff である。

Garman–Kohlhagen モデルでは、FX Rate のリスク中立ドリフトは Domestic 金利と Foreign 金利の差によって決まる。

$$\frac{dS_t}{S_t} = (r_d - r_f)dt + \sigma_{FX}dW_t$$

Coupon 日の FX 分布を Monte Carlo で生成し、各 Coupon 日の期待 Coupon、Coupon Leg、Redemption Leg および PRDC NPV を計算した。

FX Spot と FX volatility の感応度は、Floor と Cap によって非線形となる。Monte Carlo 評価には統計誤差があるため、NPV だけでなく標準誤差と信頼区間を確認する必要がある。

本章は非 Callable PRDC を対象とした。実際の Callable PRDC には、Domestic 金利、Foreign 金利、FX、Volatility Surface、相関および発行体の早期行使判断を同時に扱う、より高度なモデルが必要となる。

```
chapter09_summary_tbl <- tibble::tribble(
  ~section,          ~main_result,
  "Coupon payoff",   "Floored and capped FX-linked coupon",
  "FX process",      "Garman-Kohlhagen risk-neutral dynamics",
  "Monte Carlo valuation", "Coupon leg and redemption leg NPV",
  "Spot sensitivity", "Nonlinear response caused by cap and floor",
  "Volatility sensitivity", "Distributional effect on coupon regions",
  "Monte Carlo error", "Standard error and confidence interval",
  "Model boundary",   "Non-callable deterministic-rate PRDC"
)

GaussQuant::show_tbl_GQH(
  chapter09_summary_tbl,
  "Chapter II-9 summary",
  n = 20
)

#> # A tibble: 7 x 2
#>   section          main_result
#>   <chr>            <chr>
#> 1 Coupon payoff    Floored and capped FX-linked coupon
#> 2 FX process       Garman-Kohlhagen risk-neutral dynamics
#> 3 Monte Carlo valuation Coupon leg and redemption leg NPV
#> 4 Spot sensitivity Nonlinear response caused by cap and floor
#> 5 Volatility sensitivity Distributional effect on coupon regions
#> 6 Monte Carlo error Standard error and confidence interval
#> 7 Model boundary   Non-callable deterministic-rate PRDC

cat(
  "\nChapter II-9 Exotic derivatives and PRDC completed successfully.\n"
)

#>
#> Chapter II-9 Exotic derivatives and PRDC completed successfully.
```